

数理統計学01 Bernoulli試行と関連確率分布

二項分布、幾何分布、
負の二項分布、など

(確率)分布にしたがう 確率変数 X とその函数として得られる確率変数

確率変数 = ランダムに値が決まる量のモデル化

現実 ランダムに値が決まると考えられる量

- ・サイコロやルーレットの出目
- ・キャンブルで得られる賞金の額
- ・無作為抽出で得られた標本 (サンプル, データ)

数学的
モデル化

ある(確率)分布にしたがう 確率変数

データのモデル化として
確率変数達の組
(X_1, \dots, X_n)を使う。

数学的には「確率変数はその函数の期待値が定義されているもの」と思ってよい。
 $\leftarrow X$ $\leftarrow E[f(X)]$ $\leftarrow f(X)$ も確率変数
と書く

例 (一様乱数生成のくりかえし) コンピュータでの `rand()` のくりかえし,
`rand()` は 確率変数で モデル化される.
`rand()` のくりかえしの結果は 一様分布の標本(サンプル) の例になっている.

一様乱数の生成の繰り返し

確率変数 の理解に向けて、コンピュータでの `rand()` フィルについて説明する。

0以上1未満の区間上の一様分布の(擬似)乱数(以下ではこれを **一様乱数** と短く呼ぶことにする)を10個生成すると以下のようになる。

```
[rand() for _ in 1:10]
```

```
10-element Vector{Float64}:
0.5105030210947423
0.13229885279256504
0.05873542170272006
0.742812017444488
0.8417141593154808
0.44238748406950934
0.5002487759410339
0.7049642022880609
0.6687158029467306
0.7672724745322447
```

0 ~ 1 の 一様乱数生成のくりかえし

コンピュータでの `rand()` は 値がランダムに決まる量という意味での確率変数 のわかりやすい例になっていると思える。

例 (Bernoulli 試行, ベルヌイ試行, ベルヌイ試行) pを成功確率といふ

Bernoulli 試行とは、

確率	p	$1-p$
値	1	0

 で「1と0をランダムに生成すること」

- 0.7086835170539888 → 0 → 外れ
- 0.3129878077458778 → 0 → 外れ
- 0.4432299124211534 → 0 → 外れ
- 0.6380100590067396 → 0 → 外れ
- 0.7457553759007464 → 0 → 外れ
- 0.0042479988608554 → 1 → 当たり
- 0.4282692167397828 → 0 → 外れ
- 0.2591080281694401 → 1 → 当たり
- 0.6056891396222264 → 0 → 外れ
- 0.4718831513039459 → 0 → 外れ
- 0.2359750577106341 → 1 → 当たり
- 0.3658417371594386 → 0 → 外れ
- 0.4169159761488047 → 0 → 外れ
- 0.2234702295437706 → 1 → 当たり
- 0.2267949185649013 → 1 → 当たり
- 0.1054052960574101 → 1 → 当たり
- 0.5401955636162634 → 0 → 外れ
- 0.3620455865151407 → 0 → 外れ
- 0.9332297268604005 → 0 → 外れ
- 0.1009962782059489 → 1 → 当たり

0～1のあいだの一様乱数 T について

$$\begin{cases} T < 0.3 \Rightarrow 1 \text{を生成} \\ T \geq 0.3 \Rightarrow 0 \text{を生成} \end{cases}$$

1 → 当たり, 0 → 外れ ↑
 $p=0.3$

当たりの例

- ・くじが当たる。
- ・商品を買ってもうえる。
- ・病気になる。
- ・製品が不良である。

離散(確率)分布

確率	p_1	p_2	p_3	\dots
値	a_1	a_2	a_3	\dots

probability (mass) function,
pmf

確率(質量)函数 $P(x)$

$$P(a_i) = p_i \geq 0, \quad \sum_{i=1}^{\infty} P(a_i) = 1$$

(以下では カンタンのため $a_i \in \mathbb{R}$ であるとする。)

有限または可算な離散集合 $\{a_1, a_2, \dots\}$ 上の

確率(質量)函数 $P(x)$ が与えられているとき、

$P(x)$ によって 離散分布 (discrete distribution) が定義されたといふ。

例 (ベルヌイ Bernoulli 分布) 確率 $\begin{array}{c|cc} & p & 1-p \\ \hline \text{値} & 1 & 0 \end{array}$, $0 \leq p \leq 1$, $P(1) = p$, $P(0) = 1-p$.

つまり, $P(x) = p^x (1-p)^{1-x}$ ($x = 1, 0$). この分布を Bernoulli(p) と書く。

(n 個 Bernoulli 分布を合わせると試行回数 n の Bernoulli 試行が得られる。)

← この p を成功確率とよぶ

連続(確率)分布

(probability) density function, pdf

\mathbb{R} 上の(確率)密度函数: $p(x) \geq 0, \int_{-\infty}^{\infty} p(x) dx = 1$

実際には
 $\int_0^{\infty} x \int_a^b$ に
 なったりする。

☞ \mathbb{R}^n 上の確率密度函数も同様に定める。

→ 多変量の連続分布

\mathbb{R} 上の確率密度函数 $p(x)$ が与えられたとき、

$p(x)$ によって 連続分布 (continuous distribution) が定義されたといふ。

例 0~1 の一様分布 (rand() のモデル化, Uniform(0,1) と書く。)

$$p(x) = \begin{cases} 1 & (0 < x < 1) \\ 0 & (\text{それ以外}) \end{cases} \quad \begin{array}{l} \leftarrow 0 \leq x < 1 \text{ も} \ 0 < x \leq 1 \text{ も} \ 0 \leq x \leq 1 \text{ もよい}, \\ \text{コンピューターの rand()} \text{ は } 0 \leq x < 1 \end{array}$$

例 平均 μ , 分散 σ^2 の 正規分布 (Normal(μ, σ) と書く) □ は標準偏差

$$p(x) = p(x | \mu, \sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad p(z|0,1) = \frac{e^{-z^2/2}}{\sqrt{2\pi}}$$

平均 0, 分散 1^2 の正規分布を 標準正規分布 といい, Normal() と書く。 □

連続分布(密度函数 $p(x)$) での確率

連続分布において、確率を

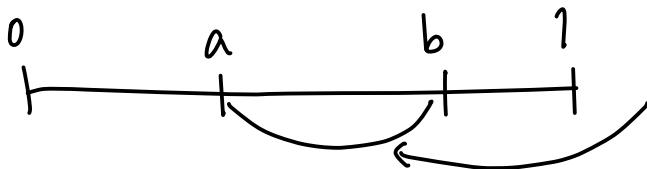
$$(c \text{ 以上で } (c \text{ より} 大きく} d \text{ 以下の } (d \text{ より} 小さい) \text{ 確率}) = \int_c^d p(x) dx$$

と定める。

$$(\text{ひつたり } c \text{ に等しい確率}) = \int_c^c p(x) dx \stackrel{\downarrow}{=} 0$$

例 $0 \leq p \leq 1$ のとき、($\text{Uniform}(0,1)$ での値が p 以下(半満)になる確率) = $\int_0^p 1 dt = p$.

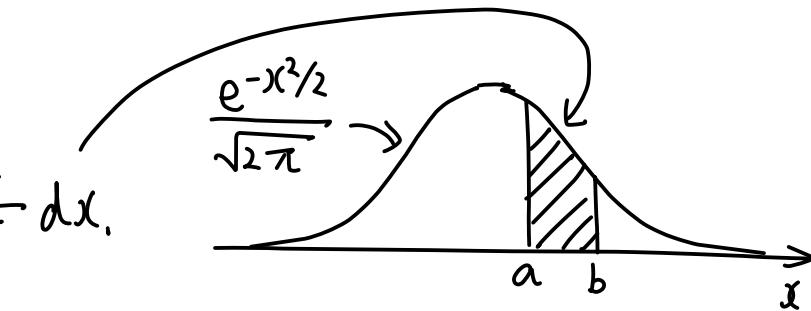
$0 \leq a \leq b \leq 1$ のとき、($\text{Uniform}(0,1)$ での値が a 以上 b 以下になる確率) = $\int_a^b 1 dt = b - a$.



この長さが $0 \sim 1$ での一様分布における確率.

例 $a \leq b$ のとき 標準正規分布について

$$(\text{値が } a \text{ 以上 } b \text{ 以下になる確率}) = \int_a^b \frac{e^{-x^2/2}}{\sqrt{2\pi}} dx.$$



$$\int_{-1}^1 \frac{e^{-x^2/2}}{\sqrt{2\pi}} dx \approx 68.27\%, \quad \int_{-2}^2 \frac{e^{-x^2/2}}{\sqrt{2\pi}} dx \approx 95.45\%, \quad \int_{-1.96}^{1.96} \frac{e^{-x^2/2}}{\sqrt{2\pi}} dx \approx 95.00\%$$

自分でコンピュータを使って確認せよ!

離散分布における確率変数

離散分布	確率	$P(a_1)$	$P(a_2)$	\dots
値		a_1	a_2	\dots

↑ 仮にこの分布の名前は D とする。

において,

random variable

↓

各 a_i に実数 $f(a_i)$ を対応させる 函数 $f(x)$ を 离散分布上の 確率変数 と呼ぶ。

特に, a_i を a_i 自身に対応させる確率変数 X を (X は a_i を a_i に対応させた函数)

分布 D にしたがう確率変数 とよび, $X \sim D$ と書く。 ($X \sim P(x)$ と書くこともある。)

そして, 各 a_i に $f(a_i)$ を対応させる確率変数を $f(X)$ と表す,

直観的には $\begin{cases} X \text{ の値は確率 } P(a_i) \text{ で } a_i \text{ になる。} \\ f(X) \text{ の値は確率 } P(a_i) \text{ で } f(a_i) \text{ になる。} \end{cases}$

↑ X は確率質量函数 $P(x)$ を持つといふ。

$f(x)$ の期待値 (expectation value) の定義

$$E[f(X)] = \sum_i f(a_i) P(a_i).$$

$E[X] = \sum_i a_i P(a_i)$ を 分布 D の期待値 もしくは 分布 D の平均 とよぶ。

注意 標本 x_1, x_2, \dots, x_n の平均 $\frac{1}{n} \sum_{i=1}^n x_i$ と分布 D の平均を区別せよ!

例 X は 成功確率 $p=0.3$ の Bernoulli 分布にしたがう確率変数とすれ:

$$X \sim \text{Bernoulli}(0.3), \quad P(1)=0.3, \quad P(0)=0.7$$

この Bernoulli 分布の期待値は

$$E[X] = 1 \times 0.3 + 0 \times 0.7 = 0.3.$$

確率 0.3 で“当たりが出るくじ”で、

当たりが出たら 1000 円もうえ、外れが出たら 300 円とされるという状況は、

上の Bernoulli 分布における次のように定義された確率変数 $f(X)$ でモデル化され:

$$f(x) = \begin{cases} 1000 \text{ 円} & (x=1) \\ -300 \text{ 円} & (x=0) \end{cases}$$

← 小さな文字 x は小文字 ↗ 大文字

このとき、 $f(x)$ の期待値は

$$E[f(x)] = 1000 \text{ 円} \times 0.3 + (-300 \text{ 円}) \times 0.7 = 90 \text{ 円},$$

このように期待値の計算で使える 函数たち ($X, f(x), \dots$) を 確率変数 とよぶ。

連続分布における確率変数

確率密度函数 $p(x)$ で定められた確率分布 D における 確率変数 とは x の函数 $f(x)$ のことである。

X は確率密度函数
 $p(x)$ を持つという
↓

特に, x を x 自身に対応させる確率変数 X を 分布 D にしたがう確率変数 と呼び, $X \sim D$ と書く, $(X \sim p(x) \text{ と書くこともある。})$
following D

x の函数 $f(x)$ が定める確率変数を $f(X)$ と書く。

$f(X)$ の期待値の定義, $E[f(X)] = \int f(x) p(x) dx$. ← 適切な定積分

$E[X] = \int x p(x) dx$ (定積分) を 分布 D の期待値 もしくは 分布 D の平均 とする。

注意 標本 x_1, x_2, \dots, x_n の平均 $\frac{1}{n} \sum_{i=1}^n x_i$ と分布 D の平均を区別せよ!

例 T は $0 \sim 1$ の一様分布にしたがう確率変数であるとする:

$$T \sim \text{Uniform}(0,1) \sim p(t) = \begin{cases} 1 & (0 < t < 1) \\ 0 & (\text{それ以外}) \end{cases}$$

この分布の期待値は

$$E[T] = \int_{-\infty}^{\infty} t p(t) dt = \int_0^1 t dt = \left[\frac{t^2}{2} \right]_0^1 = \frac{1}{2}. \quad \leftarrow \begin{array}{l} \text{区間 } 0 \sim 1 \text{ の} \\ \text{中点,} \end{array}$$

$$f(t) = \begin{cases} 1000 \text{ 円} & (t < 0.3) \\ -300 \text{ 円} & (t \geq 0.3) \end{cases} \quad \text{で定まる確率変数 } f(T) \text{について,}$$

$$\begin{aligned} E[f(T)] &= \int_{-\infty}^{\infty} f(t) p(t) dt = \int_0^{0.3} 1000 \text{ 円} dt + \int_{0.3}^1 (-300 \text{ 円}) dt \\ &= 1000 \text{ 円} \times 0.3 + (-300 \text{ 円}) \times 0.7 = 90 \text{ 円.} \end{aligned}$$

他の例:

$$E[T^m] = \int_0^1 t^m dt = \left[\frac{t^{m+1}}{m+1} \right]_0^1 = \frac{1}{m+1}. \quad \leftarrow \begin{array}{l} \text{Uniform}(0,1) \text{ の} \\ \text{モーメント} \end{array}$$

$$E[(T - \frac{1}{2})^2] = \int_0^1 (t - \frac{1}{2})^2 dt = \left[\frac{1}{3} (t - \frac{1}{2})^3 \right]_0^1 = \frac{1/8 - (-1/8)}{3} = \frac{1}{12}. \quad \leftarrow \begin{array}{l} \text{Uniform}(0,1) \text{ の} \\ \text{分散} \end{array}$$

確率変数に関する確率

確率変数 X について、次のように書く：

条件を書いた $P(c \leq f(x) \leq d) = (c \leq f(x) \leq d \text{ となる確率})$

\leq と \leqq は
同じ意味

X が $\{a_1, a_2, \dots\}$ 上の確率質量函数 $P(x)$ で定まる離散分布にしたがうとき、

$$P(c \leq f(x) \leq d) = \sum_{c \leq f(a_i) \leq d} P(a_i) = \begin{cases} c \leq f(a_i) \leq d \text{ を満たす } a_i \text{ の全体} \\ \text{に} \text{ 関する } P(a_i) \text{ の和} \end{cases}$$

X が確率密度函数 $p(x)$ を持つとき、

$$P(c \leq f(x) \leq d) = \int_{\{x \in \mathbb{R} \mid c \leq f(x) \leq d\}} p(x) dx.$$

$$1_{c \leq f(x) \leq d}(x) = \begin{cases} 1 & (c \leq f(x) \leq d) \text{ のとき,} \\ 0 & (\text{それ以外}) \end{cases}$$

が

$$P(c \leq f(x) \leq d) = E[1_{c \leq f(x) \leq d}(x)] = \begin{cases} \sum_i 1_{c \leq f(x) \leq d}(a_i) P_i \\ \int_{\mathbb{R}} 1_{c \leq f(x) \leq d}(x) p(x) dx \end{cases}$$

確率は期待値で書ける。
 $X_{c \leq f(x) \leq d}(x)$ と書くこともある。

$E[\cdot]$ の基本性質

(1) 線形性： $E[\alpha f(x) + \beta g(x)] = \alpha E[f(x)] + \beta E[g(x)].$

(2) 単調性： $f(x) \leq g(x)$ (すべての x について) $\Rightarrow E[f(x)] \leq E[g(x)].$

(3) 規格化条件： 定数 α について $E[\alpha] = \alpha$, (特に $E[1] = 1$).

計算のコツ できるだけ基本性質だけを使ってます！

連續分布での証明

→ 積分

$$\begin{aligned} (1) \quad E[\alpha f(x) + \beta g(x)] &= \int (\alpha f(x) + \beta g(x)) p(x) dx \\ &= \alpha \int f(x) p(x) dx + \beta \int g(x) p(x) dx = \alpha E[f(x)] + \beta E[g(x)]. \end{aligned}$$

(2) $p(x) \geq 0$ 且 $f(x) \leq g(x)$ 且 $f(x) p(x) \leq g(x) p(x)$ となるので、

$$E[f(x)] = \int f(x) p(x) dx \leq \int g(x) p(x) dx = E[g(x)].$$

$$(3) \quad \int p(x) dx = 1 \text{ 且}$$

$$E[\alpha] = \int \alpha p(x) dx = \alpha \int p(x) dx = \alpha.$$

q.e.d.

確率変数 $Y = f(X)$ の分散

平均からの距離の2乗の
平均を分散と呼ぶ

$Y = f(X)$ の期待値を $\mu_Y = E[Y] = E[f(X)]$ と書くとき、

$$\sigma_Y^2 = \text{Var}(Y) = \text{Var}(f(X)) = E[(Y - \mu)^2] = E[(f(X) - \mu_Y)^2]$$

を $Y = f(X)$ の 分散 (variance) とよぶ。

注意 標本 x_1, x_2, \dots, x_n の平均を $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ と書くときの

標本の分散 $\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ と確率変数の分散はちがうものである。

↑ 慣習的に不偏分散 $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})$ を使うことが多い。

分散の平方根を 標準偏差 (standard deviation) とよび、次のように書く：

$$\sigma_Y = \text{std}(Y) = \sqrt{\text{Var}(Y)}.$$

分散の計算には、 $\mu_Y = E[Y]$ のときの

$$\text{Var}(Y) = E[Y^2] - E[Y]^2$$

よく使われる。

$E[\cdot]$ の線形性と
規格化条件しか
使っていない。

よく使われる

$$\text{Var}(Y) = E[(Y - \mu_Y)^2] \text{ もりではなく}$$

証明

$$\begin{aligned} \text{Var}(Y) &= E[(Y - \mu_Y)^2] = E[Y^2 - 2\mu_Y Y + \mu_Y^2] \\ &= E[Y^2] - 2\mu_Y E[Y] + \mu_Y^2 = E[Y^2] - 2\mu_Y^2 + \mu_Y^2 \\ &= E[Y^2] - \mu_Y^2 = E[Y^2] - E[Y]^2. \end{aligned}$$

自習問題

答えは github においてある資料にある。

問題: 期待値と分散の特徴付け

X は有限離散分布に従う確率変数であるとし, 実数 t について $f(t) = E[(X - t)^2]$ とおく. このとき, $f(t)$ を最小化する t の値は X の期待値 $E[X]$ になり, 最小値 $f(E[X])$ は X の分散 $\text{var}(X)$ になることを示せ.

この条件は假定なり

注意: a を確率変数 X の中央値とするとき, $E[|X - a|]$ は中央値からの距離の期待値になる. これも確率変数 X の分布の広がりの大きさの指標の1つとして使える. 分散の定義について「どうして2乗するのか?」という質問は非常によくある質問だが, 分布の広がりの大きさの指標は無数にあるので, 分散に特権的な優位性があるわけではない. 期待値の代わりに中央値を考え, 2乗せずに単なる絶対値を考えるのもよい. その他にも中央値と四分位数の組み合わせもよく使われている. 分散や四分位数について教えることが多いのは単によく使われるからである. しかし, 期待値と分散の組み合わせを頻繁に目にする数学的理由もあって, 中心極限定理 によって正規分布で近似されると考えられる分布が応用上よく現れるという事情がある.

確率変数のロケーションスケール変換

$E[\cdot]$ の基本性質の応用

確率変数 X と定数 a, b について、

$X \mapsto aX+b$ という変換のこと

$$(1) E[aX+b] = aE[X] + b \quad (\text{これは } E[\cdot] \text{ の基本性質より易しい。})$$

$$(2) \text{Var}(aX+b) = a^2 \text{Var}(X).$$

証明 $\mu = E[X], \mu' = E[aX+b] = a\mu + b$

$$\begin{aligned} \text{Var}(aX+b) &= E[(aX+b-\mu')^2] = E[(aX+b-(a\mu+b))^2] \\ &= E[(a(X-\mu))^2] = E[a^2(X-\mu)^2] = a^2 E[(X-\mu)^2] = a^2 \text{Var}(X). \end{aligned}$$

$$(3) a \geq 0 \text{ のとき, } \text{std}(aX+b) = a \text{std}(X).$$

証明 $\text{std}(aX+b) = \sqrt{\text{Var}(aX+b)} = \sqrt{a^2 \text{Var}(X)} = a \sqrt{\text{Var}(X)} = a \text{std}(X). \quad \square$

よく使われる。

特に, $\mu = E[X], \sigma = \text{std}(X)$ のとき, $Z = \frac{X-\mu}{\sigma}$ とおくと, $E[Z] = 0, \text{Var}(Z) = 1$.

証明 $E[Z] = E\left[\frac{X-\mu}{\sigma}\right] = \frac{1}{\sigma}(E[X]-\mu) = \frac{1}{\sigma^2}(E[X]-E[X]) = 0.$

$$\text{Var}(Z) = \text{Var}\left(\frac{X-\mu}{\sigma}\right) \stackrel{\text{上式}}{=} \frac{\text{Var}(X)}{\sigma^2} = \frac{\text{Var}(X)}{\text{std}(X)^2} = 1.$$

上の(2)

q.e.d.

例 $X \sim \text{Bernoulli}(p)$ のとき,

$$E[X] = 1 \cdot p + 0 \cdot (1-p) = p,$$

$$E[X^2] = 1^2 \cdot p + 0^2 \cdot (1-p) = p,$$

$$\text{Var}(X) = E[X^2] - E[X]^2 = p - p^2 = p(1-p). \quad \square$$

例 $T \sim \text{Uniform}(0,1)$ のとき,

$$E[T] = \int_0^1 t dt = \frac{1}{2}$$

$$E[T^2] = \int_0^1 t^2 dt = \frac{1}{3}$$

$$\text{Var}(T) = E[T^2] - E[T]^2 = \frac{1}{3} - \frac{1}{4} = \frac{1}{12}. \quad \square$$

例 $X \sim \text{Normal}(0,1)$ のとき,

$$E[X] = \int_{-\infty}^{\infty} x \frac{e^{-x^2/2}}{\sqrt{2\pi}} dx = 0 \quad (\text{被積分函数が奇函数から}).$$

$$\text{Var}(X) = E[X^2] = \int_{-\infty}^{\infty} x^2 \frac{e^{-x^2/2}}{\sqrt{2\pi}} dx = 1 \quad \text{とおぼえて示す}.$$

Gauss積分の公式 $\int_{-\infty}^{\infty} e^{-y^2} dy = \sqrt{\pi}$ において,

$$\alpha > 0 \text{ で } y = \sqrt{\alpha} x \text{ とおくと, } \sqrt{\alpha} \int_{-\infty}^{\infty} e^{-\alpha x^2} dx = \sqrt{\pi}.$$

$$\text{ゆえに, } \int_{-\infty}^{\infty} e^{-\alpha x^2} dx = \sqrt{\pi} \alpha^{-1/2}.$$

$$\text{両辺を } \alpha \text{ で微分して } -1 \text{ 倍すると, } \int_{-\infty}^{\infty} x^2 e^{-\alpha x^2} dx = \frac{1}{2} \sqrt{\pi} \alpha^{-3/2}.$$

$$\alpha = \frac{1}{2} \text{ とおぼえて, } \int_{-\infty}^{\infty} x^2 e^{-x^2/2} dx = \frac{1}{2} \sqrt{\pi} 2^{3/2} = \sqrt{2\pi},$$

□

試行回数 n , 成功確率 p の Bernoulli 試行の確率分布

与えられた 1 と 0 からなる長さ n の数列 (x_1, \dots, x_n) ($x_i = 1, 0$) に対して,
毎回確率 p で 1 が, 確率 $1-p$ で 0 がランダムに得られる Bernoulli 試行を
 n 回行ったときに得られる 1 と 0 からなる長さ n の数列が (x_1, \dots, x_n) になる確率は
Bernoulli 分布で^ての確率

$$P(x_i) = p^{x_i} (1-p)^{1-x_i} = \begin{cases} 1 & (x_i=1) \\ 0 & (x_i=0) \end{cases}$$

n 回の
Bernoulli 試行の
確率質量函数 pmf

の積になる:

$$P(x_1, \dots, x_n) = \prod_{i=1}^n (p^{x_i} (1-p)^{1-x_i}) = p^{x_1 + \dots + x_n} (1-p)^{n - (x_1 + \dots + x_n)}$$

ここで, $x_1 + \dots + x_n$ は 1 と 0 からなる数列 (x_1, \dots, x_n) の中の 1 の個数になる。

$P(x_1, \dots, x_n)$ ($x_i = 1, 0$) によって定まる多変量離散分布を

$$\text{Bernoulli}(p)^n = \underbrace{\text{Bernoulli}(p) \times \dots \times \text{Bernoulli}(p)}_{n \text{ 個}}$$

と表す。

試行回数 n , 成功確率 p の二項分布 (binomial distribution)

試行回数 n , 成功確率 p の Bernoulli 試行で得られる

1と0からなる長さ n の数列の中に1が k 個含まれる確率は、

$x_1 + \dots + x_n = k$ となるようだ

$$P(x_1, \dots, x_n) = p^{x_1 + \dots + x_n} (1-p)^{n-(x_1 + \dots + x_n)} = p^k (1-p)^{n-k}$$

の形になり, その個数は k 個の1の位置と n 個の x_i たちから選ぶ組合せの数

$$\binom{n}{k} = \frac{n!}{k!(n-k)!} = \frac{n(n-1)\dots(n-k+1)}{k!} \quad \leftarrow nC_k ではなく \binom{n}{k} と書く.$$

に等しい。

$$P(k) = \binom{n}{k} p^k (1-p)^{n-k} \quad (k=0, 1, \dots, n)$$

である。 $P(k)$ が定める離散分布を 二項分布 と呼ぶ, $\text{Binomial}(n, p)$ と表す。

$$\sum_{k=0}^n P(k) = \sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} = (p + (1-p))^n = 1$$

二項定理 $(x+y)^n = \sum_{k=0}^n \frac{n!}{k!(n-k)!} x^k y^{n-k}$.

自習問題

$K \sim \text{Binomial}(n, p)$ のときの $E[K] = np$, $\text{Var}(K) = np(1-p)$ を示せ. □

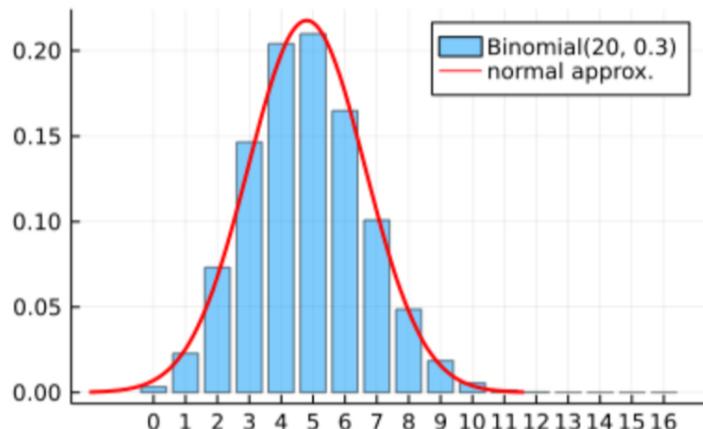
答えは github においてある資料にある。インターネットで検索しても答えが見付かる。

二項分布の確率質量函数のグラフ

二項分布 $\text{Binomial}(n, p)$ はその期待値 np と反対側の期待値 $n(1 - p)$ の両方が大きなとき, $\text{Binomial}(n, p)$ と等しい平均 $\mu = np$ と分散 $\sigma^2 = np(1 - p)$ を持つ正規分布で近似されること(二項分布の中心極限定理)がよく知られている。(実際には np がそう大きくなくとも悪くない近似になる。これは階乗のStirlingの公式による近似がそう悪くならないからだと考えられる。)

二項分布の中心極限定理は階乗に関するStirlingの(近似)公式を使えば示せるが、そこそこ面倒な計算が必要になる。そのような計算を避けたい人も避けなかった人も、コンピュータで二項分布と正規分布のグラフを重ねてプロットすれば二項分布が正規分布で近似されることをすぐに納得できると思う。正規分布については後で詳しく説明する。

```
bin = Binomial(16, 0.3)
μ, σ = mean(bin), std(bin)
x = support(bin)
bar(x, x -> pdf(bin, x); label="Binomial(20, 0.3)", alpha=0.5)
plot!(; xtick=x)
plot!(Normal(μ, σ); label="normal approx.", lw=2, c=:red)
```

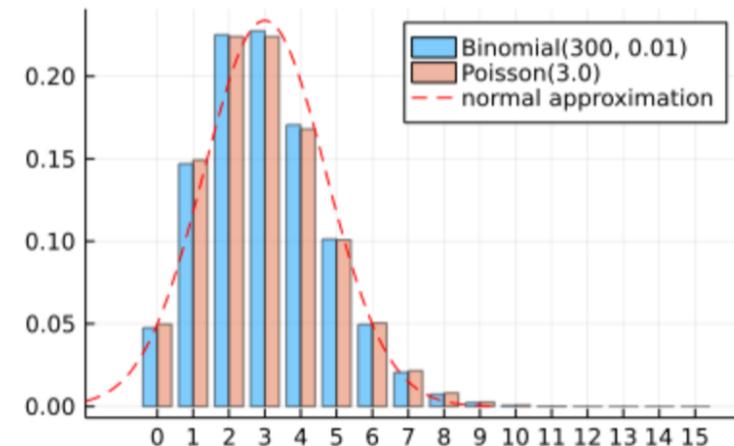


正規分布近似 (中心極限定理)

次のセルを見ればわかるように, p が小さな場合の二項分布は期待値 np のPoisson分布で近似される。

より正確に言うと, 固定された $\lambda > 0$ について, $p = \lambda/n$ とおくと, 二項分布 $\text{Binomial}(n, p)$ は $n \rightarrow \infty$ で Poisson 分布 $\text{Poisson}(\lambda)$ に近付く。Poisson 分布(ポアソン分布)の定義を知らない人はこれを Poisson 分布の定義だと思っててもよい。この点については後で説明する予定である。

```
λ, n = 3, 100
p = λ/n
bin = Binomial(n, p)
μ, σ = mean(bin), std(bin)
x = 0:5λ
groupedbar(x, [pdf.(bin, x) pdf.(Poisson(n*p), x)];
            label=[ "Binomial(300, 0.01)" "Poisson($n*p)" ], alpha=0.5)
plot!(; xtick=x, xlim=(-2, 16.5))
plot!(Normal(μ, σ); label="normal approximation", lw=1, c=:red, ls=:dash)
```



Poisson分布近似

自習問題

問題: 当たりが30%の確率で出るくじを100回引いた場合

当たりが毎回 $p = 30\% = 0.3$ の確率で出るくじを $n = 100$ 回引いたときに当たりが出た回数 K は二項分布 $\text{Binomial}(n, p)$ に従う確率変数とみなされる。

- (1) 当たりの回数 K の期待値と分散と標準偏差を求めよ.
- (2) 当たりの回数 K が25回以下になる確率と20回以下になる確率を求めよ.
- (3) 当たりの回数 K が35回以上になる確率と40回以上になる確率を求めよ.

有効桁3桁で求めよ.

答えは github においてある資料にある。

成功確率 p の幾何分布

$0 < p \leq 1$ と仮定し, $m = 0, 1, 2, \dots$ とする.

成功確率 p の Bernoulli 試行をつづけたとき,

ちょうど $n = m+1$ 回目で "1" がはじめて出る確率は,

m 回 0 がつづいて, $m+1$ 回目に 1 が"出る確率に等しいので,

$$P(m) = (1-p)^m \times p = p(1-p)^m \quad (m=0, 1, 2, \dots)$$

になる. この $P(m)$ が定める離散分布を 幾何分布 とよぶ, Geometric(p) と表す,

$$\sum_{m=0}^{\infty} P(m) = 1 \text{ となることの証明: } \sum_{m=0}^{\infty} p(1-p)^m = p \frac{1}{1-(1-p)} = p \times \frac{1}{p} = 1. \quad \text{等比級数の和}$$

自習問題

$M \sim \text{Geometric}(p)$, $N = M+1 = (1 \text{ が} \text{出るまで} \text{の試行回数})$ のとき,

$$E[M] = \frac{1-p}{p}, \quad E[N] = E[M]+1 = \frac{1}{p}, \quad \text{Var}(M) = \text{Var}(N) = \frac{1-p}{p^2}$$

を示せ.

□

答えは github においてある資料にある.

自習問題

幾何分布の応用 → ガチャ

問題: 当たりが出る確率が1%のガチャを当たりが出るまで回す場合

当たりが出る確率で出るガチャを引き続けて当たりが出るまで回す回数を N と書く.

(1) N の期待値と分散と標準偏差を求めよ.

(2) 当たりが初めて出るまでの回数が150回以上になる確率と200回以上になる確率と300回以上になる確率を求めよ.

確率や標準偏差の値は有効桁3桁以上が合っていれば正解とする.

答えは github についてある資料にある.

成功回数 k , 成功確率 p の負の二項分布

$k > 0, m = 0, 1, 2, \dots$ とする。

成功確率 p の Bernoulli 試行を k 回行なうとき、

← 当たりが k 回出るまで

ちょうど $n = k+m$ 回目に 1 が k 個出る確率は、

← タイをまわした回数

最初の $k+m-1$ 回中に 0 から m 回出て、 $k+m$ 回目に 1 が k 個出る確率に等しいので

$$P(m) = \binom{k+m-1}{m} p^{k-1} (1-p)^m \times p = \binom{k+m-1}{m} p^k (1-p)^m \quad (m=0, 1, 2, \dots)$$

になる。この $P(m)$ が定める m の分布を 負の二項分布とよび、次のように表す：

$$\text{Negative Binomial}(k, p) = \text{Neg Bin}(k, p).$$

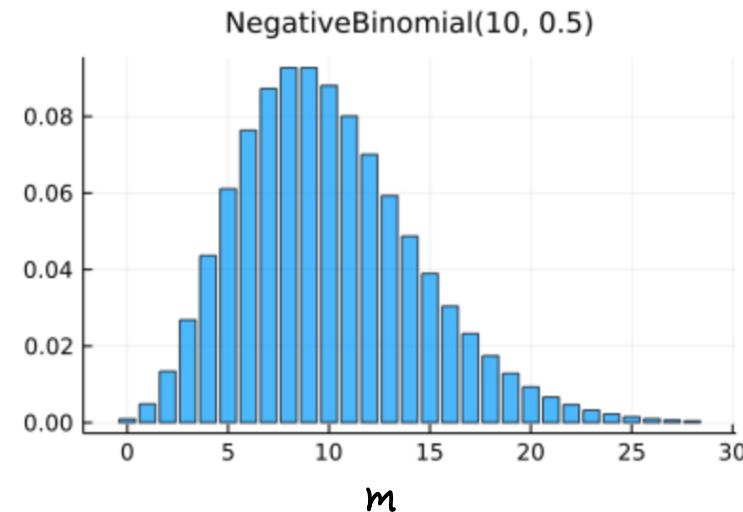
m は k 回 1 が k 個出るまでに出た 0 の個数を意味している。

$P(m)$ を $n = k+m$ で表わすと、 $\binom{k+m-1}{m} = \binom{k+m-1}{k-1} = \binom{n-1}{k-1}$ なので、

$$P(n-k) = \binom{n-1}{k-1} p^k (1-p)^{n-k} \quad (n = k, k+1, k+2, \dots).$$

これは二項分布の確率の式に似ているが少しちがう。

負の二項分布の確率質量函数のグラフ



M は負の二項分布 $\text{NegativeBinomial}(k, p)$ に従う確率変数であるとし,
 $N = M + k$ とおく. L は正の整数であるとし, $\theta = 1/(Lp)$, $T = N/L$ とおく
と, L を大きくしたとき, T の分布はガンマ分布 $\text{Gamma}(k, \theta)$ で近似される.

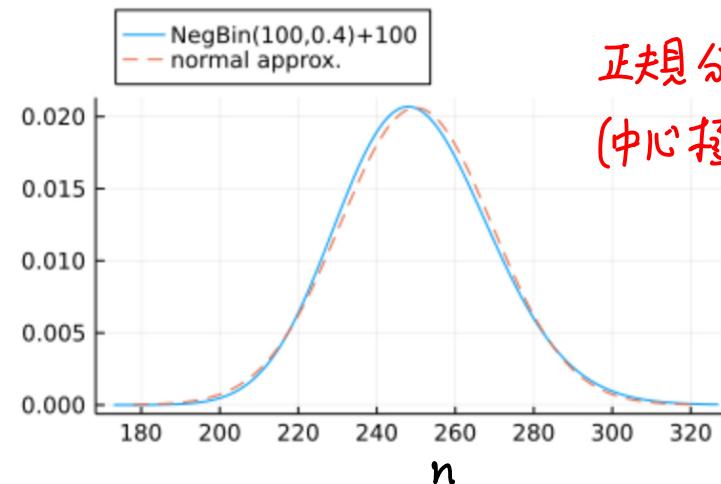
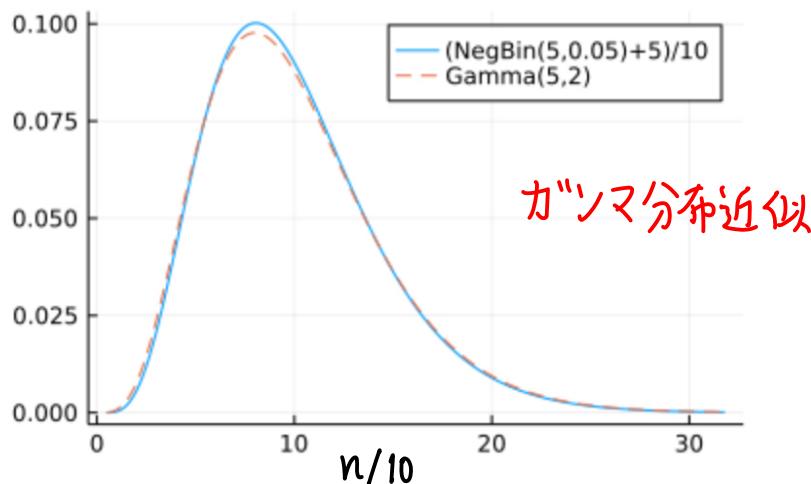
```
k, θ = 5, 2
L = 10
p = 1/(L*θ)

negbin = NegativeBinomial(k, p)
μ, σ = mean(negbin), std(negbin)
m = 0:round(Int, μ + 5σ)
n = m .+ k
t = n ./ L
plot(t, pdf.(negbin, m)*L; label=(NegBin($k,$p)+$k)/$L")
plot!(t, pdf.(Gamma(k, θ), t); label="Gamma($k,$θ)", ls=:dash)
```

k が大きなとき, 負の二項分布 $\text{NegativeBinomial}(k, p)$ は正規分布で近似される.

```
k, p = 100, 0.4

negbin = NegativeBinomial(k, p)
μ, σ = mean(negbin), std(negbin)
m = round(Int, μ - 4σ):round(Int, μ + 4σ)
n = m .+ k
plot(n, pdf.(negbin, m); label="NegBin($k,$p)+$k")
plot!(Normal(μ+k, σ); label="normal approx.", ls=:dash)
plot!(; legend=:outertop)
```



どうして負の二項分布とよぶか？ 以下， $|x| < 1$ とする。

二項係数： $\binom{a}{m} = \frac{a(a-1)(a-2)\cdots(a-m+1)}{m!}$

$(a \text{ は } 0 \text{ 以上の整数でなくててもよい。})$
 $a = 0, 1, 2, \dots$ のときには
 $\binom{a}{m} = \frac{a!}{m!(a-m)!}$

$f(x) = (1+x)^a$ とおくと，

$$f^{(m)}(x) = a(a-1)\cdots(a-m+1)(1+x)^{a-m} \text{ とおいて， } \frac{1}{m!} f^{(m)}(0) = \binom{a}{m},$$

$f(x)$ の Taylor 展開を 二項展開 と呼ぶ： $(1+x)^a = \sum_{m=0}^{\infty} \binom{a}{m} x^m \quad (|x| < 1)$

この (a, x) を $(-a, -x)$ に書きかえると

$$(1-x)^{-a} = \sum_{m=0}^{\infty} (-1)^m \binom{-a}{m} x^m \quad (|x| < 1).$$

-1倍の negative

仮に 負の二項係数と呼ぼう。

このノート内で“”特殊な用語””

さらば，

$$(-1)^m \binom{-a}{m} = (-1)^m \frac{(-a)(-a-1)\cdots(-a-m+1)}{m!} = \frac{a(a+1)\cdots(a+m-1)}{m!} = \binom{a+m-1}{m}$$

この $a = k$ の場合が 負の二項分布に出来ている。

自習問題

$M \sim \text{NegativeBinomial}(k, p)$, $N = k + M$ のとき,

$$E[M] = \frac{k(1-p)}{p}, \quad E[N] = k + E[M] = \frac{k}{p}, \quad \text{Var}(M) = \text{Var}(N) = \frac{k(1-p)}{p^2}$$

となることを示せ. 答えは [github](#) においてある資料にある.

自習問題

問題: 当たりが出る確率が5%のガチャを当たりが出るまで回す場合

当たりが $p = 5\% = 0.05$ で出るガチャを当たりがちょうど $k = 5$ 回出るまでに回した回数を N と書くことにする. N は負の二項分布 $\text{NegativeBinomial}(k, p)$ に従う確率変数 M によって $N = M + k$ と書ける.

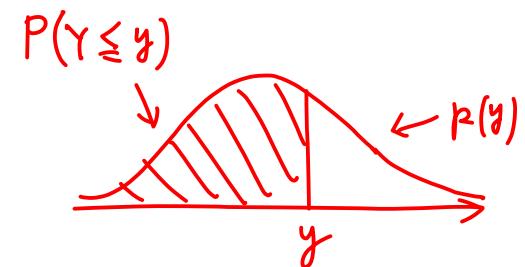
(1) N の期待値と分散と標準偏差を求めよ.

(2) N が150回以上, 200回以上になる確率を求めよ.

確率や標準偏差の値は有効桁3桁以上が合っていれば正解とする.

答えは [github](#) においてある資料にある.

累積分布函数 (cumulative distribution function, cdf) と
分位点函数 (quantile function)



確率変数 $Y = f(X)$ がしたがう分布の 累積分布函数 $F_Y(y)$ を

$$\underline{F_Y(y) = P(Y \leq y) = (\text{Y} \leq y \text{ となる確率})}$$

と定める。累積分布函数 $F_Y(y)$ は y について広義単調増加函数になり、

$$\lim_{y \rightarrow -\infty} F_Y(y) = 0, \quad \lim_{y \rightarrow \infty} F_Y(y) = 1, \quad \lim_{y \downarrow b} F_Y(y) = F_Y(b) \quad (\text{右側連続}) \text{ に} \rightarrow$$

例 $X \sim \text{Bernoulli}(0.3)$ のとき、

$$F_X(x) = \begin{cases} 0 & (x < 0) \\ 0.7 & (0 \leq x < 1) \\ 1 & (1 \leq x) \end{cases}$$

例 $T \sim \text{Uniform}(0,1)$ のとき、

$$F_T(x) = \begin{cases} 0 & (x < 0) \\ x & (0 \leq x < 1) \\ 1 & (1 \leq x) \end{cases}$$

累積分布函数の逆函数（存在しない場合は適当に代替物を定める）を
分位点函数（クォンタイル函数）と呼び、 $Q(p) = F_Y^{-1}(p)$ と書くことにする。

$Q_Y(0.5) = F_Y^{-1}(0.5)$ を Y がしたがう分布の 中央値 (median) と呼び、

$Q_Y(0.25)$ と $Q_Y(0.75)$ を Y がしたがう分布の 四分位点 (四分位数, quartile) と呼び、

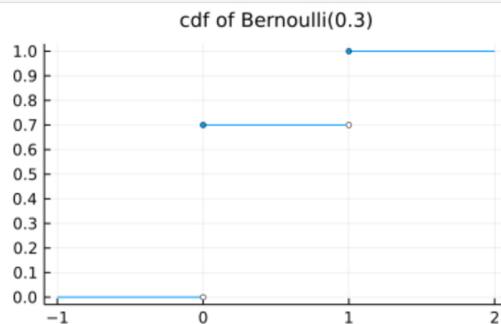
標本 (サンプル) x_1, \dots, x_n の中央値や四分位数とはちがうものであることに注意せよ。

Bernoulli分布の累積分布函数

Bernoulli分布 Bernoulli(p) の累積分布函数は次になる:

$$F(x) = \begin{cases} 0 & (x < 0) \\ 1-p & (0 \leq x < 1) \\ 1 & (1 \leq x) \end{cases}$$

```
ber = Bernoulli(0.3)
x = vcat([-1:0.02:-0.02; NaN], [0:0.02:0.98; NaN], 1:0.02:2)
plot(x, x -> cdf(ber, x); label="")
title!("cdf of Bernoulli(0.3)")
plot!(; ytick = 0:0.1:1)
scatter!(0:1, x -> cdf(ber, x - 0.02); label="", c=:white, ms=3)
scatter!(0:1, x -> cdf(ber, x); label="", c=1, ms=3)
```



一様分布の累積分布函数

$a < b$ のとき, 一様分布 Uniform(a, b) の確率密度函数は

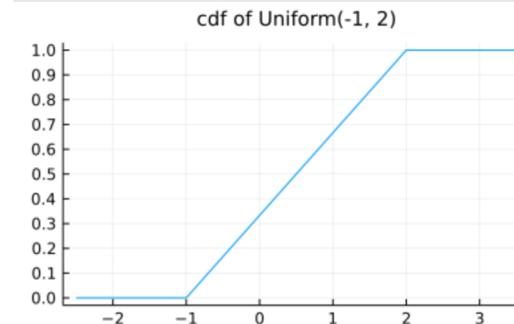
$$p(x) = \begin{cases} 1/(b-a) & (a < x < b) \\ 0 & (\text{otherwise}) \end{cases}$$

である. ゆえに, 一様分布 Uniform(a, b) の累積分布函数は

$$F(x) = \int_{-\infty}^x p(x') dx' = \begin{cases} 0 & (x \leq a) \\ (x-a)/(b-a) & (a \leq x \leq b) \\ 1 & (b \leq x) \end{cases}$$

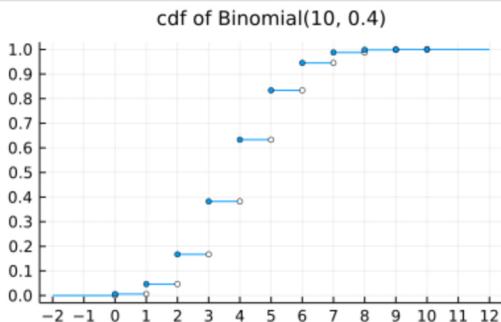
になる.

```
plot(x -> cdf(Uniform(-1, 2), x), -2.5, 3.5; label="")
title!("cdf of Uniform(-1, 2)")
yticks!(0:0.1:1)
```



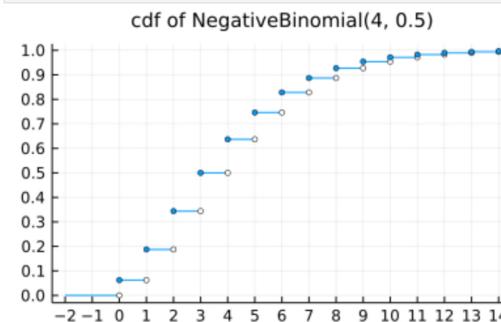
二項分布の累積分布函数のグラフ

```
bin = Binomial(10, 0.4)
x = vcat([-2:0.02:-0.02; NaN], ([k:0.02:k+0.98; NaN] for k in 0:9)
plot(x, x -> cdf(bin, x); label="")
title!("cdf of Binomial(10, 0.4)")
plot!(); xtick = -2:12, ytick = 0:0.1:1)
scatter!(0:10, x -> cdf(bin, x - 0.02); label="", c=:white, ms=3)
scatter!(0:10, x -> cdf(bin, x); label="", c=1, ms=3)
```



負の二項分布の累積分布函数のグラフ

```
negbin = NegativeBinomial(4, 0.5)
x = vcat([-2:0.02:-0.02; NaN], ([k:0.02:k+0.98; NaN] for k in 0:14)
plot(x, x -> cdf(negbin, x); label="")
title!("cdf of NegativeBinomial(4, 0.5)")
plot!(); xtick = -2:14, ytick = 0:0.1:1)
scatter!(0:14, x -> cdf(negbin, x - 0.02); label="", c=:white, ms=3)
scatter!(0:14, x -> cdf(negbin, x); label="", c=1, ms=3)
```



標準正規分布の累積分布函数と分位点函数

誤差函数が

$$\operatorname{erf}(x) = \frac{2}{\sqrt{\pi}} \int_0^x \exp(-u^2) du$$

と定義される。この函数はコンピュータでの基本特殊函数ライブラリに含まれており、効率的に計算可能である。この函数を使うと、正規分布の累積分布函数は次のように書ける: $t = \sqrt{2}u$ とおくと、

$$\begin{aligned} F(z) &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^z e^{-t^2/2} dt = \frac{1}{2} + \frac{1}{\sqrt{2\pi}} \int_0^z e^{-t^2/2} dt \\ &= \frac{1}{2} + \frac{1}{\sqrt{\pi}} \int_0^{z/\sqrt{2}} e^{-u^2} du = \frac{1}{2} + \frac{1}{2} \operatorname{erf}\left(\frac{z}{\sqrt{2}}\right) = \frac{1 + \operatorname{erf}(z/\sqrt{2})}{2}. \end{aligned}$$

$y = \operatorname{erf}(x)$ の逆函数 $x = \operatorname{erfinv}(y)$ もコンピュータでの基本特殊函数ライブラリに含まれており、効率的に計算可能である。標準正規分布の累積分布函数 $p = F(z)$ の逆函数(分位点函数, quantile function)は

$$z = Q_{\text{Normal}}(p) = \sqrt{2} \operatorname{erfinv}(2p - 1)$$

と書ける。標準正規分布の分位点函数は統計学で非常によく使われる。例えば

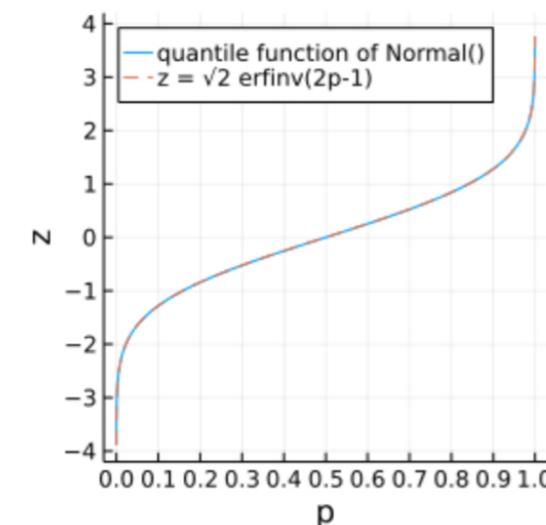
$$Q_{\text{Normal}}(0.975) \approx 1.96$$

は非常に有名な数値である。これは標準正規分布において値が 1.96 以上になる確率が 2.5% になることを意味している。

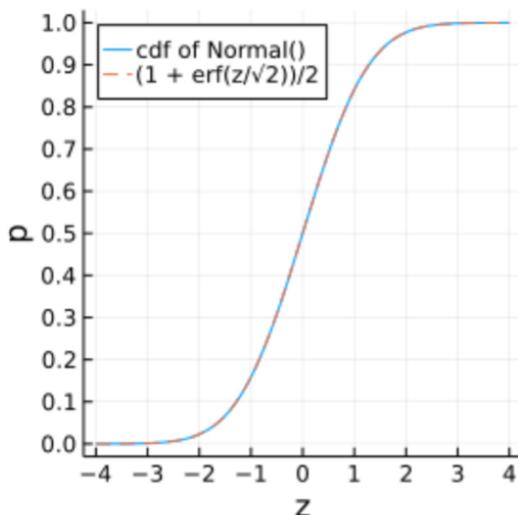
```
quantile(Normal(), 0.975)
```

```
1.9599639845400576
```

```
plot(p -> cdf(Normal(), z), -4, 4;
     label="cdf of Normal()", legend=:topleft)
plot!(z -> (1 + erf(z/sqrt(2)))/2, -4, 4;
      label="(1 + erf(z/sqrt(2))/2", ls=:dash)
plot!(; xtick=-5:5, ytick = 0:0.1:1,
      xlabel="z", ylabel="p")
plot!(; size=(300, 300))
```



```
plot(z -> quantile(Normal(), p), 0, 1;
     label="quantile function of Normal()", legend=:topleft)
plot!(p -> sqrt(2)*erfinv(2p-1), 0, 1;
      label="z = sqrt(2) erfinv(2p-1)", ls=:dash)
plot!(; xtick = 0:0.1:1, ytick=-5:5,
      xlabel="p", ylabel="z", ylim=(-4.2, 4.2))
plot!(; size=(300, 300))
```



自習問題

問題: 標準正規分布の四分位数

標準正規分布の累積分布函数と分位点函数はそれぞれ

$$p = F(z) = \int_{-\infty}^z \frac{e^{-t^2/2}}{\sqrt{2\pi}} dt = \frac{1 + \operatorname{erf}(z/\sqrt{2})}{2},$$
$$z = Q(p) = F^{-1}(p) = \sqrt{2} \operatorname{erfinv}(2p - 1)$$

と書ける。標準正規分布の四分位数 $Q(0.25), Q(0.75)$ をコンピュータを使って小数点以下第2桁まで求めよ。

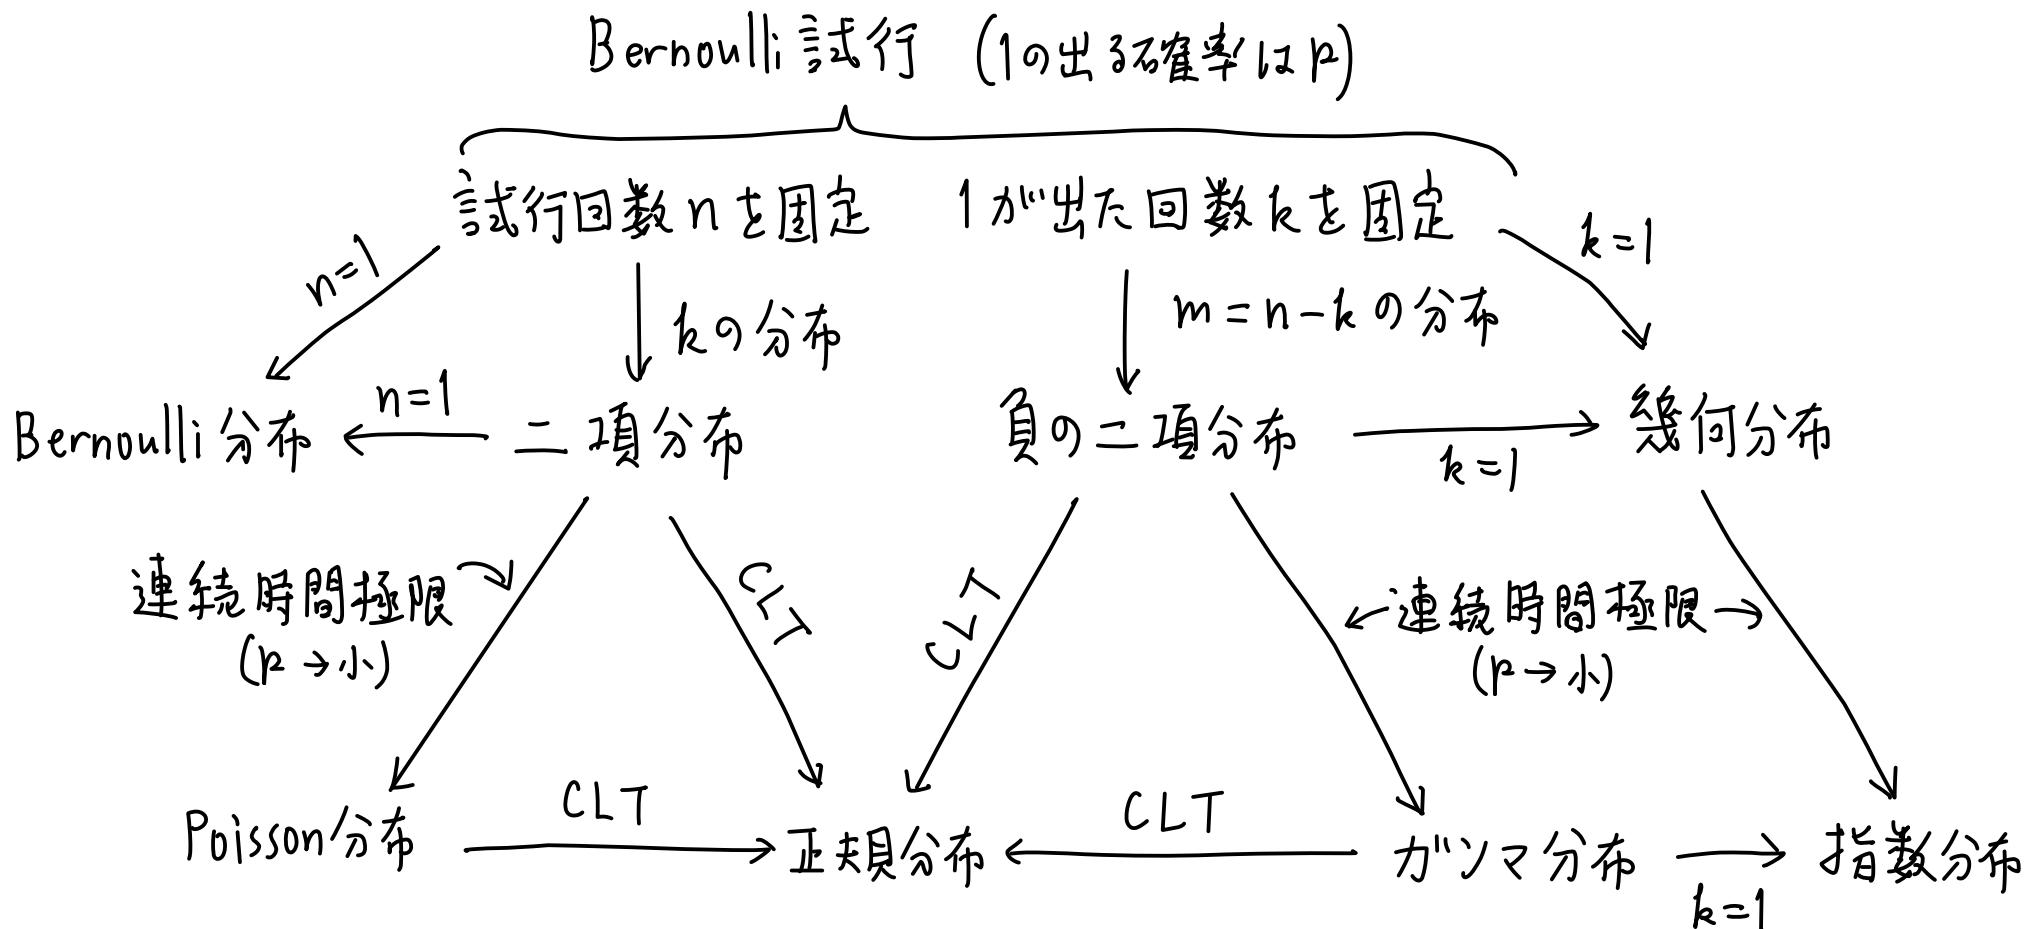
答えは github における資料にある。

まずは WolframAlpha などで $\operatorname{erfinv}(x)$ を使って求めることをためしめよ。

$$\operatorname{erf}(x) = \frac{2}{\sqrt{\pi}} \int_0^x \exp(-u^2) du$$

は誤差函数 (error function) とよばれている。
(erfinv はその逆函数)

Bernoulli 試行の関連確率分布の図



CLT = 中心極限定理 (central limit theorem)

Gauss積分、ガンマ函数、ベータ函数

ガソマ分布とベータ分布も定義してしまう。

Gauss積分

$$\int_{-\infty}^{\infty} e^{-y^2} dy = \sqrt{\pi}$$

$$y = \frac{x - \mu}{\sqrt{2\sigma^2}}$$

Gauss積分は正規分布の「分母」

$$\int_{-\infty}^{\infty} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx = \sqrt{2\pi\sigma^2}$$

↓ 一般化, $d > 0$

$$\int_{-\infty}^{\infty} e^{-y^2} |y|^{2d-1} dy = 2 \int_0^{\infty} e^{-y^2} y^{2d-1} dy$$

$$y = x^{\frac{1}{2}}, \quad dy = \frac{1}{2} x^{-\frac{1}{2}} dx$$

$$\downarrow \int_0^{\infty} e^{-x} x^{d-1} dx.$$

ガソマ函数

$$\Gamma(d) = \int_0^{\infty} e^{-x} x^{d-1} dx = \int_{-\infty}^{\infty} e^{-y^2} |y|^{2d-1} dy,$$

ガソマ函数は
Gauss積分の一般化

ベータ函数

$$\Beta(\alpha, \beta) = \int_0^1 t^{\alpha-1} (1-t)^{\beta-1} dt = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)},$$

ガソマ函数と
ベータ函数は
正規分布に関する
統計学に
自然に出て来る。

これらは統計学的には正規分布モデルの話になつてゐる
と考へなされる。(それ以外の見方もできる。)

$$\int_{-\infty}^{\infty} e^{-x^2} dx = \sqrt{\pi}$$

の証明

$$I = \int_{-\infty}^{\infty} e^{-x^2} dx \text{ とおくと,}$$

$$I^2 = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-(x^2+y^2)} dx dy$$

= (右の山の体積)

$$= \int_0^1 (\text{高さ } z \text{ での断面の面積}) dz$$

$$= \int_0^1 \pi (\sqrt{-\log z})^2 dz$$

$$= -\pi \int_0^1 \log z dz$$

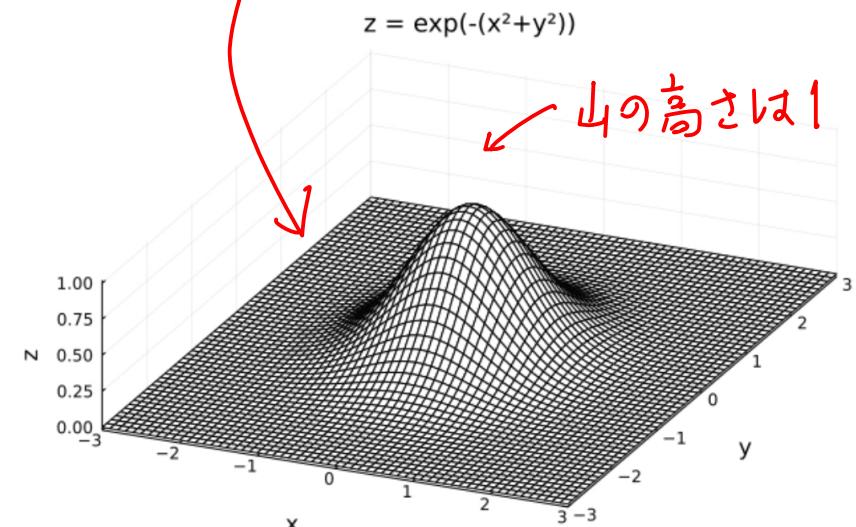
半径は $\sqrt{-\log z}$

$$= -\pi [z \log z - z]_0^1$$

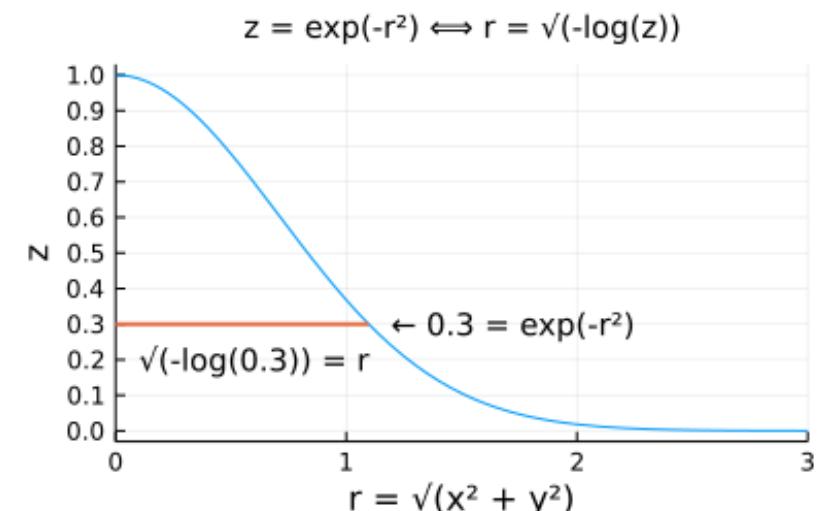
$$= -\pi (1 \underbrace{\log 1 - 1}_{=0} - (0 \underbrace{\log 0 - 0}_{=0})) = \pi,$$

$$\therefore I = \sqrt{\pi}.$$

この山の体積が I^2 になる。



この山は z 軸 $x = y = 0$ を中心にして回転対称である。次のグラフは横軸を半径 $r = \sqrt{x^2 + y^2}$ とした場合のこの山の高さのグラフである。



Gauss積分の一般化

$\alpha > 0$ と仮定する. $y = x^{\frac{1}{2}}, dy = \frac{1}{2}x^{-\frac{1}{2}}dx$

$$\int_{-\infty}^{\infty} e^{-y^2} |y|^{2\alpha-1} dy = 2 \int_0^{\infty} e^{-y^2} y^{2\alpha-1} dy = \underbrace{\int_0^{\infty} e^{-x} x^{\alpha-1} dx}_{= \text{ガンマ函数 } \Gamma(\alpha)}$$

計算例 $k=0, 1, 2, \dots$ について, $\alpha = k + \frac{1}{2} = \frac{2k+1}{2}$ のとき,

$$\int_{-\infty}^{\infty} e^{-y^2} y^{2k} dy = \frac{1 \cdot 3 \cdots (2k-1)}{2^k} \sqrt{\pi}.$$

証明 $\int_{-\infty}^{\infty} e^{-y^2} dy = \sqrt{\pi}$ のとき, $y = \sqrt{a}t$ とおくと, $\int_{-\infty}^{\infty} e^{-at^2} \sqrt{a} dt = \sqrt{\pi}$.

$\int_{-\infty}^{\infty} e^{-at^2} dt = \sqrt{\pi} a^{-\frac{1}{2}}$. この両辺に $\left(-\frac{\partial}{\partial a}\right)^k$ を作用させると,

$$\int_{-\infty}^{\infty} e^{-at^2} t^{2k} dt = \frac{1}{2} \frac{3}{2} \cdots \frac{2k-1}{2} \sqrt{\pi} a^{-\frac{2k+1}{2}}.$$

$a=1$ のとき,

$$\int_{-\infty}^{\infty} e^{-t^2} t^{2k} dt = \frac{1 \cdot 3 \cdots (2k-1)}{2^k} \sqrt{\pi},$$

口頭での説明は略す。

□

ガンマ函数 $\alpha > 0$ と仮定する。

$$\Gamma(\alpha) = \int_0^\infty e^{-x} x^{\alpha-1} dx = \int_{-\infty}^\infty e^{-y^2} |y|^{2\alpha-1} dy,$$

他にも色々役に立つ。

これは Gauss 積分の一般化になつてゐるが、正規分布で役に立つ。

例 $\Gamma(\frac{1}{2}) = \int_{-\infty}^\infty e^{-y^2} dy = \sqrt{\pi}$. 例 $\Gamma(1) = \int_0^\infty e^{-x} dx = [-e^{-x}]_0^\infty = 1$.

$\boxed{\Gamma(\alpha+1) = \alpha \Gamma(\alpha)}$

↑ 凸数等式

$$\begin{aligned} \Gamma(\alpha) &= \int_0^\infty e^{-x} x^\alpha dx = \int_0^\infty (-e^{-x})' x^\alpha dx \\ &= \left[-e^{-x} x^\alpha \right]_0^\infty - \int_0^\infty (-e^{-x}) (x^\alpha)' dx \quad \text{部分積分} \\ &= \int_0^\infty e^{-x} \alpha x^{\alpha-1} dx = \alpha \Gamma(\alpha), \end{aligned}$$

$\alpha > 0$ より $0^\alpha = 0$

$k = 0, 1, 2, \dots$ とすと

$$\Gamma(n+1) = n!$$

ガンマ函数は
Gauss 積分と
階乗の

例 $\Gamma(k+1) = k \Gamma(k) = k(k-1) \Gamma(k-1) = \cdots = k(k-1) \cdots 2 \cdot 1 \Gamma(1) = k!$

例 $\Gamma\left(\frac{2k+1}{2}\right) = \frac{2k-1}{2} \Gamma\left(\frac{2k-1}{2}\right) = \frac{2k-1}{2} \frac{2k-3}{2} \Gamma\left(\frac{2k-3}{2}\right) = \cdots$

$$= \frac{2k-1}{2} \frac{2k-3}{2} \cdots \frac{3}{2} \frac{1}{2} \Gamma\left(\frac{1}{2}\right) = \frac{1 \cdot 3 \cdots (2k-1)}{2^k} \sqrt{\pi} \quad \leftarrow \begin{array}{l} \text{前ページで} \\ \text{すでに示してある。} \end{array}$$

自習問題 $\Gamma\left(\frac{2k+1}{2}\right) = \frac{(2k)!}{2^{2k} k!} \sqrt{\pi} \quad (k=0, 1, 2, \dots)$ を示せ. \leftarrow Github にある資料に
答えが書いてある。

通常ガンマ函数は次の形で使われる。

$\alpha > 0, \theta > 0$ と仮定する。

$$\int_0^\infty e^{-x/\theta} x^{\alpha-1} dx = \theta^\alpha \Gamma(\alpha).$$

証明 $x = \theta t$ とおくと、(左辺) = $\int_0^\infty e^{-t} \theta^{\alpha-1} t^{\alpha-1} \theta dt = \theta^\alpha \Gamma(\alpha)$. \square

ガンマ分布の定義

Gamma(α, θ) と表す.

α : 形状パラメータ
 θ : スケールパラメータ

次の確率密度函数で定義される $x > 0$ における分布を ガンマ分布 と呼ぶ。

$$p(x|\alpha, \theta) = \frac{1}{\theta^\alpha \Gamma(\alpha)} e^{-x/\theta} x^{\alpha-1} \quad (x > 0),$$

$\alpha = 1$ のとき、指數分布
と呼ぶ、Exponential(θ)

$X \sim \text{Gamma}(\alpha, \theta)$ のとき、 $E[f(X)] = \frac{1}{\theta^\alpha \Gamma(\alpha)} \int_0^\infty f(x) e^{-x/\theta} x^{\alpha-1} dx$, と表す。

自習問題 分布 $\text{Gamma}(\alpha, \theta)$ の期待値と分散がそれぞれ $\alpha\theta, \alpha\theta^2$ となることを示せ、

ヒント $E[X^k]$ を求めよ、 $\text{Var}(X) = E[X^2] - E[X]^2$ を使い。 \square

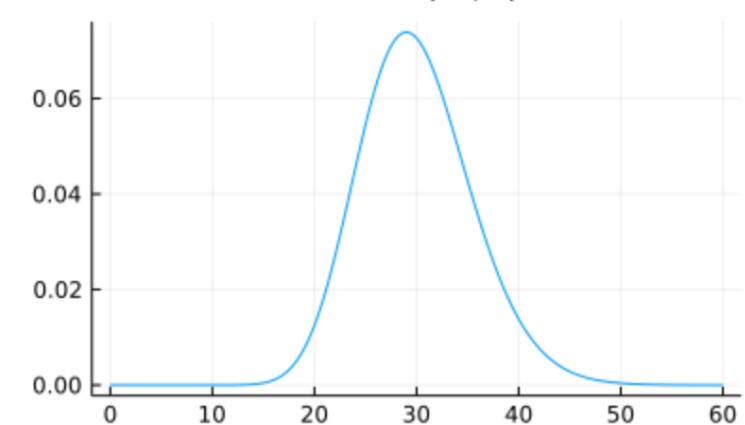
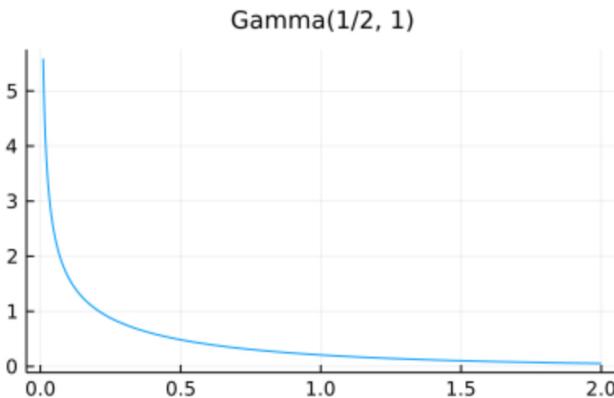
答えは Github におけるある資料にある。

ガンマ函数について
非常に良い練習になる。

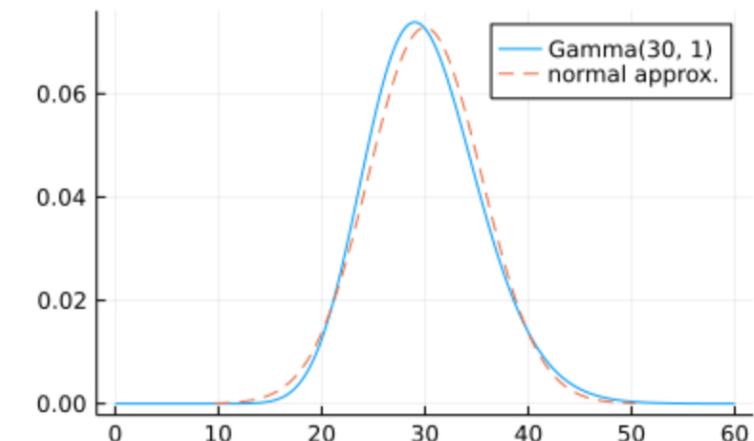
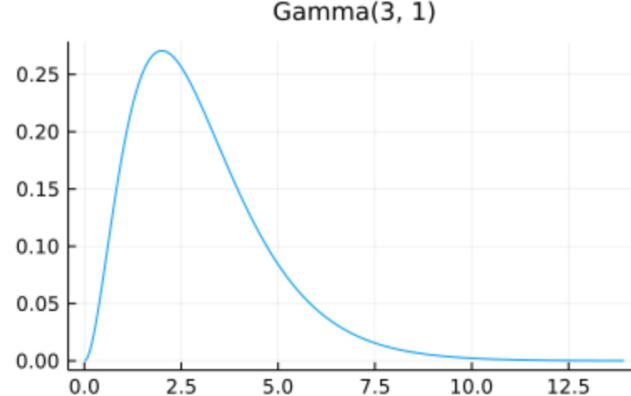
ガンマ分布
 $\text{Gamma}(\alpha, \theta)$
 のグラフ

スケールパラメータ θ

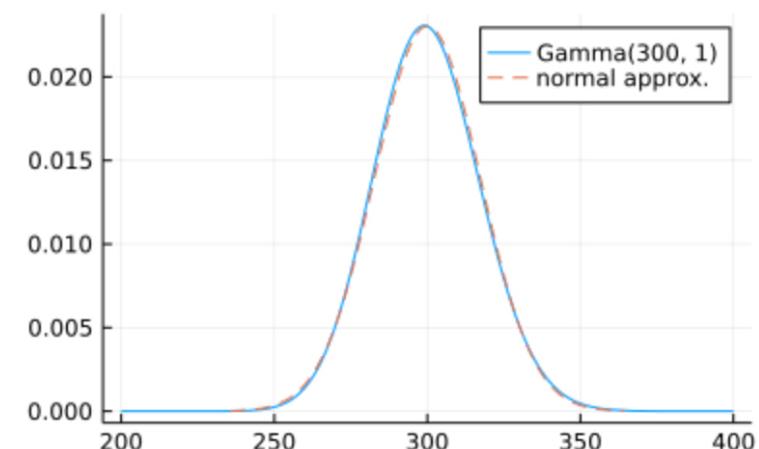
を変えても、グラフの
 形状は変わらない。
 だから、グラフの
 形状を知りたければ
 形状パラメータ α を
 動かしてグラフを
 描けばよい。



形状パラメータ α が大きなガンマ分布は正規分布で近似される。



形状パラメータを大きく
 すると、ガンマ分布は
 正規分布に近づく →



自習問題

$n-1$ 次元単位球面 S^{n-1} と n 次元単位球体 B^n が次のように定義される:

$$S^{n-1} = \{(x_1, \dots, x_n) \in \mathbb{R}^n \mid x_1^2 + \dots + x_n^2 = 1\}, \quad B^n = \{(x_1, \dots, x_n) \in \mathbb{R}^n \mid x_1^2 + \dots + x_n^2 \leq 1\}$$

このとき、次が成立することを示せ:

$$A_{n-1} = (S^{n-1} \text{ の面積}) = \frac{2\pi^{n/2}}{\Gamma(n/2)}, \quad V_n = (B^n \text{ の体積}) = \frac{A_{n-1}}{n} = \frac{\pi^{n/2}}{\Gamma(n/2+1)}. \quad \square$$

答えは Github においてある資料にある。人生全体の中で「1週間くらい考える価値のある問題」。

例 ($n = 1, 2, 3, 4, 5$ の場合)

$$A_0 = (S^0 = \{\pm 1\} \text{ の点の個数}) = \frac{2\pi^{1/2}}{\Gamma(1/2)} = 2, \quad V_1 = (\text{区間 } [-1, 1] \text{ の長さ}) = \frac{2}{1} = 2.$$

$$A_1 = (S^1 \text{ の長さ}) = \frac{2\pi}{\Gamma(1)} = 2\pi, \quad V_2 = (B^2 \text{ の面積}) = \frac{2\pi}{2} = \pi.$$

$$A_2 = (S^2 \text{ の面積}) = \frac{2\pi^{3/2}}{\Gamma(3/2)} = \frac{2\pi^{3/2}}{(1/2)\pi^{1/2}} = 4\pi, \quad V_3 = (B^3 \text{ の体積}) = \frac{4\pi}{3}$$

$$A_3 = \frac{2\pi^2}{\Gamma(2)} = 2\pi^2, \quad V_4 = \frac{2\pi^2}{4} = \frac{\pi^2}{2}$$

$$A_4 = \frac{2\pi^{5/2}}{\Gamma(5/2)} = \frac{2\pi^{5/2}}{(3/2)(1/2)\pi^{1/2}} = \frac{8\pi^2}{3}, \quad V_5 = \frac{8\pi^2}{3 \cdot 5} = \frac{8\pi^2}{15}. \quad \square$$

Stirling の 公 式

$$n! = n^n e^{-n} \sqrt{2\pi n} (1 + O(1)) \quad \begin{cases} O(1) \text{ は } n \rightarrow \infty \text{ の} \\ 0 \text{ に収束する量} \end{cases}$$

↑ 空気のごとく使われる。 小文字

証明

$n \rightarrow \infty$ のとき $\frac{n!}{n^n e^{-n} \sqrt{n}} \rightarrow \sqrt{2\pi}$ となることを示せばよい。 ポイント!

$$n! = \Gamma(n+1) = \int_0^\infty e^{-x} x^n dx \quad \boxed{x = n + \sqrt{n} y \quad y = n \left(1 + \frac{y}{\sqrt{n}}\right)} \text{ とおくと,}$$

$$n! = \int_{-\sqrt{n}}^{\infty} e^{-(n+\sqrt{n}y)} \left(n \left(1 + \frac{y}{\sqrt{n}}\right)\right)^n \sqrt{n} dy = \underline{n^n e^{-n} \sqrt{n}} \int_{-\sqrt{n}}^{\infty} e^{-\sqrt{n}y} \left(1 + \frac{y}{\sqrt{n}}\right)^n dy.$$

$$\log \left(e^{-\sqrt{n}y} \left(1 + \frac{y}{\sqrt{n}}\right)^n \right) = n \log \left(1 + \frac{y}{\sqrt{n}}\right) - \sqrt{n}y = n \left(\frac{y}{\sqrt{n}} - \frac{y^2}{2n} + O(n^{-3/2}) \right) - \sqrt{n}y$$

$$\log(1+a) = a - \frac{a^2}{2} + \frac{a^3}{3} + \dots$$

$$= -\frac{y^2}{2} + O(n^{-1/2}) \rightarrow -\frac{y^2}{2} \quad (n \rightarrow \infty)$$

ゆえに、 $n \rightarrow \infty$ のとき、 $e^{-\sqrt{n}y} \left(1 + \frac{y}{\sqrt{n}}\right)^n \rightarrow e^{-y^2/2}$ なので、

Laplace 近似
という方法を
使っている。
積分表示の御利益!

$$\frac{n!}{n^n e^{-n} \sqrt{n}} = \int_{-\sqrt{n}}^{\infty} e^{-\sqrt{n}y} \left(1 + \frac{y}{\sqrt{n}}\right)^n dy \rightarrow \int_{-\infty}^{\infty} e^{-y^2/2} dy = \sqrt{2\pi}, \quad \boxed{\text{q.e.d.}}$$

極限の交換が気になる人は自分でどうにかすること、Lebesgue の収束定理を使えば容易。

自習問題

$n=1, 2, \dots, 10$ について、 $a = n!$ と $b = n^n e^{-n} \sqrt{2\pi n}$ と
相対誤差 $\frac{b}{a} - 1$ を計算せよ。 b については小数点以下第3桁まで、
相対誤差については小数点以下第5桁まで求めよ。

Github についてある資料に答がある、

例 $a = 3! = 6, b = 3^3 e^{-3} \sqrt{2\pi \cdot 3} \approx 5.836, \frac{b}{a} - 1 \approx -0.02730 < 3\%$

$n=3$ ですでに相対誤差が 3% を切っている！

Stirling の公式は $n \rightarrow \infty$ として証明された $n!$ の近似公式だが、
大きくなれてもかなり精度が高い。

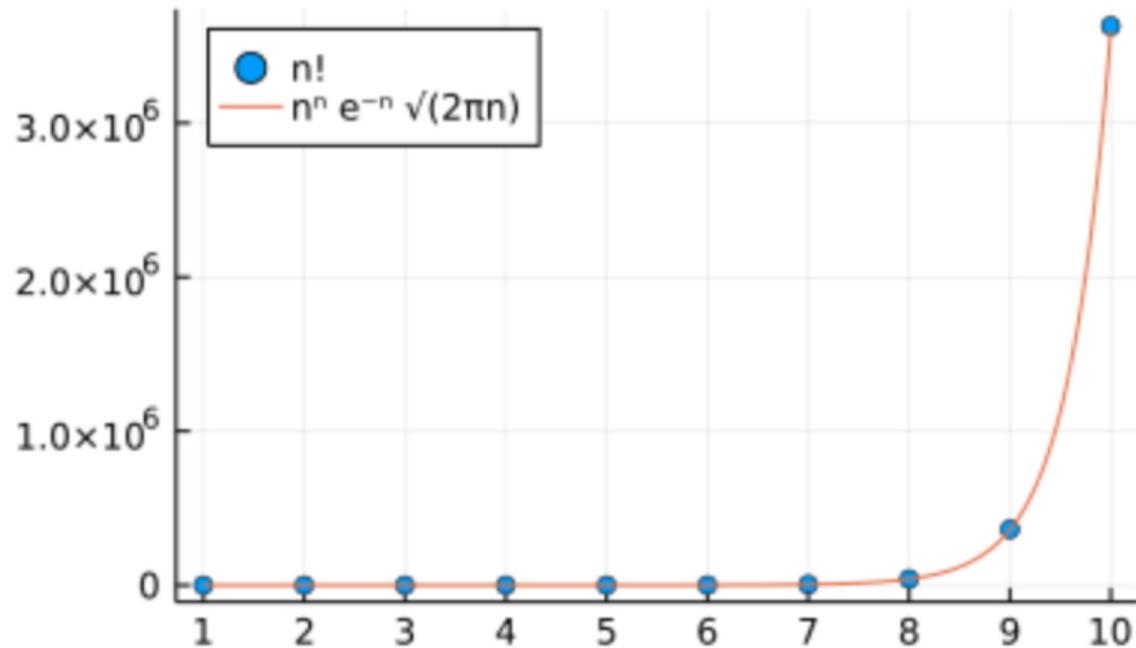
重要

おまけ $n! = n^n e^{-n} \sqrt{2\pi n} \left(1 + \frac{1}{12n} + O\left(\frac{1}{n^2}\right)\right)$ が成立している。

$$1! = 1, 1^1 e^{-1} \sqrt{2\pi \cdot 1} \left(1 + \frac{1}{12 \cdot 1}\right) = \frac{13\sqrt{2\pi}}{12e} \approx 0.99898 \dots \leftarrow \text{ほぼ } 1!$$

$\frac{1}{12n}$ で補正した近似公式であれば $n=1$ で相当な精度になっている！

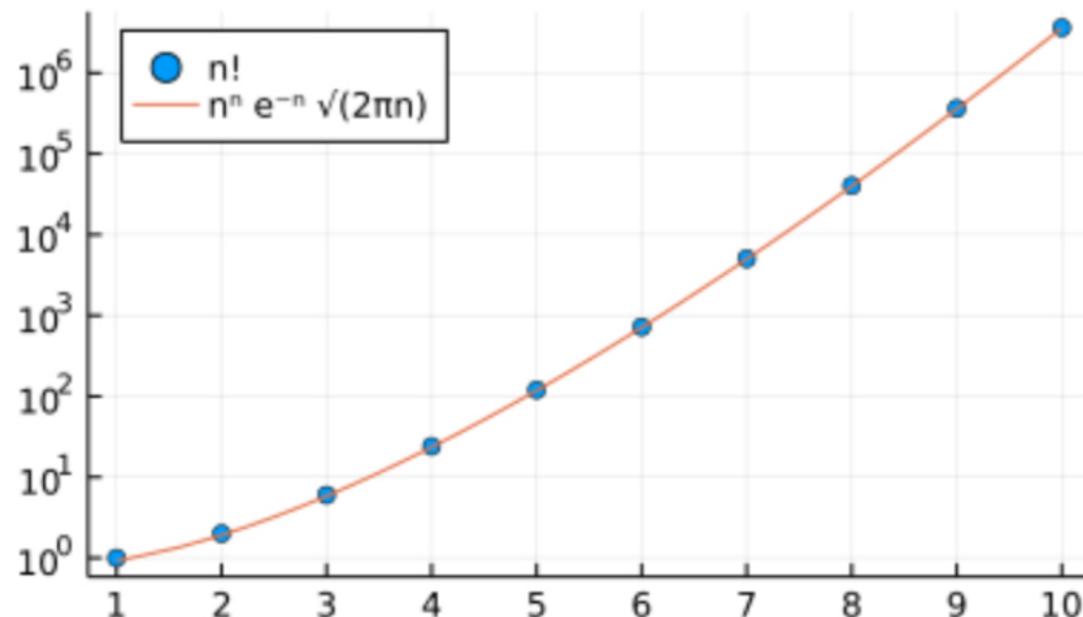
Stirling approximation of $n!$



スターリングの公式による
 $n!$ の近似のグラフ

$n=10$ 以下でも
よく一致している。

Stirling approximation of $n!$



対数スケールで比較

Stirling の公式を使った
近似は精度が高いので
使い易い。

ディガンマ, トリガンマ, ポリガンマ函数

応用上, ガンマ函数の導函数が必要になる場合がある.

$$\Gamma(\alpha) = \int_0^\infty e^{-x} x^{\alpha-1} dx \text{ より}, \quad \Gamma^{(k)}(\alpha) = \int_0^\infty e^{-x} x^{\alpha-1} (\log x)^k dx.$$

$\Gamma^{(k)}(\alpha)$ そのものではなく,

$$\Psi(\alpha) = \frac{\partial}{\partial \alpha} (\log \Gamma(\alpha)) = \frac{\Gamma'(\alpha)}{\Gamma(\alpha)}, \quad \Psi'(\alpha), \quad \Psi^{(k)}(\alpha) = \left(\frac{\partial}{\partial \alpha} \right)^{k+1} \log \Gamma(\alpha)$$

はそれぞれ ディガンマ, トリガンマ, ポリガンマ 函数と呼ばれる基本特殊函数であり,
コンピュータ上のライブラリで簡単に計算できる.

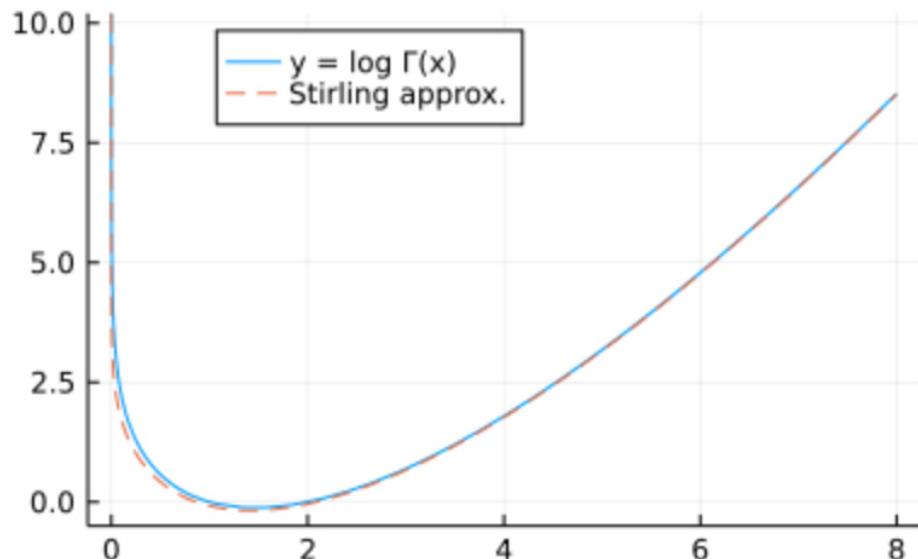
このことを知つていると, ガンマ函数の導函数が必要な計算 (たとえば ガンマ分布
モデルの最尤法) のコンピュータでの実装で困らない.

$$\Gamma(\alpha) = \lim_{n \rightarrow \infty} \frac{n^\alpha n!}{\alpha(\alpha+1)\cdots(\alpha+n)} \quad \leftarrow \text{Gauss の乗法公式} \quad \text{より}, \quad \Psi(\alpha) = (\log \Gamma(\alpha))' = \lim_{n \rightarrow \infty} \left(\log n - \sum_{k=0}^n \frac{1}{\alpha+k} \right),$$

$$\Psi'(\alpha) = \sum_{k=0}^{\infty} \frac{1}{(\alpha+k)^2}, \quad -\Psi(1) = \gamma \approx 0.5772 \quad (\text{Euler の } \gamma) \text{ などが得られる},$$

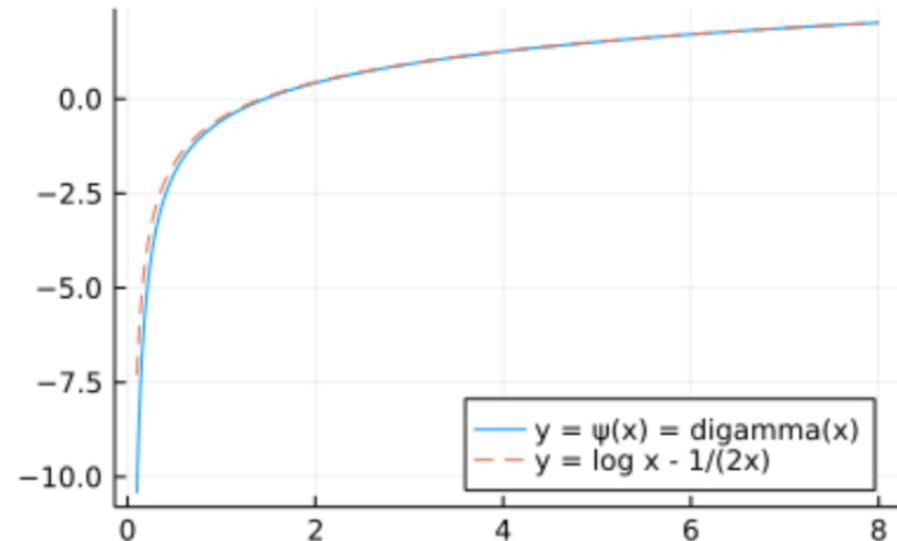
$$\Gamma(\alpha+1) = \alpha \Gamma(\alpha) \text{ から}, \quad \Psi(\alpha+1) = \Psi(\alpha) + \frac{1}{\alpha}, \quad \Psi'(\alpha+1) = \Psi'(\alpha) - \frac{1}{\alpha^2} \text{ などが得られる}.$$

対数ガンマ函数 $\log \Gamma(x)$, ディガンマ函数 $\psi(x) = (\log \Gamma(x))'$, トリガンマ函数 $\psi'(x)$ のグラフ



対数ガンマ ↑

ディガンマ

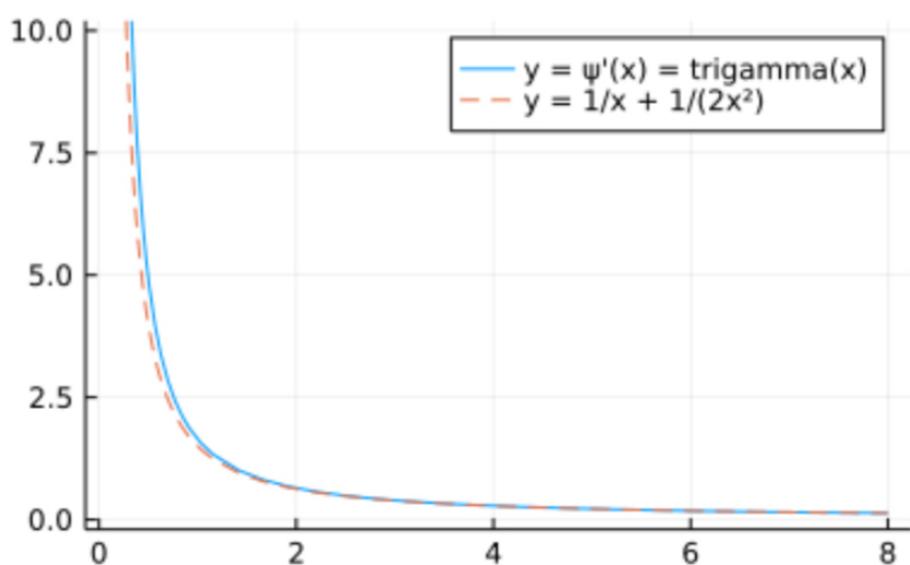


$$\log \Gamma(x) \approx x \log x - x - \frac{1}{2} \log x + \log \sqrt{2\pi}$$

トリ
ガ
ン
マ

$$\psi(x) \approx \log x - \frac{1}{2x}$$

$$\psi'(x) \approx \frac{1}{x} + \frac{1}{2x^2}$$



ベータ函数 $B(\alpha, \beta) = \int_0^1 t^{\alpha-1} (1-t)^{\beta-1} dt \quad (\alpha, \beta > 0)$. $\begin{cases} t=1-u \text{ とおくと} \\ B(\alpha, \beta) = B(\beta, \alpha) \text{ となるわかる} \end{cases}$

ベータ函数のガンマ函数表示 $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$ \leftarrow (後で示す.)

他の表示 $B(\alpha, \beta) = \int_0^1 \frac{u^{\alpha-1} du}{(1+u)^{\alpha+\beta}} = 2 \int_0^{\pi/2} (\cos \theta)^{2\alpha-1} (\sin \theta)^{2\beta-1} d\theta$

$$t = \frac{u}{1+u} = 1 - \frac{1}{1+u} \quad \uparrow$$

\uparrow
 $u = \frac{t}{1-t} \quad \leftarrow$ t が確率のとき, $\frac{t}{1-t}$ をオッズ (odds) と呼ぶ.

$x = \log u = \log \frac{t}{1-t}$ をlogit変換と呼び,

その逆変換 $t = \frac{e^x}{1+e^x} = \frac{1}{1-e^{-x}}$ をlogistic変換と呼ぶ.

$$\begin{array}{c} 0 < t < 1 \\ \uparrow \\ 0 < u < \infty \\ \uparrow \\ -\infty < x < \infty \end{array}$$

$$\begin{cases} \text{logit}(t) = \log \frac{t}{1-t} \\ \text{logistic}(x) = \frac{1}{1+e^{-x}} \end{cases}$$

ベータ分布の定義 次の確率密度函数が定める $0 < t < 1$ における分布を**ベータ分布**と呼ぶ:

$$p(t|\alpha, \beta) = \frac{1}{B(\alpha, \beta)} t^{\alpha-1} (1-t)^{\beta-1} \quad (0 < t < 1).$$

\uparrow
 Beta(α, β) と書く

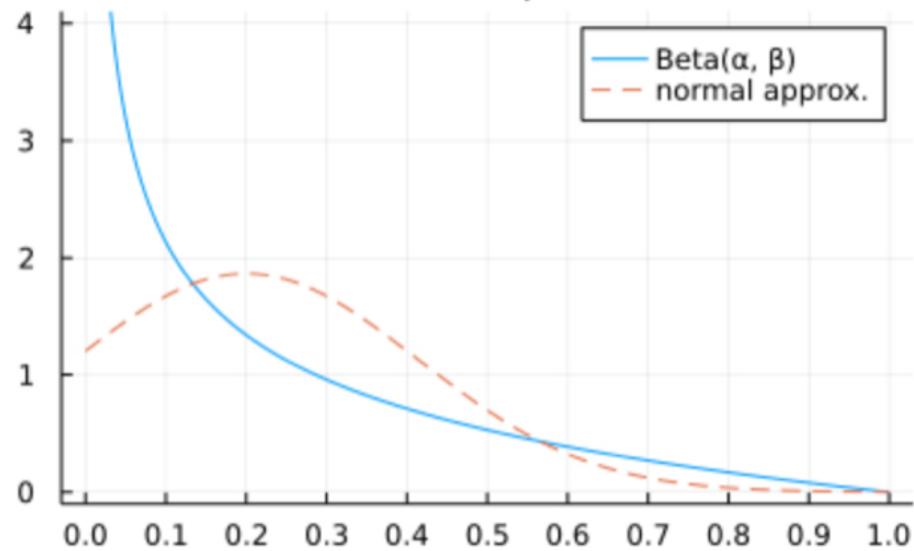
自習問題 ベータ函数のガンマ函数表示を用いて,

分布 Beta(α, β) の期待値と分散がそれぞれ $\frac{\alpha}{\alpha+\beta}$, $\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$ になることを示せ.

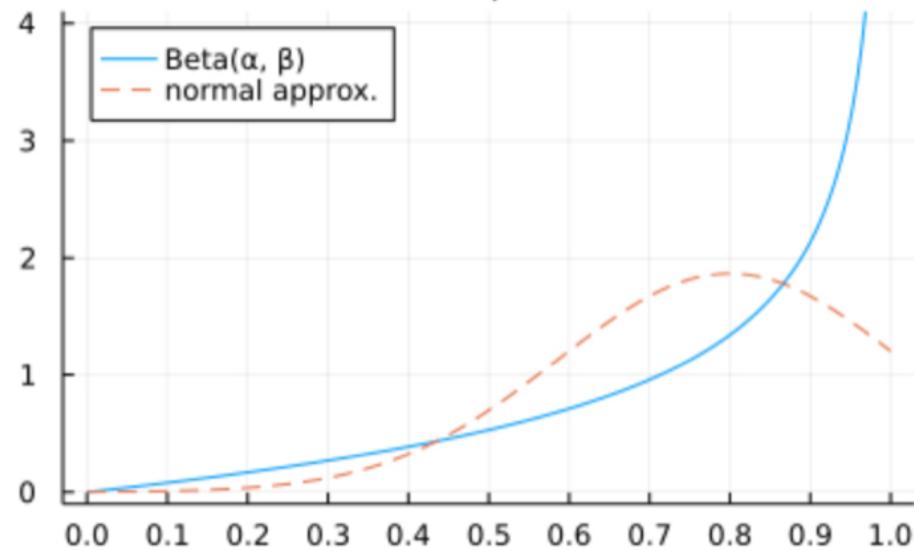
Githubにおいてある資料に答えがある.

ベータ分布のグラフ

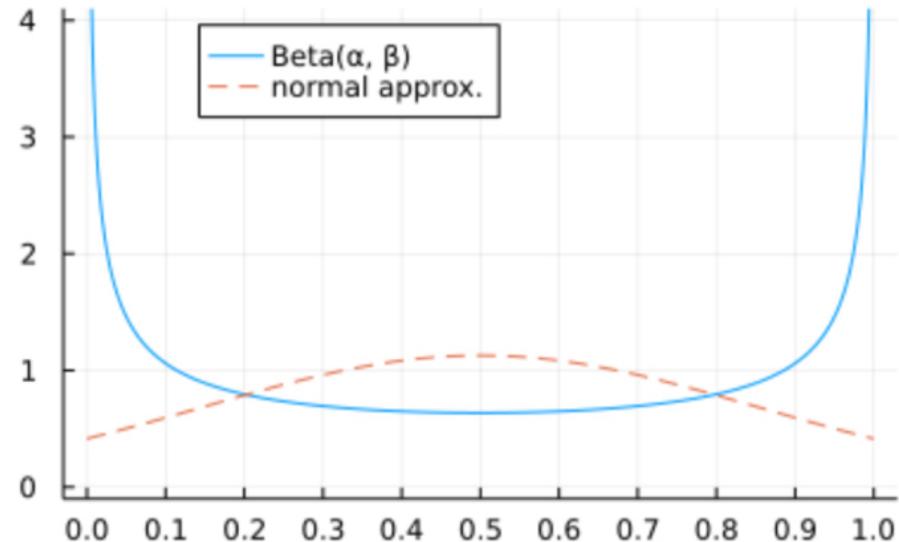
$\alpha = 0.5, \beta = 2$



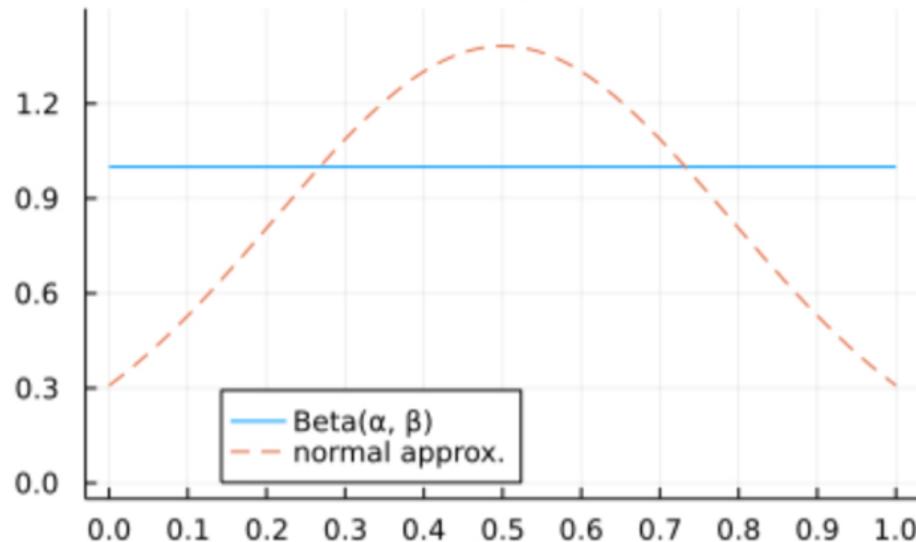
$\alpha = 2, \beta = 0.5$



$\alpha = 0.5, \beta = 0.5$



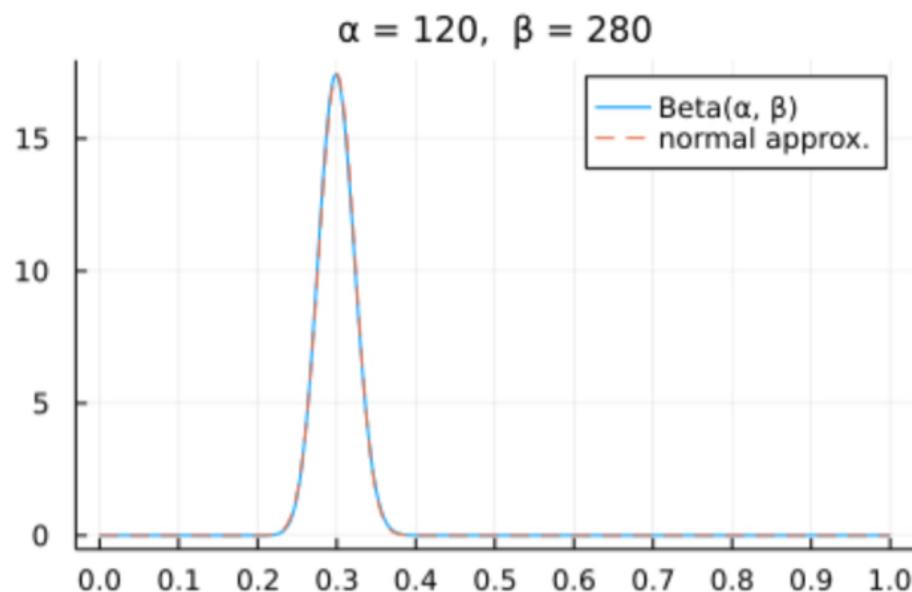
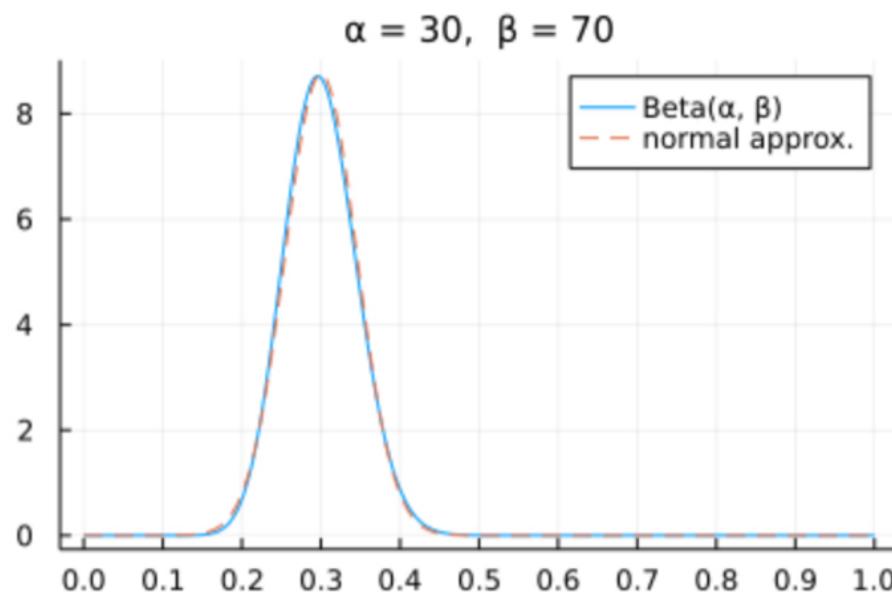
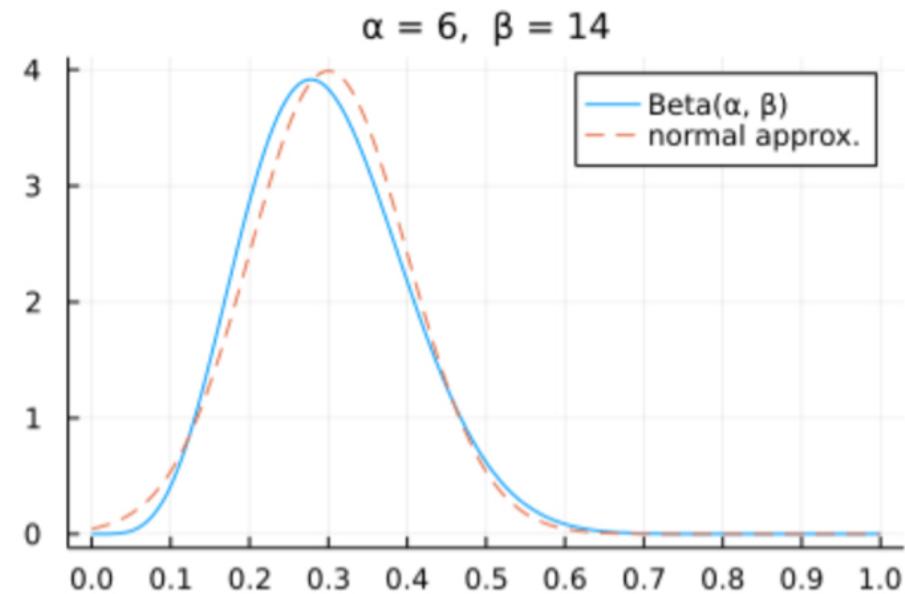
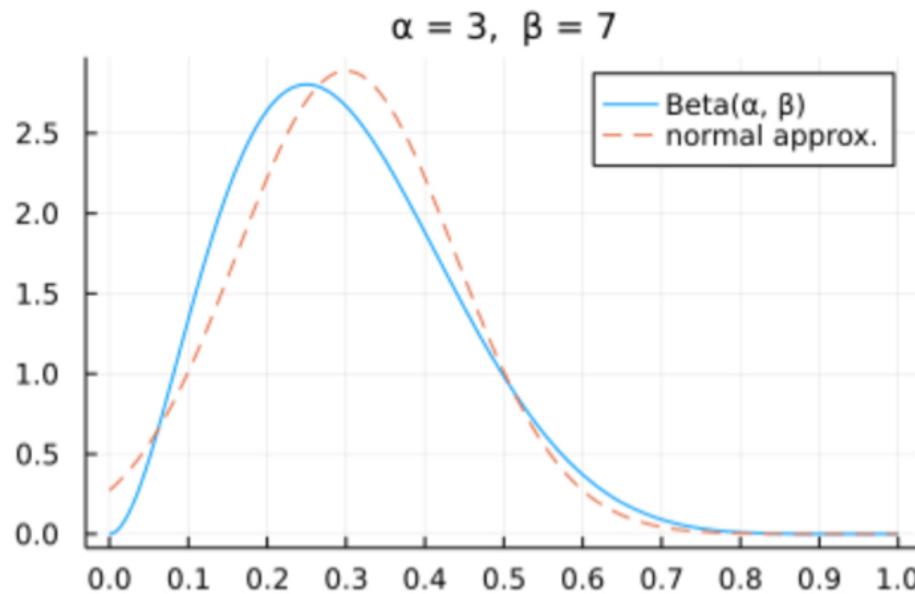
$\alpha = 1, \beta = 1$



Uniform(0,1)と同じ

ベータ分布のグラフ(つくり)

パラメータを大きくすると正規分布で近似される。



ベータ函数の極限でガソマ函数が得られること

$$\lim_{n \rightarrow \infty} n^\alpha B(\alpha, n+b) = \Gamma(\alpha)$$

↑ 正規分布から外れた世界 ↑ 正規分布の世界

↑ 証明

極限

$$n^\alpha B(\alpha, n+b) = n^\alpha \int_0^1 t^{\alpha-1} (1-t)^{n+b-1} dt = \int_0^n x^{\alpha-1} \left(1 - \frac{x}{n}\right)^{n+b-1} dx,$$

$$\lim_{n \rightarrow \infty} \left(1 - \frac{x}{n}\right)^{n+b-1} = e^{-x} \quad (\because \lim_{n \rightarrow \infty} \left(1 - \frac{x}{n}\right)^n = e^{-x}, \lim_{n \rightarrow \infty} \left(1 - \frac{x}{n}\right)^{b-1} = 1)$$

$$\text{ゆるべ}, \lim_{n \rightarrow \infty} n^\alpha B(\alpha, n+b) = \int_0^\infty x^{\alpha-1} e^{-x} dx = \Gamma(\alpha).$$

□

$\sqrt{\pi}$

II

例 $\nu \rightarrow \infty$ のとき, $\sqrt{\nu} B\left(\frac{1}{2}, \frac{\nu}{2}\right) = \sqrt{2} \left(\frac{\nu}{2}\right)^{\frac{1}{2}} B\left(\frac{1}{2}, \frac{\nu}{2}\right) \rightarrow \sqrt{2} \Gamma\left(\frac{1}{2}\right) = \sqrt{2\pi}$,

これは次のようにしても示せよ:

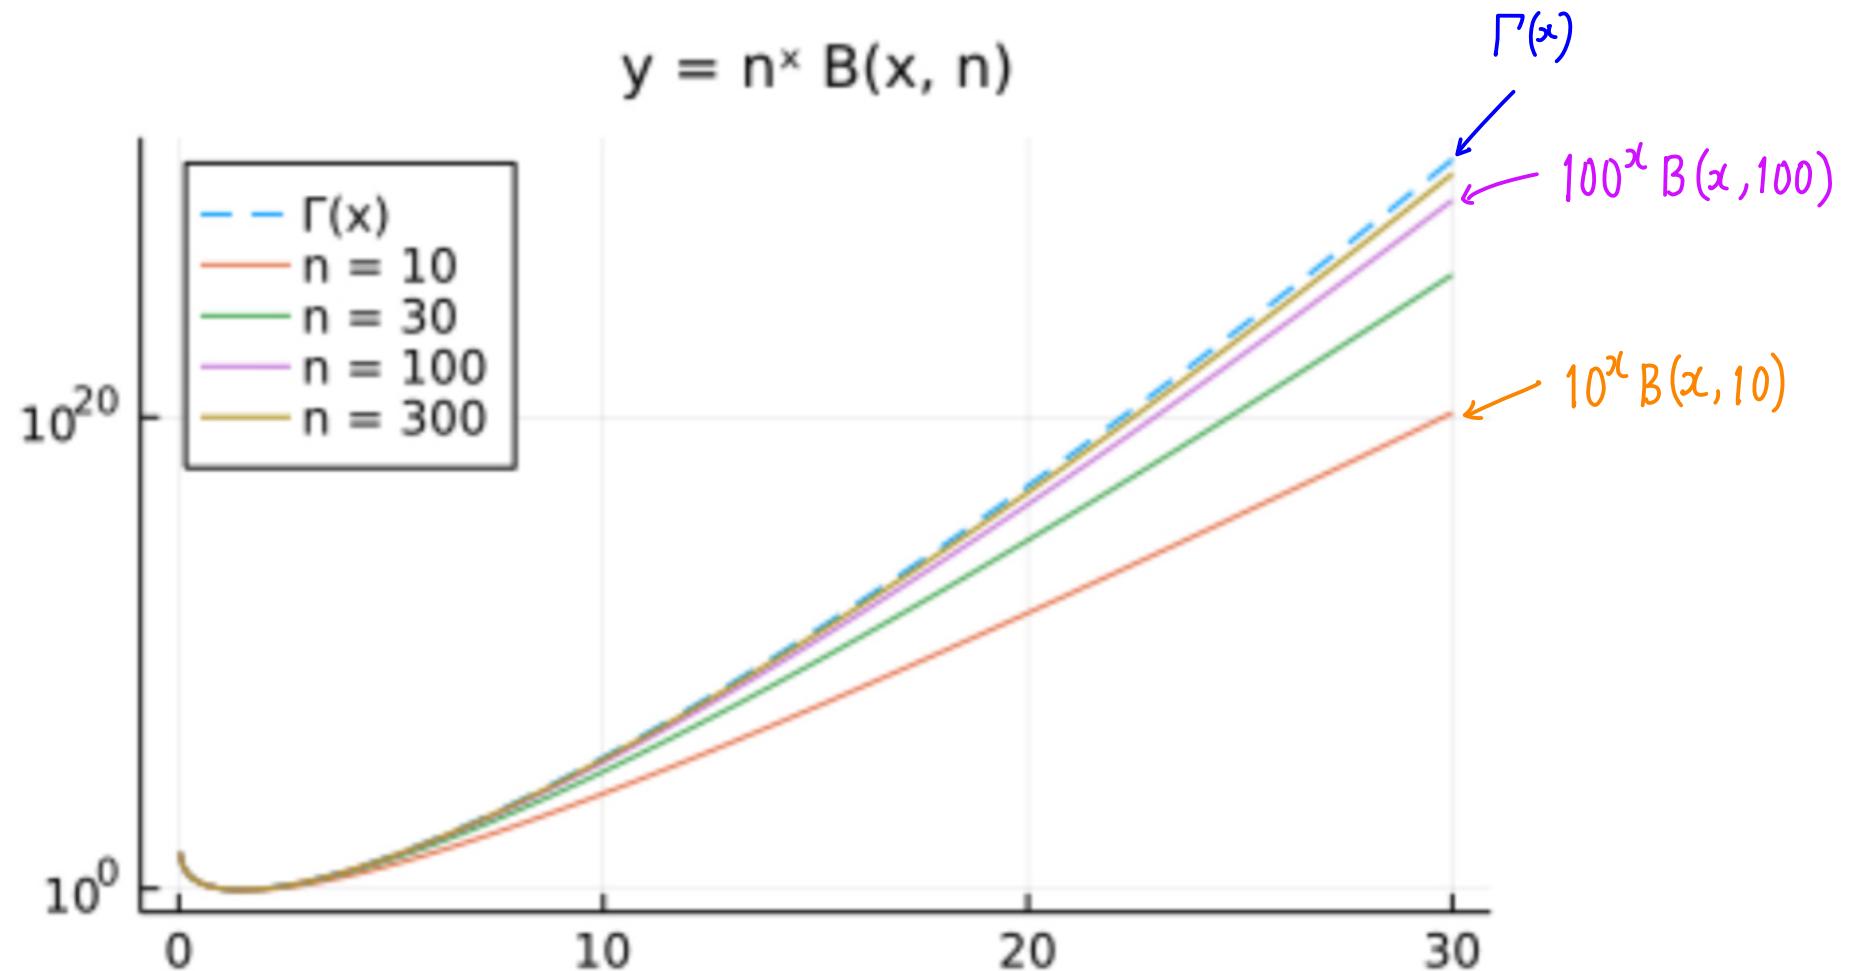
$$u = \frac{t^2}{\nu}, \frac{du}{dt} = 2 \frac{t}{\nu}, u^{1/2} = \frac{t}{\sqrt{\nu}}$$

$$\sqrt{\nu} B\left(\frac{1}{2}, \frac{\nu}{2}\right) = \sqrt{\nu} \int_0^\infty \frac{u^{\frac{1}{2}-1} du}{(1+u)^{(\nu+1)/2}} = 2 \int_0^\infty \left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2} dt = \int_{-\infty}^\infty \left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2} dt$$

(後で使う)

$$= \int_{-\infty}^\infty \left(1 + \frac{t^2/2}{\nu/2}\right)^{-\nu/2-1/2} dt \xrightarrow{\nu \rightarrow \infty} \int_{-\infty}^\infty e^{-t^2/2} dt = \sqrt{2\pi}. \quad \square$$

$y = n^x B(x, n)$ と $y = \Gamma(x)$ を対数スケールで同時プロット



自習問題(易) $B(\alpha, \beta) = 2 \int_0^{\pi/2} (\cos \theta)^{2\alpha-1} (\sin \theta)^{2\beta-1} d\theta$ を示せ ($t = \cos^2 \theta$ とおく),

答えは Github においてある資料にある。

$$\text{特に } B\left(\frac{1}{2}, \beta\right) = 2 \int_0^{\pi/2} (\sin \theta)^{2\beta-1} d\theta, \quad B\left(\alpha, \frac{1}{2}\right) = 2 \int_0^{\pi/2} (\cos \theta)^{2\alpha-1} d\theta.$$

$\sin \theta$ や $\cos \theta$ のべきの 0 から $\frac{\pi}{2}$ までの積分はベータ函数で計算できる。

ベータ函数の別の基本表示 (確率密度ではなくオッズ $u = \frac{t}{1-t}$ による表示)

$$B(\alpha, \beta) = \int_0^\infty \frac{u^{\alpha-1} du}{(1+u)^{\alpha+\beta}}.$$

重要!

$$\uparrow \\ t = \frac{u}{1+u} = 1 - \frac{1}{1+u}$$

証明 $B(\alpha, \beta) = \int_0^1 t^{\alpha-1} (1-t)^{\beta-1} dt$ で $t = \frac{u}{1+u} = 1 - \frac{1}{1+u}$ とおくと,

$$dt = \frac{du}{(1+u)^2} \text{ と } u = \frac{t}{1-t} \text{ より}, \quad \begin{array}{c|cc} t & 0 & 1 \\ \hline u & 0 & \infty \end{array} \text{ より},$$

$$B(\alpha, \beta) = \int_0^\infty \left(\frac{u}{1+u}\right)^{\alpha-1} \left(\frac{1}{1+u}\right)^{\beta-1} \frac{du}{(1+u)^2} = \int_0^\infty \frac{u^{\alpha-1} du}{(1+u)^{\alpha+\beta}}.$$

□

この計算は t分布 や F分布 と深く関係している。

自習問題(易)

$$\int_{-\infty}^{\infty} \left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2} dt = \sqrt{\nu} B\left(\frac{1}{2}, \frac{\nu}{2}\right) \quad (\nu > 0).$$

答えは
Githubにみる
ある資料にある。

ヒント (左辺) = $2 \int_0^{\infty} \left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2} dt$ で $t = \sqrt{\nu} u$ とおいて、ベータ函数の別の基本表示を使い、

$T\text{Dist}(\nu)$ と書く

太分布の定義

次の確率密度函数によつて定義される分布を 太分布 と呼ぶ:

$$p(t|\nu) = \frac{1}{\sqrt{\nu} B\left(\frac{1}{2}, \frac{\nu}{2}\right)} \left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2} \quad (t \in \mathbb{R}), \quad \leftarrow \nu \text{を} \underline{\text{自由度}} \text{と呼ぶ},$$

$\nu=1$ の太分布を Cauchy分布 といひ "Cauchy()" と書く。

$$p(t|1) = \frac{1}{\pi} \frac{1}{1+t^2} \quad (t \in \mathbb{R}) \quad \leftarrow$$

太分布 $T\text{Dist}(\nu)$ は $\nu \rightarrow \infty$ で "標準正規分布" に収束する

$$\begin{cases} \nu & \\ \mu & \nu \\ \mu - & \nu - \\ \mu & \nu \\ \mu - & \nu \end{cases}$$

$$\lim_{\nu \rightarrow \infty} p(t|\nu) = \frac{1}{\sqrt{2\pi}} e^{-t^2/2}.$$

証明

すでに $\lim_{\nu \rightarrow \infty} \sqrt{\nu} B\left(\frac{1}{2}, \frac{\nu}{2}\right) = \sqrt{2\pi}$ を示した。その計算ですでに

$$\begin{aligned} & \log\left(1 + \frac{a}{n}\right)^{-n} \\ &= -n \log\left(1 + \frac{a}{n}\right) \\ &= -n\left(\frac{a}{n} - \frac{a^2}{2n^2} + \dots\right) \end{aligned}$$

$\nu \rightarrow \infty$ のとき, $\left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2} = \left(1 + \frac{t^2/2}{\nu/2}\right)^{-\frac{\nu}{2}-\frac{1}{2}} \rightarrow e^{-\frac{t^2}{2}}$ となることを
使っている。
 $(1 + \frac{a}{n})^n \rightarrow e^{-a} (n \rightarrow \infty)$

□

大分布 $TDist(\nu)$ のグラフ

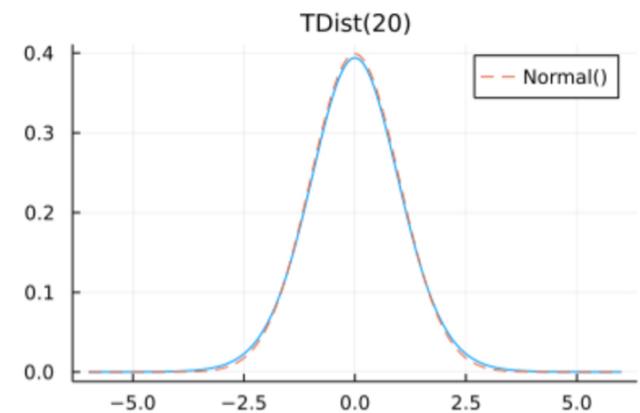
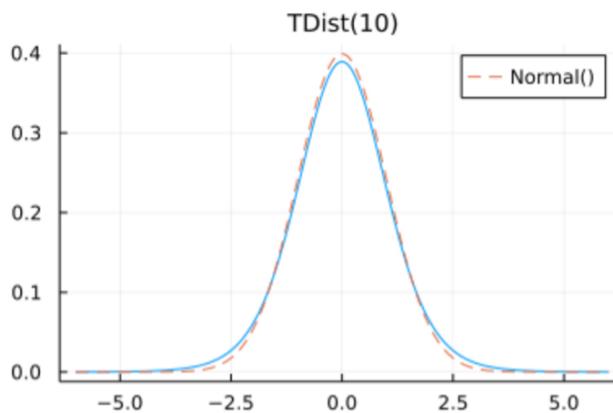
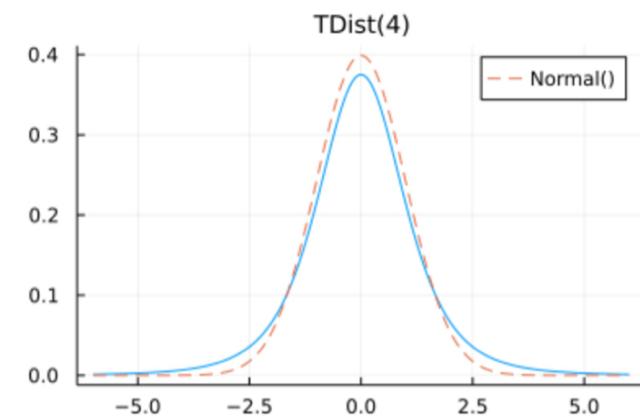
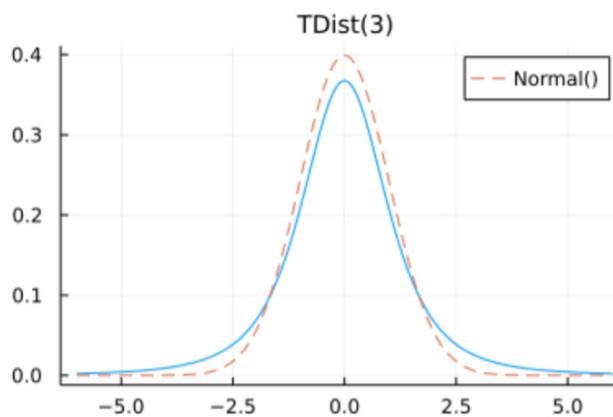
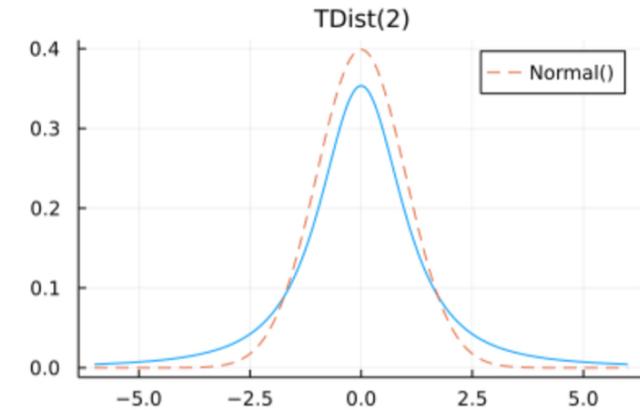
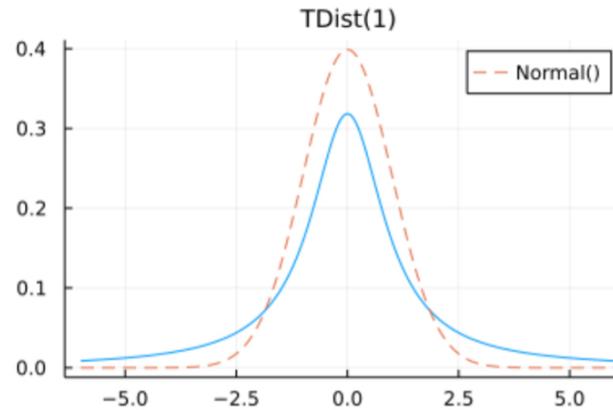
点線は標準正規分布

$$\frac{e^{-t^2/2}}{\sqrt{2\pi}}$$

実線は大分布

$$\frac{1}{\sqrt{\nu} B(\frac{1}{2}, \frac{\nu}{2})} \left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2}$$

自由度 ν を大きくすると、
大分布は標準正規分布
に近づく。



ベータ函数のガンマ函数表示

大学新入生向けの微積分の講義でアビに
やっていると思うが確率分布と相似のよい方法でやるなあそ。

$$\Gamma(\alpha) \Gamma(\beta) = \Gamma(\alpha + \beta) B(\alpha, \beta)$$

積分 $J[f]$ に関する公式 函数 $f(z, t)$ に対して, $J[f]$ を次のように定める:

$$J[f] = \int_0^\infty \int_0^\infty f\left(z+y, \frac{z}{z+y}\right) e^{-z} z^{\alpha-1} \cdot e^{-y} y^{\beta-1} dz dy.$$

このとき, 次の公式が成立している:

$$J[f] = \int_0^\infty \left(\int_0^1 f(z, t) e^{-z} z^{\alpha+\beta-1} \cdot t^{\alpha-1} (1-t)^{\beta-1} dt \right) dz. \quad \square$$

後で証明する。

上の公式を $f=1$ ($f(z, t)$ は z と t によらずに 1) の場合に適用すると,

$$J[1] = \int_0^\infty e^{-z} z^{\alpha-1} dz \cdot \int_0^\infty e^{-y} y^{\beta-1} dy = \Gamma(\alpha) \Gamma(\beta),$$

$$J[1] = \int_0^\infty e^{-z} z^{\alpha+\beta-1} dz \cdot \int_0^1 t^{\alpha-1} (1-t)^{\beta-1} dt = \Gamma(\alpha+\beta) B(\alpha, \beta).$$

$$\therefore \Gamma(\alpha) \Gamma(\beta) = \Gamma(\alpha+\beta) B(\alpha, \beta).$$

J[f]に関する公式の証明

定義

$$\begin{aligned}
 J[f] &= \int_0^\infty \int_0^\infty f\left(x+y, \frac{x}{x+y}\right) e^{-x} x^{\alpha-1} \cdot e^{-y} y^{\beta-1} dx dy \\
 &= \int_0^\infty \left(\int_0^\infty f\left(x+y, \frac{x}{x+y}\right) e^{-(x+y)} x^{\alpha-1} y^{\beta-1} dy \right) dx \\
 &= \int_0^\infty \left(\int_{\color{red}x}^\infty f(z, \frac{x}{z}) e^{-z} x^{\alpha-1} (z-x)^{\beta-1} dz \right) dx \\
 &= \int_0^\infty \left(\int_0^z f(z, \frac{x}{z}) e^{-z} x^{\alpha-1} (z-x)^{\beta-1} dx \right) dz \\
 &= \int_0^\infty \left(\int_0^1 f(z, t) e^{-z} (zt)^{\alpha-1} (z(1-t))^{\beta-1} z dt \right) dz \\
 &= \int_0^\infty \left(\int_0^1 f(z, t) e^{-z} z^{\alpha+\beta-1} \cdot t^{\alpha-1} (1-t)^{\beta-1} dt \right) dz
 \end{aligned}$$

積分領域は
 $0 < x < z < \infty$

$\left\{ \begin{array}{l} x = zt, \quad dx = z dt \\ 0 < x < z \Leftrightarrow 0 < t < 1 \end{array} \right.$

f.e.d.

この結果はガンマ分布からベータ分布を作る方法を与える。

確率変数達の同時確率密度函数と独立性

確率変数達 X_1, \dots, X_n が 同時確率密度函数 $p(x_1, \dots, x_n)$ を持つとは

$$E[f(X_1, \dots, X_n)] = \int \dots \int f(x_1, \dots, x_n) p(x_1, \dots, x_n) dx_1 \dots dx_n \quad (\text{定積分})$$

が成立することを定める。このとき

$$p_{\hat{x}_i}(x_i) = \int \dots \int p(x_1, \dots, x_n) dx_1 \dots \widehat{dx_i} \dots dx_n \quad (\widehat{dx_i} \text{は } dx_i \text{ を除くという意味})$$

とおくと、 $p_{\hat{x}_i}(x_i)$ は X_i 単独の確率密度函数になる：

$$\begin{aligned} E[f_{\hat{x}_i}(x_i)] &= \int \dots \int f_{\hat{x}_i}(x_i) p(x_1, \dots, x_n) dx_1 \dots dx_n \\ &= \int f_{\hat{x}_i}(x_i) \left(\int \dots \int p(x_1, \dots, x_n) dx_1 \dots \widehat{dx_i} \dots dx_n \right) dx_i = \int f_{\hat{x}_i}(x_i) p_{\hat{x}_i}(x_i) dx_i, \end{aligned}$$

確率変数達 X_1, \dots, X_n が 独立であるとは、

$p(x_1, \dots, x_n) = p_1(x_1) \dots p_n(x_n)$ が成立することを定める。 同時確率質量函数の場合も同様

このとき、次が成立する：

$$\begin{aligned} E[f_1(X_1) \dots f_n(X_n)] &= \int \dots \int f_1(x_1) \dots f_n(x_n) p_1(x_1) \dots p_n(x_n) dx_1 \dots dx_n \\ &= \int f_1(x_1) p_1(x_1) dx_1 \dots \int f_n(x_n) p_n(x_n) dx_n \\ &= E[f_1(X_1)] \dots E[f_n(X_n)]. \end{aligned}$$

同時確率質量函数も
同様に定める。

後で再度説明する予定

確率変数の
独立性は、
多くの場合、
この形で使う。

ベータ分布のガンマ分布表示

$$X \sim \text{Gamma}(\alpha, 1), Y \sim \text{Gamma}(\beta, 1)$$

確率変数達 X, Y は 独立

これを使うとガンマ分布の乱数からベータ分布の乱数を作れる。

$$\left. \begin{array}{l} X \sim \text{Gamma}(\alpha, 1), Y \sim \text{Gamma}(\beta, 1) \\ X, Y \text{ は独立} \end{array} \right\} \Rightarrow \left\{ \begin{array}{l} X+Y \sim \text{Gamma}(\alpha+\beta, 1), \frac{X}{X+Y} \sim \text{Beta}(\alpha, \beta) \\ X+Y, \frac{X}{X+Y} \text{ は独立} \end{array} \right.$$

証明

\Rightarrow の左边より,

$$E\left[f\left(X+Y, \frac{X}{X+Y}\right)\right] = \int_0^\infty \int_0^\infty f(x+y, \frac{x}{x+y}) \frac{e^{-x} x^{\alpha-1}}{\Gamma(\alpha)} \frac{e^{-y} y^{\beta-1}}{\Gamma(\beta)} dx dy = \frac{J[f]}{\Gamma(\alpha) \Gamma(\beta)}.$$

$J[f]$ に関する公式と $\Gamma(\alpha) \Gamma(\beta) = \Gamma(\alpha+\beta) B(\alpha, \beta)$ より,

$$\frac{J[f]}{\Gamma(\alpha) \Gamma(\beta)} = \frac{J[f]}{\Gamma(\alpha+\beta) B(\alpha, \beta)} = \int_0^\infty \left(\int_0^1 f(z, t) \frac{e^{-z} z^{\alpha+\beta-1}}{\Gamma(\alpha+\beta)} \frac{t^{\alpha-1} (1-t)^{\beta-1}}{B(\alpha, \beta)} dt \right) dz.$$

これは \Rightarrow の右辺の成立を意味する。 \square

注意

上の逆向き \Leftarrow も同様に成立する。 \square

注意

仮に、ガンマ函数の乱数を

Github における資料では
実際にこれを実行している。

$x = \text{rand}(\text{Gamma}(\alpha, 1)), y = \text{rand}(\text{Gamma}(\beta, 1))$ と生成できるように

$z = x+y$ は $\text{Gamma}(\alpha+\beta, 1)$ にしたがう乱数になり、

$t = \frac{x}{z} = \frac{x}{x+y}$ は $\text{Beta}(\alpha, \beta)$ にしたがう乱数になる。 \square

積分 $K[g]$ に関する公式

函数 $g(z, u)$ について

$$K[g] = \int_0^\infty \int_0^\infty g(x+y, \frac{x}{y}) e^{-x} x^{\alpha-1} \cdot e^{-y} y^{\beta-1} dx dy$$

と定めると、

$$K[g] = \int_0^\infty \int_0^\infty g(z, u) e^{-z} z^{\alpha+\beta-1} \cdot \frac{u^{\alpha-1}}{(1+u)^{\alpha+\beta}} du dz$$

$$u = \frac{t}{1-t} \quad (\text{オッズ})$$

$$t = \frac{u}{1+u} \quad (\text{確率})$$

証明 $f(z, t) = g\left(z, \frac{t}{1-t}\right)$ と定めると、 $g(z, u) = f\left(z, \frac{u}{1+u}\right)$.

$$g(x+y, \frac{x}{y}) = f\left(x+y, \frac{x/y}{1+x/y}\right) = f\left(x+y, \frac{x}{x+y}\right) \text{ なので}, \underline{K[g] = J[f]}.$$

そこで、 $J[f]$ の公式で $t = \frac{u}{1+u} = 1 - \frac{1}{1+u}$ とおくと、 $0 < t < 1 \Leftrightarrow 0 < u < \infty$ で

$$f(z, t) t^{\alpha-1} (1-t)^{\beta-1} dt = f\left(z, \frac{u}{1+u}\right) \left(\frac{u}{1+u}\right)^{\alpha-1} \left(\frac{1}{1+u}\right)^{\beta-1} \frac{du}{(1+u)^2} = g(z, t) \frac{u^{\alpha-1}}{(1+u)^{\alpha+\beta}} du$$

$$\text{なので}, \underline{K[g] = J[f] = \int_0^\infty \int_0^\infty g(z, u) e^{-z} z^{\alpha+\beta-1} \cdot \frac{u^{\alpha-1}}{(1+u)^{\alpha+\beta}} du dz}.$$

q.e.d.

自習問題

以上の証明をノートにもっと詳しい形式で書いて内容を確認せよ。

私の経験では証明はすべて自分の手で書かないと理解できない。
(大量に時間
がとられる!)

ガンマ分布にしたがう独立な確率変数の商がしたがう分布

$X \sim \text{Gamma}(\alpha, 1)$, $Y \sim \text{Gamma}(\beta, 1)$ で X, Y が独立なとき,

$U = \frac{X}{Y}$ は次の確率密度函数を持つ:

$$p(u|\alpha, \beta) = \frac{1}{B(\alpha, \beta)} \frac{u^{\alpha-1}}{(1+u)^{\alpha+\beta}} \quad (u > 0).$$

すなわち, $E[g(U)] = \int_0^\infty g(u) p(u|\alpha, \beta) du$ が成立する.

証明 $T = \frac{X}{X+Y} \sim \text{Beta}(\alpha, \beta)$ となる

$$E[f(T)] = \frac{1}{B(\alpha, \beta)} \int_0^1 f(t) t^{\alpha-1} (1-t)^{\beta-1} dt,$$

そして, $\frac{T}{1-T} = \frac{X}{Y} = U$ なので,

$$\begin{aligned} E[g(U)] &= \frac{1}{B(\alpha, \beta)} \int_0^1 g\left(\frac{t}{1-t}\right) t^{\alpha-1} (1-t)^{\beta-1} dt \\ &= \frac{1}{B(\alpha, \beta)} \int_0^\infty g(u) \left(\frac{u}{1+u}\right)^{\alpha-1} \left(\frac{1}{1+u}\right)^{\beta-1} \frac{du}{(1+u)^2} \\ &= \frac{1}{B(\alpha, \beta)} \int_0^\infty g(u) \frac{u^{\alpha-1}}{(1+u)^{\alpha+\beta}} du \\ &= \int_0^\infty g(u) p(u|\alpha, \beta) du. \end{aligned}$$

自習問題

ノート上に詳しい証明
を自分の手で書き,
内容を確認せよ.

以上のような計算は
後で平均に関する
大検定や信頼区間を
理解するために役に立つ

(注) U がしたがう分布は
スケール変換のかけた除いて
F分布 に等しい.
↑ F検定で使われる.

q.e.d.

注意

$Z = X+Y$ と $T = \frac{X}{Z}$ だけではなく, $Z = X+Y$ と $U = \frac{X}{Y}$ も独立になる. \square

Dirichlet 積分 (ベータ函数の多変数化)

$\Delta_{n-1} = \{(t_1, \dots, t_{n-1}) \in \mathbb{R}^{n-1} \mid t_1, \dots, t_{n-1} > 0, t_1 + \dots + t_{n-1} < 1\}$ とおく。四面体の内側

$$\Delta_1 = \{t_1 \in \mathbb{R} \mid 0 < t_1 < 1\}, \quad \Delta_2 = \{(t_1, t_2) \in \mathbb{R}^2 \mid t_1, t_2 > 0, t_1 + t_2 < 1\} = \begin{array}{c} \text{triangle} \\ \text{shaded} \end{array}, \quad \Delta_3 = \begin{array}{c} \text{triangle} \\ \text{dashed lines} \end{array}$$

$\xrightarrow{\quad 0 \quad 1 \quad}$

$$B(\alpha_1, \dots, \alpha_n) = \int \dots \int_{\Delta_{n-1}} t_1^{\alpha_1-1} \dots t_{n-1}^{\alpha_{n-1}-1} (1 - (t_1 + \dots + t_{n-1}))^{\alpha_n-1} dt_1 \dots dt_{n-1}$$

\uparrow

$$(\alpha_1, \dots, \alpha_{n-1}, \alpha_n > 0) \quad = \frac{\Gamma(\alpha_1) \dots \Gamma(\alpha_{n-1}) \Gamma(\alpha_n)}{\Gamma(\alpha_1 + \dots + \alpha_{n-1} + \alpha_n)}$$

証明は Github におけるある資料にある。

自習問題

この結果をみとめて以下を示せ。

$X = \{(x_1, \dots, x_n) \in \mathbb{R}_{>0}^n \mid \left(\frac{x_1}{a_1}\right)^{p_1} + \dots + \left(\frac{x_n}{a_n}\right)^{p_n} < 1\}$ とおくとき、

$$\int \dots \int_X x_1^{\alpha_1-1} \dots x_n^{\alpha_{n-1}-1} dx_1 \dots dx_n = \frac{a_1^{\alpha_1} \dots a_n^{\alpha_n}}{p_1 \dots p_n} \frac{\Gamma(\alpha_1/p_1) \dots \Gamma(\alpha_n/p_n)}{\Gamma(\alpha_1/p_1 + \dots + \alpha_n/p_n + 1)}.$$

Dirichlet 分布

Dirichlet $(\alpha_1, \dots, \alpha_n)$

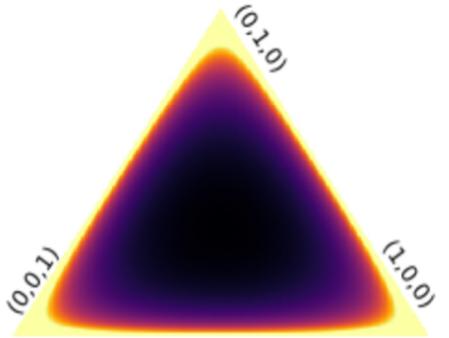
$$p(t_1, \dots, t_{n-1} \mid \alpha_1, \dots, \alpha_n) = \frac{t_1^{\alpha_1-1} \dots t_{n-1}^{\alpha_{n-1}-1} (1 - (t_1 + \dots + t_{n-1}))^{\alpha_n-1}}{B(\alpha_1, \dots, \alpha_n)}$$

$\begin{pmatrix} \text{密度函数} \\ (t_1, \dots, t_{n-1}) \\ \in \Delta_{n-1} \end{pmatrix}$

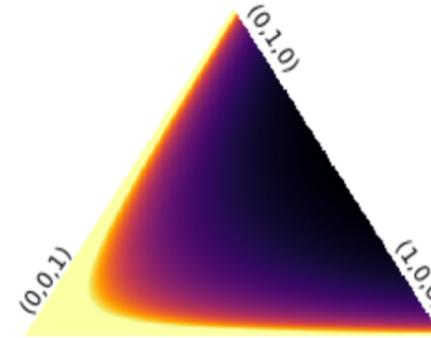
Dirichlet分布のヒートマップ

明るいところほど確率密度が高い。

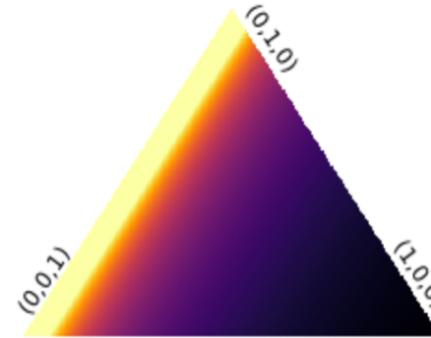
Dirichlet(0.5, 0.5, 0.5)



Dirichlet(0.5, 0.5, 1.0)

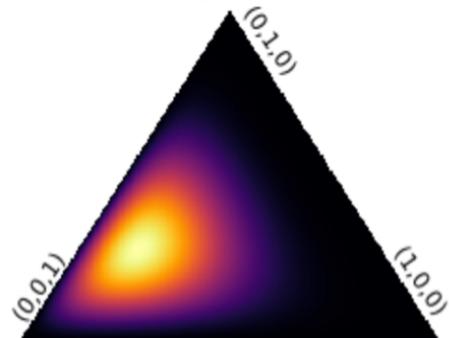


Dirichlet(0.5, 1.0, 1.0)

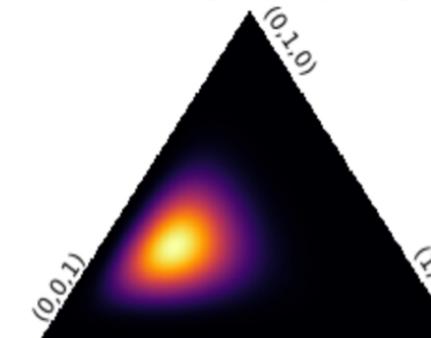


ヒートマップの方が
3次元のグラフより
見易い場合がある。

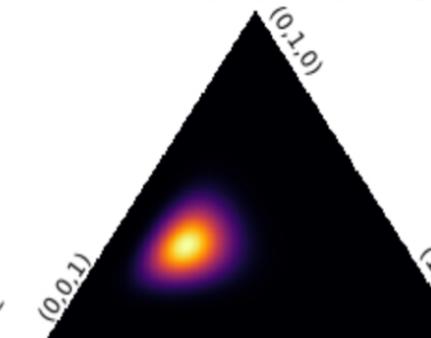
Dirichlet(2.0, 3.0, 5.0)



Dirichlet(4.0, 6.0, 10.0)



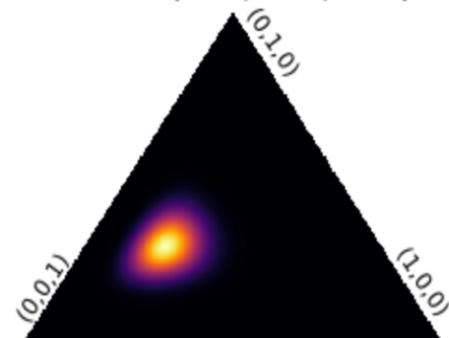
Dirichlet(8.0, 12.0, 20.0)



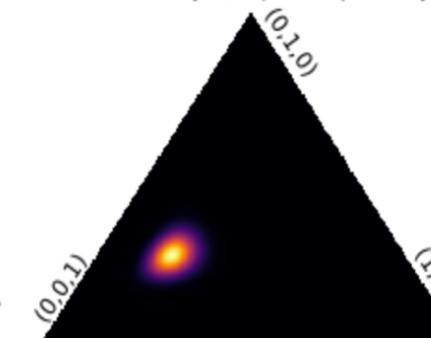
$t_1, t_2 > 0$ かつ

$$t_3 = 1 - (t_1 + t_2) > 0$$

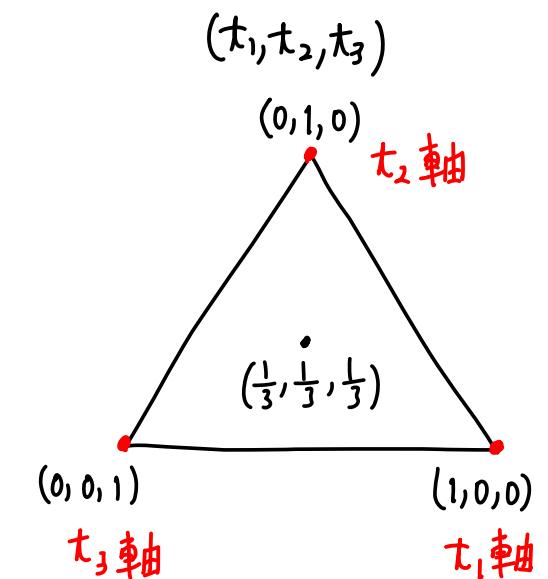
Dirichlet(10.0, 15.0, 25.0)



Dirichlet(20.0, 30.0, 60.0)



Dirichlet分布は
パラメータ → 大で
多変量正規分布
に近づく。



① 確率変数 X が確率密度函数 $p(x)$ を持つ $\leftarrow X \sim p(x)$

$$\Leftrightarrow E[f(x)] = \int f(x) p(x) dx \quad (\text{定積分})$$

$$X_1, \dots, X_n \sim p(x_1, \dots, x_n)$$

② 確率変数達 X_1, \dots, X_n が(同時)確率密度函数 $p(x_1, \dots, x_n)$ を持つ

$$\Leftrightarrow E[f(x_1, \dots, x_n)] = \int \dots \int f(x_1, \dots, x_n) p(x_1, \dots, x_n) dx_1 \dots dx_n \quad (\text{定積分})$$

そのときの X_i 単独の確率密度函数 $p_i(x_i)$ は次になる:

さらに,
$$p_i(x_i) = \int \dots \int p(x_1, \dots, x_n) dx_1 \dots \widehat{dx_i} \dots dx_n \quad (\widehat{dx_i} \text{ は } dx_i \text{ を除くという意味})$$

③ X_1, \dots, X_n は独立である $\leftarrow X_i \sim p_i(x_i)$ and X_1, \dots, X_n are independent.

$$\Leftrightarrow p(x_1, \dots, x_n) = p_1(x_1) \dots p_n(x_n)$$

$$\Leftrightarrow E[f_1(x_1) \dots f_n(x_n)] = E[f_1(x_1)] \dots E[f_n(x_n)] \quad \leftarrow \begin{array}{l} \text{確率変数の独立性は} \\ \text{この形で使う。} \end{array}$$

④ 確率変数の列 Y_1, Y_2, \dots の分布が確率変数 Y_∞ の分布に収束する (分布収束)

$$\Leftrightarrow \lim_{n \rightarrow \infty} E[f(Y_n)] = E[f(Y_\infty)], \quad \begin{array}{l} \text{分布の収束} \Leftrightarrow \text{確率変数の函数の} \\ \text{期待値の収束} \end{array}$$

(同時)
確率密度函数
についても同様

例 試行回数 n , 成功確率 p の Bernoulli 試行の分布にしたがう確率変数 X_1, \dots, X_n について,

$$E[f(X_1, \dots, X_n)] = \sum_{x_1=1,0} \dots \sum_{x_n=1,0} f(x_1, \dots, x_n) \underbrace{\prod_{i=1}^n (p^{x_i} (1-p)^{1-x_i})}_{\text{積の形}}$$

なので、 $X_i \sim \text{Bernoulli}(p)$ かつ X_1, \dots, X_n は 独立である。

例 $X \sim \text{Gamma}(\alpha, 1)$, $Y \sim \text{Gamma}(\beta, 1)$ で X と Y は 独立

$$\Leftrightarrow E[f(X, Y)] = \int_0^\infty \int_0^\infty f(x, y) \underbrace{\frac{e^{-x} x^{\alpha-1}}{\Gamma(\alpha)} \frac{e^{-y} y^{\beta-1}}{\Gamma(\beta)}}_{\text{積の形}} dx dy$$

このとき、

$$\begin{aligned} E[g(X+Y, \frac{X}{X+Y})] &= \int_0^\infty \int_0^\infty g\left(x+y, \frac{x}{x+y}\right) \frac{e^{-x} x^{\alpha-1}}{\Gamma(\alpha)} \frac{e^{-y} y^{\beta-1}}{\Gamma(\beta)} dx dy \\ &\stackrel{\text{ガンマ函数とベータ函数の関係}}{\downarrow} = \int_0^\infty \left(\int_0^1 g(z, t) \underbrace{\frac{e^{-z} z^{\alpha+\beta-1}}{\Gamma(\alpha+\beta)}}_{\text{積の形}} \underbrace{\frac{t^{\alpha-1} (1-t)^{\beta-1}}{B(\alpha, \beta)}}_{\text{積の形}} dt \right) dz. \end{aligned}$$

ゆえに、 $X+Y \sim \text{Gamma}(\alpha+\beta, 1)$, $\frac{X}{X+Y} \sim \text{Beta}(\alpha, \beta)$ かつ $X+Y$ と $\frac{X}{X+Y}$ は 独立。

例 $X_i \sim \text{Normal}(\mu, \sigma^2)$ かつ X_1, \dots, X_n は独立

$$\Leftrightarrow E[f(X_1, \dots, X_n)] = \int_{-\infty}^\infty \dots \int_{-\infty}^\infty f(x_1, \dots, x_n) \underbrace{\prod_{i=1}^n \left(\frac{e^{-(x_i-\mu)^2/(2\sigma^2)}}{\sqrt{2\pi\sigma^2}} \right)}_{\text{積の形}} dx_1 \dots dx_n.$$

例 (二項分布の Poisson 分布への収束) ← 後で説明する予定

$$K_n \sim \text{Binomial}(n, \frac{\lambda}{n}), K_\infty \sim \text{Poisson}(\lambda) \Rightarrow \lim_{n \rightarrow \infty} E[f(K_n)] = E[f(K_\infty)]$$

例 (負の二項分布のガンマ分布への収束) λ の小さな負の二項分布はガンマ分布で近似される。

$$M_L \sim \text{Negative Binomial}(d, \frac{1}{L\theta}), T_L = \frac{M_L + k}{L}, T_\infty \sim \text{Gamma}(d, \theta) \Rightarrow \lim_{L \rightarrow \infty} E[f(T_L)] = E[T_\infty],$$

例 (二項分布の中心極限定理) ← 後で解説する予定

$$K_n \sim \text{Binomial}(n, p), Z_n = \frac{K_n - np}{\sqrt{n}}, Z_\infty \sim \text{Normal}(0, p(1-p)) \Rightarrow \lim_{n \rightarrow \infty} E[f(Z_n)] = E[f(Z_\infty)],$$

例 (ガンマ分布の中心極限定理) ガンマ分布は λ が大きいとき正規分布で近似される。

$$X_\lambda \sim \text{Gamma}(\lambda, \theta), Z_\lambda = \frac{X_\lambda - \lambda\theta}{\sqrt{\lambda\theta^2}}, Z_\infty \sim \text{Normal}(0, 1) \Rightarrow \lim_{\lambda \rightarrow \infty} E[f(Z_\lambda)] = E[f(Z_\infty)],$$

例 (ベータ分布の正規分布近似) $0 < p < 1$ とする ベータ分布は p が大きいとき正規分布で近似される。

$$T_n \sim \text{Beta}(np, n(1-p)), Z_n = \frac{\sqrt{n}(T_n - p)}{p(1-p)}, Z_\infty \sim \text{Normal}(0, 1) \Rightarrow \lim_{n \rightarrow \infty} E[f(Z_n)] = E[f(Z_\infty)],$$

例 (一般の中心極限定理) X_i たるは同じ分布にしたがい独立であるとし,

$E[X_i] = \mu$ が定義され, $E[(X_i - \mu)^2] = \sigma^2 < \infty$, $E[|X_i - \mu|^3] < \infty$ であるとする。このとき,

$$Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{X_i - \mu}{\sigma}, Z_\infty \sim \text{Normal}(0, 1) \Rightarrow \lim_{n \rightarrow \infty} E[f(Z_n)] = E[f(Z)],$$

後で
解説
する。

確率分布達の解釈

① 正規分布の使い方について少し説明した後は Poisson 分布を定義する。

② Poisson 分布とガンマ分布の以下の解釈について説明

離散時間の場合 (Bernoulli 試行) $\xrightarrow{\text{連続時間極限}}$ 連続時間の場合

単位時間に L 回試行

1 が 出る

単位時間のあたりに平均 入回イベント発生

二項分布 $K \sim \text{Binomial}(L, \lambda/L)$

L 回の試行中のイベント発生回数 K の分布

イベント発生の時間的間隔の

期待値は $\theta = \frac{1}{\lambda}$

負の二項分布

$M \sim \text{Negative Binomial}(d, 1/(L\theta))$

$N := d + M$

$= \left(\begin{array}{l} \text{N 回イベントが} \\ \text{起こるまでの試行回数} \end{array} \right)$

連続時間極限

単位時間のあたりに平均 入回
イベントが起こる

Poisson 分布 $K \sim \text{Poisson}(\lambda)$

単位時間のあたりに起こる
イベントの回数 K の分布

イベント発生の時間的間隔の

期待値は $\theta = \frac{1}{\lambda}$

ガンマ分布

$T \sim \text{Gamma}(d, \theta)$

$\xrightarrow{L \rightarrow \infty}$

$\frac{N}{L}$

$\left(\begin{array}{l} \text{ちょうど N 回イベント} \\ \text{が起こるまでの時間} \end{array} \right) = T,$

③ ベータ分布の一様乱数発生のくりかえしによる解釈

① 正規分布の使い方について少し説明した後は Poisson 分布を定義する。

正規分布の使い方

正規分布に限らない一般論

常に $\sigma > 0$ とする



確率変数 X の期待値と分散がそれぞれ μ, σ^2 のとき,

$$\frac{X-\mu}{\sigma}$$

$\frac{X-\mu}{\sigma}$ の期待値と分散はそれぞれ 0 と 1 になる。 ←

標準化 と呼ぶ。

証明 $E[X] = \mu, \text{Var}(X) = E[(X-\mu)^2] = \sigma^2$ のとき, $E[\cdot]$ の線形性と規格化条件より,

$$E\left[\frac{X-\mu}{\sigma}\right] = \frac{E[X]-\mu}{\sigma} = 0, \quad \text{Var}\left(\frac{X-\mu}{\sigma}\right) = E\left[\left(\frac{X-\mu}{\sigma}\right)^2\right] = \frac{E[(X-\mu)^2]}{\sigma^2} = \frac{\sigma^2}{\sigma^2} = 1. \quad \boxed{\text{q.e.d.}}$$

一般の正規分布と標準正規分布の関係

$a, b \in \mathbb{R}, a > 0$ とする。

Github 資料に書いてある。

X が正規分布にしたがう確率変数ならば $aX+b$ も正規分布にしたがう (証明略)。

$X \sim \text{Normal}(\mu, \sigma)$ のとき, $Z = \frac{X-\mu}{\sigma}$ とおくと $Z \sim \text{Normal}(0, 1)$. ← 標準正規分布。

このことを使うと、一般の正規分布に関する計算を標準正規分布に帰着できる。
具体的な数値の計算 (コンピュータでの実装) でもこのことを使う。

正規分布に限らない一般論

X, Y が 独立な確率変数ならば

(無相関な条件)
ゆるめられる。

$$E[X+Y] = E[X] + E[Y], \quad \text{Var}(X+Y) = \text{Var}(X) + \text{Var}(Y).$$

証明 $E[X+Y] = E[X] + E[Y]$ は $E[\cdot]$ の線形性の特別な場合にすぎない。 $\mu_X = E[X], \mu_Y = E[Y]$ とおく、

$$\begin{aligned} \text{Var}(X+Y) &= E[(X+Y - (\mu_X + \mu_Y))^2] = E[((X-\mu_X) + (Y-\mu_Y))^2] = E[(X-\mu_X)^2 + 2(X-\mu_X)(Y-\mu_Y) + (Y-\mu_Y)^2] \\ &= \underbrace{E[(X-\mu_X)^2]}_{\text{Var}(X)} + 2 \underbrace{E[(X-\mu_X)(Y-\mu_Y)]}_{\text{|| } X \text{ と } Y \text{ の独立性}} + \underbrace{E[(Y-\mu_Y)^2]}_{\text{Var}(Y)} \\ &\quad \text{|| } X \text{ と } Y \text{ が無相関なら} \\ &\quad \text{独立でなくてても} \\ &= \underbrace{E[(X-\mu_X)^2]}_{\text{Var}(X)} + 2 \underbrace{E[(X-\mu_X)(Y-\mu_Y)]}_{E[X-\mu_X] E[Y-\mu_Y] = 0} + \underbrace{E[(Y-\mu_Y)^2]}_{\text{Var}(Y)} \\ &= \text{Var}(X) + \text{Var}(Y) \end{aligned}$$

$$\sigma_{X+Y}^2 = \sigma_X^2 + \sigma_Y^2$$

三平方の定理

正規分布に関する自習問題

Github リポジトリに解答例がある。

確率変数達 X, Y は 独立で(同時確率密度函数がそれぞれの確率密度函数の積になっており),

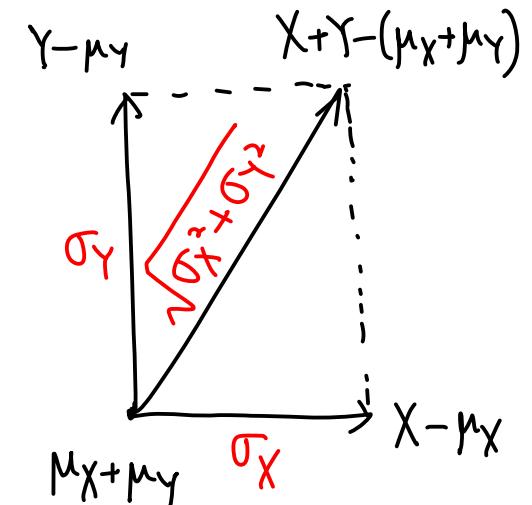
$$X \sim \text{Normal}(\mu_X, \sigma_X), \quad Y \sim \text{Normal}(\mu_Y, \sigma_Y)$$

となっているならば,

三平方の定理

$$X+Y = \text{Normal} \left(\mu_X + \mu_Y, \sqrt{\sigma_X^2 + \sigma_Y^2} \right)$$

となることを示せ。



最重要自習問題

必ず解いて欲しい問題: 正規分布における確率が95%または99%になる区間

$X \sim \text{Normal}(\mu, \sigma)$ であると仮定する. このとき, X が区間 $[\mu - c\sigma, \mu + c\sigma]$ に含まれる確率

$$P(\mu - c\sigma \leq X \leq \mu + c\sigma)$$

が $1 - \alpha$ に等しくなるような c を誤差函数

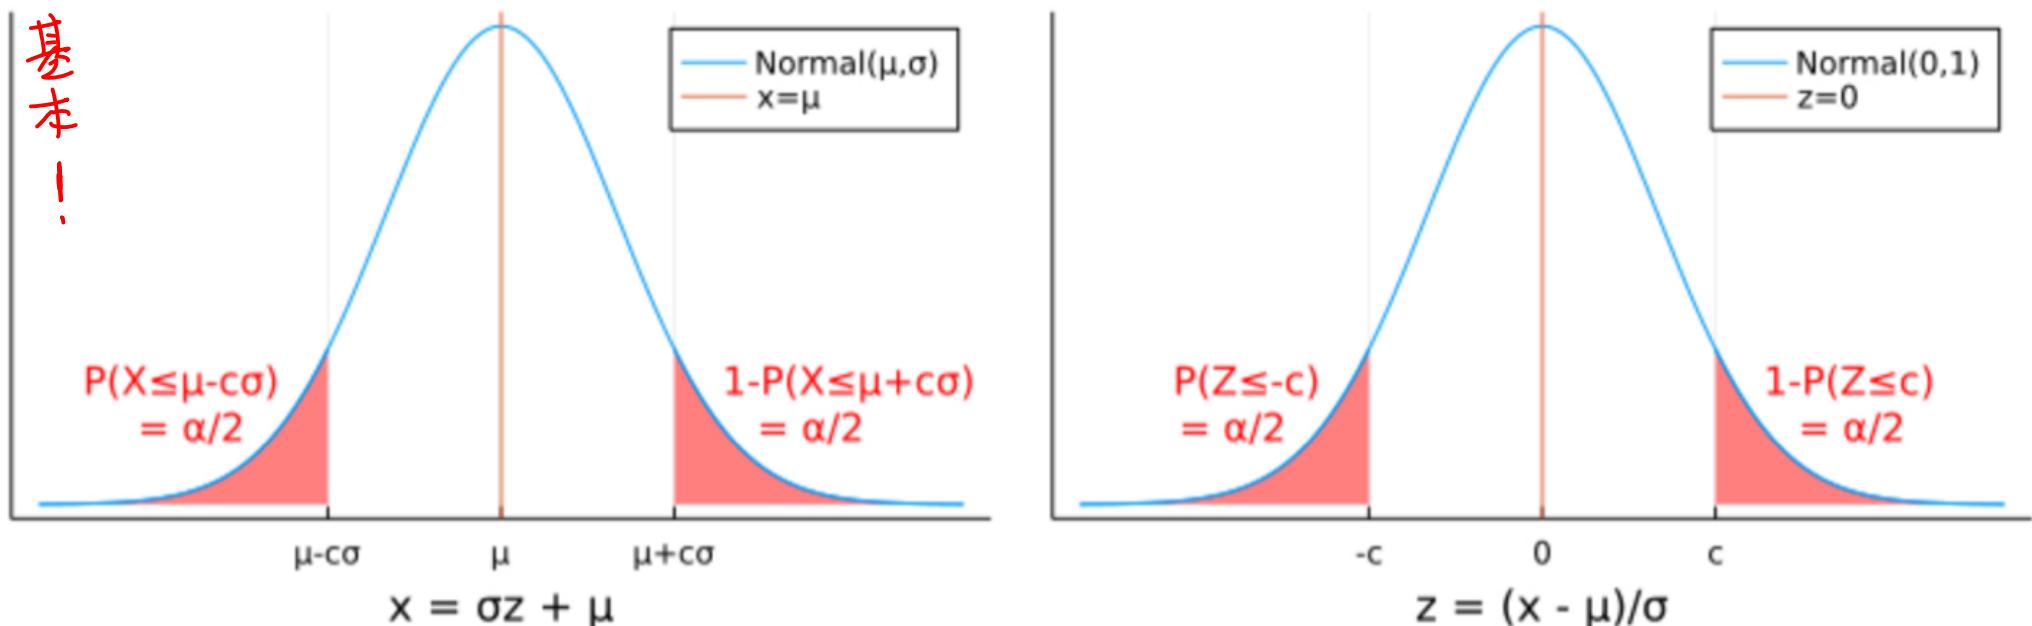
答えは
Githubに
ある.

$$y = \text{erf}(x) = \frac{2}{\sqrt{\pi}} \int_0^x \exp(-u^2) du$$

の逆函数 $x = \text{erfinv}(y)$ を使って表せ. (正規分布の定義に戻って地道に計算せよ.)

さらに, 上の確率が 95% になる c と 99% になる c を小数点以下第2桁目まで求めよ.

これた"けは
必ず"解いて
おくこと



問題: 分散が χ^2 分布の ν 分の1に従う正規分布は自由度 ν の t 分布になる

$\nu > 0$ だと仮定する. 確率変数達 Y, Z は 独立であるとし(同時確率密度函数がそれぞれの密度函数の積になる),

$$Z \sim \text{Normal}(0, 1), \quad Y \sim \text{Chisq}(\nu) = \text{Gamma}(\nu/2, 2)$$

と仮定する. $\text{Chisq}(\nu)$ の期待値は $(\nu/2)2 = \nu$ になり, 分散は $(\nu/2)2^2 = 2\nu$ になり, 標準偏差は $\sqrt{2\nu}$ になるので, ν が 2 より大きければ, 標準偏差は期待値よりも小さくなる. このとき,

$$T = \frac{Z}{\sqrt{Y/\nu}} \sim \text{TDist}(\nu)$$

となることを示せ.

標準正規分布は上の形で χ^2 分布と組み合わせて太分布にして使うことがある.

$Y \sim \text{Chisq}(\nu)$ のとき, $E[Y] = \nu$, $\text{std}(Y) = \sqrt{2\nu}$ なので $E\left[\frac{Y}{\nu}\right] = 1$, $\text{std}\left(\frac{Y}{\nu}\right) = \sqrt{\frac{2}{\nu}}$.

標準偏差 = $\sqrt{\text{分散}}$

もは $\frac{Y}{\nu}$ が定数なら, $\frac{Z}{\sqrt{Y/\nu}}$ の分散は $\frac{1}{Y/\nu} = \frac{\nu}{Y}$ になる.

実際には $\frac{Y}{\nu}$ は確率変数なのでそう单纯ではないが, $T = \frac{Z}{\sqrt{Y/\nu}}$ の分布は 1 以外の分散を持つ正規分布達の混合分布になる.

この答えは
すぐに説明する.

解答例の準備

Z は標準正規分布に従う確率変数であるとする.

Y が確率密度函数 $p(y|\nu)$ を持つとき, $z = \sqrt{y/\nu}t, dz = \sqrt{y/\nu}dt$ とおくと,

V
0

$$\begin{aligned} E[f(Z/\sqrt{Y/\nu})] &= \int_0^\infty \left(\int_{-\infty}^\infty f\left(z/\sqrt{y/\nu}\right) \frac{e^{-z^2/2}}{\sqrt{2\pi}} p(y|\nu) dz \right) dy \\ &\stackrel{\frac{z}{\sqrt{y/\nu}} = T \text{ の}}{=} \int_0^\infty \left(\int_{-\infty}^\infty f(t) \frac{e^{-yt^2/(2\nu)}}{\sqrt{2\pi}} p(y|\nu) \sqrt{\frac{y}{\nu}} dt \right) dy \\ &\stackrel{\text{密度函数の形を}}{=} \int_{-\infty}^\infty f(t) \left(\frac{1}{\sqrt{2\pi\nu}} \int_0^\infty e^{-t^2y/(2\nu)} y^{1/2} p(y|\nu) dy \right) dt \\ &\stackrel{\text{知りたければ}}{=} E[f(T)] = \int_{-\infty}^\infty f(t) p(t) dt \\ &\stackrel{\text{の } p(t) \text{ を求めればよい。}}{=} \end{aligned}$$

なので, 確率変数 $T = Z/\sqrt{Y/\nu}$ は確率密度函数

$$p(t) = \frac{1}{\sqrt{2\pi\nu}} \int_0^\infty e^{-t^2y/(2\nu)} y^{1/2} p(y|\nu) dy$$

を持つことになる.

解答例: $Y \sim \text{Chisq}(\nu) = \text{Gamma}(\nu/2, 2)$ の確率密度函数は

$$p(y|\nu) = \frac{1}{2^{\nu/2} \Gamma(\nu/2)} e^{-y/2} y^{\nu/2-1} \quad (y > 0) \quad \leftarrow \text{これは } \chi^2 \text{ 分布の定義}$$

になるので、前節の結果より、 T の確率密度函数が以下のように計算される:

$$\begin{aligned} p(t) &= \frac{1}{\sqrt{2\pi\nu} 2^{\nu/2} \Gamma(\nu/2)} \int_0^\infty e^{-t^2 y/(2\nu)} y^{1/2} e^{-y/2} y^{\nu/2-1} dy \\ &= \frac{1}{\sqrt{\nu} 2^{(\nu+1)/2} \sqrt{\pi} \Gamma(\nu/2)} \int_0^\infty \exp\left(-\frac{1+t^2/\nu}{2}y\right) y^{(\nu+1)/2-1} dy \\ &= \frac{1}{\sqrt{\nu} 2^{(\nu+1)/2} \Gamma(1/2) \Gamma(\nu/2)} \left(\frac{1+t^2/\nu}{2}\right)^{-(\nu+1)/2} \Gamma((\nu+1)/2) \quad \text{キャンセル} \\ &= \frac{\Gamma((\nu+1)/2)}{\sqrt{\nu} \Gamma(1/2) \Gamma(\nu/2)} \left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2} \\ &= \frac{1}{\sqrt{\nu} B(1/2, \nu/2)} \left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2} \end{aligned}$$

$$\left(\int_0^\infty e^{-cy} y^{\alpha-1} dy \right) \Big|_{c=\frac{1+t^2/\nu}{2}} \quad (c > 0)$$

ガンマ函数は
通常この形で
使われる。

3つめの等号で $\Gamma(1/2) = \sqrt{\pi}$ とガンマ函数のよくある使用法を使い、最後の等号で $\Gamma(\alpha)\Gamma(\beta) = \Gamma(\alpha + \beta)B(\alpha, \beta)$ を使った。最後の式は t 分布の確率密度函数である。ゆえに $T \sim \text{TDist}(\nu)$.

できた!
□

太分布のグラフ

緑の破線は比較用の
標準正規分布 $\text{Normal}(0,1)$

■のヒストグラムは

Y として $\text{Normal}(0,1)$ の

Y として $\text{Chisq}(v)$ の

乱数を大量に生成して

$T = \frac{Y}{\sqrt{Y/v}}$ を大量に計算する

ことによって作った、

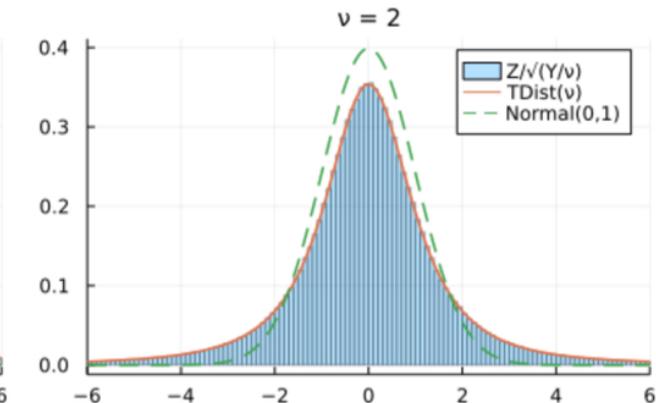
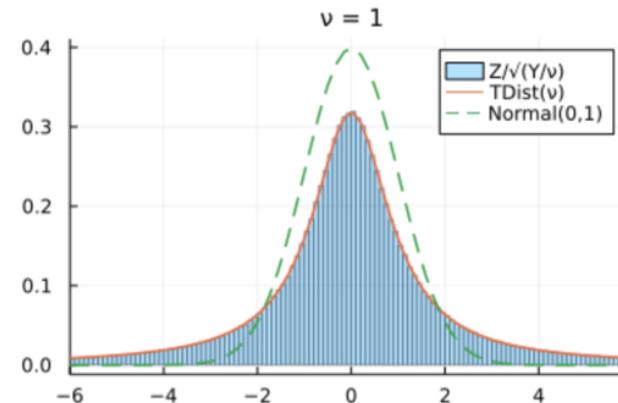
(次ページで説明)

だいだい色の実線は太分布

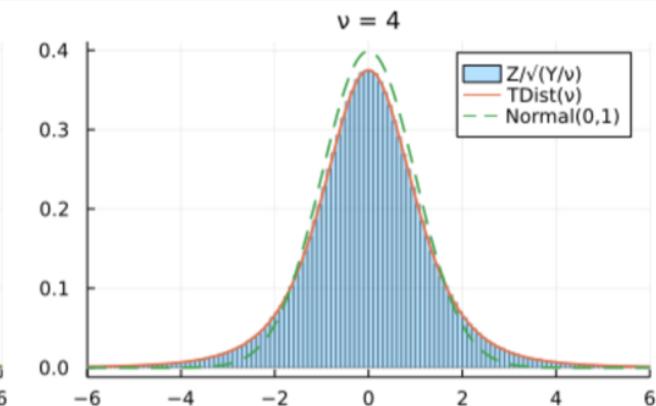
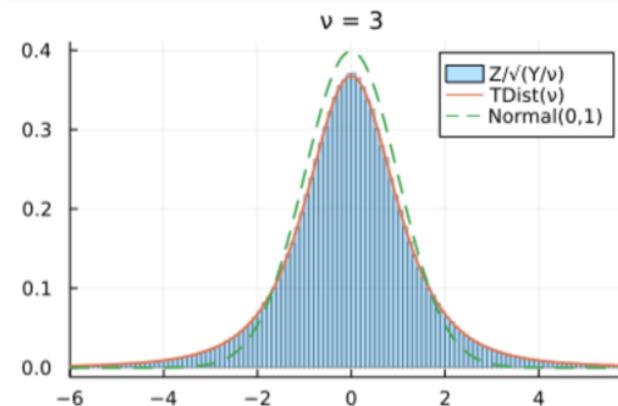
自由度 $v \rightarrow \infty$ で

太分布 \rightarrow 標準正規分布

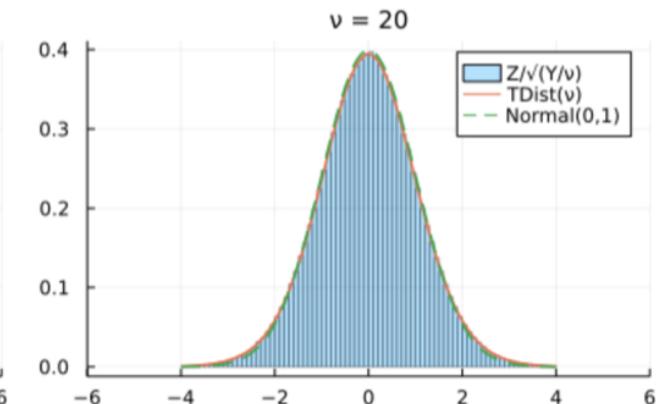
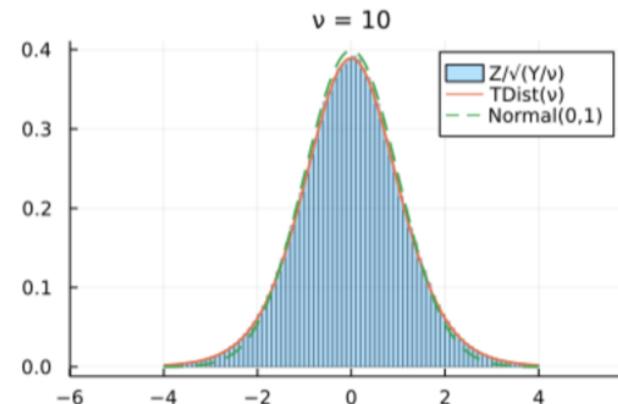
```
plot(plot_nct(1), plot_nct(2); size=(800, 250))
```



```
plot(plot_nct(3), plot_nct(4); size=(800, 250))
```



```
plot(plot_nct(10), plot_nct(20); size=(800, 250))
```



大分布の乱数の作り方

- ① 自由度 ν の χ^2 分布の乱数 $y > 0$ を生成する。
- ② 標準正規分布の乱数 $-\infty < z < \infty$ を生成して $\sqrt{y/\nu} z$ である。これは分散 $\frac{\nu}{y}$ の正規分布の乱数を生成していることになる。

この $t = \frac{z}{\sqrt{y/\nu}}$ が自由度 ν の大分布の乱数になる。

自由度 ν の
大分布

$$p(t|\nu) = \int_0^\infty \frac{e^{-\frac{t^2}{2\nu/y}}}{\sqrt{2\pi\nu/y}} \frac{e^{-\frac{y}{2}} y^{\frac{\nu}{2}-1}}{2^{\nu/2} \Gamma(1/2)} dy$$

$$= \int_0^\infty p_3(t|y) p_1(y) dy \text{ の形}$$

統計学や機械学習では
シンプルな確率分布を組み合わせて、
複雑な確率分布を作って利用する。
その理解のためにには、
その確率分布の乱数を
どのようにすれば作れるたうか?
と考えることが極めて有効である！

- ① $p_1(y)$ の分布の乱数 y を生成、
 - ② その y を使って、
 $p_2(t|y)$ の分布の乱数 t を生成、
- このパターンは非常によく出で来る！

必ず解いて欲しい問題: t 分布における確率が95%または99%になる区間

$0 < \alpha < 1, \nu > 0$ であるとし, $T \sim \text{TDist}(\nu)$ と仮定する. このとき, T が区間 $[-c, c]$ に含まれる確率

$$P(-c \leq T \leq c)$$

が $1 - \alpha$ になるような c を 正則化された不完全ベータ函数

$$y = I(x|\alpha, \beta) = I_x(\alpha, \beta) = \frac{\int_0^x v^{\alpha-1}(1-v)^{\beta-1} dv}{B(\alpha, \beta)}$$

の逆函数 $x = I^{-1}(y|\alpha, \beta)$ を使って表せ. (注意: $I_x(\alpha, \beta)$ は広く使われている標準的な記号法だが, $I(x|\alpha, \beta)$ と $I^{-1}(y|\alpha, \beta)$ はここだけの記号法である.)

さらに, $\nu = 9$ と $\nu = 19$ と $\nu = 29$ の場合に $P(-c \leq T \leq c)$ が 95% になる c と 99% になる c を小数点以下第2桁目まで求めよ.

ここだけは必ず解いておいてください

$\left\{ \begin{array}{l} \text{大検定や} \\ \text{平均の信頼区間で使われる} \end{array} \right.$

Poisson分布の定義

$\lambda > 0$ と仮定する. 確率質量函数

$$e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} e^{\lambda} = 1$$

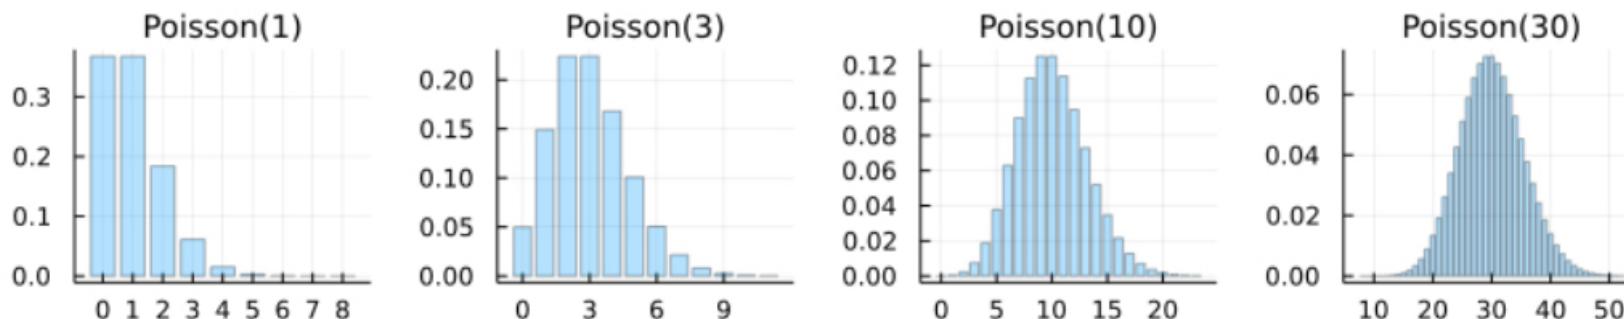
$$p(k|\lambda) = e^{-\lambda} \frac{\lambda^k}{k!} \quad (k = 0, 1, 2, \dots)$$

で定義される無限離散分布を Poisson分布 (ポアソン分布)と呼び, 次のように表すことにする:

Poisson(λ). 期待値入 ↗ 分散入 ↗ 同じ

Poisson分布は一定期間内に起こるイベントの回数の分布のモデル化としてよく使われている.

) 今日のテーマの
1つ



以上はPoisson分布 Poisson(λ) の確率質量函数のグラフの例である. ここでは λ が整数の場合のみを扱ったが, λ は整数でなくてもよい. Poisson(30) のグラフは正規分布のグラフに近くなっている. パラメータ λ が大きなPoisson分布は正規分布で近似される.

再掲

2 Poisson分布とガンマ分布の以下の解釈について説明

1が出ることをイベント発生と解釈



離散時間の場合 (Bernoulli試行) $\xrightarrow{\text{連続時間極限}}$ 連続時間の場合

単位時間に L 回試行

1が出る

単位時間のあたりに平均 L 回イベント発生

二項分布 $K \sim \text{Binomial}(L, \lambda/L)$

L 回の試行中のイベント発生回数 K の分布

イベント発生の時間的間隔の

期待値は $\theta = \frac{1}{\lambda}$

負の二項分布

$M \sim \text{Negative Binomial}(\alpha, 1/(L\theta)) = \lambda/L$

$N := \alpha + M$

$= (\text{ α 回イベントが
起こるまでの試行回数})$

$$\frac{N}{L}$$

単位時間のあたりに平均入回

イベントが起こる

Poisson分布 $K \sim \text{Poisson}(\lambda)$

単位時間のあたりに起こる
イベントの回数 K の分布

イベント発生の時間的間隔の

期待値は $\theta = \frac{1}{\lambda}$

ガンマ分布

$T \sim \text{Gamma}(\alpha, \theta)$

$= (\text{ちょうど α 回イベント
が起こるまでの時間}) = T,$

$$\text{Binomial}(n, \lambda/n) \xrightarrow{n \rightarrow \infty} \text{Poisson}(\lambda)$$

$(n=0, 1, 2, \dots, \lambda > 0, \frac{\lambda}{n} \leq 1)$

前へ°-ジのLと
nと書いた。

$$\binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \xrightarrow{n \rightarrow \infty} e^{-\lambda} \frac{\lambda^k}{k!}$$

$(k=0, 1, 2, 3, \dots)$

このように、Poisson分布は
二項分布の極限になつてゐる。

証明 $n \rightarrow \infty$ のとき、

$$\begin{aligned} \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} &= \frac{n(n-1)\dots(n-k+1)}{k!} \frac{\lambda^k}{n^k} \left(1 - \frac{\lambda}{n}\right)^{n-k} \\ &= \underbrace{\frac{n(n-1)\dots(n-k+1)}{n \cdot n \cdot \dots \cdot n}}_{\rightarrow 1} \underbrace{\left(1 - \frac{k}{n}\right)^{-k}}_{\rightarrow 1} \underbrace{\left(1 - \frac{\lambda}{n}\right)^n}_{\rightarrow e^{-\lambda}} \frac{\lambda^k}{k!} \xrightarrow{n \rightarrow \infty} e^{-\lambda} \frac{\lambda^k}{k!} \end{aligned}$$

q.e.d.

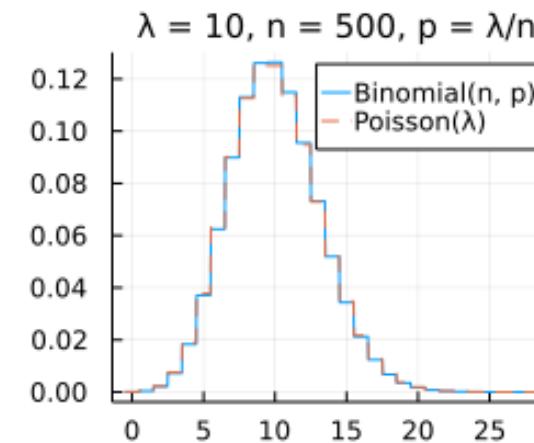
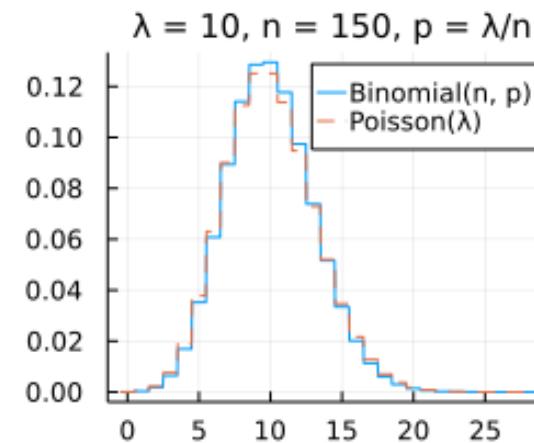
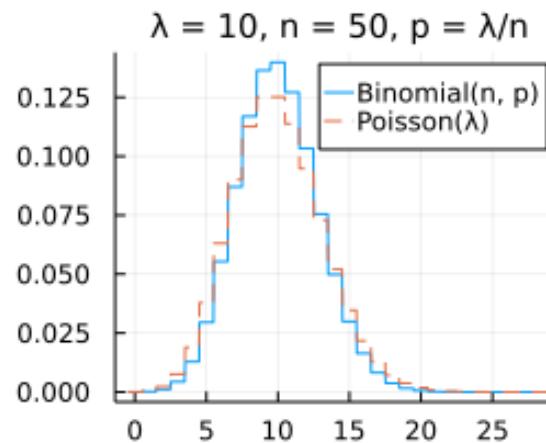
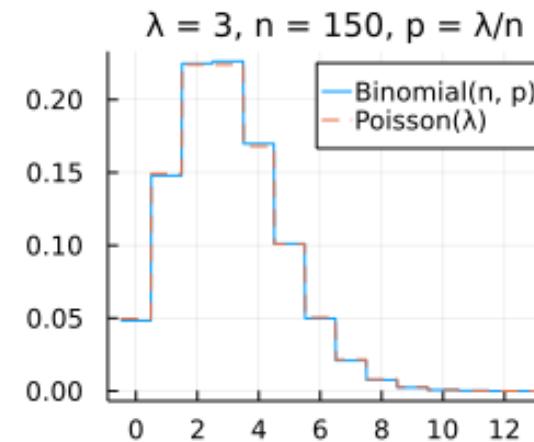
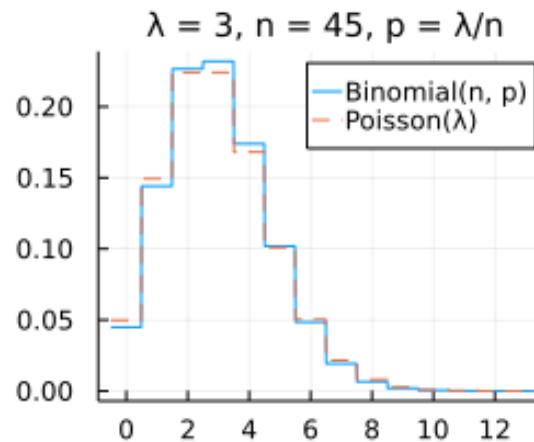
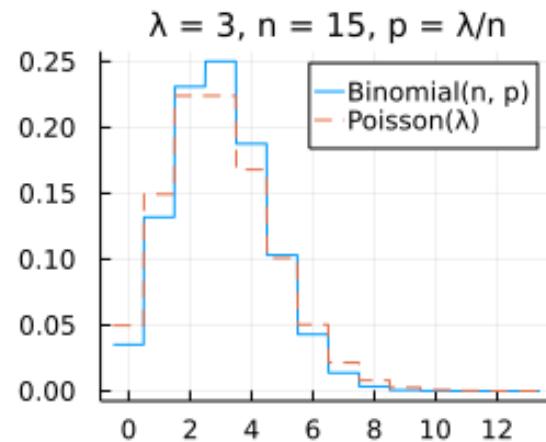
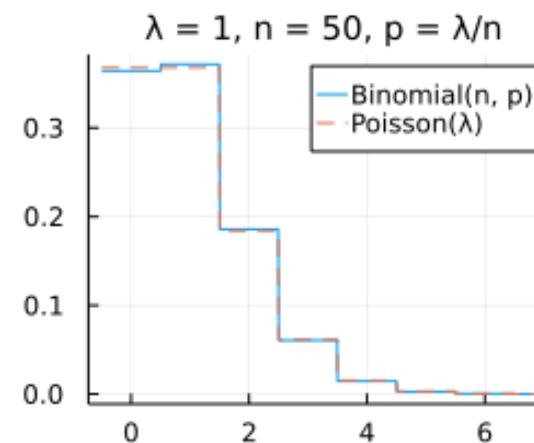
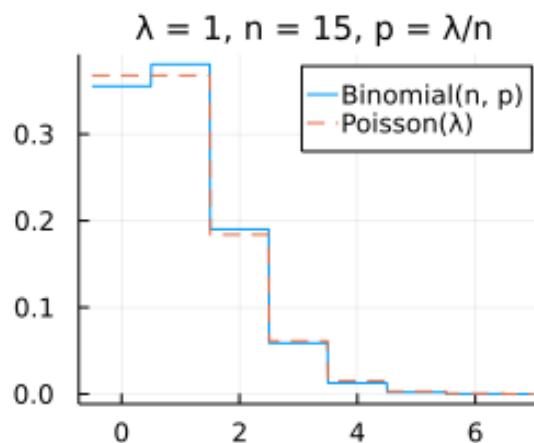
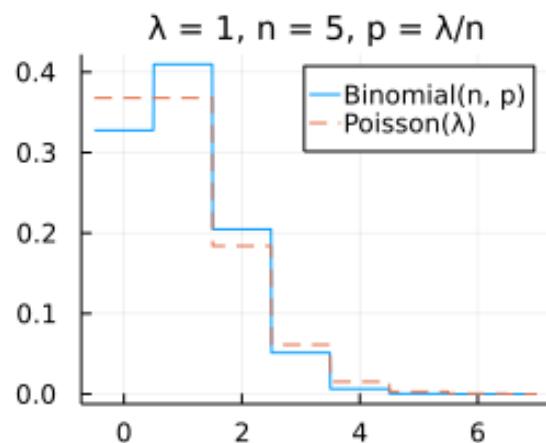
$$\left\{ \begin{aligned} &\frac{n(n-1)\dots(n-k+1)}{n \cdot n \cdot \dots \cdot n} \\ &= \frac{n}{n} \frac{n-1}{n} \dots \frac{n-k+1}{n} \xrightarrow{n \rightarrow \infty} 1 \end{aligned} \right.$$

$$\left. \begin{aligned} \log\left(1 - \frac{\lambda}{n}\right) &= L \log\left(1 - \frac{\lambda}{n}\right) \\ &= n \left(-\frac{\lambda}{n} + \frac{\lambda^2}{2n^2} + \dots \right) \\ &= -\lambda + \frac{\lambda^2}{2n} + \dots \longrightarrow -\lambda \\ \therefore \left(1 - \frac{\lambda}{n}\right)^n &\rightarrow e^{-\lambda} \end{aligned} \right\}$$

n : 小

Φ

λ



以下、Bernoulli試行で1が出ることを「イベントが起った」という。

離散時間

$$K \sim \text{Binomial}(n, \lambda/n) \longrightarrow K \sim \text{Poisson}(\lambda)$$

単位時間のあいだに n 回の
試行を行う。

$$\xrightarrow{n \rightarrow \infty \text{ 連続時間極限}}$$

連続時間

連続単位時間のあいだに
イベントが何回起ころかを見る。

確率 $p = \frac{\lambda}{n}$ でイベントが起ころる
試行を n 回行ったときに
起ころたイベントの回数 K の分布

単位時間のあいだに
起ころたイベントの回数 K の分布

$p = \frac{\lambda}{n}$ なので n 回の試行で
起ころるイベントの回数の
期待値は $np = \lambda$ になる。
分散 $np(1-p) = \lambda(1 - \frac{\lambda}{n})$

単位時間のあいだに
起ころるイベントの回数の
期待値は λ になる。

$$\xrightarrow{n \rightarrow \infty} \text{ 分散 } \lambda$$

離散時間

$$M \sim \text{NegativeBinomial}(\alpha, \frac{1}{L\theta})$$

$$T = \frac{N}{L} = \frac{\alpha+M}{L}$$

$$\xrightarrow[L \rightarrow \infty]{} T \sim \text{Gamma}(\alpha, \theta)$$

連続時間

確率 $p = \frac{1}{L\theta}$ でイベントが起こる試行を

単位時間あたり L 回ずつ、
イベントが α 回起こるまで続ける。
ちょうど α 回イベントが起こるまでの
試行回数 $N = \alpha + M$ の分布

平均して時間間隔 θ で

起こるイベントが

α 回起こるまでにかかる
時間 T の分布

連続時間極限

$$\theta = \frac{1}{Lp} = \left(\frac{\text{単位時間のあたりに}}{\text{起こるイベントの回数}} \right)^{-1} \text{ なので}$$

θ はイベントが起こる時間の間隔の
期待値になる。

$$\left(\frac{\text{ちょうど } \alpha \text{ 回イベントが}}{\text{起こるまでにかかった時間}} \right) = \frac{N}{L} = T$$

このように ガンマ分布は
負の二項分布の連続時間極限
とみなされる。

証明は次ページより、

準備

$\alpha, \theta > 0, p = \frac{1}{L\theta}, n = Lt$ とおく、 $\Gamma(n) = (n-1)!$ を使うと、

$$\binom{n-1}{n-\alpha} = \frac{\Gamma(n)}{\Gamma(n-\alpha+1)\Gamma(\alpha)} = \frac{n\Gamma(n)}{n\Gamma(\alpha)\Gamma(n-\alpha+1)} = \frac{\Gamma(n+1)}{n\Gamma(\alpha)\Gamma(n-\alpha+1)} = \frac{1}{nB(\alpha, n-\alpha+1)}.$$

(1) Negative Binomial (α, p) におけるイベントが“ちょうど” α 回起こったときの

試行回数 $N = \alpha + M$ の確率質量函数:

$$\begin{aligned}\Gamma(\alpha)\Gamma(\beta) &= B(\alpha, \beta) \\ &\times \Gamma(\alpha+\beta)\end{aligned}$$

$$P(n-\alpha | \alpha, p) = \binom{n-1}{n-\alpha} p^\alpha (1-p)^{n-\alpha} = \frac{1}{nB(\alpha, n-\alpha+1)} p^\alpha (1-p)^{n-\alpha}.$$

(2) Gamma (α, θ) の確率密度函数:

$$p(t | \alpha, \theta) = \frac{1}{\theta^\alpha \Gamma(\alpha)} e^{-t/\theta} t^{\alpha-1} \quad (t > 0).$$

(3) ベータ函数 \rightarrow ガンマ分布: $\ell \rightarrow \infty$ のとき,

$$\ell^\alpha B(\alpha, \ell+b) = \ell^\alpha \int_0^1 x^{\alpha-1} (1-x)^{\ell+b-1} dx$$

$$x = \frac{t}{\ell} \quad = \int_0^\ell t^{\alpha-1} \left(1 - \frac{t}{\ell}\right)^{\ell+b-1} dt \rightarrow \int_0^\infty t^{\alpha-1} e^{-t} dt = \Gamma(\alpha),$$

ガンマ分布が
ベータ分布の
極限になっていることを
意味している。

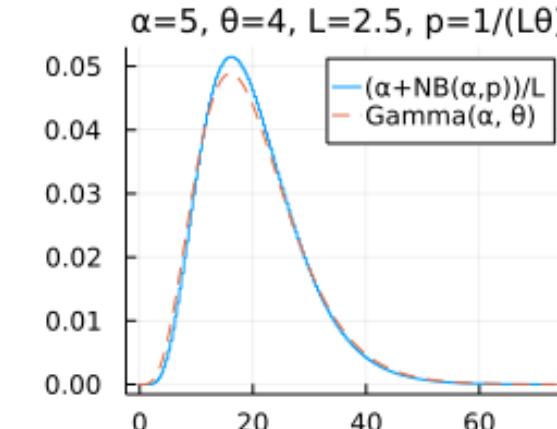
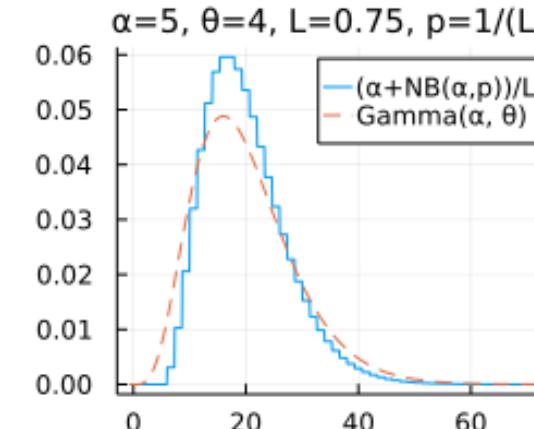
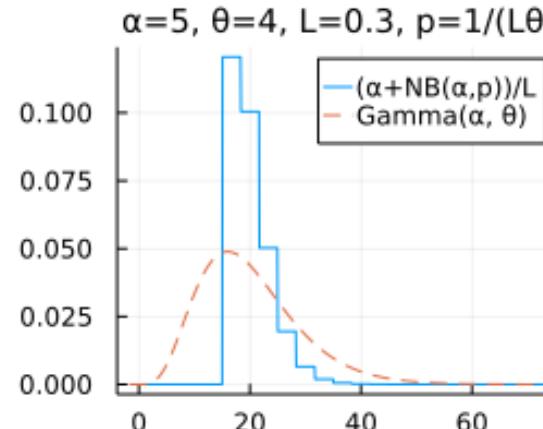
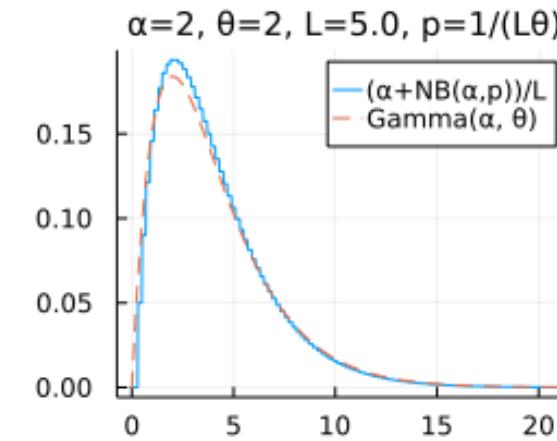
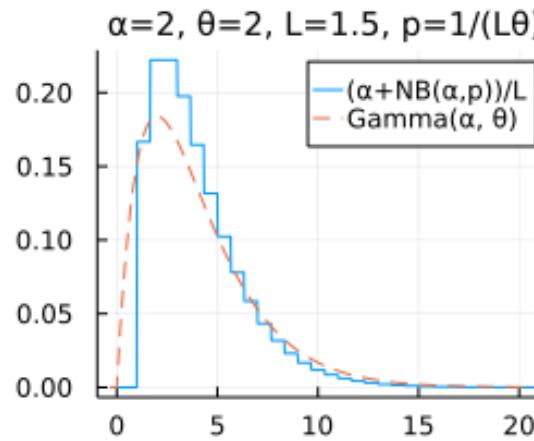
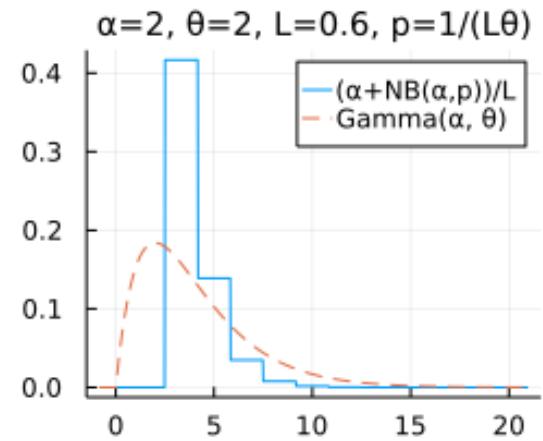
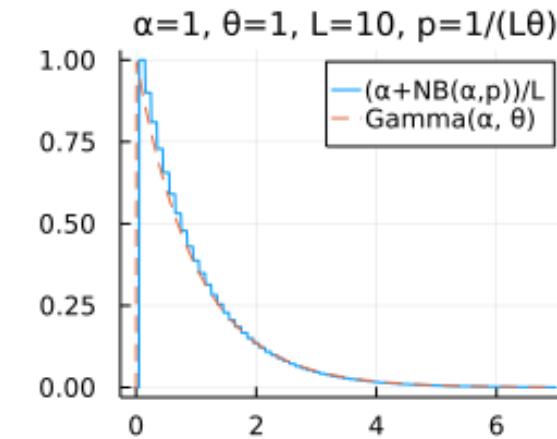
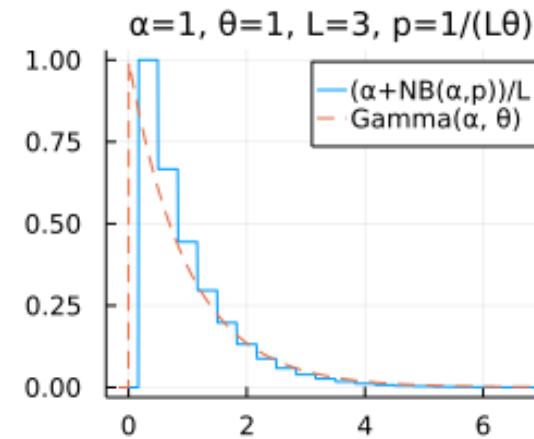
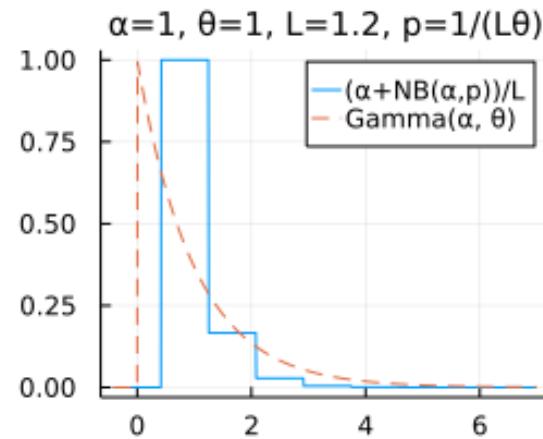
$N - d \sim \text{NegativeBinomial}(d, \frac{1}{L\theta})$ のとき, $\frac{N}{L} \xrightarrow[L \rightarrow \infty]{} T \sim \text{Gamma}(d, \theta)$

証明 $p = \frac{1}{L\theta}$, $n = Lt$ とおくと, $L \rightarrow \infty$ において,

$$\begin{aligned}
 & \frac{1}{n B(\alpha, n-\alpha+1)} p^\alpha (1-p)^{n-\alpha} \xleftarrow{(1)} e^{-t/\theta} \quad \left(1 - \frac{1}{L\theta}\right)^{Lt} = \left(1 - \frac{t/\theta}{Lt}\right)^{Lt} \\
 &= \frac{1}{Lt \cdot B(\alpha, Lt-\alpha+1)} \xrightarrow{L^\alpha \theta^\alpha} \left(1 - \frac{1}{L\theta}\right)^{Lt-\alpha} \xrightarrow{\uparrow} e^{-t/\theta} \\
 &= \frac{1}{(Lt)^\alpha B(\alpha, Lt-\alpha+1)} \xrightarrow{(3)} \frac{L^{\alpha-1} t^{\alpha-1}}{L^\alpha \theta^\alpha} \left(1 - \frac{1}{L\theta}\right)^{Lt-\alpha} \xrightarrow[L \rightarrow \infty]{\left(1 + \frac{2L}{L}\right)^\alpha \rightarrow e^\alpha} e^\alpha \\
 &= \frac{1}{\theta^\alpha (Lt)^\alpha B(\alpha, Lt-\alpha+1)} \left(1 - \frac{1}{L\theta}\right)^{Lt-\alpha} t^{\alpha-1} \frac{1}{L} \\
 &= \frac{1}{\theta^\alpha \Gamma(\alpha)} e^{-t/\theta} t^{\alpha-1} \frac{1}{L} \times (1 + o(1)) \xrightarrow{\left\{ \begin{array}{l} L \rightarrow \infty \text{ で} \\ o(1) \text{ は} L \text{ に} \end{array} \right.} \left\{ \begin{array}{l} L \rightarrow \infty \text{ で} \\ o(1) \text{ は} L \text{ に} \end{array} \right. \text{ する量}
 \end{aligned}$$

q.e.d.

L : 小 $\longrightarrow \phi \longrightarrow$ 大



応用 Poisson分布における確率とガンマ分布における確率の関係

単位時間に平均して入回のイベントが起こると仮定する。

時間 τ のあいだに起こるイベントの回数: $K_{\lambda\tau} \sim \text{Poisson}(\lambda\tau)$

平均して時間間隔 $\theta = \frac{1}{\lambda}$ でイベントが発生する。

そのとき、イベントが α 回起こるまでにかかる時間 $T_{\alpha, \theta} \sim \text{Gamma}(\alpha, \theta)$.
(α は正の整数であると仮定する。)

$K_{\lambda\tau} < \alpha \Leftrightarrow$ 時間 τ のあいだに起こるイベントの回数が α 未満

\Leftrightarrow イベントが α 回起こるまでにかかる時間が τ より大きい

$$\Leftrightarrow T_{\alpha, \theta} > \tau$$

ゆえに, $P(K_{\lambda\tau} < \alpha) = P(T_{\alpha, \theta} > \tau)$.

自習問題 直接的に示せ。

(ヒント: 両辺さてで微分)

具体的な式で書くと, $\sum_{k=0}^{\alpha-1} \frac{e^{-\lambda\tau} (\lambda\tau)^k}{k!} = \frac{\int_{\tau}^{\infty} e^{-t/\theta} t^{\alpha-1} dt}{\theta^\alpha \Gamma(\alpha)}$, 注 右の方が計算が“楽”

$$P(\alpha, x) = \frac{\int_0^x e^{-t} t^{\alpha-1} dt}{\Gamma(\alpha)}$$

注意 $Q(\alpha, x) = \frac{\int_x^{\infty} e^{-t} t^{\alpha-1} dt}{\Gamma(\alpha)}$ は 正則化された(不完全)ガンマ函数 と呼ばれ, 効率的に計算できる。

必ず解いて欲しい問題: χ^2 分布における確率が95%または99%になる範囲

$0 < \alpha < 1, \nu > 0$ であるとし, $Y \sim \text{Chisq}(\nu)$ と仮定する. このとき, Y が c 以下になる確率

$$P(Y \leq c)$$

が $1 - \alpha$ になるような c を 正則化された(不完全)ガンマ函数 (regularized (incomplete) gamma function)

$$y = P(x|\alpha) = P(\alpha, x) = \frac{\int_0^x e^{-u} u^{\alpha-1} du}{\Gamma(\alpha)} \quad (x > 0)$$

の逆函数 $x = P^{-1}(y|\alpha)$ を使って表せ. (注意: $P(\alpha, x)$ は広く使われている標準的な記号法だが, $P(x|\alpha)$ と $P^{-1}(y|\alpha)$ はここだけの記号法である.)

さらに, $\nu = 1$ と $\nu = 2$ と $\nu = 3$ の場合に $P(Y \leq c)$ が 95% になる c と 99% になる c を小数点以下第2桁目まで求めよ.

ここは必ず解いておくこと! (たくさんの種類がある χ^2 検定で使われる)
解答例は Github にある.

3

ベータ分布の一様乱数発生のくりかえしによる解釈

0~1のあいだの

一様乱数生成を
n回くりかえした結果

$$T_1 = \text{rand}()$$

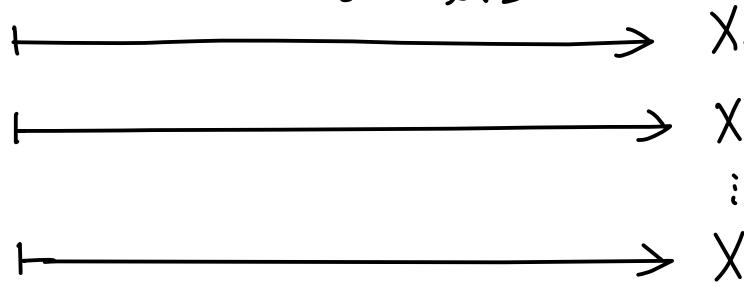
$$T_2 = \text{rand}()$$

$$T_n = \text{rand}()$$

T_i が p 以下なら 1
そうでないなら 0 に変換

Bernoulli 試行

確率 $p \geq 1$ を
確率 $1-p \geq 0$ を生成



重要

この中で下から k 番目に
小さなものを $T_{(n,k)}$ と書く。

$$T_{(n,k)} \sim \text{Beta}(k, n-k+1)$$

ポイント! 後で示す

p 以下の T_i が k 個以上



$$T_{(n,k)} \leq p \iff K_{n,p} \geq k$$

この中に含まれる 1 の
個数を $K_{n,p}$ と書く。

$$K_{n,p} \sim \text{Binomial}(n, p)$$

$$\therefore P(T_{(n,k)} \leq p) = P(K_{n,p} \geq k).$$

さらに、一様乱数生成をくりかえして、1 がちょうど k 個出るまでの試行回数を $N_{k,p}$ と書く。

$$N_{k,p} - k \sim \text{NegativeBinomial}(k, p)$$

n 回の試行で 1 となる X_i が k 個以上 $\iff N_{k,p} \leq n$

\Downarrow
 n 回の試行で p 以下の T_i が k 個以上

$$P(K_{n,p} \geq k) = P(N_{k,p} \leq n)$$

$$\Downarrow$$

 $P(T_{(n,k)} \leq p)$

前ページの結論で $T_{(n,k)} \sim \text{Beta}(k, n-k+1)$ の方がまだ示されていない。

$T_{(n,k)} \sim \text{Beta}(k, n-k+1)$ の証明

{別証がGithubにある資料にある
別証の方が論理的にクリア、しかし計算はめんどくさ

$T_{(n,k)} = (0 \sim 1 の一様乱数達 T_1, T_2, \dots, T_n の中で k 番目に小さいもの)$ であった。

$T_{(n,k)} \in [t, t+dt]$ となる確率は、

dt について2次以上の項を無視すると次のようになり近似される：

$$P(T_{(n,k)} \in [t, t+dt]) \approx \frac{n!}{(k-1)! \cdot 1! \cdot (n-k)!} \underbrace{t^{k-1} dt (1-t)^{n-k}}_{\text{SS}}$$

↑

n個の T_i を
 $k-1$ 個と1個と $n-k$ 個

$T_{(n,k)}$ より小 $T_{(n,k)}$ $T_{(n,k)}$ より大
に分割する方法の数

$$\text{そして}, \frac{n!}{(k-1)! (n-k)!} = \frac{\Gamma(n+1)}{\Gamma(k) \Gamma(n-k+1)} = \frac{1}{B(k, n-k+1)}.$$

ゆえに、 $T_{(n,k)}$ の確率密度函数は $\frac{t^{k-1} (1-t)^{n-k}}{B(k, n-k+1)} = \begin{cases} \text{Beta}(k, n-k+1) \text{の} \\ \text{確率密度函数} \end{cases}$

q.e.d.

应用

二項分布、負の二項分布、ペータ分布における確率の関係

すでに以下が示されている。

$T_{(n,k)} \sim \text{Beta}(k, n-k+1)$, $K_{n,p} \sim \text{Binomial}(n, p)$, $N_{k,p} - k \sim \text{NegativeBinomial}(k, p)$ のとき、

$$P(T_{(n,k)} \leq p) = P(K_{n,p} \geq k) = P(N_{k,p} \leq n)$$

具体的方式而書<之,

$$\frac{\int_0^p t^{k-1} (1-t)^{n-k} dt}{B(k, n-k+1)} = \sum_{i \geq k} \binom{n}{i} p^i (1-p)^{n-i} = \sum_{j \leq n} \binom{j-1}{j-k} p^k (1-p)^{j-k}.$$

A B C

これが大きいとき少し重い計算になる。

自習問題

$A = B$ を直接的に示せ、(これは $A = C$ も)

注意

$$I_p(\alpha, \beta) = \frac{\int_0^p t^{\alpha-1} (1-t)^{\beta-1} dt}{B(\alpha, \beta)} \text{ は } \underline{\text{正則化された不完全ベータ函数}}$$

と呼ばれ、コンピュータで効率的に計算できる。

1

二項分布

$\text{Binomial}(n, p)$

と

ベータ分布

$\text{Beta}(k, n-k+1)$

と

負の二項分布

Negative

$\text{Binomial}(k, p)$

における

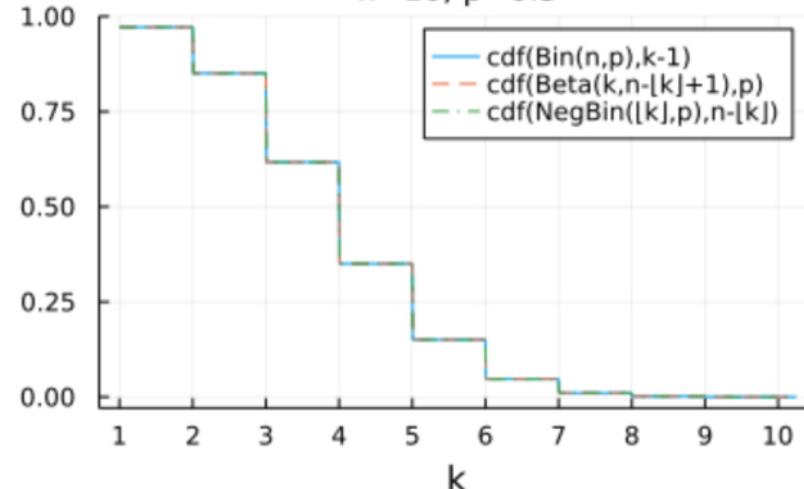
確率が

いつも

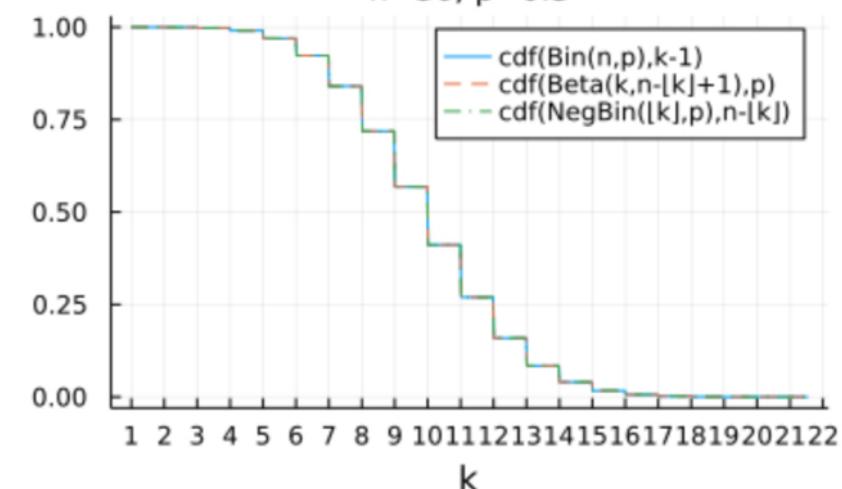
一致している。

```
plot(plot_cdf_bin_beta_nb(10, 0.3), plot_cdf_bin_beta_nb(30, 0.3);  
      size=(800, 250), bottommargin=4Plots.mm)
```

$n=10, p=0.3$

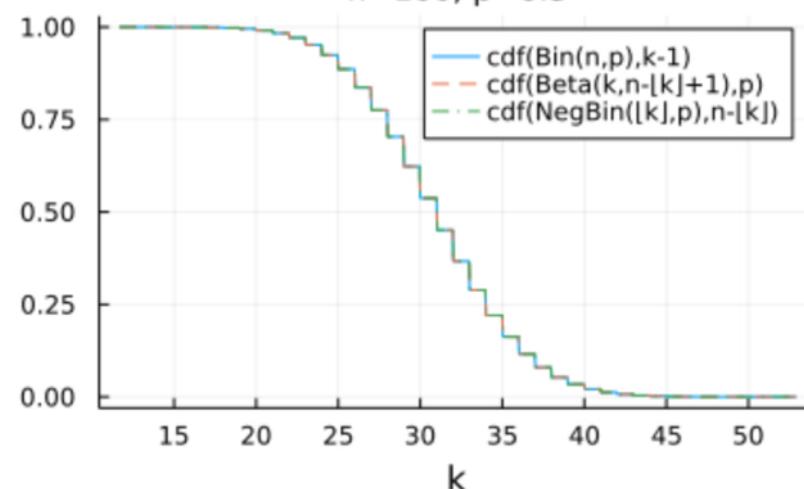


$n=30, p=0.3$

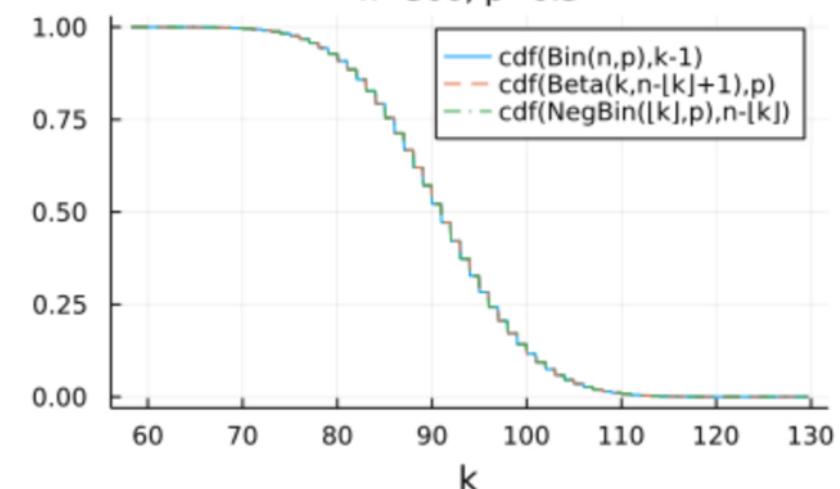


```
plot(plot_cdf_bin_beta_nb(100, 0.3; xtick=0:5:100), plot_cdf_bin_beta_nb(300, 0.3; xtick=0:10:1000);  
      size=(800, 250), bottommargin=4Plots.mm)
```

$n=100, p=0.3$



$n=300, p=0.3$



二項分布とベータ分布の関係のClopper-PearsonのP値函数への応用

二項分布モデルに基く比率 p (成功確率パラメータと呼んで来た)の Clopper-Pearsonの信頼区間 を与えるP値函数(以下 Clopper-PearsonのP値函数と呼ぶ)の効率的な計算に、前節で述べた二項分布とベータ分布の関係が実際に使われている。

Clopper-PearsonのP値函数は二項分布モデル $\text{Binomial}(n, p)$ と「 n 回中 k 回成功した」というデータの整合性を測る函数である。Clopper-PearsonのP値函数は以下のように定義される。

二項分布 $\text{Binomial}(n, p)$ の累積分布函数を、確率変数 $K \sim \text{Binomial}(n, p)$ を使って

二項分布のcdf

$$F(k) = P(K \leq k) = \sum_{j=0}^k \binom{n}{j} p^j (1-p)^{n-j}$$

P値の計算に
これが必要

と定義する。Clopper-PearsonのP値函数 $\text{pvalue}_{\text{CP}}(k|n, p)$ を次のように定める:

$$\underline{\text{pvalue}_{\text{CP}}(k|n, p)} = \min(1, 2\underline{F(k)}, 2(1 - \underline{F(k-1)}) = \min(1, 2P(K \leq k), 2P(K \geq k)).$$

$\min(P(K \leq k), P(K \geq k))$ は二項分布におけるデータの値 k 以上に端側に偏る確率を意味し、その2倍がClopper-PearsonのP値である。P値が小さいほど、二項分布モデル $\text{Binomial}(n, p)$ と「 n 回中 k 回成功した」というデータの整合性が低いと考える。

二項分布の累積分布函数はベータ分布の累積分布函数で書けるのであった。確率変数 $T_k \sim \text{Beta}(k, n-k+1)$ を使えば次が成立している:

$$\underline{F(k) = P(K \leq k) = 1 - P(T_{k+1} \leq p)}, \quad \underline{1 - F(k-1) = P(K \geq k) = P(T_k \leq p)}.$$

そして、右辺の計算で必要な $P(T_k \leq p)$ は次のように書ける:

ベータ分布のcdf

$$\underline{P(T_k \leq p) = \frac{\int_0^p t^{k-1} (1-t)^{n-k} dt}{B(k, n-k+1)}}.$$

これらを使うと
P値の計算で
これを使える。

この右辺は、基本特殊函数の1つである正則化された不完全ベータ函数になっており、コンピュータで効率的に計算できる。

注意: $0 < \alpha < 1$ のとき、「 n 回中 k 回成功した」というデータが与える信頼度 $1 - \alpha$ のClopper-Pearsonの信頼区間は $\text{pvalue}_{\text{CP}}(k|n, p) \geq \alpha$ を満たすパラメータ p の範囲と定義される:

$$\text{CI}_{\text{CP}}(k|n) = \{p \in [0, 1] \mid \text{pvalue}_{\text{CP}}(k|n, p) \geq \alpha\}.$$

この辺りの話は後で詳しく説明することになる。

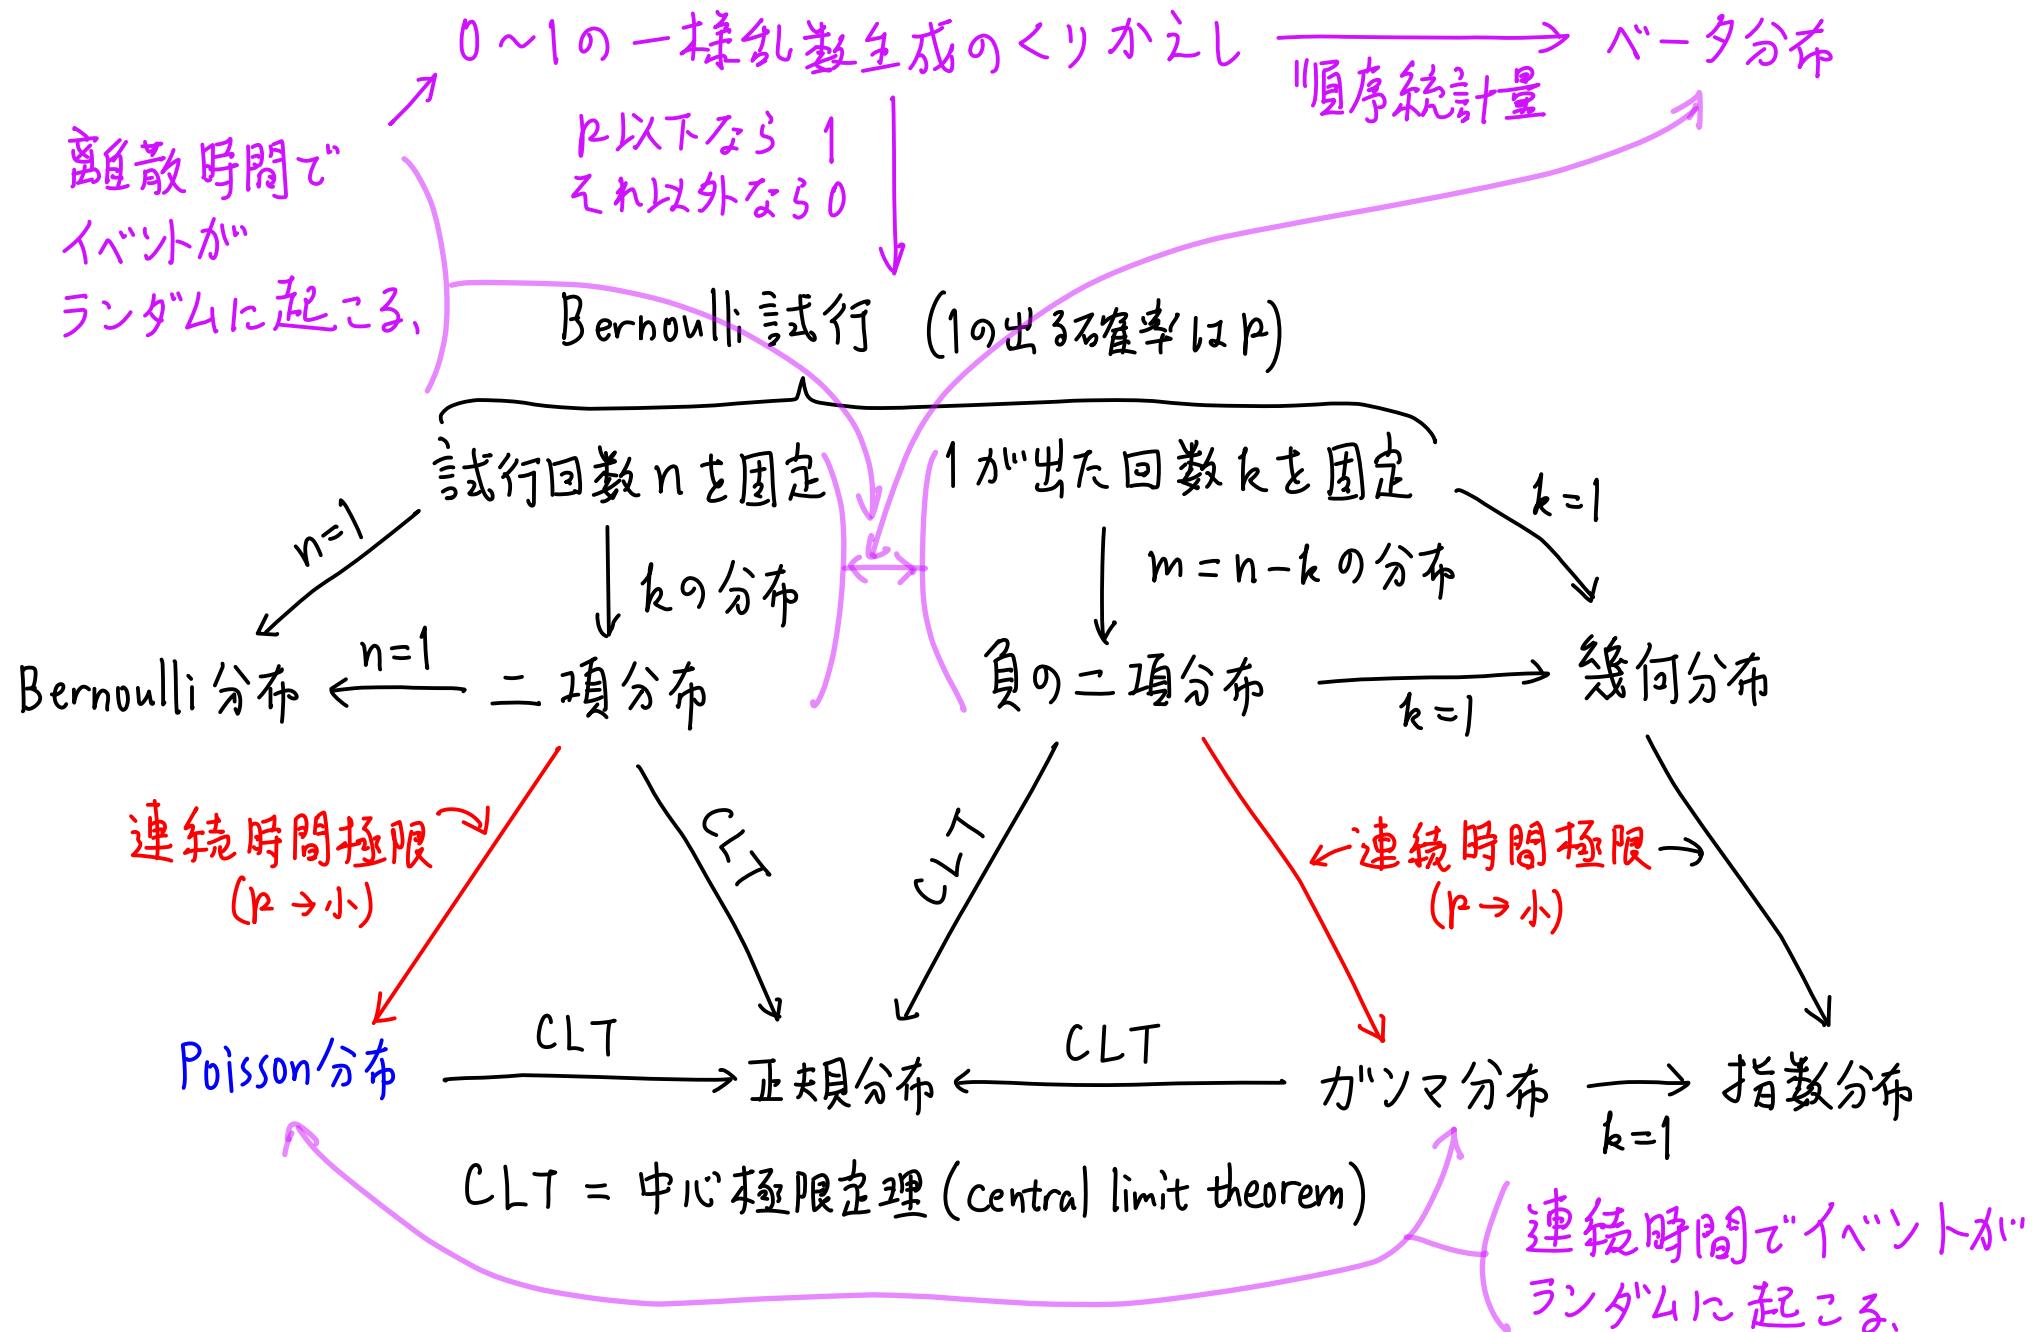
重要な応用

二項分布と
ベータ分布の関係は
あとでパラメータ p の
Clopper-Pearsonの
信頼区間の計算で
使われる。

Clopper-Pearsonの
信頼区間は
統計学入門における
非常に基本的な
題材である!

基本的な応用

Bernoulli 試行の関連確率分布の図



将来より進んだことの勉強に役に立つ問題

問題: Poisson分布の中心極限定理の直接証明

パラメータ $\lambda > 0$ を持つPoisson分布の確率質量函数の定義は

$$p(k|\lambda) = e^{-\lambda} \frac{\lambda^k}{k!} \quad (k = 0, 1, 2, \dots)$$

であった. k は λ ごとに異なる値を取るものとし, 固定された x について

$$k = \lambda + \sqrt{\lambda}x + o(\sqrt{\lambda}) \quad "dk \approx \sqrt{\lambda} dx"$$

を満たしていると仮定する. ここで $o(\sqrt{\lambda})$ は $\sqrt{\lambda}$ で割ると $\lambda \rightarrow \infty$ で 0 に収束する量を表す. このとき次が成立することを示せ:

$$p(k|\lambda) = \frac{e^{-\lambda^2/2}}{\sqrt{2\pi}} \frac{1}{\sqrt{\lambda}} (1 + o(1)).$$

$k \approx \lambda + \sqrt{\lambda}x$
↓
 $\curvearrowleft p(k|\lambda) dk \approx \frac{e^{-x^2/2}}{\sqrt{2\pi}} dx$

ここで $o(1)$ は $\lambda \rightarrow \infty$ で 0 に収束する量である.

注意: 以下の解答例は二項分布の中心極限定理の証明のひな型になる.

解答例: まず, 問題文よりも弱い次の条件を仮定する:

$$k = \lambda + o(\lambda) = \lambda(1 + o(1))$$

ここで $o(\lambda)$ は λ で割ると $\lambda \rightarrow \infty$ で 0 に収束する量である. このとき, $k!$ に

Stirlingの公式を適用すると,

$$p(k|\lambda) = e^{-\lambda} \frac{\lambda^k}{k^k e^{-k} \sqrt{2\pi k}} (1 + o(1)) = \frac{1}{\sqrt{2\pi\lambda}} \left(\frac{k}{\lambda}\right)^{-k} e^{k-\lambda} (1 + o(1)).$$

そして,

$$-\log \left(\left(\frac{k}{\lambda}\right)^{-k} e^{k-\lambda} \right) = k \log \frac{k}{\lambda} - (k - \lambda) \quad \longleftarrow \text{KL情報量の各項を与える.}$$

詳しくは Github における資料を見よ.

まだ説明していないこと:

Poisson分布たちの積の
条件付き確率分布でも
二項分布や多項分布
を作れる.

Poisson 分布の
中心極限定理への理解

↓
二項分布や多項分布の
中心極限定理への理解

↓
Kullback-Leibler 情報量への理解

標本分布

← データの生成のされ方の法則のモデル化

現実での仕事

複雑よくわからない現実

↓ 観測、測定、調査

データ = 数値の列や表
 x_1, x_2, \dots, x_n

統計モデルと
データの数値の比較

↓
推定・推測・推論

↓
意思決定と行動

関連の数学的モデル

未知の現実の法則のモデル化としての
任意の確率分布 $q(x), Q(x)$

(iid の場合には $q(x_1) \dots q(x_n)$ や $Q(x_1) \dots Q(x_n)$)

統計分析で使う具体的な確率分布
 $p(x|\theta), P(x|\theta)$

例 正規分布、二項分布、etc.

統計分析で使う確率分布の標本分布

$p(x_1|\theta) \dots p(x_n|\theta)$ や $P(x_1|\theta) \dots P(x_n|\theta)$

と現実から得たデータの数値列を比較する。

$p(x|\theta)$ 具体的な
分布

データの数値

標本分布

標本分布の定義の準備

X_1, X_2, \dots, X_n は確率変数であるとする。

同時確率分布

X_i : 単独の確率分布だけではなく、 (X_1, \dots, X_n) の全体の確率分布を考える。

(X_1, \dots, X_n) の函数 $f(X_1, \dots, X_n)$ の期待値 $E[f(X_1, \dots, X_n)]$ が定義されていれば
 (X_1, \dots, X_n) 全体の確率分布が得られたことになる。

離散

$$0 \leq P(x_1, \dots, x_n) \leq 1, \quad \sum_{x_1, \dots, x_n} P(x_1, \dots, x_n) = 1.$$

$$E[f(X_1, \dots, X_n)] = \sum_{x_1, \dots, x_n} f(x_1, \dots, x_n) \underbrace{P(x_1, \dots, x_n)}_{\text{同時確率質量函数}}$$

連続

$$0 \leq p(x_1, \dots, x_n) < \infty, \quad \int \cdots \int p(x_1, \dots, x_n) dx_1 \cdots dx_n = 1,$$

$$E[f(X_1, \dots, X_n)] = \int \cdots \int f(x_1, \dots, x_n) \underbrace{p(x_1, \dots, x_n)}_{\text{同時確率密度函数}} dx_1 \cdots dx_n,$$

以上の設定のもとで、各 X_i 単独の 確率質量(密度) 関数は

$$P_i(x_i) = \sum_{x_i \text{ 以外の } x_1, \dots, x_n} P(x_1, \dots, x_n)$$

$$\left(P_i(x_i) = \int \dots \int p(x_1, \dots, x_n) dx_1 \dots \widehat{dx_i} \dots dx_n \right) \text{ になる。}$$

証明

$$E[f(X_i)] = \sum_{x_1, \dots, x_n} f(x_i) P(x_1, \dots, x_n) = \sum_{x_i} f(x_i) \left(\sum_{x_i \text{ 以外の } x_1, \dots, x_n} P(x_1, \dots, x_n) \right)$$

$$\begin{aligned} E[f(X_i)] &= \int \dots \int f(x_i) p(x_1, \dots, x_n) dx_1 \dots dx_n \\ &= \int f(x_i) \underbrace{\left(\int \dots \int p(x_1, \dots, x_n) dx_1 \dots \widehat{dx_i} \dots dx_n \right)}_{= P_i(x_i)} dx_i \end{aligned}$$

q.e.d.

$P_i(x_i)$
||

独立性

確率変数達 X_1, \dots, X_n が 独立 (independent) であるとは、
以下の互いに同値な条件が成立していることと定める：

$$(1) E[f_1(X_1) \cdots f_n(X_n)] = E[f_1(X_1)] \cdots E[f_n(X_n)]. \quad \leftarrow \begin{array}{l} \text{計算では} \\ \text{この形で使われる} \end{array}$$

$$(2) \text{離散の場合には } P(x_1, \dots, x_n) = P_1(x_1) \cdots P_n(x_n) \text{ で}$$

$$\text{連続の場合には } p(x_1, \dots, x_n) = \underbrace{p_1(x_1) \cdots p_n(x_n)}_{\downarrow},$$

(2)の後者 \Rightarrow (1) の証明

$$\begin{aligned} E[f_1(X_1) \cdots f_n(X_n)] &= \int \cdots \int f_1(x_1) \cdots f_n(x_n) \overbrace{p_1(x_1) \cdots p_n(x_n)}^{\downarrow} dx_1 \cdots dx_n \\ &= \int f_1(x_1) p_1(x_1) dx_1 \cdots \int f_n(x_n) p_n(x_n) dx_n \\ &= E[f_1(X_1)] \cdots E[f_n(X_n)]. \end{aligned}$$

□

iid = i.i.d. = independent and identically distributed = 独立同分布

X_1, \dots, X_n が 独立同分布 (iid)

$\overset{\text{def.}}{\iff} X_1, \dots, X_n$ は独立でかつ X_i の各々は共通の同じ分布にしたがう。

X_1, \dots, X_n が各 X_i が分布 D にしたがう独立同分布な確率変数達であると
 (X_1, \dots, X_n) がしたがう同時確率分布を D^n と書き、

分布 D の サイズ n の標本分布 (distribution of size- n samples)

とよび、以下のように書く：

- $X_1, \dots, X_n \sim D$ (independent),
- $(X_1, \dots, X_n) \sim D^n$,
- (X_1, \dots, X_n) is a size- n sample of D .

例 試行回数 n の Bernoulli 試行の分布 $\text{Bernoulli}(p)^n$ は

Bernoulli 分布 $\text{Bernoulli}(p)$ のサイズ " n " の 構本分布である:

$$P(x_1, \dots, x_n) = \prod_{i=1}^n (p^{x_i} (1-p)^{1-x_i}) = p^{x_1 + \dots + x_n} (1-p)^{n-(x_1 + \dots + x_n)}.$$

ここで、 (x_1, \dots, x_n) は 1 と 0 からなる長さ n の 数列。

$(X_1, \dots, X_n) \sim \text{Bernoulli}(p)^n$ のとき、 $K = X_1 + \dots + X_n = (1 \text{ の個数})$ とみくら,

$P(K=k) = \binom{n}{k} p^k (1-p)^{n-k}$ なので、 $K \sim \text{Binomial}(n, p)$ (二項分布)。

$n=5, p=\frac{1}{3}$ のとき,

$$P((X_1, \dots, X_5) = (1, 0, 0, 1, 1)) = p^3 (1-p)^2 = \frac{1^3 2^2}{3^5} = \frac{4}{243}$$

$$P(K=3) = \binom{5}{3} p^3 (1-p)^2 = 10 p^3 (1-p)^2 = \frac{40}{243} \approx 16.46\%$$

このモデルは以下のモデル化に使われる:

(何人死したか)

- 薬を使った n 人の患者が 〇〇 日以内に死んだか死なずいた人たか。
- 広告を見た人が商品を買ったか買わなか。(何人買ったか)

例 平均 μ , 分散 σ^2 を持つ正規分布 $\text{Normal}(\mu, \sigma)$ のサイズ n の標本分布の
(同時) 確率密度函数の形は次のようになる:

$$p(x_1, \dots, x_n | \mu, \sigma) = \prod_{i=1}^n \left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right) \right) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right).$$

このモデルは、たとえば、

- 無作為抽出されたうちの n 人の中の男子の身長の数値 (x_1, \dots, x_n) の分布のモデル化に使える、(身長の分布は正規分布にかなり近いことが知られている。)

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (\text{標本平均}), \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (\text{不偏分散}) \text{ とおくと,}$$

$n-1$ である理由はあとで説明する。

$$\begin{aligned} \sum_{i=1}^n (x_i - \mu)^2 &= \sum_{i=1}^n ((x_i - \bar{x}) + (\bar{x} - \mu))^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + 2(\bar{x} - \mu) \underbrace{\sum_{i=1}^n (x_i - \bar{x})}_{=0} + n(\bar{x} - \mu)^2 \\ &= (n-1)s^2 + n(\bar{x} - \mu)^2 \end{aligned}$$

よし、

$$p(x_1, \dots, x_n | \mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2} \left((n-1)s^2 + n(\bar{x} - \mu)^2\right)\right).$$

\bar{x} と s^2 だけ
で書ける! □

\bar{x} と s^2 は正規分布モデルの十分統計量

標本分布内の確率的ゆらぎの大きさの例

n 回中 K 回成功 $\rightarrow p$ を $\hat{p} = \frac{K}{n}$ で推定

$K \sim \text{Binomial}(n, p)$ のとき, $E[K] = np$, $\text{std}(K) = \sqrt{\text{Var}(K)} = \sqrt{np(1-p)}$ であるので,

$\hat{p} = \frac{K}{n}$ とおくと, $E[\hat{p}] = \frac{1}{n}E[K] = p$, $\underline{\text{std}(\hat{p})} = \frac{1}{n}\text{std}(K) = \sqrt{\frac{p(1-p)}{n}}$.

(\hat{p} は p の不偏推定量) これを SE と書いて, 標準誤差 (standard error) と呼ぶ.

以上は二項分布内の様子、(数学的 フィクション)

二項分布は、毎回独立に 未知の確率 p で当たりが出るルーレットを n 回まわしたときの当たりの回数 k の分布のモデル化になっている。

このようなルーレットを n 回まわしたとき、 k 回当たりが出たとする。 ← [データ]

そして、未知である当たりの確率 p の推定値を $\frac{k}{n}$ で求めるこ^うとにしよう (最尤法),

二項分布モデルを使って、推定値の $\frac{k}{n}$ と真の値 p のちがいの大きさを推定したい。(つづく)

ポイント 未知の値 p の推定値をデータ「 n 回中 k 回当たりが出た」から $\frac{k}{n}$ と求めても、
誤差がどの程度であるかを見極もらないと意味のある統計分析にならない!
 ここで確率論的な計算を使う。

誤差の大きさの指標

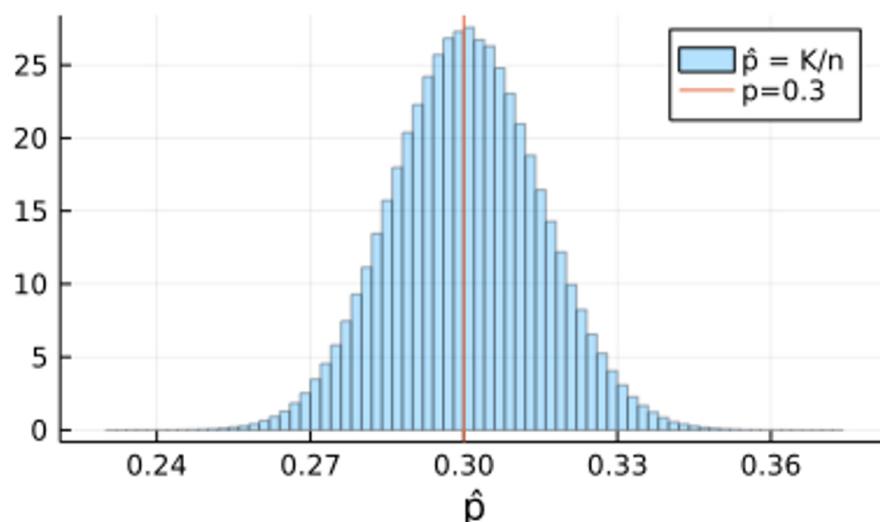
二項分布内で $\hat{p} = \frac{k}{n}$ の真の標準偏差の式は $\sqrt{\frac{p(1-p)}{n}}$ で未知の値 p を含む。
 その間にデータから求めた推定値 k/n を代入して得られる $\sqrt{\frac{(k/n)(1-k/n)}{n}}$ を
 真の標準偏差の推定値として使ったりする。
 ($k=0, n$ のような場合にはあぶないやつ。)

数値例

$n=1000, p=0.3$ のとき、

$$\text{std}(\hat{p}) = \text{std}\left(\frac{k}{n}\right) = \sqrt{\frac{p(1-p)}{n}} = \sqrt{\frac{0.3 \times 0.7}{1000}} \approx 0.015$$

$n = 1000, p = 0.3$



$\hat{p} = \frac{k}{n}$ の分布

$$\hat{p} = \frac{k}{n}$$

は
直の値の $p = 0.30$ から

約2倍
 ± 0.03 程度の範囲に 95 % 以上が
分布している。

超重要必修自習問題

必修問題: 大阪都構想に関する住民投票の結果について

2015年と2020年の大阪都構想に関する住民投票の結果は

- 2015年: 賛成: 694,844 (49.6%) 反対: 705,585 (50.4%)
 - 2020年: 賛成: 675,829 (49.4%) 反対: 692,996 (50.6%)

であった(検索).

どちらでも僅差で反対派が勝利した。パーセントの数値を見ると大変な僅差であったようにも見える。この数値に二項分布モデルを適用したらどうなるかを計算するのがこの問題の内容である。(注意・警告: ただし、二項分布モデルの適用がこの場合に妥当であるかどうかは度外視する。妥当であるか否かは目的によって異なる。)

確率変数 K は二項分布 $\text{Binomial}(n, p)$ に従うと仮定する.

(1) $n = 694844 + 705585 = 1400429$, $p = 0.5$ のとき, 確率 $P(K \leq 694844)$ の2倍の値を求めよ.

(2) $n = 675829 + 692996 = 1368825$, $p = 0.5$ のとき, 確率 $P(K \leq 675829)$ の2倍の値を求めよ.

(3) $n = 694844 + 705585 = 1400429$ のとき、以下を求めよ：

- $P(K \geq 694844) = 2.5\%$ になるようなパラメータ p の値 p_L ,
 - $P(K < 694844) = 2.5\%$ になるようなパラメータ p の値 p_U .

(4) $n = 675829 + 692996 = 1368825$ のとき、以下を求めよ：

- $P(K \geq 675829) = 2.5\%$ になるようなパラメータ p の値 p_L ,
 - $P(K < 675829) = 2.5\%$ になるようなパラメータ p の値 p_H .

p_I, p_{II} の L, U は lower, upper の頭文字のつもりである.

確率やパラメータの数値は有効桁4桁まで求めよ。0.000000000000000000000001234 のように0を沢山含む表示は見難いので、

$$1.234 \times 10^{20} = \underbrace{0.00000000000000000000}_{20} 1234$$

のように書かずに

$$1.234\text{E}-20 = 1.234\text{e}-20$$

のように書くこと。1.234E-20, 1.234e-20 のどちらでもよい。

ヒント: $K \sim \text{Binomial}(n, p)$ のとき,

$$P(K \geq k) = 1 - \text{cdf}(\text{Binomial}(n, p), k - 1) = \text{cdf}(\text{Beta}(k, n - k + 1), p),$$

$$P(K \leq k) = \text{cdf}(\text{Binomial}(n, p), k) = 1 - \text{cdf}(\text{Beta}(k + 1, n - k), p).$$

これらの公式から、与えられた n と k について $P(K \geq k) = \alpha/2$ を満たす $p = p_L$ と $P(K \leq k) = \alpha/2$ を満たす $p = p_U$ はそれぞれ次のように表されることがわかる:

$$p_L = \text{quantile}(\text{Beta}(k, n - k + 1), \alpha/2),$$

$$p_U = \text{quantile}(\text{Beta}(k + 1, n - k), 1 - \alpha/2).$$

WolframAlphaでは Beta は `BetaDistribution` と書く。

注意: この問題の内容を一般化するだけで **検定** (統計的仮説検定, statistical hypothesis testing) や **信頼区間** (confidence interval) の一般論が得られる。(1), (2)はP値(モデルのデータへの適合度の指標の一種)を求める問題になっており, (3), (4)は 95% 信頼区間 $[p_L, p_U]$ を求める問題になっている(ただし両方Clopper-Pearsonの信頼区間の場合)。

ヒント

リアルなデータが

二項分布モデルを通して見ると

どのように見えるか？

GitHubにある資料に答える詳しい解説がある。

X, Y と X, Z と Y, Z の各々の対が独立でも X, Y, Z 全体が独立でない例

右の $P(x, y, z)$ が
定める分布に
したがう X, Y, Z
はそのようないい。

	$z = 1$		$z = 0$	
	$y = 1$	$y = 0$	$y = 1$	$y = 0$
$x = 1$	$P(1, 1, 1) = 1/4$	$P(1, 0, 1) = 0$	$P(1, 1, 0) = 0$	$P(1, 0, 0) = 1/4$
$x = 0$	$P(0, 1, 1) = 0$	$P(0, 0, 1) = 1/4$	$P(0, 1, 0) = 1/4$	$P(0, 0, 0) = 0$

$$P(x, y) = P(x, y, 1) + P(x, y, 0) = \frac{1}{4} \quad ((x, y) = (1, 1), (1, 0), (0, 1), (0, 0) の 4通り)$$

$$P(x, z) = P(x, 1, z) + P(x, 0, z) = \frac{1}{4} \quad ((x, z) も 4通り)$$

$$P(y, z) = P(1, y, z) + P(0, y, z) = \frac{1}{4} \quad ((y, z) も 4通り)$$

$$P(x) = P(x, y=1) + P(x, y=0) = \frac{1}{2} \quad (x=0, 1 で 2通り), \text{ 同様に } z, \quad P(y) = P(z) = \frac{1}{2},$$

$$\text{ゆえに, } P(x, y) = P(x)P(y), \quad P(x, z) = P(x)P(z), \quad P(y, z) = P(y)P(z).$$

X, Y, Z は対ごとに独立、

$$\text{しかし, } P(1, 1, 1) = \frac{1}{4} \text{ と } P(x=1)P(y=1)P(z=1) = \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} = \frac{1}{8} \text{ は等しくない,}$$

X, Y, Z の全体は独立ではない、

つつき、

確率変数の独立性の現実における解釈に関する重大な注意

上の例は具体的には次のような状況だと解釈可能である。

(1) $P(x) = 1/2$ の解釈: $X = 1$ は薬Aを与えたことを, $X = 0$ は薬Bを与えたことを意味する。全員に確率 $1/2$ で薬Aまたは薬Bを与えた。

$x = 1 = \text{薬A}$	$P(x = 1) = 1/2$
$x = 0 = \text{薬B}$	$P(x = 0) = 1/2$

(2) $P(y) = 1/2$ の解釈: $Y = 1$ は薬に効果があったことを, $Y = 0$ は薬に効果が無かったことを意味する。全体で見たら, $1/2$ の確率で薬には効果があった。

$y = 1 = \text{効果有}$	$y = 0 = \text{効果無}$
$P(y = 1) = 1/2$	$P(y = 0) = 1/2$

(3) $P(z) = 1/2$ の解釈: $Z = 1$ は女性であることを, $Z = 0$ は男性であることを意味する。女性である確率と男性である確率は $1/2$ だった。

$z = 1 = \text{女性}$	$z = 0 = \text{男性}$
$P(z = 1) = 1/2$	$P(z = 0) = 1/2$

(4) 男女の区別をやめると、薬Aも薬Bも効果がある確率は半々であり、薬Aと薬Bのどちらを与えたかと効果があったかどうかは独立である。男女を合わせた($z = 1, 0$ の場合の和を取って得られる)確率質量函数 $P(x, y)$ の表

	$y = 1 = \text{効果有}$	$y = 0 = \text{効果無}$
$x = 1 = \text{薬A}$	$P(x = 1, y = 1) = 1/4$	$P(x = 1, y = 0) = 1/4$
$x = 0 = \text{薬B}$	$P(x = 0, y = 1) = 1/4$	$P(x = 0, y = 0) = 1/4$

は $x = 1$ の薬Aの場合も $x = 0$ の薬Bの場合も男女の区別をやめると薬Aと薬Bで効果に変わりがないことを意味している。

(5) 薬Aと薬Bのどちらを与えたかと男女のどちらであるかは独立である。そのことは効果の有無を意味する $y = 1, 0$ について和を取って得られる確率質量函数 $P(x, z)$ の表

	$z = 1 = \text{女性}$	$z = 0 = \text{男性}$
$x = 1 = \text{薬A}$	$P(x = 1, z = 1) = 1/4$	$P(x = 1, z = 0) = 1/4$
$x = 0 = \text{薬B}$	$P(x = 0, z = 1) = 1/4$	$P(x = 0, z = 0) = 1/4$

からわかる。

(6) 薬Aと薬Bのどちらを与えたかを無視すると、男女のどちらであるかと薬の効果の有無は独立である。そのことは薬Aと薬Bのどちらを与えたかを意味する $x = 1, 0$ について和を取って得られる確率質量函数 $P(y, z)$ の表

	$y = 1 = \text{効果有}$	$y = 0 = \text{効果無}$
$z = 1 = \text{女性}$	$P(y = 1, z = 1) = 1/4$	$P(y = 0, z = 1) = 1/4$
$z = 0 = \text{男性}$	$P(y = 1, z = 0) = 1/4$	$P(y = 0, z = 0) = 1/4$

からわかる。

(7) しかし、男女を区別すると全然違う結果が見えて来る。薬Aは女性だけに効果があり、薬Bは男性だけに効果がある。 $z = 1$ の女性の場合に制限した確率質量函数 $P(x, y, z)$ $P(x, y, z)$ の表

	$z = 1 = \text{女性}$
	$y = 1 = \text{効果有}$
$x = 1 = \text{薬A}$	$P(1, 1, 1) = 1/4$
$x = 0 = \text{薬B}$	$P(0, 1, 1) = 0$
	$y = 0 = \text{効果無}$
$x = 1 = \text{薬A}$	$P(1, 0, 1) = 0$
$x = 0 = \text{薬B}$	$P(0, 0, 1) = 1/4$

より、 $x = 1$ の薬Aの場合には $y = 1$ の効果有の確率が正であるが、 $x = 0$ の薬Bの場合には $y = 1$ の効果有の確率が0になっている。 $z = 0$ の男性の場合に制限した確率質量函数 $P(x, y, z)$ の表

	$z = 0 = \text{男性}$
	$y = 1 = \text{効果有}$
$x = 1 = \text{薬A}$	$P(1, 1, 0) = 0$
$x = 0 = \text{薬B}$	$P(0, 1, 0) = 1/4$
	$y = 0 = \text{効果無}$
$x = 1 = \text{薬A}$	$P(1, 0, 0) = 1/4$
$x = 0 = \text{薬B}$	$P(0, 0, 0) = 0$

より、 $x = 1$ の薬Aの場合には $y = 1$ の効果有の確率が0で効果がないが、 $x = 0$ の薬Bの場合には $y = 1$ の効果有の確率が正になっている。

このように現実世界において確率変数達が独立か否かは重大な意味を持ち得る。ある重要な条件(上の場合には女性か男性か)を無視して、「XとYは独立である」(どちらの薬を与えても効果は同じである)と結論すると大変なことになってしまいかもしれない。XとYも、XとZも、YとZも独立であっても、XとYとZの全体は独立でないかもしれない。

確率変数達の共分散と相関係数

X, Y は確率変数とし、 $E[X] = \mu_X$, $\text{Var}(X) = \sigma_X^2$ とする。

共分散 (covariance) \longleftrightarrow ベクトルの内積

自分で確認せよ、(GitHubに答えがある。)

$$\sigma_{XY} = \text{cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = E[XY] - E[X]E[Y],$$

Cauchy-Schwarz の不等式

$$E[XY]^2 \leq E[X^2]E[Y^2] \text{ もう} \checkmark$$

$$|\text{Cov}(X, Y)| \leq \text{std}(X) \text{ std}(Y) \quad (\sigma_{XY} \leq \sigma_X \sigma_Y).$$

GitHub に証明あり、
線形代数の場合と同じ

相關係數 (correlation coefficient)

$$\rho_{XY} = \text{cor}(X, Y) = \frac{\text{cov}(X, Y)}{\text{std}(X) \text{std}(Y)} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y} \leftrightarrow \frac{(\text{内積})}{(J_{1L4})(J_{1L4})} = \cos \theta,$$

無相關 (uncorrelated)

$\rho_{XY} = \text{cor}(X, Y) = 0$ のとき、 X と Y は無相関であるという。

GitHubに答へか
ある

(数学的には $\sigma_{XY} = \text{cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = 0$ と同値。)
 ただし、 $\sigma_{XY} \approx 0$ であっても $\rho_{XY} \neq 0$ のことがあるので注意。)

例を挙げよ、

X_1, \dots, X_n は、 $i \neq j$ ならば X_i と X_j が無相関なとき、対ごとに無相関であるといふ。

独立 \Rightarrow 無相関

証明 X, Y は独立であると仮定する。

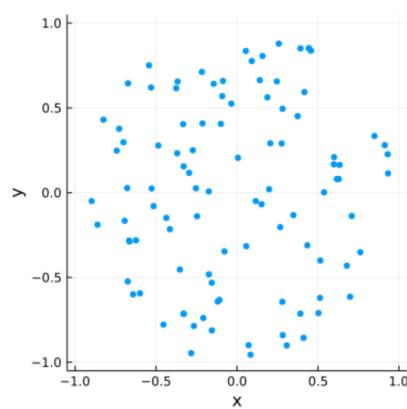
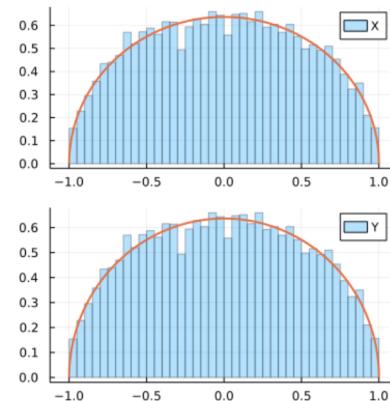
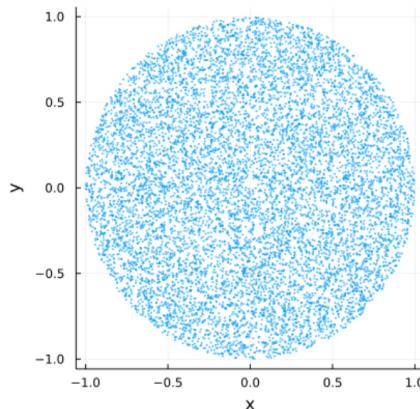
このとき, $E[f(X)g(Y)] = \underbrace{E[f(X)]E[g(Y)]}$ なので,

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = E[X - \mu_X]E[Y - \mu_Y] = 0 \cdot 0 = 0.$$

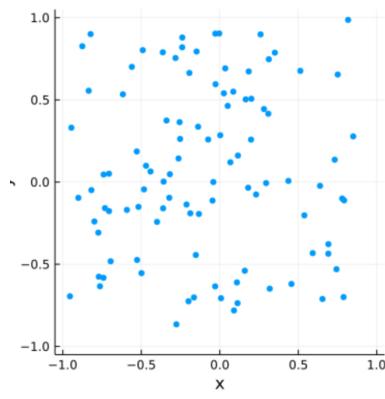
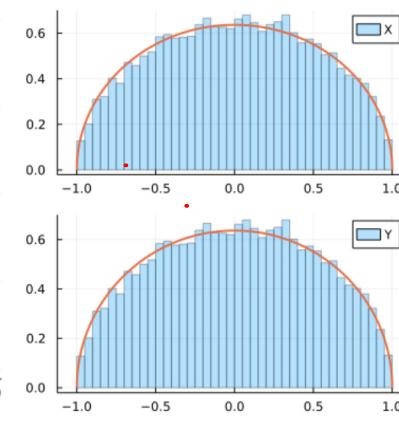
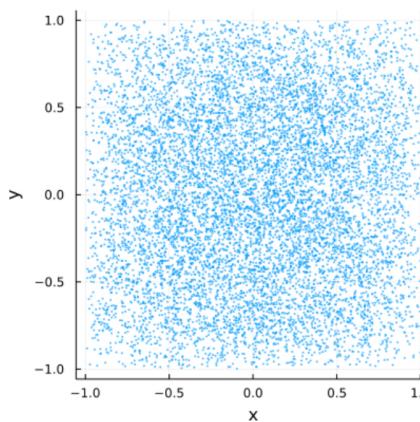
f.e.d.

逆は成立しない。

以下のとおりかう例を自分で作ってみよ、 \leftarrow 答えは GitHub にある。



単位円盤上の一様分布は「無相関だが独立ではない場合」の例になっている。



これは X, Y が独立な場合であり、ゆえに無相関にもなっている。

$\sigma_{XX} = \text{cov}(X, X) = \text{Var}(X) = \sigma_X^2$ なので、其分散の概念は分散の概念を含む。

$$\begin{aligned} i \neq j のとき X_i \text{ と } Y_j \text{ が無相関} &\Rightarrow \text{cov}\left(\sum_{i=1}^n X_i, \sum_{j=1}^n Y_j\right) = \sum_{i=1}^n \text{cov}(X_i, Y_i), \\ (\text{特に独立}) \\ i \neq j のとき X_i \text{ と } X_j \text{ が無相関} &\Rightarrow \text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i). \end{aligned}$$

← これ以後
空気のいいとく
使われる。

証明 $\mu_{X_i} = E[X_i]$, $\mu_{Y_i} = E[Y_i]$ とおくと, $i \neq j$ のとき, X_i と Y_j が無相関であることより
 $i \neq j \Rightarrow \text{cov}(X_i, Y_j) = E[(X_i - \mu_{X_i})(Y_j - \mu_{Y_j})] = 0.$

ゆえに,

$$\begin{aligned} \text{cov}\left(\sum_{i=1}^n X_i, \sum_{j=1}^n Y_j\right) &= E\left[\left(\sum_{i=1}^n X_i - \sum_{i=1}^n \mu_{X_i}\right)\left(\sum_{j=1}^n Y_j - \sum_{j=1}^n \mu_{Y_j}\right)\right] \\ &= E\left[\sum_{i=1}^n (X_i - \mu_{X_i}) \sum_{j=1}^n (Y_j - \mu_{Y_j})\right] \\ &= \sum_{i=1}^n \sum_{j=1}^n E[(X_i - \mu_{X_i})(Y_j - \mu_{Y_j})] \quad \leftarrow \text{これは } i \neq j \text{ のとき } 0 \\ &= \sum_{i=1}^n E[(X_i - \mu_{X_i})(Y_i - \mu_{Y_i})] = \sum_{i=1}^n \text{cov}(X_i, Y_i). \end{aligned}$$

q.e.d.

特に X_1, \dots, X_n が独立なとき,

$$E\left[\sum_{i=1}^n X_i\right] = \sum_{i=1}^n E[X_i], \quad \text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i)$$

← 非常によく使われる。

医学研究でよく見るメタアナリシスに興味がある人向けの自習問題

答えは
GitHubにある。

2.11 問題(メタアナリシスの出発点): 共通の期待値と異なる分散を持つ確率変数の荷重平均

X_1, \dots, X_n は対ごとに無相関な確率変数達であるとし, X_i 達は共通の期待値 μ と共に分散 $\sigma_i^2 > 0$ を持つと仮定する:

$$E[X_1] = \dots = E[X_n] = \mu, \quad E[X_i] = \sigma_i^2 \quad (i = 1, \dots, n)$$

このとき, 共通の期待値 μ の推定量 $\hat{\mu}$ を荷重 w_i による荷重平均

$$\hat{\mu} = \sum_{i=1}^n w_i X_i, \quad \sum_{i=1}^n w_i = 1$$

の形で定義したい. 条件 $\sum_{i=1}^n w_i = 1$ より, 不偏性 $E[\hat{\mu}] = \mu$ がただちに導かれる. このとき, $\hat{\mu}$ の分散 $\text{var}(\hat{\mu})$ を最小化する荷重 w_i は

$$w_i = \frac{1/\sigma_i^2}{\sum_{i=1}^n 1/\sigma_i^2}, \quad \text{i.e.} \quad \hat{\mu} = \frac{\sum_{i=1}^n X_i / \sigma_i^2}{\sum_{i=1}^n 1/\sigma_i^2}$$

になることを示せ. さらに, このとき

$$\text{var}(\hat{\mu}) = \frac{1}{\sum_{i=1}^n 1/\sigma_i^2} < \min(\sigma_1^2, \dots, \sigma_n^2)$$

となることも示せ.

注意: この結果はことなる分散を持つ複数の推定量をうまくまとめることによって, 分散がより小さな推定量を作れることを意味している. これは同一の量に関する異なる研究の結果をまとめるメタアナリシスの出発点になる.

標本(サンプル, データ)の平均, 分散, 共分散, 相関係数

$E[X], \text{Var}(X), \text{cov}(X, Y), \text{cor}(X, Y)$
とは区別あることに注意!

現実から数値データの場合

数値のデータ $(x_1, y_1), \dots, (x_n, y_n)$ について,

標本平均 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ $\left(\bar{x^2} = \frac{1}{n} \sum_{i=1}^n x_i^2, \quad \bar{xy} = \frac{1}{n} \sum_{i=1}^n x_i y_i, \text{ etc.} \right)$

(不偏補正されない) 標本分散 $\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \bar{x^2} - (\bar{x})^2$

不偏分散 $s_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{n}{n-1} (\bar{x^2} - (\bar{x})^2).$

どうして $n-1$ であるかは後で説明する。
証明せよ,

不偏共分散 $s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{n}{n-1} (\bar{xy} - \bar{x}\bar{y})$

相関係数 $r_{xy} = \frac{s_{xy}}{s_x s_y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\left(\sum_{i=1}^n (x_i - \bar{x})^2\right)^{1/2} \left(\sum_{i=1}^n (y_i - \bar{y})^2\right)^{1/2}}$ $\leftrightarrow \cos \theta$

確率変数の場合

以下は $E[X]$, $\text{Var}(X)$, $\text{cov}(X, Y)$, $\text{cor}(X, Y)$ とはちがうものであることに注意!

確率変数達 $(X_1, Y_1), \dots, (X_n, Y_n)$ は以下をみたしてみると仮定する:

- (1) $E[X_i] = \mu_X$, $E[Y_i] = \mu_Y$ (共通の期待値 (μ_X, μ_Y) を持つ.)
- (2) $\text{Var}(X_i) = \sigma_X^2$, $\text{Var}(Y_i) = \sigma_Y^2$, $\text{cov}(X_i, Y_i) = \sigma_{XY}$ (共通の分散と共分散を持つ)
- (3) $i \neq j$ のとき, $\text{cov}(X_i, X_j) = \text{cov}(Y_i, Y_j) = \text{cov}(X_i, Y_j) = 0$ (無相関)

等に iid 成立は

標本平均 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, $\bar{X^2} = \frac{1}{n} \sum_{i=1}^n X_i^2$, $\bar{XY} = \frac{1}{n} \sum_{i=1}^n X_i Y_i$, etc.

不偏分散 $S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n}{n-1} (\bar{X^2} - (\bar{X})^2)$. 証明せよ.

どうして $n-1$ で割るかは後で説明する.

不偏共分散 $S_{XY} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) = \frac{n}{n-1} (\bar{XY} - \bar{X}\bar{Y})$

相関係数 $R_{XY} = \frac{S_{XY}}{S_X S_Y} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{(\sum_{i=1}^n (X_i - \bar{X})^2)^{1/2} (\sum_{i=1}^n (Y_i - \bar{Y})^2)^{1/2}}$ $\leftrightarrow \cos \theta$

これらは確率変数 X_i, Y_i の函数なので確率変数になる。

$E[X]$, $\text{Var}(X)$, $\text{cov}(X, Y)$, $\text{cor}(X, Y)$ (\leftarrow これらは数値になる) とはちがうものである!

標本平均の期待値、分散、共分散

$$E[\bar{X}] = \mu_X, \quad E[\bar{Y}] = \mu_Y, \quad \text{Var}(\bar{X}) = \frac{\sigma_X^2}{n}, \quad \text{Var}(\bar{Y}) = \frac{\sigma_Y^2}{n}, \quad \text{Cov}(\bar{X}, \bar{Y}) = \frac{\sigma_{XY}}{n},$$

① ② ③ ④ ⑤

証明 ①の X が Y の場合 \Rightarrow ② で； ⑤ の $X=Y$ の場合 \Rightarrow ③, ④ なので ①, ⑤ を示せば十分。

$$E[\bar{X}] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \mu_X.$$

$= \mu_X$

$$\begin{aligned} \text{Cov}(\bar{X}, \bar{Y}) &= E[(\bar{X} - \mu_X)(\bar{Y} - \mu_Y)] = E\left[\frac{1}{n} \sum_{i=1}^n (X_i - \mu_X) \cdot \frac{1}{n} \sum_{j=1}^n (Y_j - \mu_Y)\right] \\ &= \frac{1}{n^2} \sum_{i,j=1}^n E[(X_i - \mu_X)(Y_j - \mu_Y)] = \frac{1}{n^2} n \sigma_{XY} = \frac{\sigma_{XY}}{n}. \end{aligned}$$

$\begin{cases} i=j のとき \sigma_{XY}, \\ i \neq j のとき 0 \end{cases}$

q.e.d.

注意 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ の 標準偏差 $\text{std}(\bar{X}) = \sqrt{\text{Var}(\bar{X})} = \frac{\sigma_X}{\sqrt{n}}$ は、

\bar{X} の実現値で値 μ_X を推定するときの誤差の大きさの指標になる。

($SE = \text{std}(\bar{X})$ と書いて、 μ_X の推定量 \bar{X} の 標準誤差 (standard error) と呼ぶ。)

\bar{X} の標準偏差は $n \rightarrow \infty$ で 0 に収束する！

□

不偏(共)分散の定義はどうして $n-1$ で割るか

答え $E[\hat{S}_X^2] = \sigma_X^2$, $E[\hat{S}_{XY}] = \sigma_{XY}$ となるから.

(このとき, \hat{S}_X^2 , \hat{S}_{XY} はそれぞれ σ_X^2 , σ_{XY} の 不偏推定量であるといふ.)

証明 $E[\hat{S}_X^2] = \sigma_X^2$ は $E[\hat{S}_{XY}] = \sigma_{XY}$ の $X=Y$ の場合なので後者のみを示せばよし,

$$\begin{aligned} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) &= \sum_{i=1}^n ((X_i - \mu_X) - (\bar{X} - \mu_X))((Y_i - \mu_Y) - (\bar{Y} - \mu_Y)) \\ &= \sum_{i=1}^n (X_i - \mu_X)(Y_i - \mu_Y) - \underbrace{\left(\sum_{i=1}^n (X_i - \mu_X)\right)}_{= n(\bar{X} - \mu_X)} (\bar{Y} - \mu_Y) - (\bar{X} - \mu_X) \underbrace{\left(\sum_{i=1}^n (Y_i - \mu_Y)\right)}_{= n(\bar{Y} - \mu_Y)} + n(\bar{X} - \mu_X)(\bar{Y} - \mu_Y) \end{aligned}$$

$$= \sum_{i=1}^n (X_i - \mu_X)(Y_i - \mu_Y) - n \underbrace{(\bar{X} - \mu_X)(\bar{Y} - \mu_Y)}$$

↑これの期待値は $\sum_{i=1}^n \text{cov}(X_i, Y_i) = n \sigma_{XY} = \sigma_{XY}$

↑これの期待値は $\text{cov}(\bar{X}, \bar{Y}) = \frac{\sigma_{XY}}{n}$

ゆえに, $E\left[\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})\right] = n \sigma_{XY} - n \frac{\sigma_{XY}}{n} = (n-1) \sigma_{XY}$,

(これが $n-1$ でわる理由)

したがって, $E[\hat{S}_{XY}] = E\left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})\right] = \frac{1}{n-1} (n-1) \sigma_{XY} = \sigma_{XY}$,

q.e.d.

4 最小二乗法による線形回帰

$\bar{x}, \bar{y}, s_x^2, s_y^2, s_{xy}$ の応用

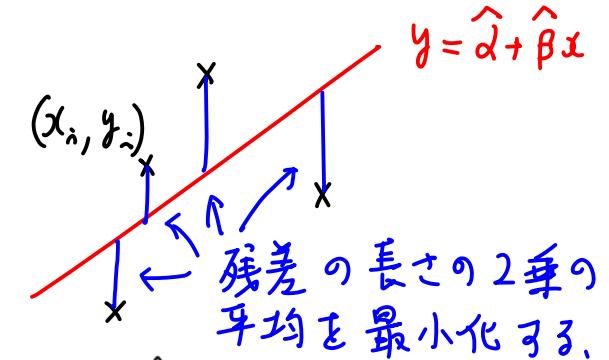
最小二乗法による単純な線形回帰について説明しよう。以下、 x_1, \dots, x_n のうち2つは互いに異なると仮定する。

与えられたデータ $(x_1, y_1), \dots, (x_n, y_n)$ における y_i 達の値を x_i 達の値の共通の一次函数 $\alpha + \beta x_i$ (α, β は i によらない)で近似することを考える。そのとき、

$$\varepsilon_i = y_i - (\alpha + \beta x_i)$$

を 残差 と呼ぶ。このとき、平均二乗残差

$$f(\alpha, \beta) = \frac{1}{n} \sum_{i=1}^n (y_i - (\alpha + \beta x_i))^2$$



を最小化することを **最小二乗法** と呼び、最小二乗法で求めた係数 α, β の値を **回帰係数** と呼び、 $\hat{\alpha}, \hat{\beta}$ と書き、それに対応する一次函数

$$y = \hat{\alpha} + \hat{\beta} x$$

を **回帰直線** (regression line)と呼ぶ。このとき、 x を **説明変数** や **独立変数** などと呼び、 y を **目的変数**、**従属変数**、**反応変数** などと呼ぶ。

これは一次函数によるデータの近似になっているので、**線形回帰** (ordinary least squares, OLS, linear regression)と呼ばれる。この場合には説明変数が x の1つだけなので **単回帰** (simple regression, simple linear regression)と呼ぶこともある。説明変数が多変数になった場合には **重回帰** (multiple regression)と呼ぶ。

以下ではさらに、**最小平均二乗残差** (もしくは単に **平均二乗残差**)の値を次のように書くことにする：

$$\hat{\sigma}^2 = f(\hat{\alpha}, \hat{\beta}) = \frac{1}{n} \sum_{i=1}^n (y_i - (\hat{\alpha} + \hat{\beta} x_i))^2$$

注意: 最小二乗法は説明変数 x と目的変数 y について対称ではないので、それらの変数の立場を逆転して作った回帰直線は元の回帰直線に一致しない。下の方で紹介するGalton (1886)の回帰直線の節も参照せよ。

GitHubの方を見よ、

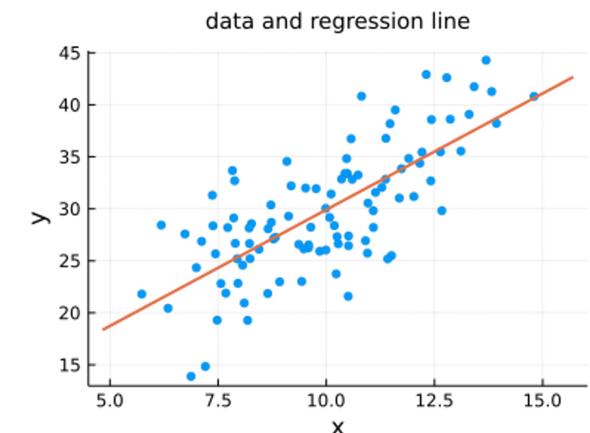
最小二乗法による線形回帰の解は $\bar{x}, \bar{y}, s_x^2, s_y^2, s_{xy}$ で書ける!

4.1 問題: 最小二乗法による線形回帰の公式の導出

データ x_i の標本平均と不偏分散をそれぞれ \bar{x}, s_x^2 と書き、 y_i の標本平均と不偏分散をそれぞれ \bar{y}, s_y^2 と書き、 x_i と y_i の不偏共分散を s_{xy} と書くとき、以上の $\hat{\alpha}, \hat{\beta}, \hat{\sigma}^2$ は次のように表されることを示せ：

$$\hat{\beta} = \frac{s_{xy}}{s_x^2}, \quad \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}, \quad \hat{\sigma}^2 = \frac{n-1}{n} \frac{s_x^2 s_y^2 - s_{xy}^2}{s_x^2}.$$

$$\begin{aligned}\hat{\alpha} &= 7.562346117161635 \\ \hat{\beta} &= 2.235682111246986 \\ \hat{\sigma} &= 4.148269982085684\end{aligned}$$



以下ではこの公式をまとめを使って良い。

① $\hat{\beta} = \frac{s_{xy}}{s_x^2}, \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$ で回帰直線 $y = \hat{\alpha} + \hat{\beta}x$ が求まる。

② $\hat{\sigma}^2 = \frac{n-1}{n} \frac{s_x^2 s_y^2 - s_{xy}^2}{s_x^2}$ で最小平均二乗残差が求まる。

自習問題 上の公式が成立する理由を知りたい人は自分で証明してみよ！

ヒント $f(\alpha, \beta)$ をみ、 β で偏微分して 0 とおく。 GitHub に答えがある。

ヒント $f(\alpha, \beta)$ を「平方完成形」に変形してみよ。

重要必修自習問題

$\bar{x}, \bar{y}, s_x^2, s_y^2, s_{xy}$ の計算の例

4.2 必修問題: 最小二乗法の計算例 (Anscombe's quartet)

以下に示した $(x_1, y_1), \dots, (x_n, y_n)$ 型の4つのデータのそれぞれについて,

- x_i 達の標本平均 \bar{x}
- y_i 達の標本平均 \bar{y}
- x_i 達の不偏分散 s_x^2 ,
- y_i 達の不偏分散 s_y^2 ,
- x_i 達と y_i 達の不偏共分散 s_{xy} ,
- 回帰直線 $y = \hat{\alpha} + \hat{\beta}x$ の係数 $\hat{\alpha}, \hat{\beta}$ と最小平均二乗残差の平方根 $\hat{\sigma}$

を求めよ. それぞれについて小数点以下第1桁まで求めよ.

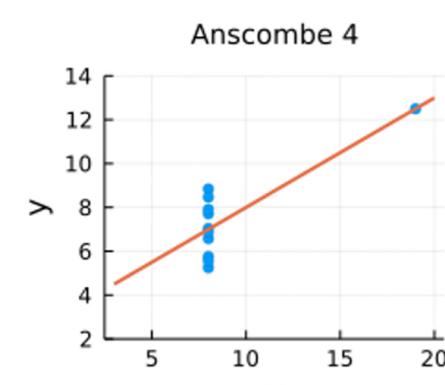
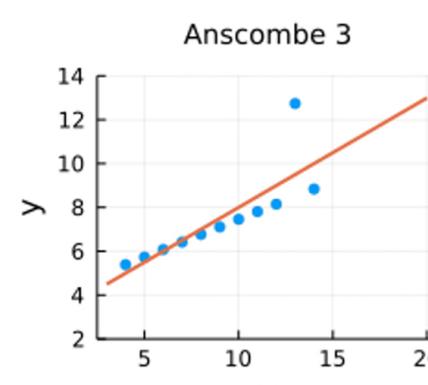
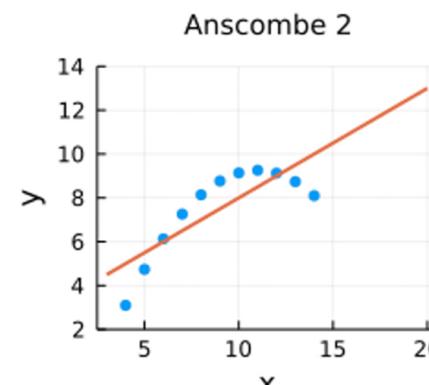
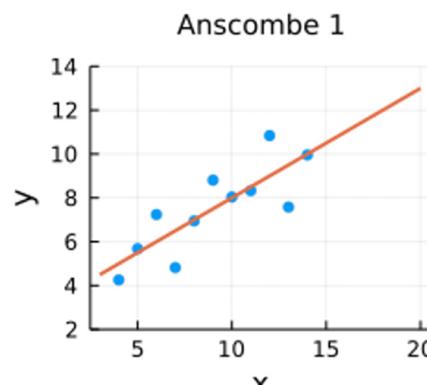
$\checkmark h=11$

答えは GitHub にある.

アンスコムの例

データ1の四が
最小二乗法による
線形回帰が適切

1. $(10, 8.04), (8, 6.95), (13, 7.58), (9, 8.81), (11, 8.33), (14, 9.96), (6, 7.24), (4, 4.26), (12, 10.84), (7, 4.82), (5, 5.68)$
2. $(10, 9.14), (8, 8.14), (13, 8.74), (9, 8.77), (11, 9.26), (14, 8.1), (6, 6.13), (4, 3.1), (12, 9.13), (7, 7.26), (5, 4.74)$
3. $(10, 7.46), (8, 6.77), (13, 12.74), (9, 7.11), (11, 7.81), (14, 8.84), (6, 6.08), (4, 5.39), (12, 8.15), (7, 6.42), (5, 5.73)$
4. $(8, 6.58), (8, 5.76), (8, 7.71), (8, 8.84), (8, 8.47), (8, 7.04), (8, 5.25), (19, 12.5), (8, 5.56), (8, 7.91), (8, 6.89)$



できれば“この図も自分で描いてみてください”

ゴルトン氏のグラフの再現

タテ軸：親の身長，ヨコ軸：成長した子の身長

Galton, Francis. Regression towards mediocrity in hereditary stature.
Journal of the Anthropological Institute, Vol. 5 (1886), 246-263.
https://galton.org/bib/JournalItem.aspx_action=view_id=157

楕円とx軸に平行な直線
の接点を通る

回帰直線 $x = \hat{\alpha}' + \hat{\beta}'y$

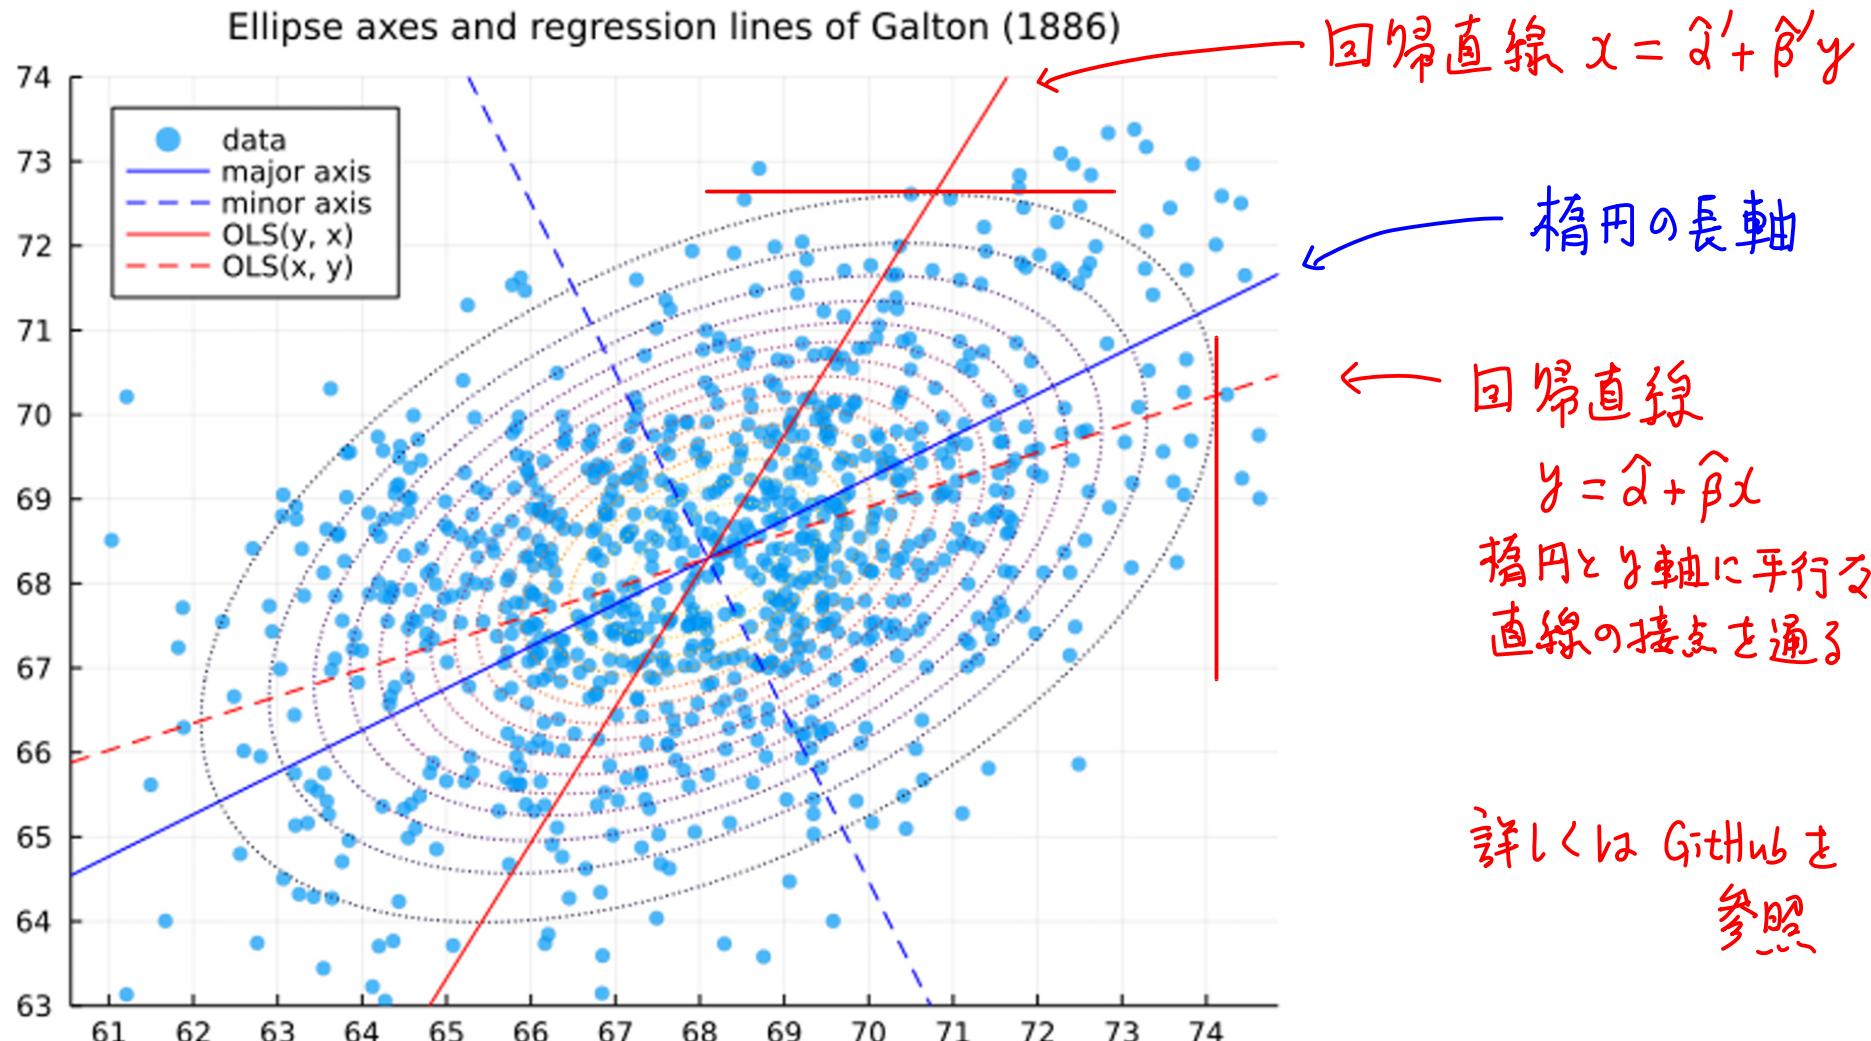
楕円の長軸

回帰直線

$$y = \hat{\alpha} + \hat{\beta}x$$

楕円とy軸に平行な
直線の接点を通る

詳しくは GitHub を
参照



独立同分布な確率変数達の標本平均と不偏分散の分布 (中心極限定理に向けて)

X_1, X_2, \dots, X_n は各々が分布 D にしたがう独立同分布な確率変数達とする。

X_i たち共通の期待値と分散をそれぞれ μ, σ^2 と書く。このとき、

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad (\text{標本平均}), \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (\text{不偏分散})$$

も確率変数になり、次が成立することをすべてに示してある：

$$E[\bar{X}] = \mu, \quad E[S^2] = \sigma^2, \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{n}, \quad \Leftrightarrow \text{std}(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

分布 D の 歪度 (わいど, skewness) \bar{k}_3 と 尖度 (せんど, kurtosis) \bar{k}_4 が次のように定義される：

$$\bar{k}_3 = E\left[\left(\frac{X_i - \mu}{\sigma}\right)^3\right], \quad \bar{k}_4 = E\left[\left(\frac{X_i - \mu}{\sigma}\right)^4\right] - 3 \quad \begin{array}{l} (D = \text{Normal}(\mu, \sigma) \text{ のとき}) \\ (\bar{k}_3 = \bar{k}_4 = 0 \text{ となる。}) \end{array}$$

このとき、 \bar{X} と S^2 の共分散と S^2 の分散は以下のように表される：

$$\text{Cov}(\bar{X}, S^2) = \sigma^3 \frac{\bar{k}_3}{n}, \quad \text{Var}(S^2) = \sigma^4 \left(\frac{\bar{k}_4}{n} + \frac{2}{n-1} \right) \approx \sigma^4 \frac{\bar{k}_4 + 2}{n}$$

証明は GitHub の方を見よ。めんどくさな長い計算が必要。

(\bar{X}, S^2) について基本的な次の 5 つの値が分布 D からどうのよに決まるかがわかった：

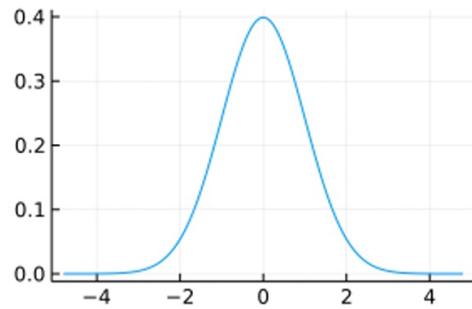
$$E[\bar{X}] = \mu, \quad E[S^2] = \sigma^2, \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{n}, \quad \text{Cov}(\bar{X}, S^2) = \sigma^3 \frac{\bar{k}_3}{n}, \quad \text{Var}(S^2) = \sigma^4 \left(\frac{\bar{k}_4}{n} + \frac{2}{n-1} \right).$$

前ページのような式を見せられてもイX-ジがわからずと思うので、
 (\bar{X}, S^2) の乱数を1万個生成してプロットしてみよう。)

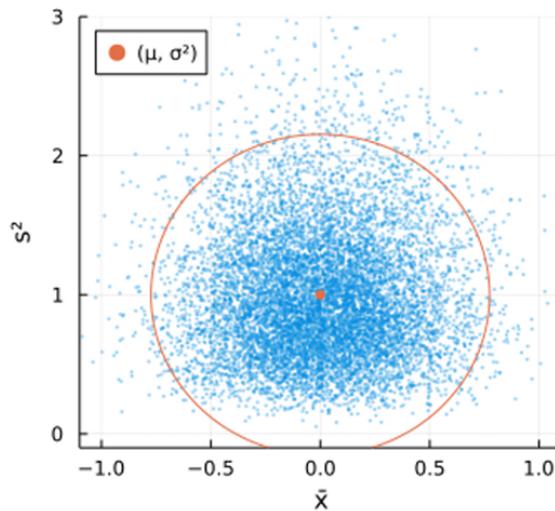
理解のために
これ重要！

Normal{Float64}($\mu=0.0$, $\sigma=1.0$)

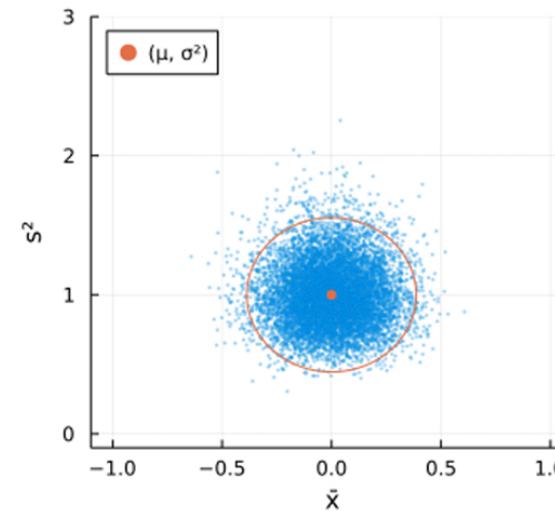
$\mu = 0.0$
 $\sigma^2 = 1.0$
skewness = 0.0
kurtosis = 0.0



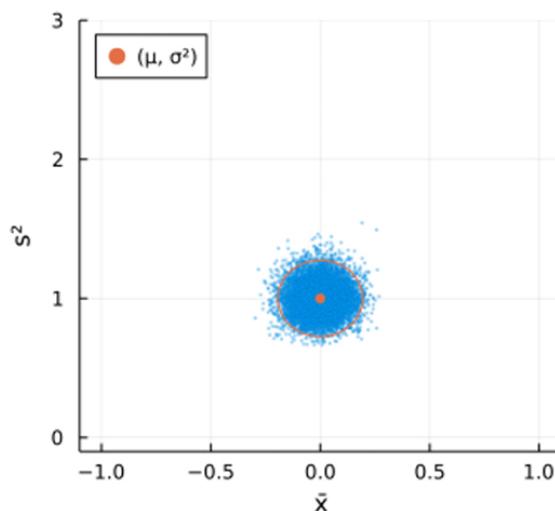
$n = 10$



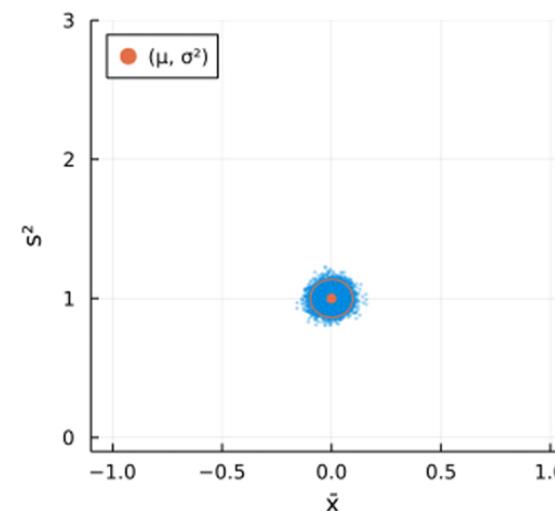
$n = 40$



$n = 160$



$n = 640$

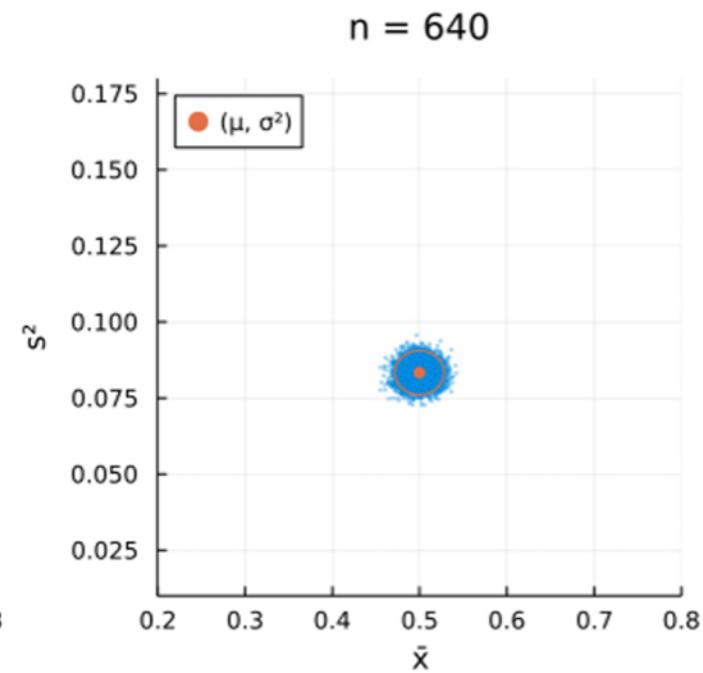
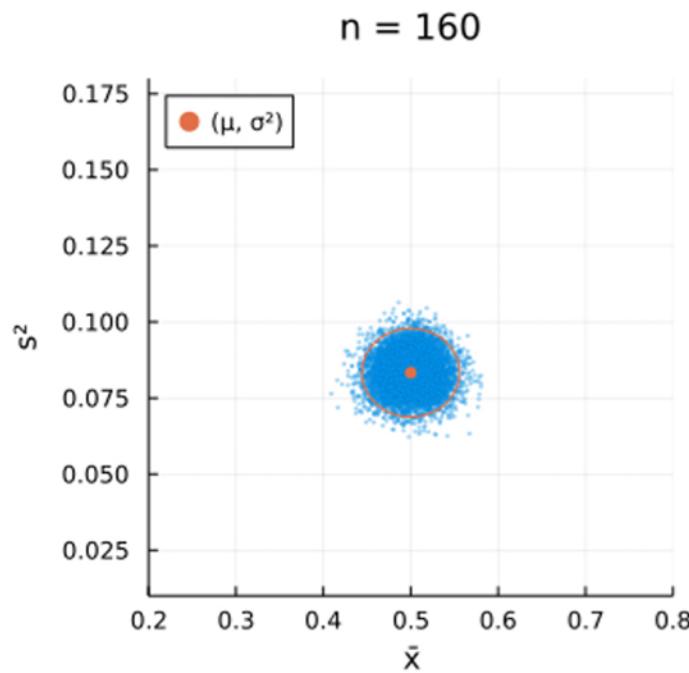
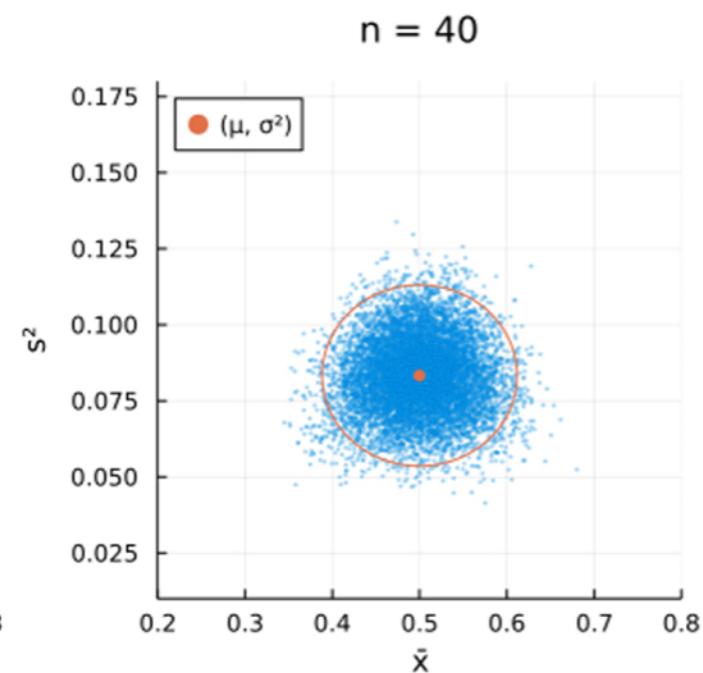
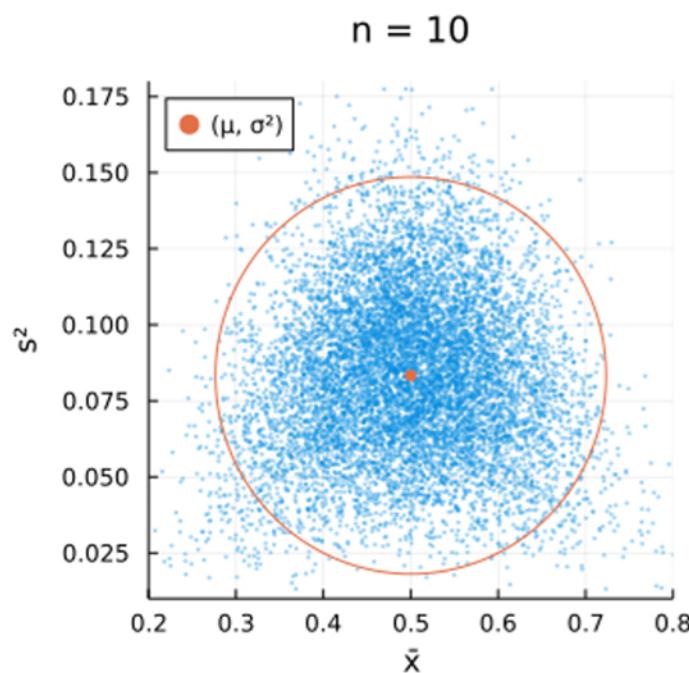
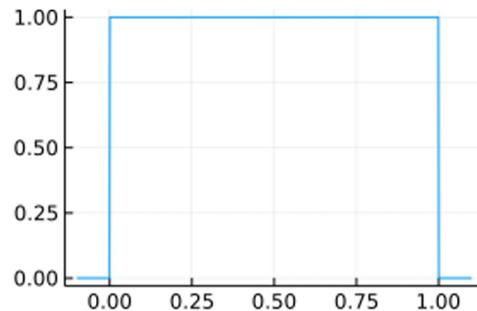


正規分布の場合、

```

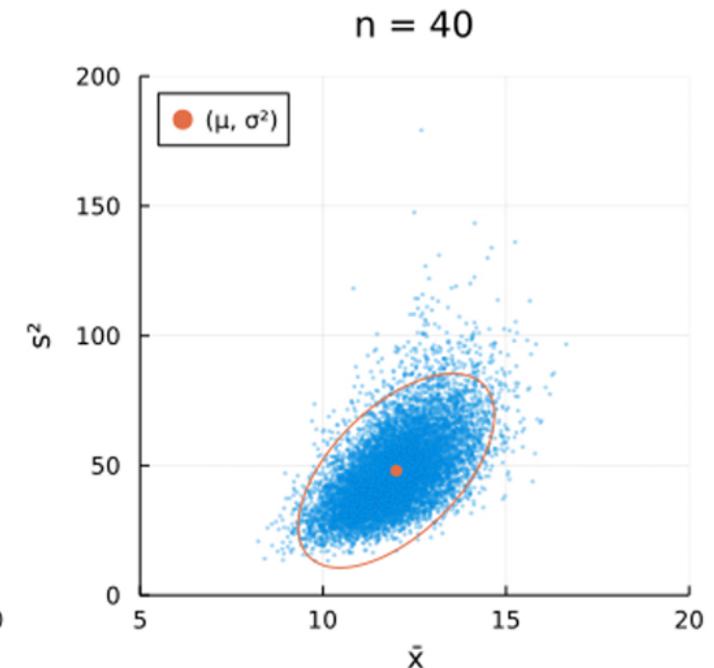
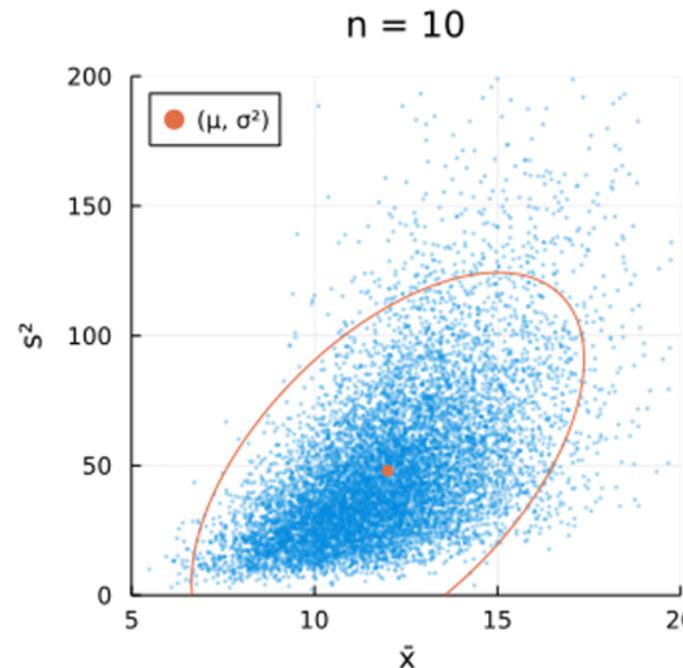
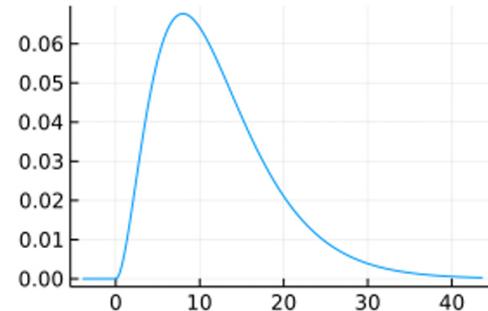
Uniform{Float64}(a=0.0, b=1.0)
μ = 0.5
σ² = 0.0833333333333333
skewness = 0.0
kurtosis = -1.2

```

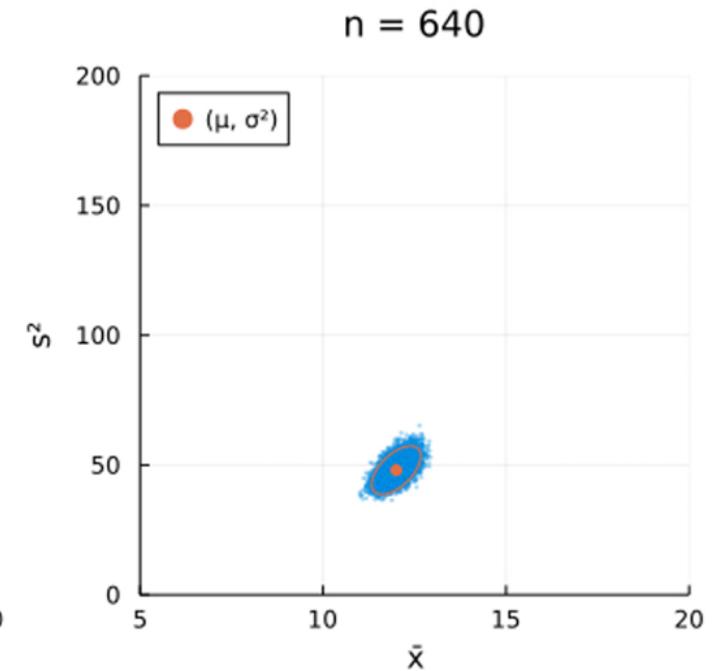
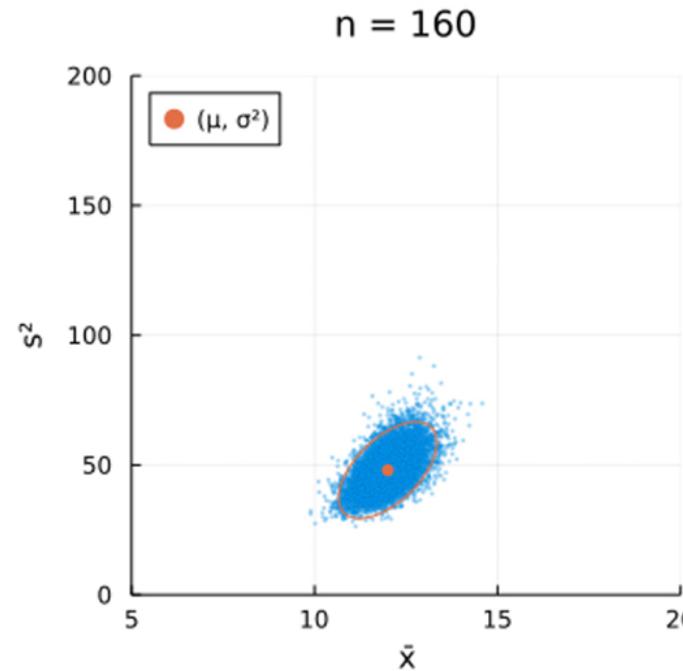


正規分布の場合に
非常に近い

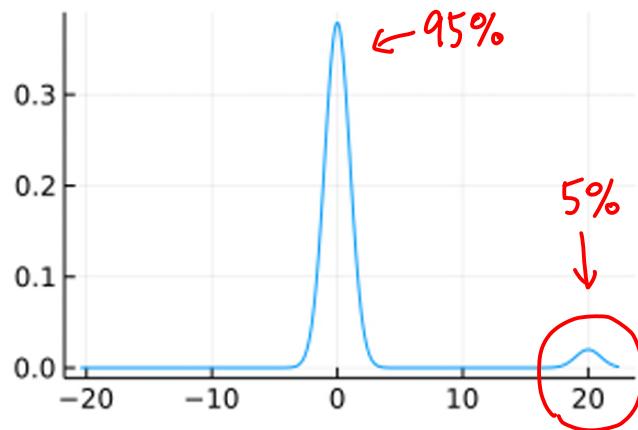
Gamma{Float64}($\alpha=3.0$, $\theta=4.0$)
 $\mu = 12.0$
 $\sigma^2 = 48.0$
skewness = 1.1547005383792517
kurtosis = 2.0



左右非対称な分布
の標本分布における
 (\bar{x}, s^2) の分布は
左右非対称になる。

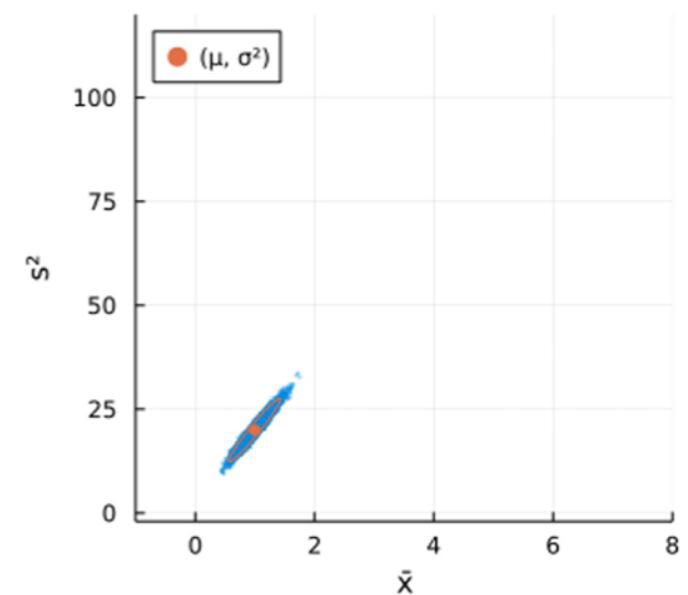
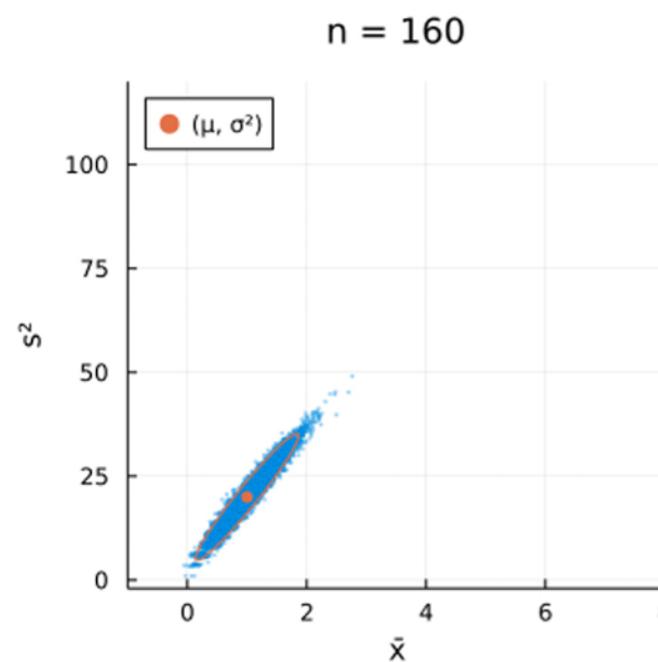
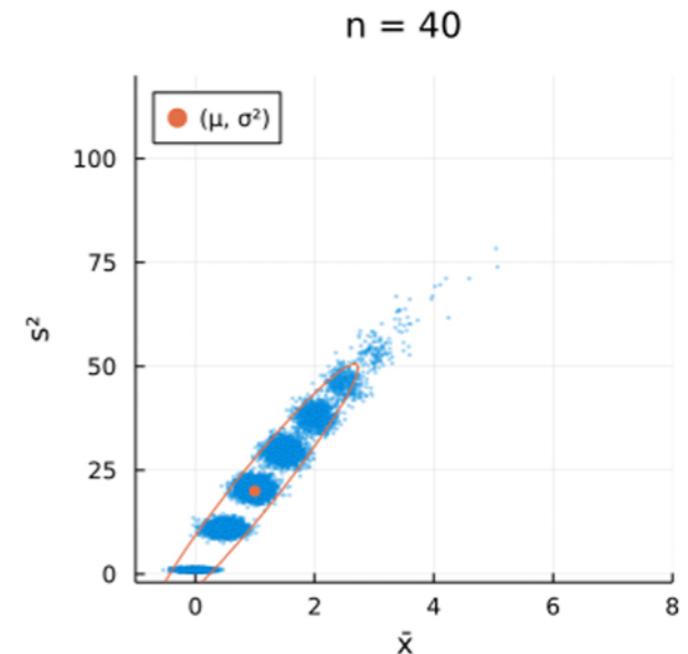
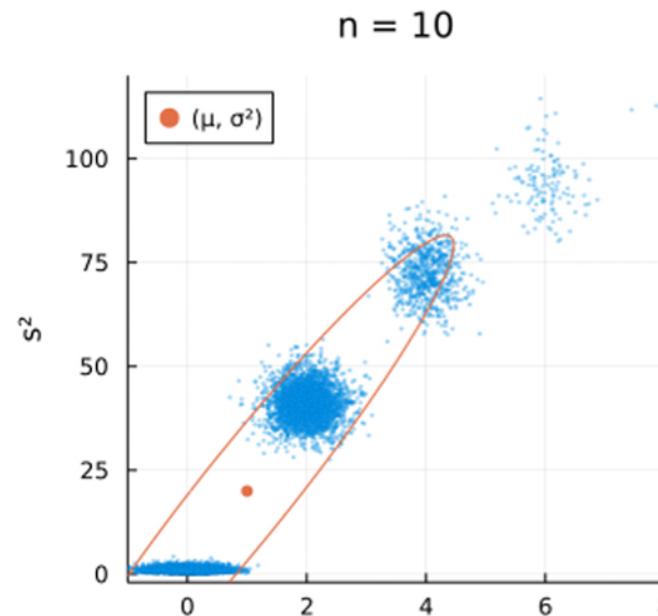


$\mu = 1.0$
 $\sigma^2 = 20.0$
skewness = 3.823676241524649
kurtosis = 13.58499999999097



95% の標準正規分布と
5% の別の正規分布を
混ぜた混合正規分布

この5%のせいで
非常に「面白いこと」
になってしまっている。



GitHubのちには他の例もあるので見てみてください。

正規分布の場合

(結果のみ, 証明は GitHub の資料にある.)

X_1, X_2, \dots, X_n が平均 μ , 分散 σ^2 の正規分布のサイズ n の標本分布にはしたがう確率変数達であるとき,

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad (\text{標本平均}), \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (\text{不偏分散})$$

は 独立 になり),

$$\bar{X} \sim \text{Normal}(\mu, \frac{\sigma}{\sqrt{n}}) = \mu + \sqrt{\frac{\sigma^2}{n}} \text{Normal}(0, 1)$$

$$S^2 \sim \text{Gamma}\left(\frac{n-1}{2}, \frac{2\sigma^2}{n-1}\right) = \frac{\sigma^2}{n-1} \text{Gamma}\left(\frac{n-1}{2}, 2\right) = \frac{\sigma^2 \text{Chisq}(n-1)}{n-1}$$

が成立する. ゆえに,

$$Z := \frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}}, \quad Y = \frac{(n-1)S^2}{\sigma^2}, \quad T = \frac{Z}{\sqrt{Y/(n-1)}} = \frac{Z}{\sqrt{S^2/n}}$$

とおくと, Z と Y は独立で, 次が成立する:

$$Z \sim \text{Normal}(0, 1), \quad Y \sim \text{Chisq}(n-1), \quad T \sim \text{TDist}(n-1)$$

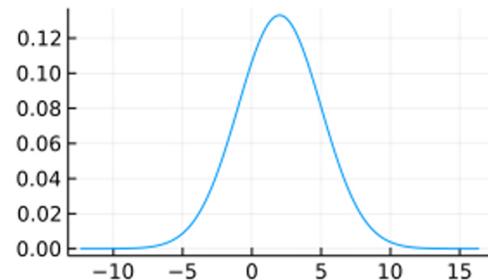
□

以上の結果には再度ふれることになると思われる.

前ページのように式だけで説明されてもイメージがわかない。
グラフを描いてみよう!) これ大事!

Normal{Float64}($\mu=2.0, \sigma=3.0$)

$\mu = 2.0$
 $\sigma^2 = 9.0$
skewness = 0.0
kurtosis = 0.0

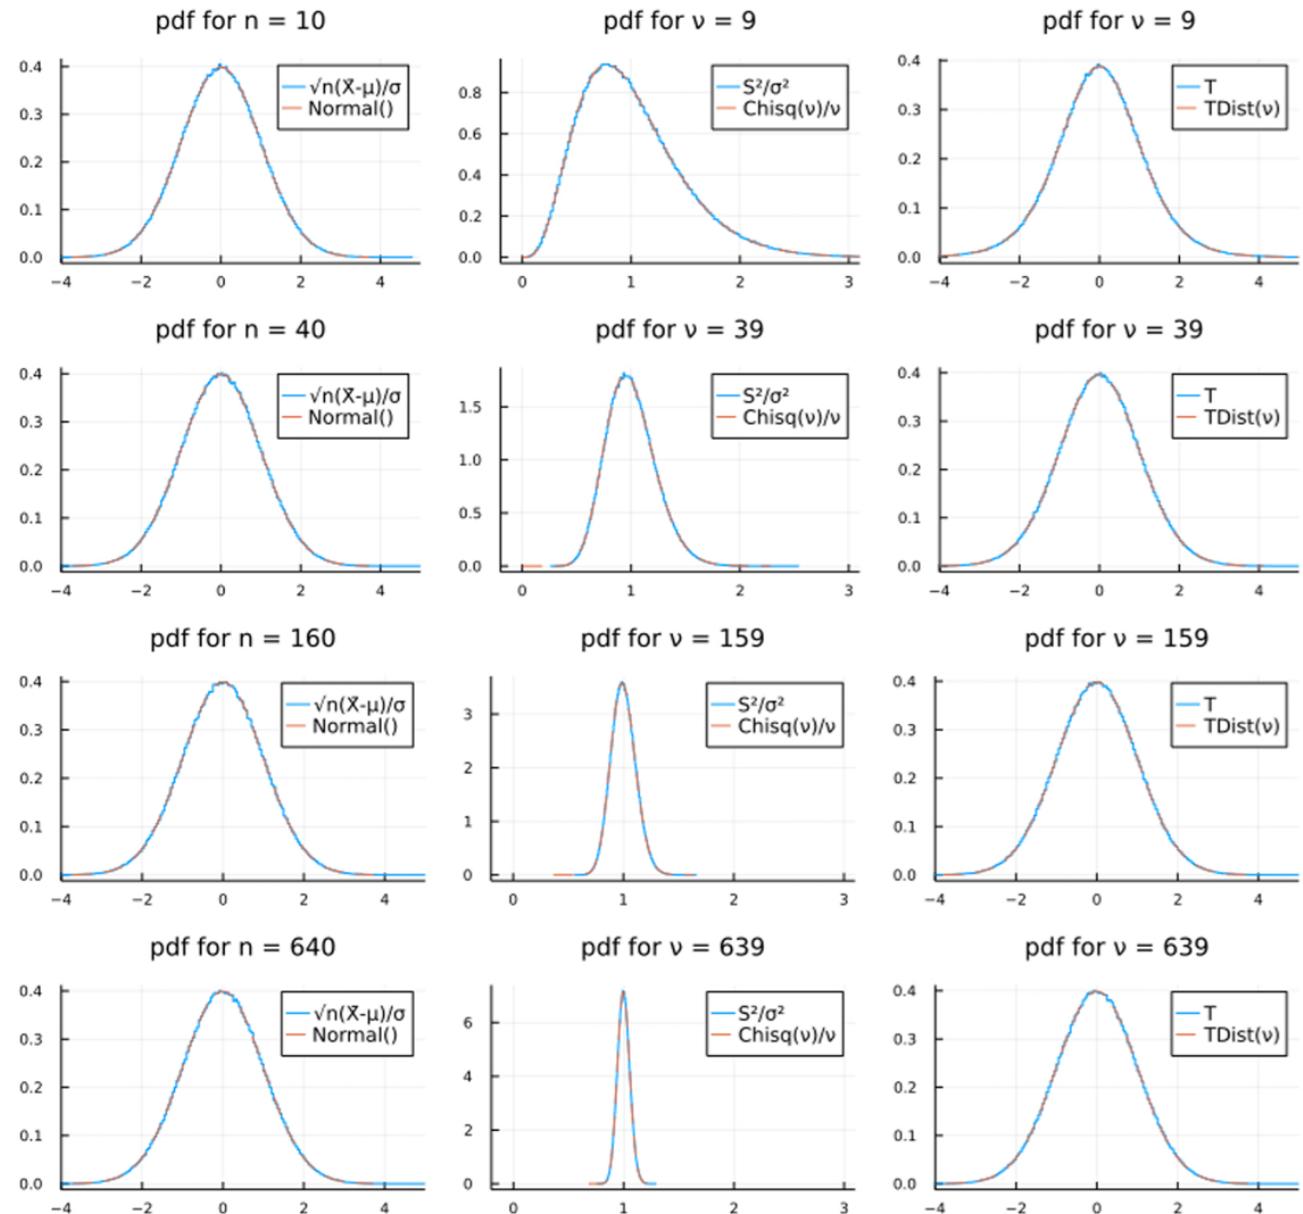


$Z = \frac{\sqrt{n}(\bar{X}-\mu)}{\sigma}$ の分布は
Normal(0,1) に一致,

$S^2/(n-1)$ の分布は
Chisq(n-1)/(n-1) に一致,

$T = \frac{Z}{\sqrt{S^2/n}}$ の分布は
TDist(n-1) に一致

一致しきてイメージがわきにくい,



正規分布以外の標本分布で Z , S^2/σ^2 , T の分布をプロットしてみよう、

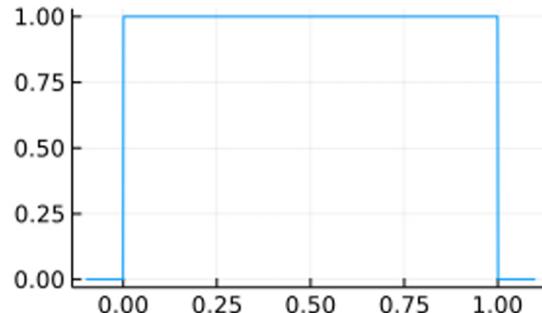
Uniform{Float64}(a=0.0, b=1.0)

$\mu = 0.5$

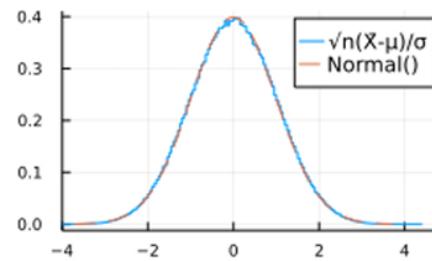
$\sigma^2 = 0.0833333333333333$

skewness = 0.0

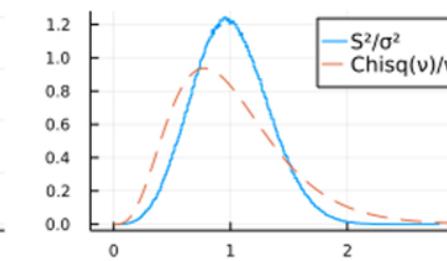
kurtosis = -1.2



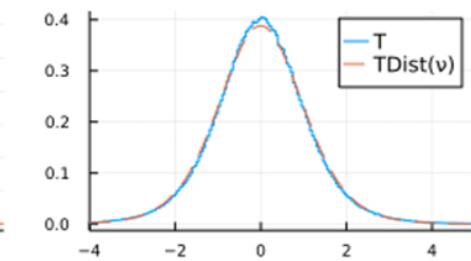
pdf for $n = 10$



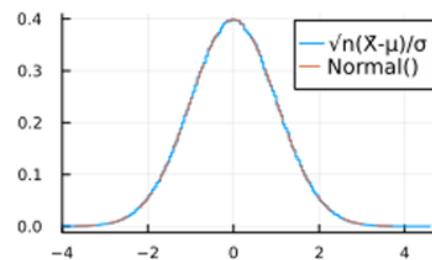
pdf for $v = 9$



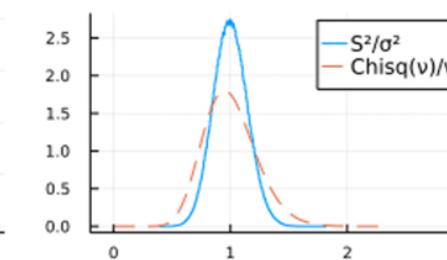
pdf for $v = 9$



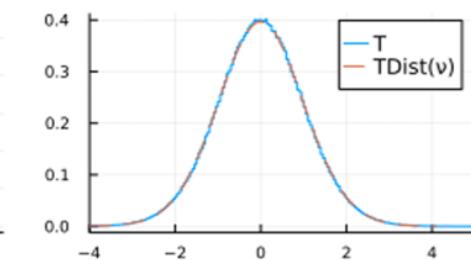
pdf for $n = 40$



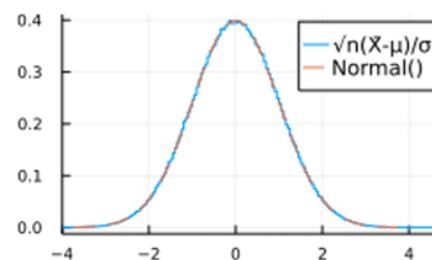
pdf for $v = 39$



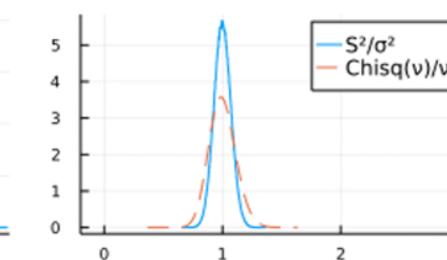
pdf for $v = 39$



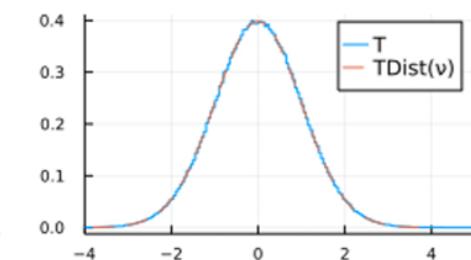
pdf for $n = 160$



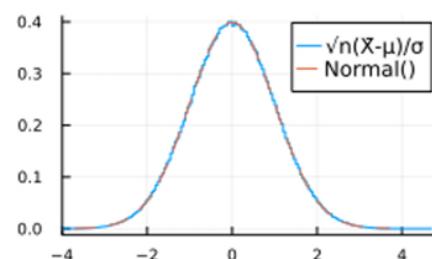
pdf for $v = 159$



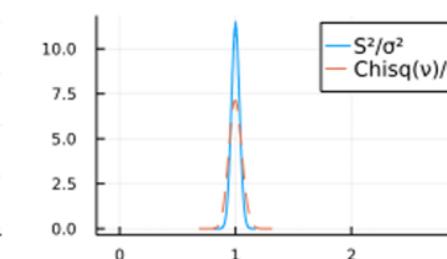
pdf for $v = 159$



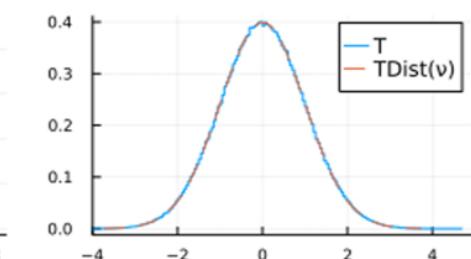
pdf for $n = 640$



pdf for $v = 639$



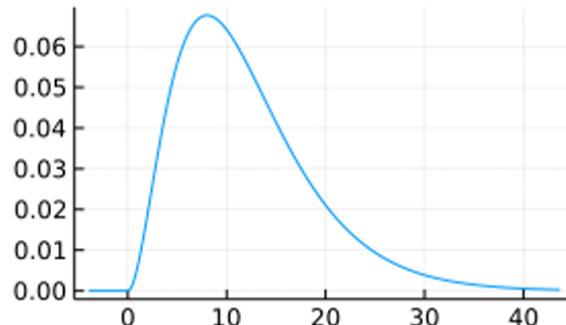
pdf for $v = 639$



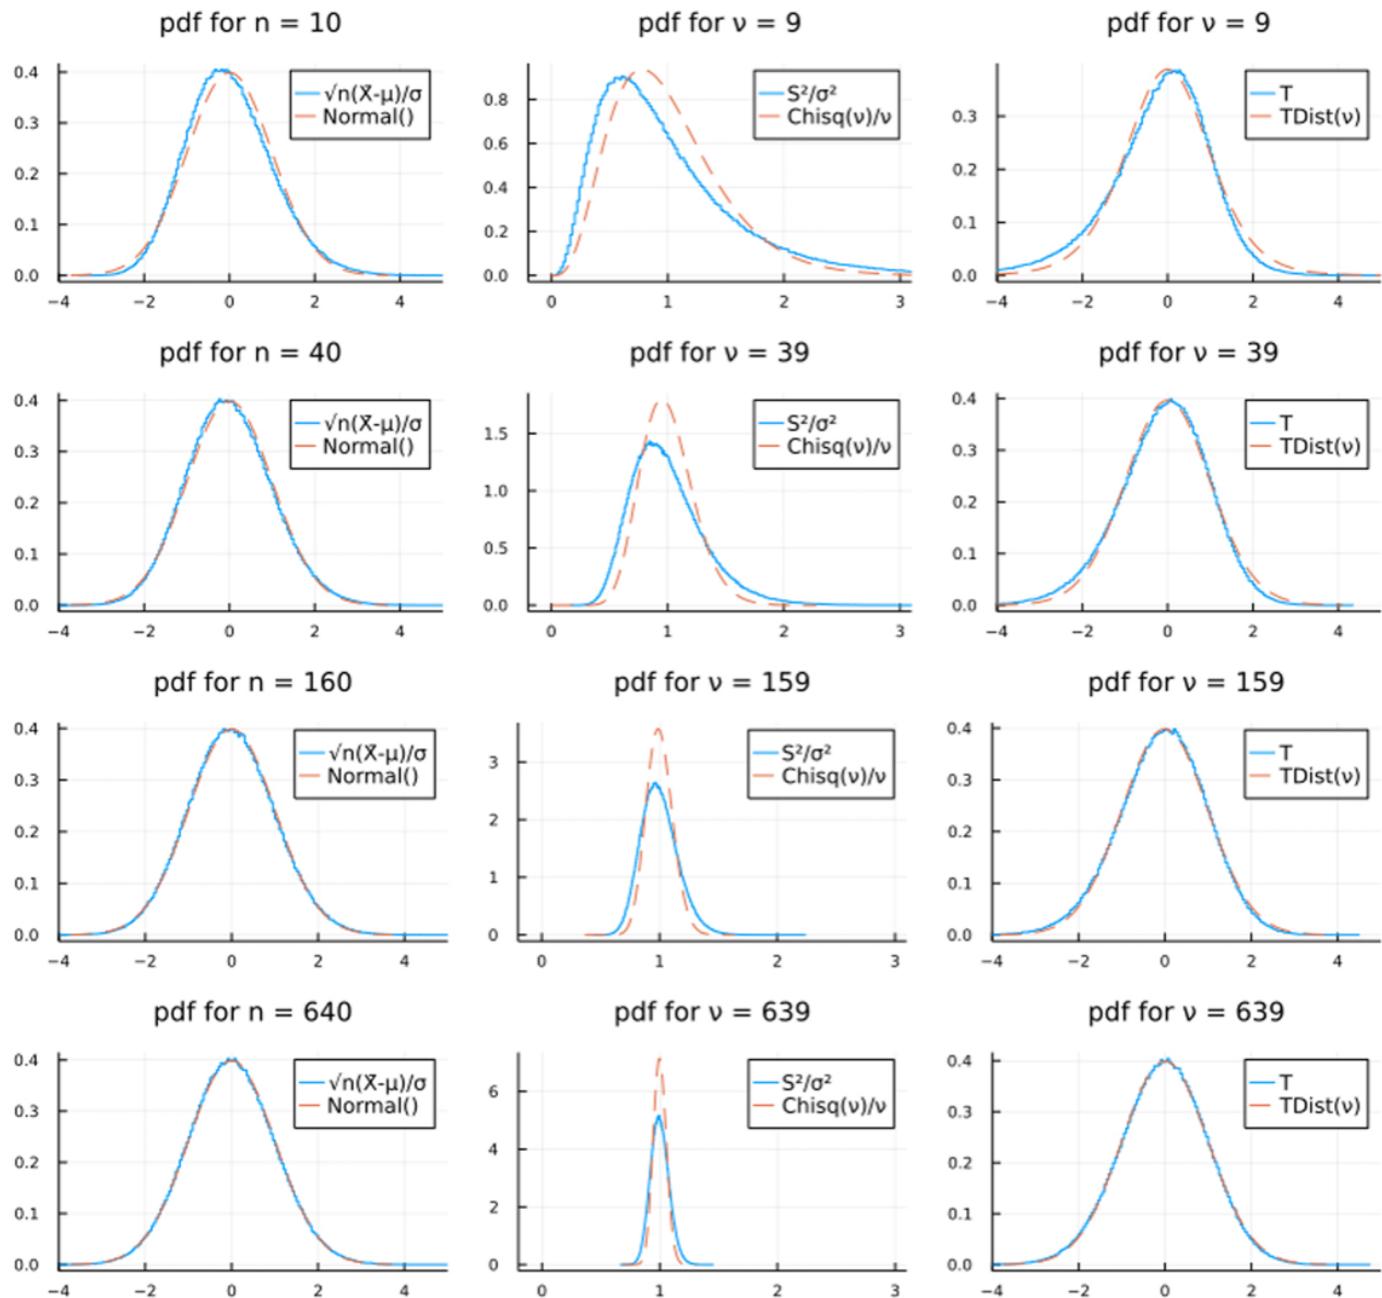
Z と T は正規分布の場合と同様に
Normal(0,1), TDist($n-1$)
とよく一致している。

S^2/σ^2 は一致していない。

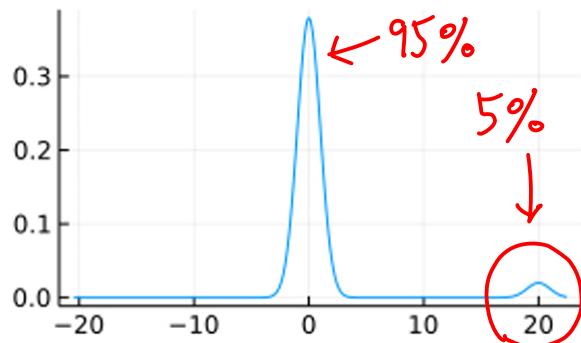
$\text{Gamma}\{\text{Float64}\}(\alpha=3.0, \theta=4.0)$
 $\mu = 12.0$
 $\sigma^2 = 48.0$
skewness = 1.1547005383792517
kurtosis = 2.0



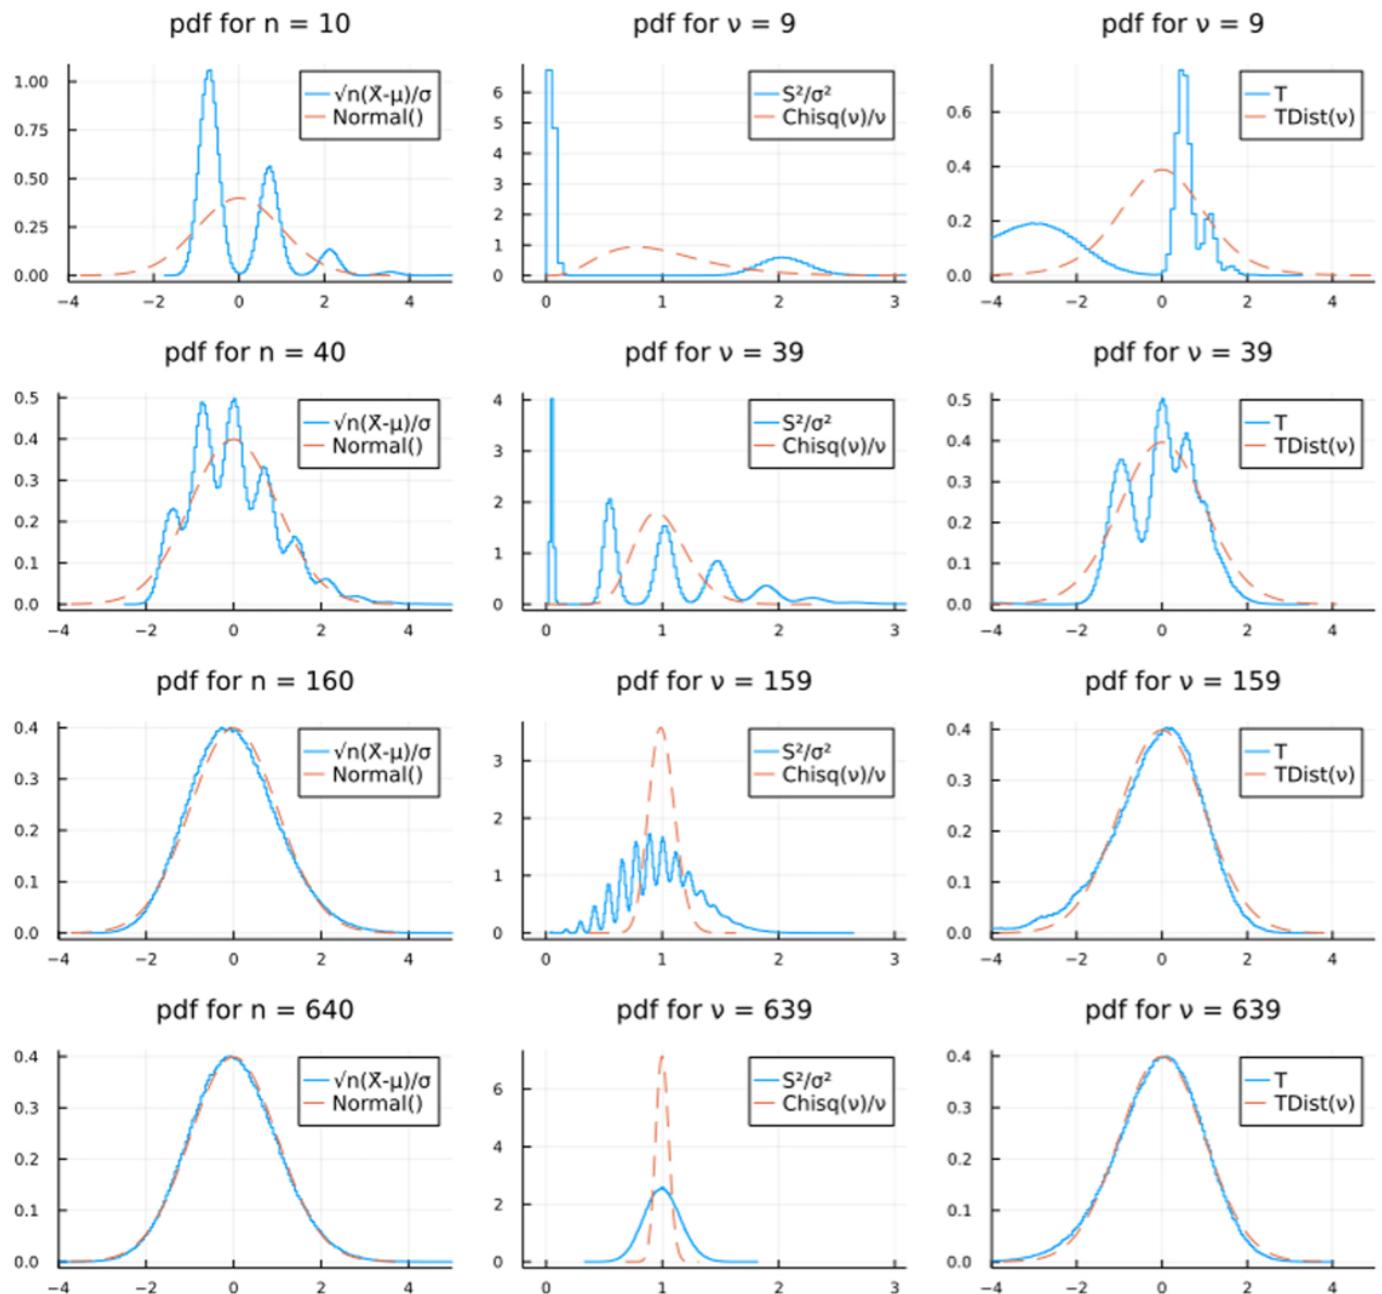
どのよきに一致しないか
に注目せよ、



$\mu = 1.0$
 $\sigma^2 = 20.0$
skewness = 3.823676241524649
kurtosis = 13.584999999999097



5%の小さな山のせいいで
「面白いこと」になっちゃう！



大数の法則と中心極限定理

$\frac{X_1 + \dots + X_n}{n}$ や $\frac{X_1 + \dots + X_n}{\sqrt{n}}$ や $X_1 + \dots + X_n$ がみたる法則

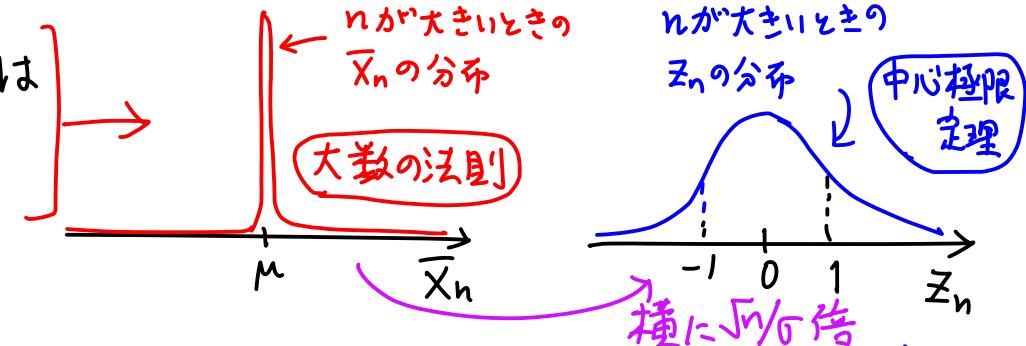
まとめ

X_1, X_2, X_3, \dots は独立同分布確率変数列であるとする。

大数の法則 各 X_i がしたがう分布の期待値がうまく定義されないと仮定する。

(すなわち, $E[|X_i|] < \infty$ が成立していると仮定する.) X_i たち共通の期待値を $\mu = E[X_i]$ と書く。

このとき, 確率変数 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ の分布は
 n を大きくすると μ に集中して行く。



中心極限定理 (正規分布による近似定理)

$E[|X_i|] < \infty$, $\mu = E[X_i]$, $\sigma^2 = E[(X_i - \mu)^2] < \infty$ であると仮定する。このとき, n を大きくすると,

(1) $Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{X_i - \mu}{\sigma}$ の分布は標準正規分布 $Normal(0,1)$ で近似される。

(2) $X_1 + \dots + X_n$ の分布は正規分布 $Normal(n\mu, \sqrt{n}\sigma)$ で近似される。

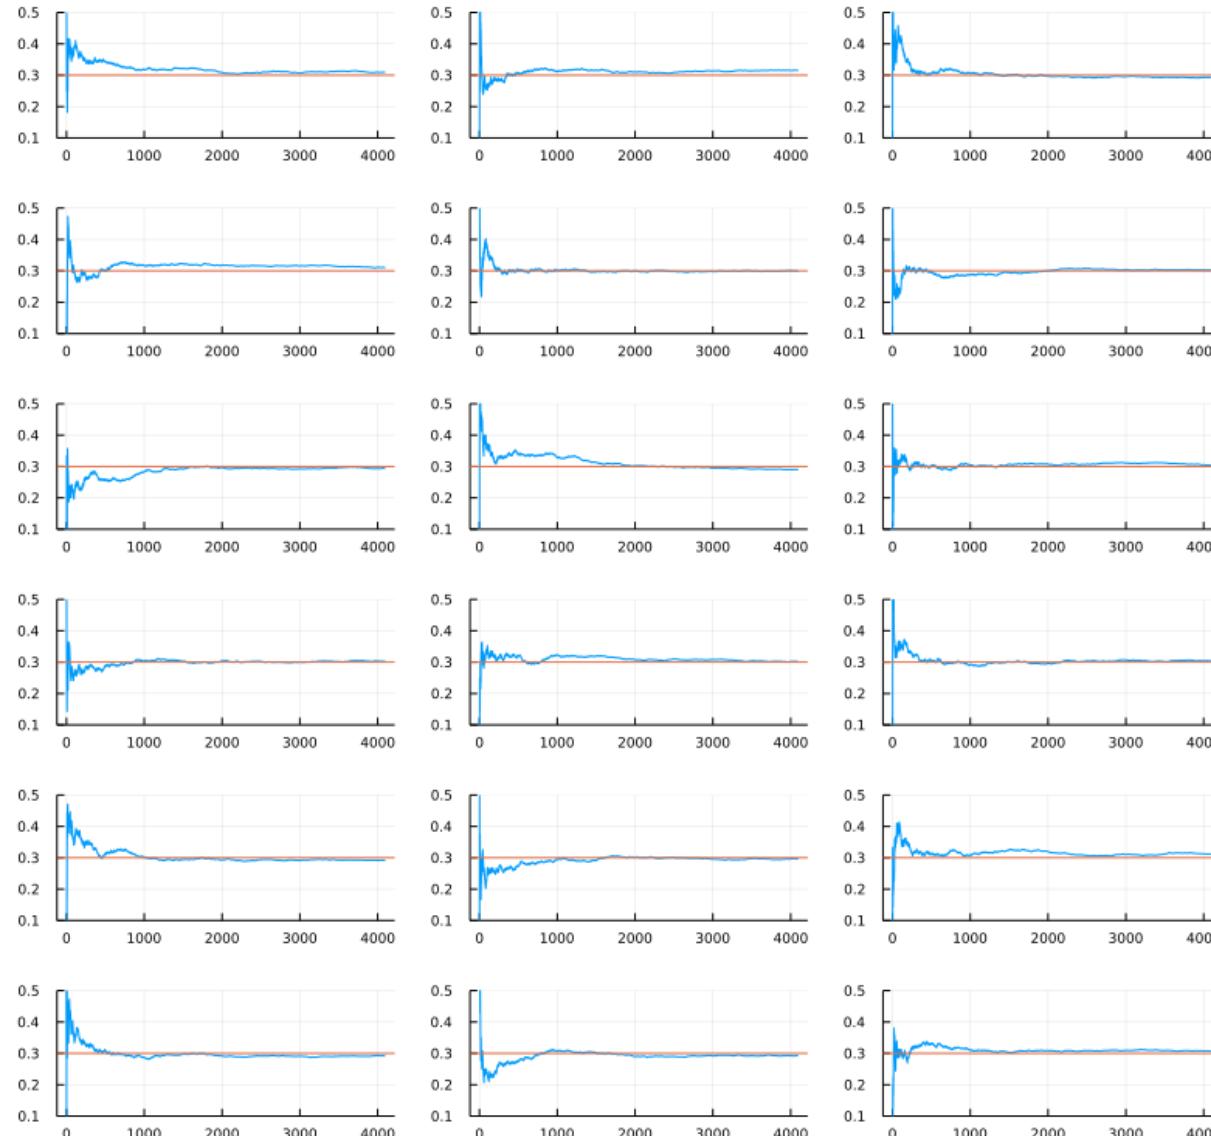
(3) $\bar{X}_n = \frac{X_1 + \dots + X_n}{n}$ の分布は正規分布 $Normal(\mu, \frac{\sigma}{\sqrt{n}})$ で近似される。

(4) $\sigma Z_n = \frac{(X_1 - \mu) + \dots + (X_n - \mu)}{\sqrt{n}}$ の分布は正規分布 $Normal(0, \sigma)$ で近似される。

(1) ~ (4) は同値。

大数の法則のデモンストレーション

Law of large numbers for Bernoulli(0.3)



Bernoulli試行の場合

確率 0.3 で 1 に
確率 0.7 で 0 になる
独立試行の結果

$$X_1, X_2, \dots, X_N \quad (N=2^{12})$$

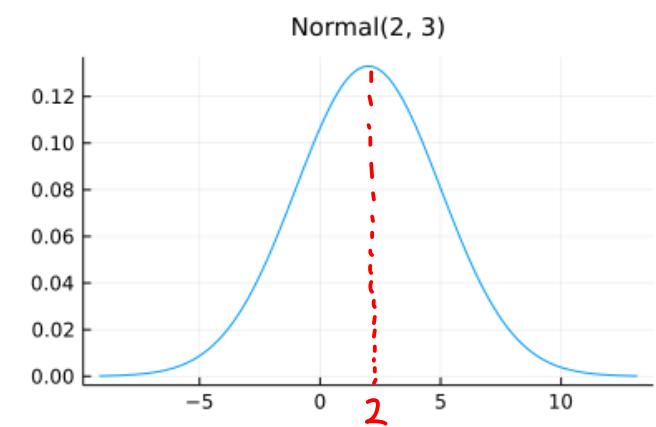
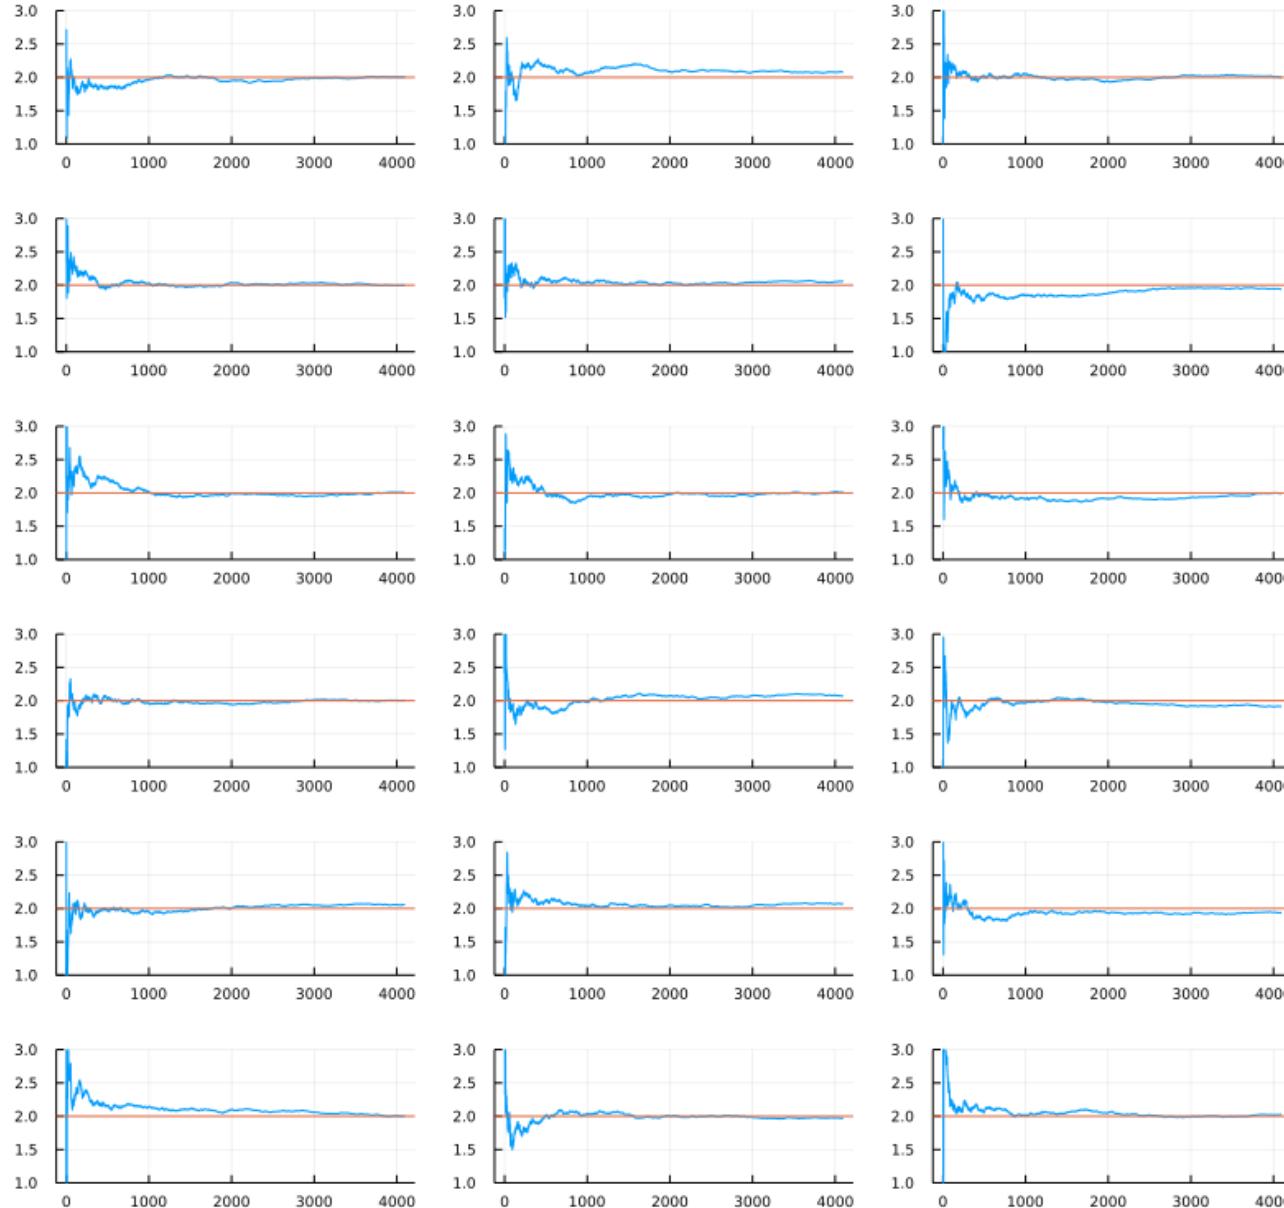
を 18 個ランダムに生成し、

$$\bar{X}_n = \frac{X_1 + \dots + X_n}{n}$$

のグラフを 18 個描いた。
ヨコ軸が n で、タテ軸が \bar{X}_n 、
 n を大きくすると、
 \bar{X}_n は 0.3 に近付く、

正規分布の大数の法則

Law of large numbers for Normal(2, 3)



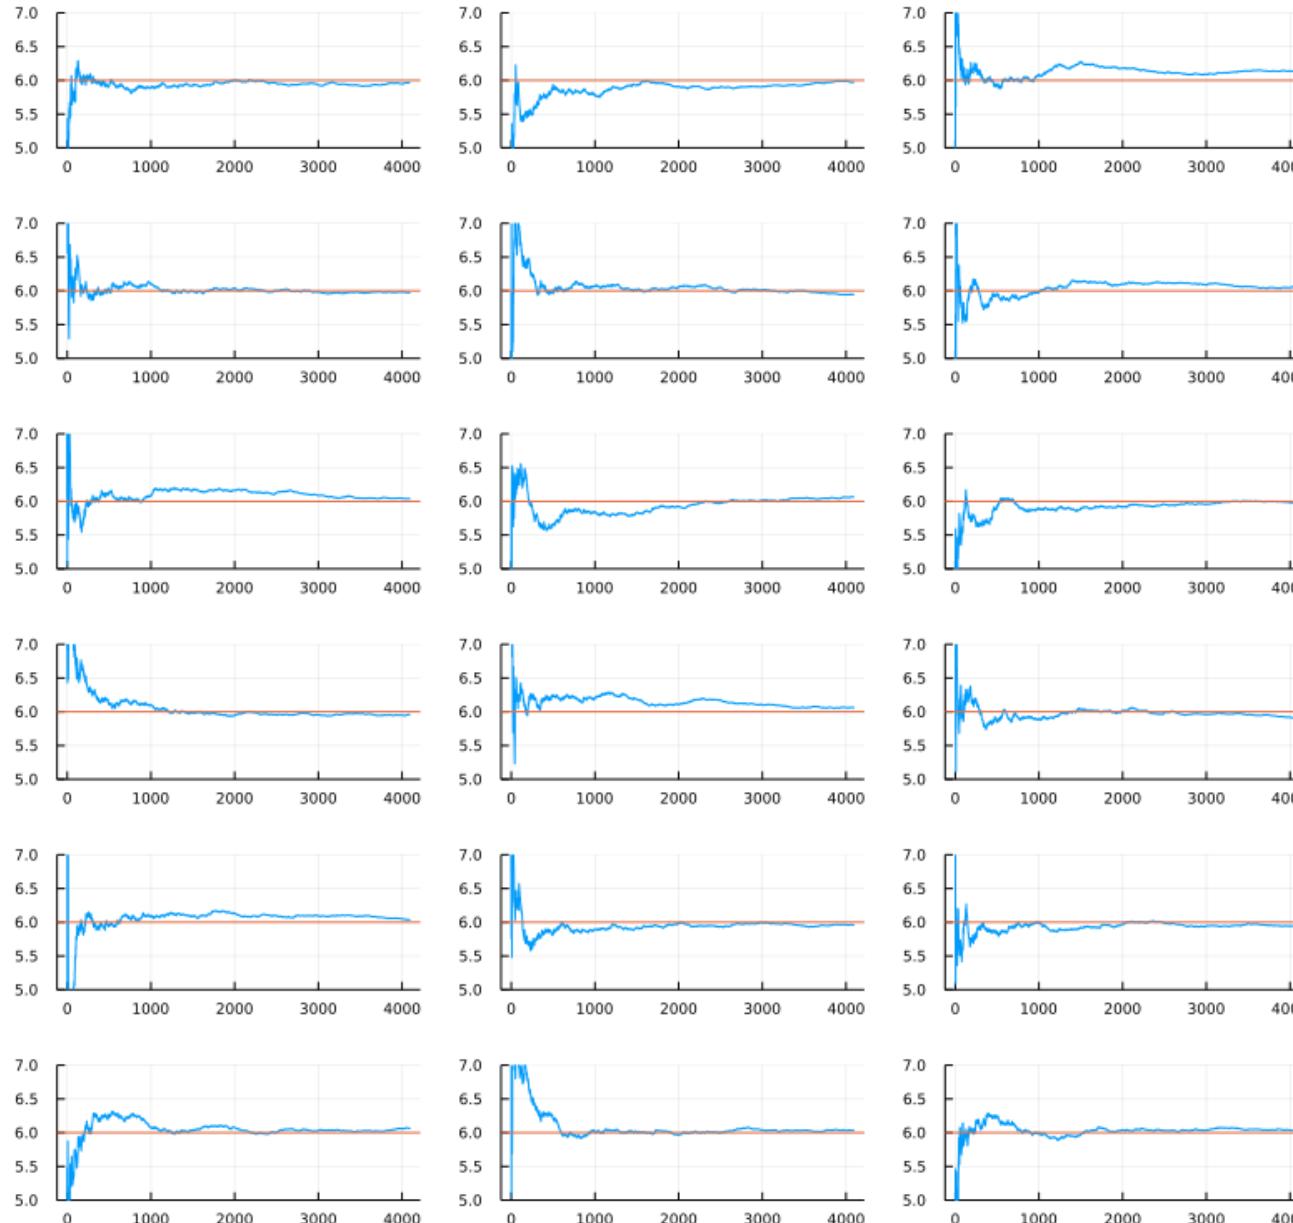
上の正規分布の乱数
 X_1, X_2, \dots, X_N
 を $N = 2^{12}$ 個生成することを
 18回行った、
 各々について、

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

 と $n = 1, 2, \dots, N$ について
 計算してプロット、
 \bar{X}_n は $n \rightarrow \infty$ で
 分布 $\text{Normal}(2, 3)$ の平均値
 の 2 に収束する、

ガンマ分布の大数の法則

Law of large numbers for Gamma(2, 3)



一般に $\text{Gamma}(\alpha, \theta)$ の
平均 μ と分散 σ^2 は
 $\mu = \alpha\theta$, $\sigma^2 = \alpha\theta^2$.

ガソマ分布の乱数列

X_1, X_2, \dots, X_N ($N=2^{12}$)

を18回生成して,
その各々について,

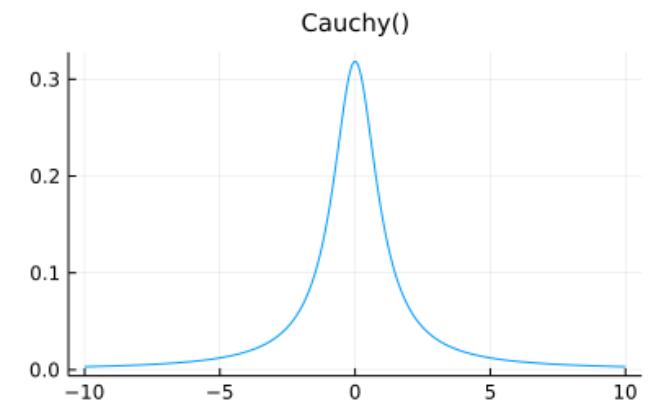
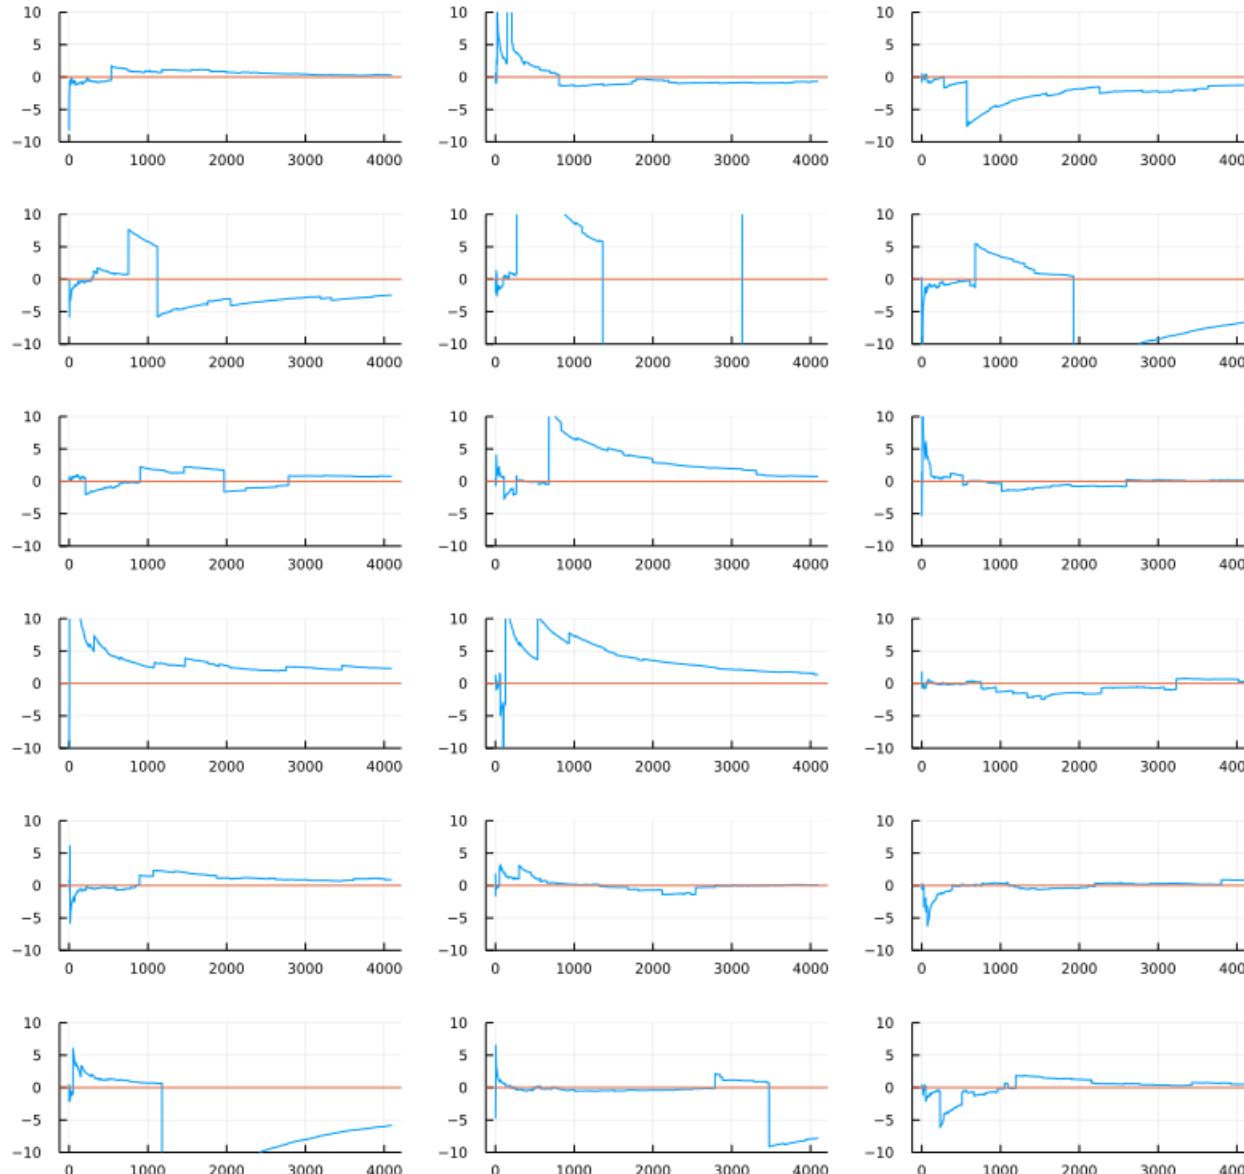
$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

を計算してプロット,

\bar{X}_n は 6 に収束する.

大数の法則が成立しない場合の例 (Cauchy分布)

Law of large numbers for Cauchy() does not hold



$$p(x) = \frac{1}{\pi} \frac{1}{1+x^2}$$

$X \sim \text{Cauchy}()$ のとき、

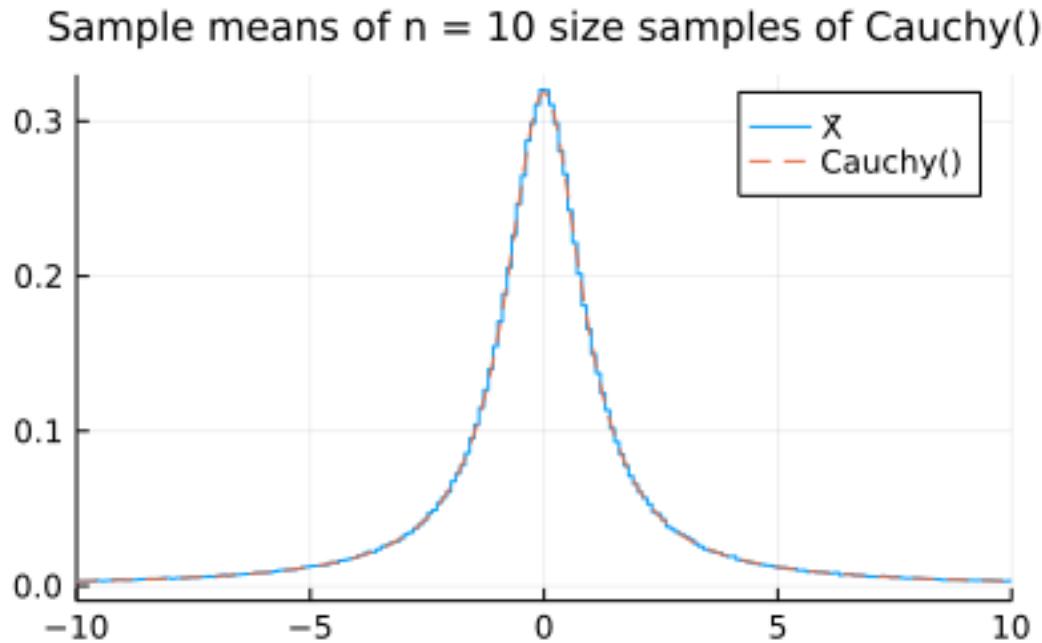
$$E[|X|] = \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{|x|}{1+x^2} dx = \infty$$

X の期待値 $E[X]$ は
うまく定義されない、

Cauchy分布にしたがう乱数
では極端に絶対値が大き
な値が出来やすいので、
大数の法則は成立しない、

$n \rightarrow$ 大で 0 に近付く
ように見える場合もあるが
たまに出る極端な値が
それを大なしにする、

Cauchy分布の再成性



青の線は $n=10$ 場合の \bar{X}_n の分布
---の線は Cauchy 分布

X_1, X_2, \dots, X_n は
それぞれが Cauchy 分布

$$p(x) = \frac{1}{\pi} \frac{1}{1+x^2}$$

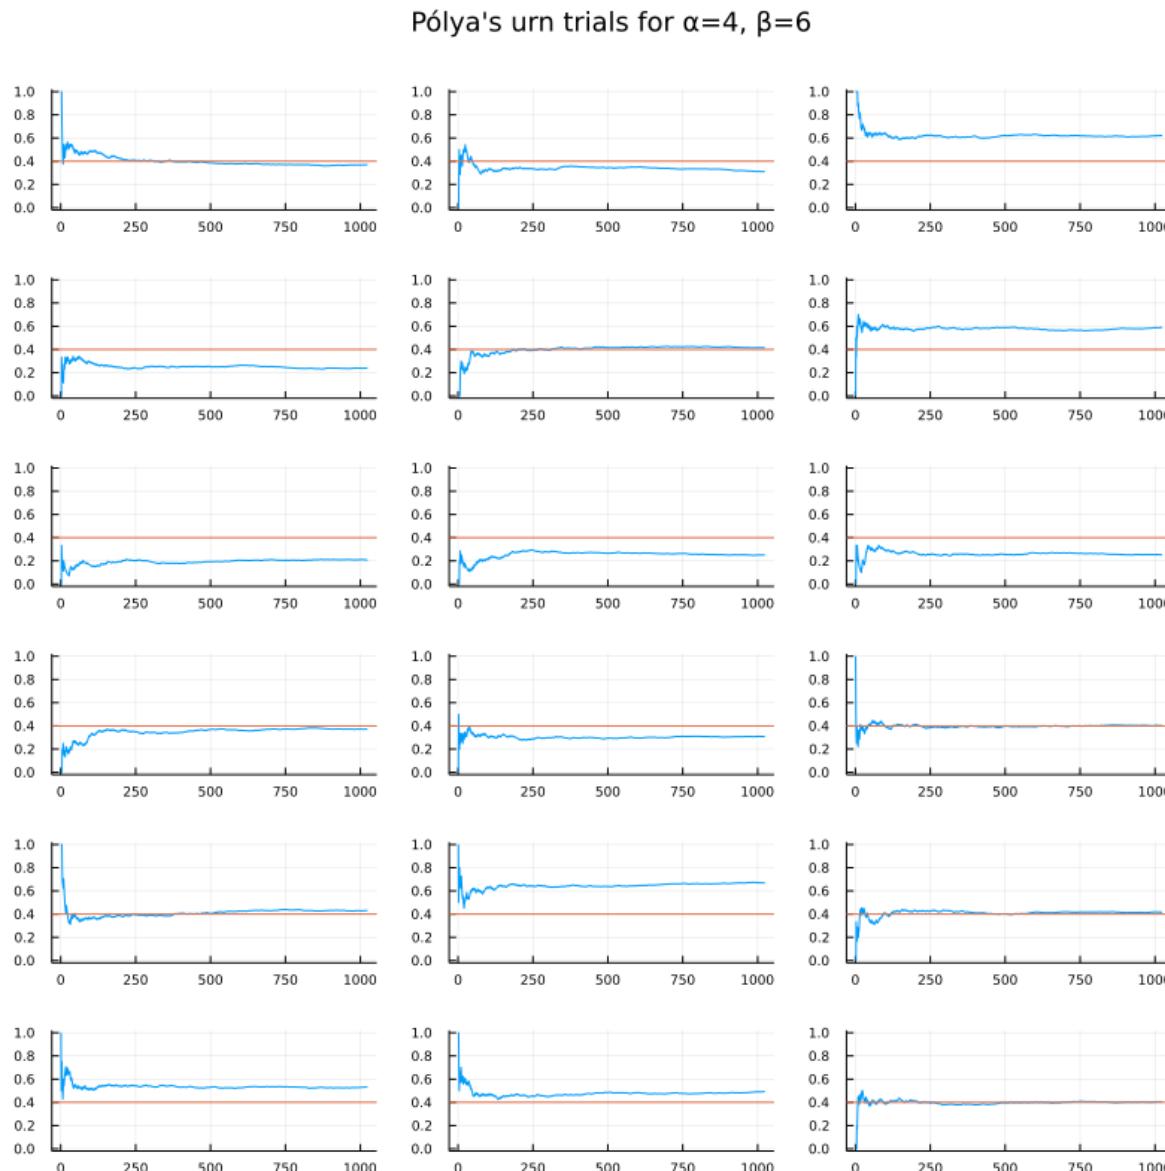
にしたがう独立同分布な
確率変数(乱数)たちであるとする
このとき、

$$\bar{X}_n = \frac{X_1 + X_2 + \dots + X_n}{n}$$

も同じ Cauchy 分布にしたがう。

独立性が成立していないせいで大数の法則が成立しない例 Pólyaのつぼ

つぼの中には最初赤い玉が α 個、白い玉が β 個入っている。



つぼからランダムに玉をとりだし、赤なら赤い玉をつぼに2個もどし、白なら白い玉をつぼに2個もどす、つぼの中の玉の個数は毎回1個ずつ増え行く。

$$\begin{cases} \text{赤} \Rightarrow X_i = 1 \\ \text{白} \Rightarrow X_i = 0 \end{cases}$$

$$\leftarrow \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \text{ のグラフ}$$

\bar{X}_n は毎回ちがう値に収束する。

Polyaのつぼの試行の確率分布の記述

例 $\left(\begin{smallmatrix} \text{赤} & \text{白} & \text{赤} & \text{白} \\ 1 & 0 & 0 & 1 & 0 \end{smallmatrix} \right) = \frac{\alpha}{\alpha+\beta} \cdot \frac{\beta}{\alpha+\beta+1} \cdot \frac{\beta+1}{\alpha+\beta+2} \cdot \frac{\alpha+1}{\alpha+\beta+3} \cdot \frac{\beta+2}{\alpha+\beta+4}.$

一般に (x_1, x_2, \dots, x_n) の中の k 個が赤 = 1 のとき,

$$\left((x_1, x_2, \dots, x_n) \text{ の順で出る確率} \right) = \frac{\alpha(\alpha+1) \cdots (\alpha+k-1) \cdot \beta(\beta+1) \cdots (\beta+n-k-1)}{(\alpha+\beta)(\alpha+\beta+1) \cdots (\alpha+\beta+n-1)}$$

別の表示 (GitHub にある「確率分布の解釈」のノートを参照せよ.)

$$\begin{aligned} \Gamma(\alpha+k) &= (\alpha+k-1) \Gamma(\alpha+k-1) = (\alpha+k-1)(\alpha+k-2) \Gamma(\alpha+k-2) \\ &= \cdots = (\alpha+k-1) \cdots (\alpha+1) \alpha \Gamma(\alpha) \end{aligned} \quad ; \quad \frac{\Gamma(\alpha+k)}{\Gamma(\alpha)} = \alpha(\alpha+1) \cdots (\alpha+k-1)$$

$$\left((x_1, x_2, \dots, x_n) \text{ の順で出る確率} \right) = \frac{\Gamma(\alpha+k)}{\Gamma(\alpha)} \frac{\Gamma(\beta+n-k)}{\Gamma(\beta)} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha+\beta+n)} = \frac{B(\alpha+k, \beta+n-k)}{B(\alpha, \beta)}$$

$$= \int_0^1 p^k (1-p)^{n-k} \frac{p^{\alpha-1} (1-p)^{\beta-1}}{B(\alpha, \beta)} dp = \int_0^1 \underbrace{\prod_{i=1}^n (p^{x_i} (1-p)^{1-x_i})}_{\text{Bernoulli 試行}} \underbrace{\frac{p^{\alpha-1} (1-p)^{\beta-1}}{B(\alpha, \beta)}}_{\text{ベータ分布}} dp$$

大数の法則の証明

(大数の弱法則のみを示す。)

X_1, X_2, \dots は独立同分布確率変数列であると仮定する。

$E[|X_i|] < \infty$, $\mu = E[X_i]$, $\sigma^2 = E[(X_i - \mu)^2] < \infty$ の場合の大数の弱法則のみを示す。

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \text{ とおく。このとき,}$$

$$E[\bar{X}_n] = \mu, \quad \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}.$$

$n \rightarrow \infty$ で

0 に収束する。

これを後で使う。

証明

$E[\cdot]$ の線形性と規格化条件より,

$$E[\bar{X}_n] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{1}{n} \sum_{i=1}^n \mu = \mu.$$

$$\bar{X}_n - \mu = \frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n \mu = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)$$

$$(\bar{X}_n - \mu)^2 = \frac{1}{n^2} \sum_{i,j=1}^n (X_i - \mu)(X_j - \mu) = \frac{1}{n^2} \sum_{i=1}^n (X_i - \mu)^2 + \frac{1}{n^2} \sum_{i \neq j} (X_i - \mu)(X_j - \mu)$$

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum_{i=1}^n \underbrace{E[(X_i - \mu)^2]}_{= \sigma^2} + \frac{1}{n^2} \sum_{i \neq j} \underbrace{E[(X_i - \mu)(X_j - \mu)]}_{= E[X_i - \mu] E[X_j - \mu]}$$

$$= \frac{\sigma^2}{n}$$

$$= E[X_i - \mu] E[X_j - \mu] \\ = 0 \times 0$$

q.e.d.

Chebychev の不等式

平均 μ , 分散 σ^2 を持つ確率変数 X と $\varepsilon > 0$ について,

$$P(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}. \quad \leftarrow X \text{ が } \mu \text{ から離れる確率は } \sigma^2 \text{ を使って上からあさえられる}.$$

証明

$|X - \mu| \geq \varepsilon$ という条件は $1 \leq \frac{(X - \mu)^2}{\varepsilon^2}$ と同値である。ゆえに,

$$P(|X - \mu| \geq \varepsilon) = P\left(1 \leq \frac{(X - \mu)^2}{\varepsilon^2}\right)$$

$$= E\left[1 \leq \frac{(X - \mu)^2}{\varepsilon^2} \text{ のとき } 1, \text{ それ以外のとき } 0\right]$$

確率は期待値で表わされる。

$E[\cdot]$ の
単調性

$$\leq E\left[\frac{(X - \mu)^2}{\varepsilon^2}\right] \leq \frac{(X - \mu)^2}{\varepsilon^2}$$

期待値の方が計算しやすい。

$E[\cdot]$ の
線形性

$$= E[(X - \mu)^2]$$

(確率変数 X とは
 $f(x)$ の期待値 $E[f(X)]$ が
定義されているものである。)

$$= \frac{\sigma^2}{\varepsilon^2},$$

q.e.d.

大数の弱法則

X_1, X_2, \dots は独立同分布確率変数列であるとし,

$$E[|X_i|] < \infty, \mu = E[X_i], \sigma^2 = E[(X_i - \mu)^2] < \infty, \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

と仮定する. このとき, 任意の $\varepsilon > 0$ に対して,

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2} \frac{1}{n} \rightarrow 0 \quad (\text{as } n \rightarrow \infty).$$

↙ $n \rightarrow \infty$ で
 ↙ \bar{X}_n の分布が
 ↙ μ に集中する
 という意味

すなわち,

$$1 \geq P(|\bar{X}_n - \mu| < \varepsilon) = 1 - P(|\bar{X}_n - \mu| \geq \varepsilon) \geq 1 - \frac{\sigma^2}{\varepsilon^2} \frac{1}{n} \rightarrow 1 \quad (\text{as } n \rightarrow \infty),$$

証明

$E[\bar{X}_n] = \mu, \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}$ と Chebyshov の不等式より,

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{\varepsilon^2} \frac{1}{n} \rightarrow 0 \quad (\text{as } n \rightarrow \infty).$$

q.e.d.

証明は一瞬で完了する!

注意

大数の強法則 $P(\lim_{n \rightarrow \infty} \bar{X}_n = \mu) = 1$ を示すには $\sum_{n=1}^{\infty} P(|\bar{X}_n - \mu| \geq \varepsilon) < \infty$

を示せれば“十分だ”が, $\sum_{n=1}^{\infty} \frac{1}{n} = \infty$ なので 弱法則から 強法則は出で来ない. □

自習問題

問題: 大数の法則に関する誤解

当たりとはずれが毎回独立にどちらも 50% の確率で出るルーレットを回し続ける状況を考える。当たりが出たら、胴元から1万円もらい、はずれが出たら1万円支払うというルールになっているとする。この賭け事に参加しているある人がこう言った:

はずれの方が沢山出続けてたくさん負けてしまった! でも、確率論の大数の法則によって、これからは当たりの方が出易くなって、負けは帳消しになるだろう。

この発言が間違っていることについて説明せよ。

不偏分散の分布も $n \rightarrow \infty$ で σ^2 に集中する. (おまけ)

不偏分散の $n \rightarrow \infty$ での挙動

X_1, X_2, X_3, \dots は独立同分布確率変数の列であるとし、その最初の n 個の標本平均と不偏分散をそれぞれ次のように書くことにする：

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, \quad S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

以下では $\mu = E[X_i]$ がうまく定義されており、 $\sigma^2 = E[(X_i - \mu)^2] < \infty$, $E[|X_i - \mu|^3] < \infty$, $E[(X_i - \mu)^4] < \infty$ となっていると仮定する。

「標本分布について」のノートで以下を示していたのであった。 X_i 達が共通に従う分布の歪度(わいど, skewness)と尖度(せんど, kurtosis)をそれぞれ

$$\bar{\kappa}_3 = E \left[\left(\frac{X_i - \mu}{\sigma} \right)^3 \right], \quad \bar{\kappa}_4 = E \left[\left(\frac{X_i - \mu}{\sigma} \right)^4 \right] - 3$$

と書くと、

$$E[\bar{X}_n] = \mu, \quad E[S_n^2] = \sigma^2, \\ \text{var}(\bar{X}_n) = \frac{\sigma^2}{n}, \quad \text{cov}(\bar{X}_n, S_n^2) = \sigma^3 \frac{\bar{\kappa}_3}{n}, \quad \text{var}(S_n^2) = \sigma^4 \left(\frac{\bar{\kappa}_4}{n} + \frac{2}{n-1} \right).$$

ゆえに、Chebyshevの不等式を X, μ, σ^2 がそれぞれ S_n^2 , $E[S_n^2] = \sigma^2$, $\text{var}(S_n^2) = \sigma^4(\bar{\kappa}_4/n + 2/(n-1))$ の場合に適用すると、任意の $\varepsilon > 0$ について、

尖度(せんど)

$$P(|S_n^2 - \sigma^2| \geq \varepsilon) \leq \frac{\sigma^4}{\varepsilon^2} \left(\frac{\bar{\kappa}_4}{n} + \frac{2}{n-1} \right) \rightarrow 0 \quad \text{as } n \rightarrow \infty.$$

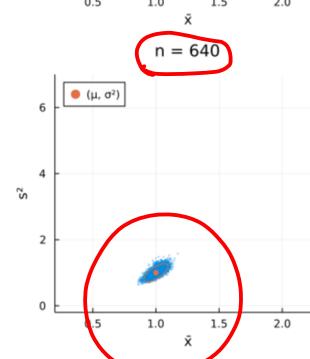
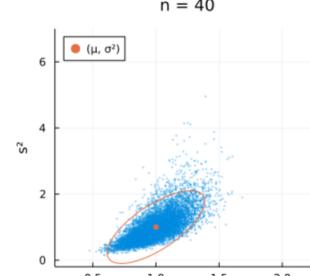
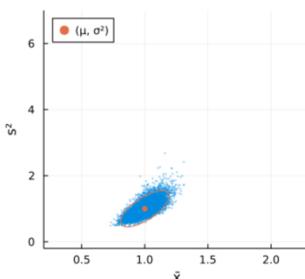
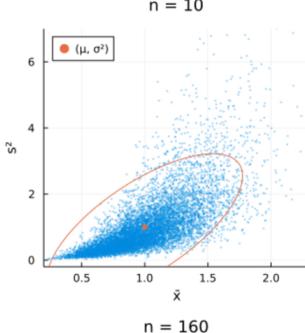
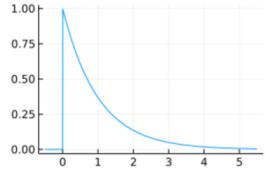
このように、不偏分散 S_n^2 についても大数の弱法則が成立しており、 S_n^2 の分布は $n \rightarrow \infty$ で σ^2 の近くに集中して行く。

以下は前回の資料より

$$(\bar{X}_n, S_n^2) = \left(\frac{1}{n} \sum_{i=1}^n X_i, \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \right)$$
 の分布

指數分布の標本分布における \bar{X}, S^2 の同時分布

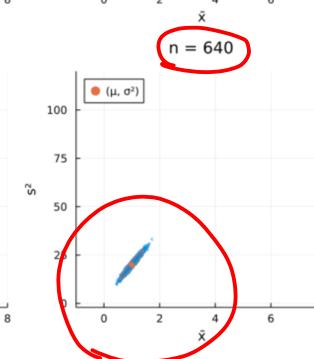
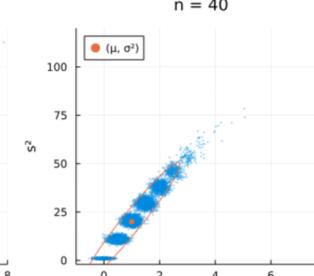
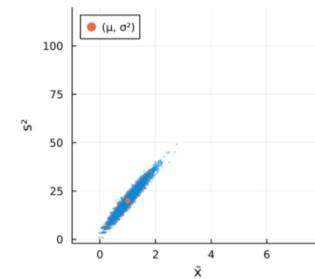
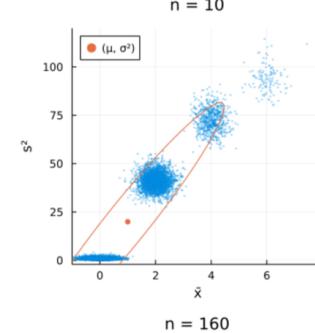
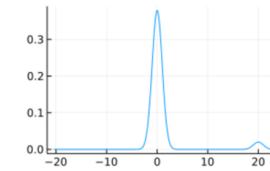
```
plot_x_and_Sx2_2x2(Exponential(); xlim=(0.2, 2.3), ylim=(-0.2, 7))
Exponential{Float64}(θ=1.0)
μ = 1.0
σ² = 1.0
skewness = 2.0
kurtosis = 6.0
```



非対称な2つ山の混合正規分布の標本分布における \bar{X}, S^2 の同時分布

```
plot_x_and_Sx2_2x2(MixtureModel([Normal(), Normal(20)], [0.95, 0.05]);
                      xlim=(-1, 8), ylim=(-2, 120))
MixtureModel{Normal{Float64}}(K = 2)
components[1] (prior = 0.9500): Normal{Float64}(μ=0.0, σ=1.0)
components[2] (prior = 0.0500): Normal{Float64}(μ=20.0, σ=1.0)

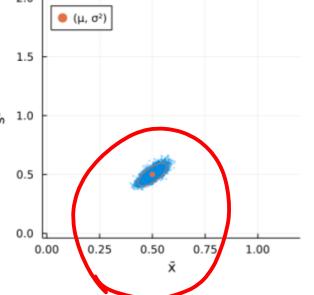
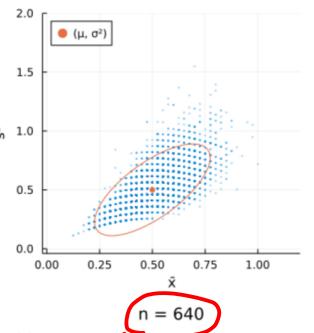
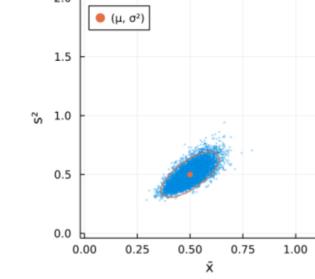
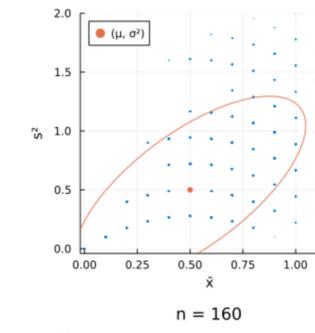
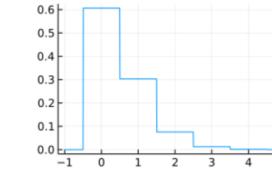
μ = 1.0
σ² = 20.0
skewness = 3.823676241524649
kurtosis = 13.58499999999097
```



Poisson分布の標本分布における \bar{X}, S^2 の同時分布

```
plot_x_and_Sx2_2x2(Poisson(0.5); xlim=(-0.02, 1.2), ylim=(-0.04, 2.0))
Poisson{Float64}(λ=0.5)

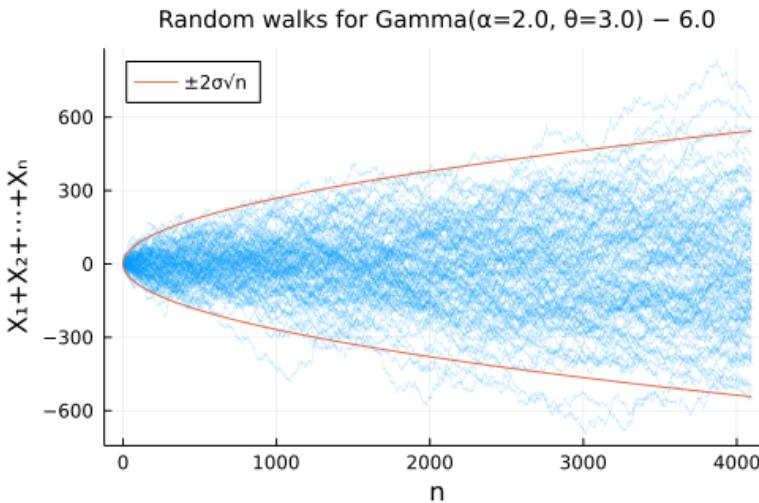
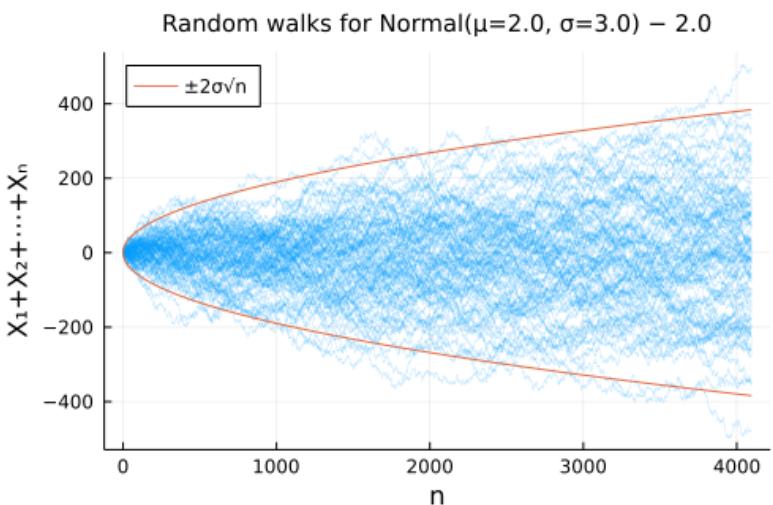
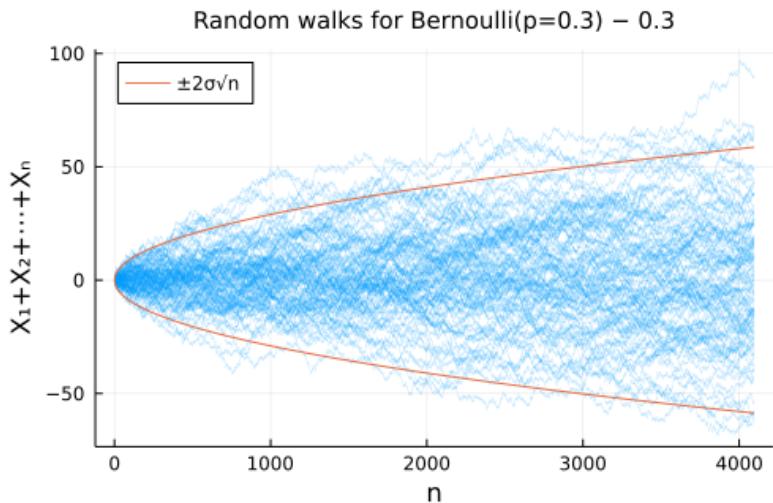
μ = 0.5
σ² = 0.5
skewness = 1.414213562373095
kurtosis = 2.0
```



n を大きくすると (\bar{X}_n, S_n^2) の分布は (μ, σ^2) に集中して行く。

$n \rightarrow \infty$ で (\bar{X}_n, S_n^2) のさじばり方の大きさは $\frac{1}{\sqrt{n}}$ に比例する。

$E[X_i] = 0$ となる X_i たちの和 $X_1 + \dots + X_n$ の動き方を 100 個同時プロット



$\frac{\sqrt{n}}{n} \rightarrow 0$
↓
大数の法則

$\frac{\sqrt{n}}{\sqrt{n}} \rightarrow 1$
↓
中心極限定理

独立同分布確率変数列 X_1, X_2, \dots について,
 $E[X_i] = 0, \text{Var}(X_i) = \sigma^2 < \infty$ が成立しているとき,
 $n \mapsto X_1 + \dots + X_n$
 のグラフを大量にプロットすると,
 $X_1 + \dots + X_n$ は $\pm 2\sigma\sqrt{n}$ のあたりに
 大部分が含まれる。 → 中心極限定理へ！

中心極限定理

$\frac{X_1 + \dots + X_n}{\sqrt{n}\sigma}$ の分布は標準正規分布に近付く！

中心極限定理

X_1, X_2, \dots は独立同分布確率変数列であるとし、

$$E[|X_i|] < \infty, \mu = E[X_i], \sigma^2 = E[(X_i - \mu)^2] < \infty, E[|X_i - \mu|^3] < \infty$$

と仮定する。このとき、

注意 $E[Z_n] = 0, \text{Var}(Z_n) = E[Z_n^2] = \frac{n}{\sigma^2} E[(\bar{X}_n - \mu)^2] = 1$.

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{X_i - \mu}{\sigma}, Z \sim \text{Normal}(0,1)$$

とおくと、

$$E\left[\frac{X_i - \mu}{\sigma}\right] = 0, \text{Var}\left(\frac{X_i - \mu}{\sigma}\right) = 1$$

n が大きいとき、

$$\lim_{n \rightarrow \infty} E[f(Z_n)] = E[f(Z)] = \int_{-\infty}^{\infty} f(z) \frac{e^{-z^2/2}}{\sqrt{2\pi}} dz. \quad \leftarrow Z_n の分布は標準正規分布で近似されるという意味$$

同値な別の表現

n が大きいとき、

$$(1) \text{ 近似的に } Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{X_i - \mu}{\sigma} \sim \text{Normal}(0,1).$$

$$(2) \text{ 近似的に } \sigma Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n (X_i - \mu) \sim \text{Normal}(0, \sigma)$$

ゆるい仮定のもとで
独立同分布な

$$(3) \text{ 近似的に } \bar{X}_n = \mu + \frac{\sigma}{\sqrt{n}} Z_n \sim \text{Normal}(\mu, \frac{\sigma}{\sqrt{n}})$$

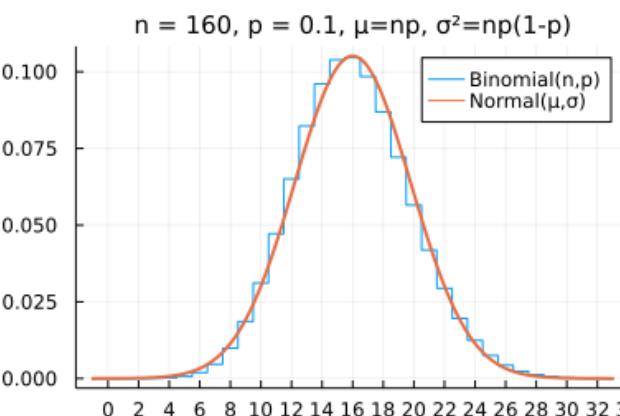
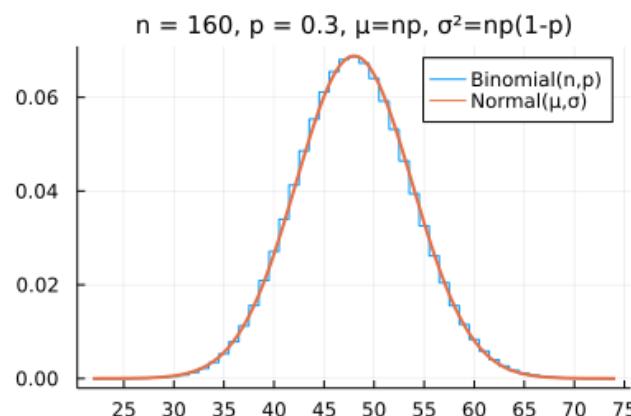
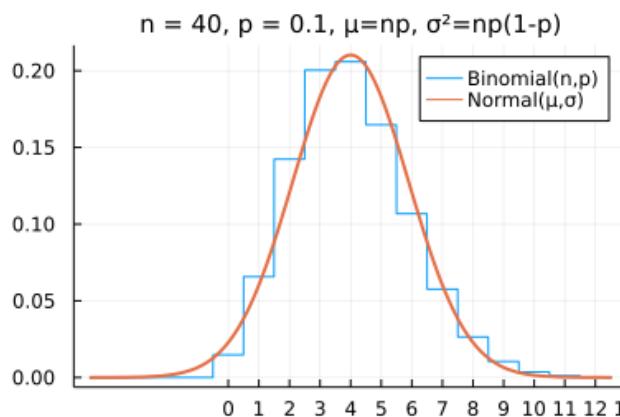
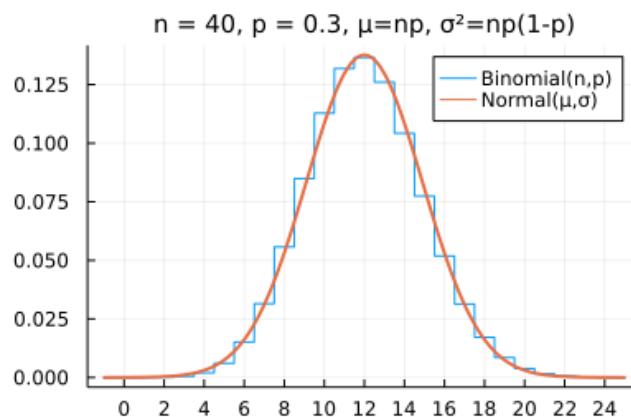
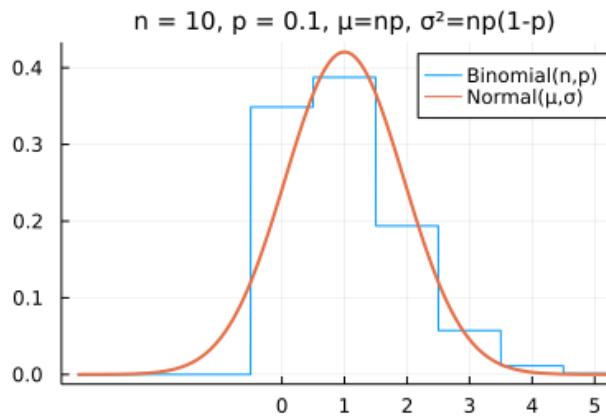
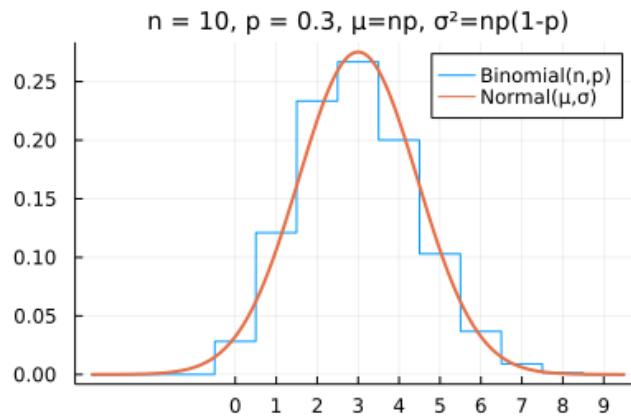
確率変数たちの和は
近似的に

$$(4) \text{ 近似的に } n\bar{X}_n = X_1 + \dots + X_n \sim \text{Normal}(n\mu, \sqrt{n}\sigma).$$

正規分布にしたがう。

二項分布の中心極限定理

np と $n(1-p)$ が
大きいと精度が高くなる。



X_1, X_2, \dots を
各々が分布 Bernoulli(p)

にしたがう
独立同分布確率変数列
とすると,

$$K_n = X_1 + \dots + X_n \\ \sim \text{Binomial}(n, p),$$

$$E[K_n] = np =: \mu,$$

$$\text{Var}(K_n) = np(1-p) =: \sigma^2$$

n が大きなとき,
近似的的

$$K_n \sim \text{Normal}\left(np, \sqrt{np(1-p)}\right)$$

証明は GitHub 資料にある。
かなりおもしろい。
Kullback-Leibler 情報量に
関係す。

必修自習問題

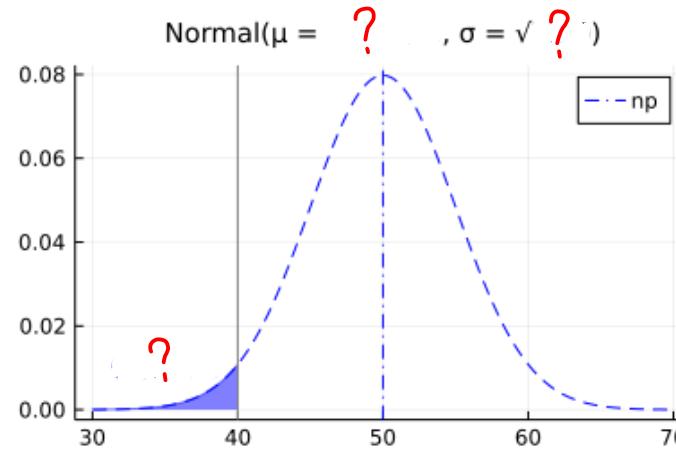
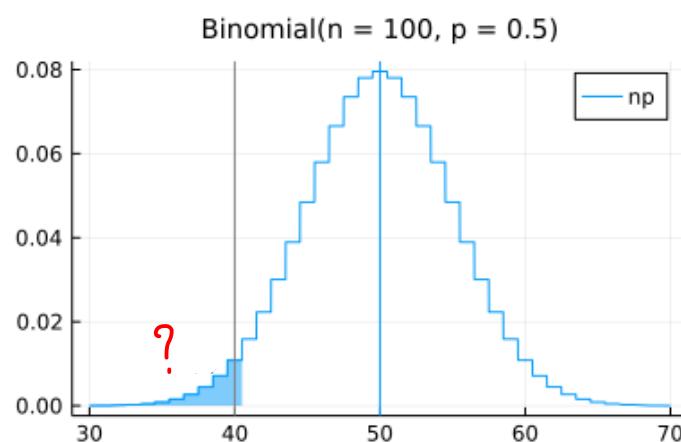
答えは GitHub にある、

2.3 必修重要問題: 二項分布の正規分布近似を使った確率の近似計算1

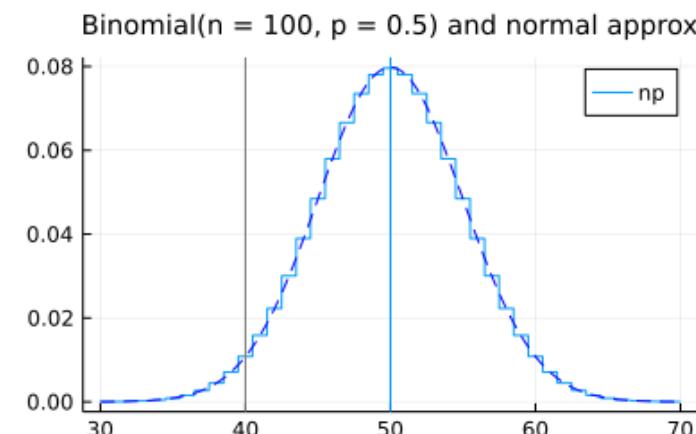
確率変数 K は二項分布 $\text{Binomial}(100, 1/2)$ に従っていると仮定する。

(1) 確率 $P(K \leq 40)$ を小数点以下第5桁まで求めよ。

(2) 二項分布 $\text{Binomial}(100, 1/2)$ と同じ期待値と分散を持つ正規分布に従う確率変数 X について確率 $P(X \leq 40)$ を小数点以下第5桁まで求めよ。



左の図の4つの？を
求める問題、



← このように二項分布の
正規分布近似が
非常にうまくいっている、

必修自習問題

2.4 必修重要問題: 二項分布の正規分布近似を使った確率の近似計算2

$0 < p < 1$ であると仮定し, K は二項分布 $\text{Binomial}(100, p)$ に従う確率変数であるとする.

(1) $P(K \leq 40) = 0.025$ を満たす p の値 p_U を小数点以下第4桁まで求めよ.

(2) $P(K \geq 40) = 0.025$ を満たす p の値 p_L を小数点以下第4桁まで求めよ.

$\hat{p} = 40/100 = 0.4$ とおく. X は K と同じ平均 np と推定された分散 $n\hat{p}(1 - \hat{p})$ を持つ正規分布に従う確率変数であるとする.

(3) $P(X \leq 40) = 0.025$ を満たす p の値 q_U を小数点以下第4桁まで求めよ.

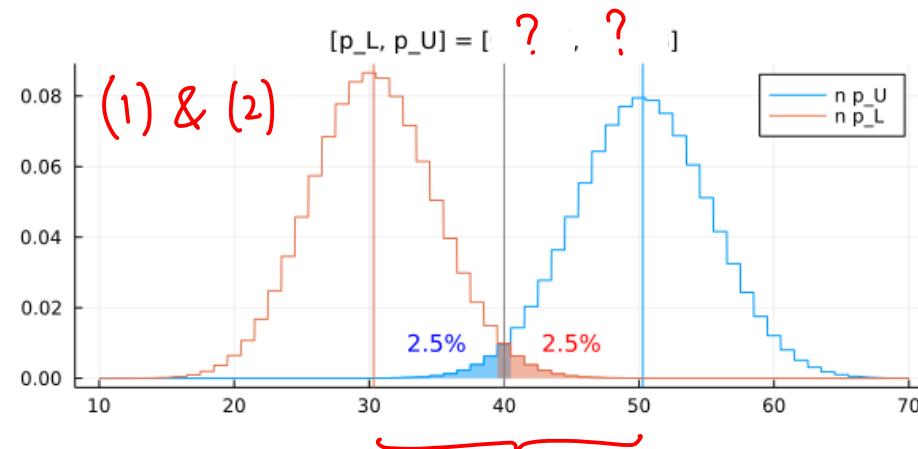
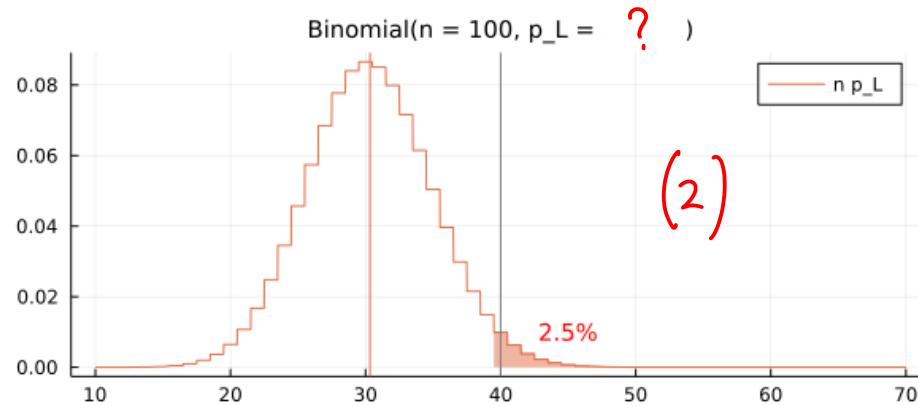
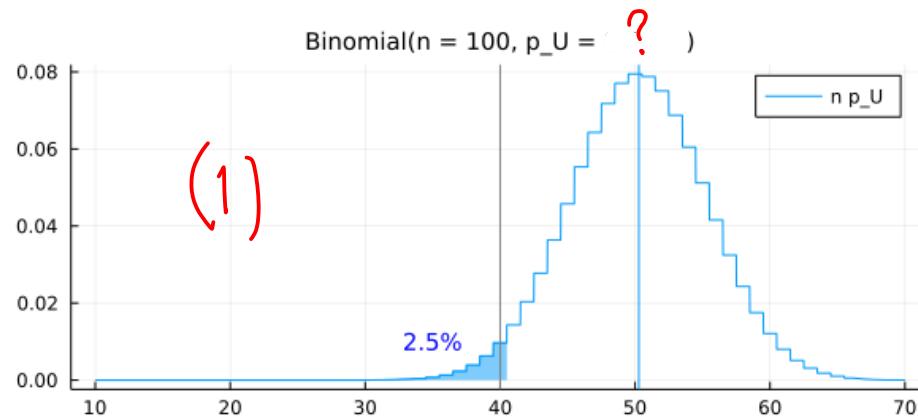
(4) $P(X \geq 40) = 0.025$ を満たす p の値 q_L を小数点以下第4桁まで求めよ.

注意: これらによって計算される区間 $[p_L, p_U]$ と $[q_L, q_U]$ はデータ「100回中40回当たり」というデータから得られる p の 95% 信頼区間と呼ばれる. 前者は **Clopper-Pearsonの信頼区間** と, 後者は **Waldの信頼区間** と呼ばれる.

こちらの問題の方が前ページの問題よりずっとむずかしい,
単位をとるためのがんばりどころ!

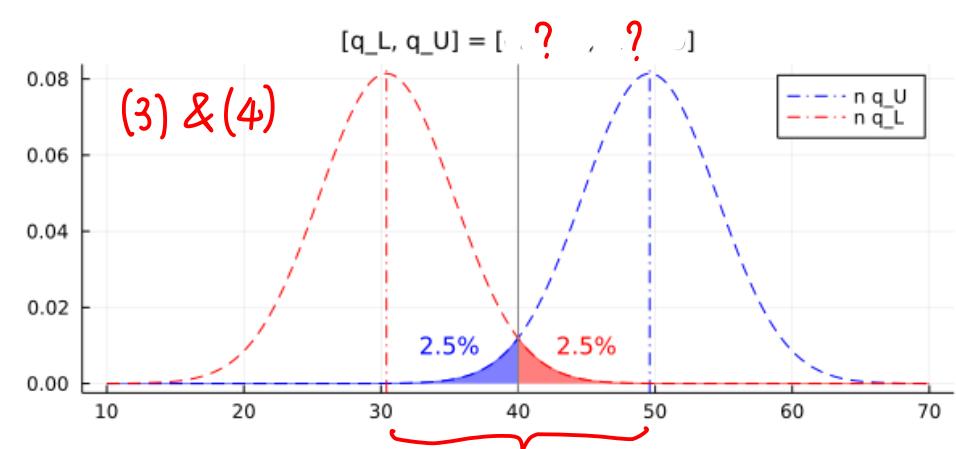
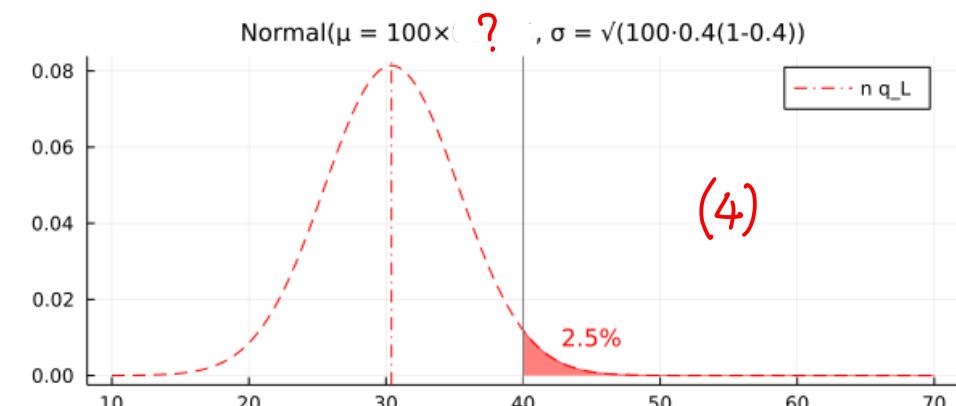
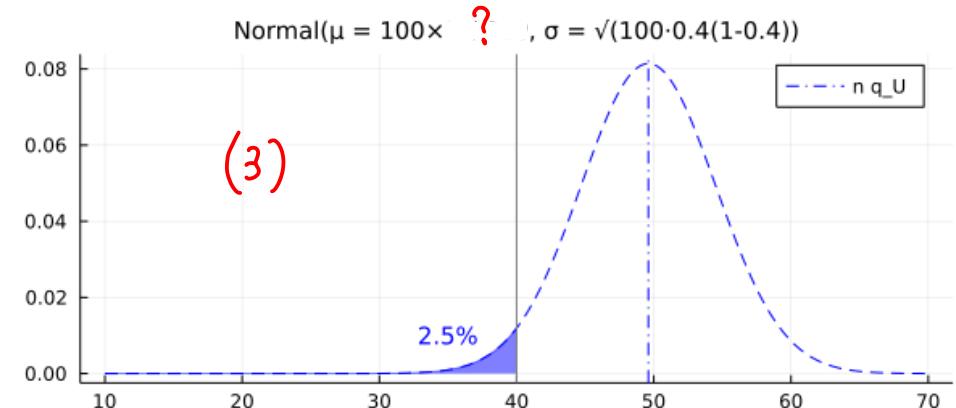
次ページに図による問題の説明がある.

(1) と (2) について →



データ $k=40$ に対する Clopper-Pearson の信頼区間 × 100

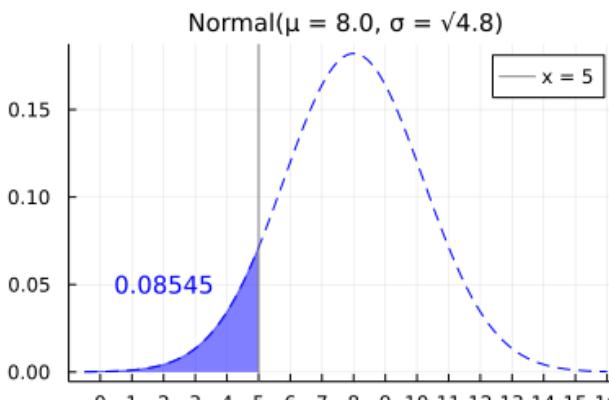
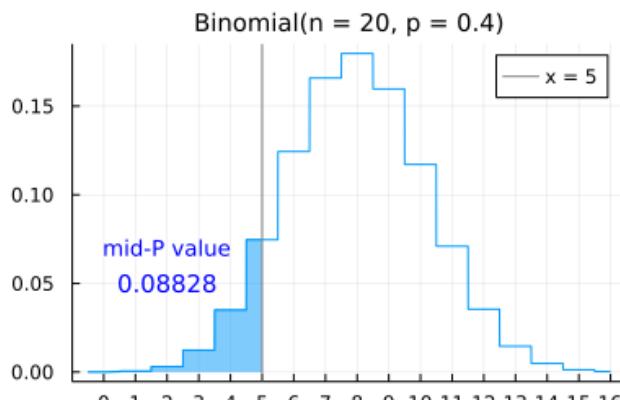
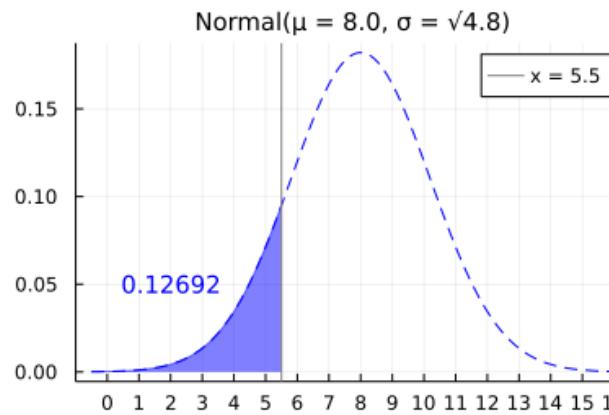
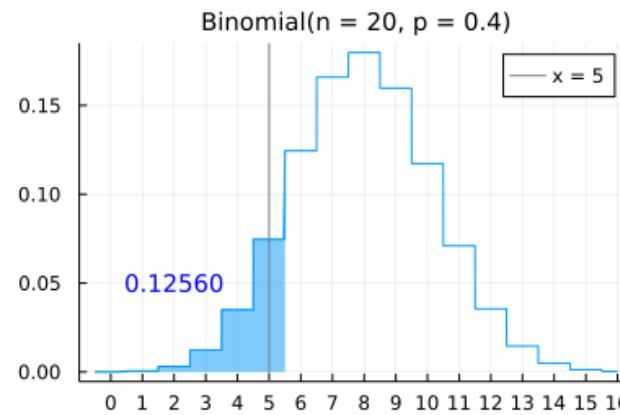
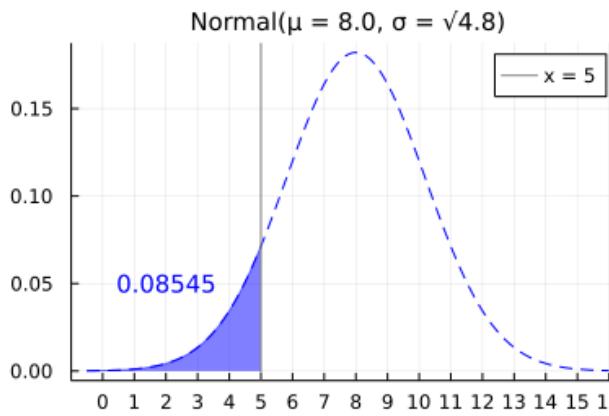
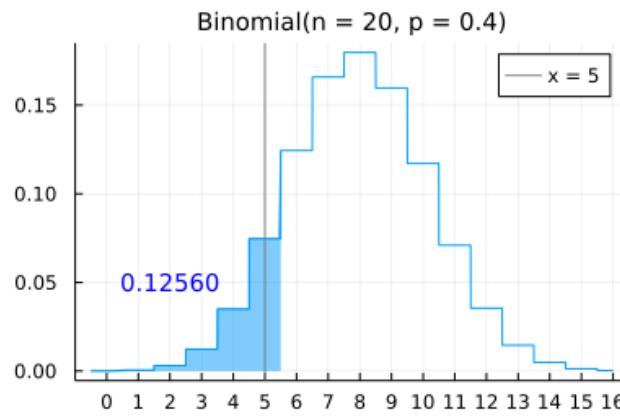
(3) と (4) について →



Wald の 信頼区間 × 100

離散分布を正規分布のような連続分布で近似するときの注意

$n=20, p=0.4$



$$\mu = np = 8,$$

$$\sigma^2 = np(1-p) = 20 \times 0.4 \times 0.6 = 4.8$$

$K \sim \text{Binomial}(n, p)$

$X \sim \text{Normal}(\mu, \sigma)$

$P(K \leq 5) \approx 0.12560$ と
 $P(X \leq 5) \approx 0.08545$
の値が大きくなっている。

$P(K \leq 5) \approx 0.12560$ ← 近い
 $P(X \leq 5.5) \approx 0.12692$ ← 連続性補正

$P(X \leq 5) \approx 0.08545$ ← 近い

$$\frac{P(K \leq 4) + P(K \leq 5)}{2} \approx 0.08828$$

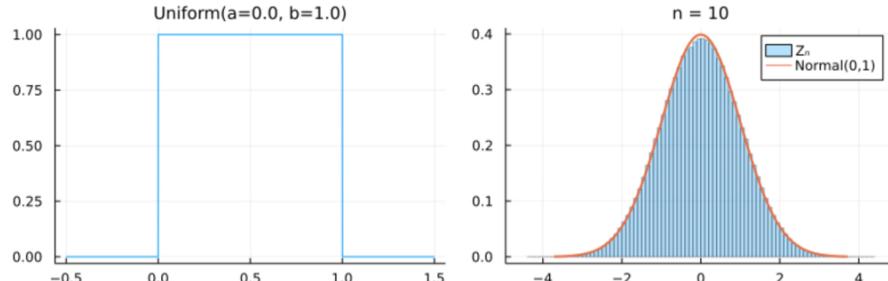
mid-P補正

中心極限定理のデモ

各 X_i がしたかう分布によって、 $Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$ が標準正規分布でよく近似されるようになる n の大きさはありますか。

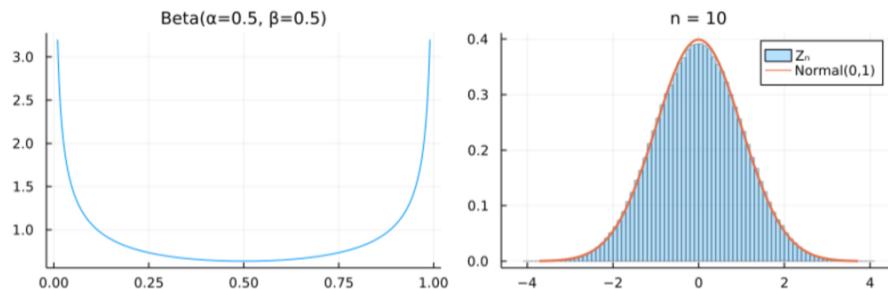
```
# 中心極限定理による収束が速い場合1の再現
plot_central_limit_theorem(Uniform(0, 1), 10; a=-0.5, b=1.5)
```

skewness(dist) = 0.0
kurtosis(dist) = -1.2



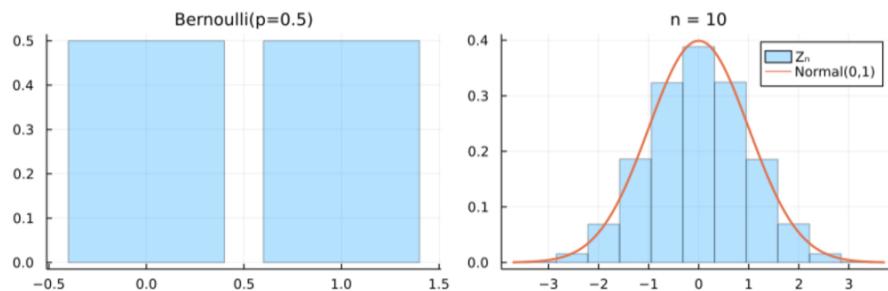
```
# 中心極限定理による収束が速い場合2
plot_central_limit_theorem(Beta(0.5, 0.5), 10; a=0.01, b=0.99)
```

skewness(dist) = 0.0
kurtosis(dist) = -1.5



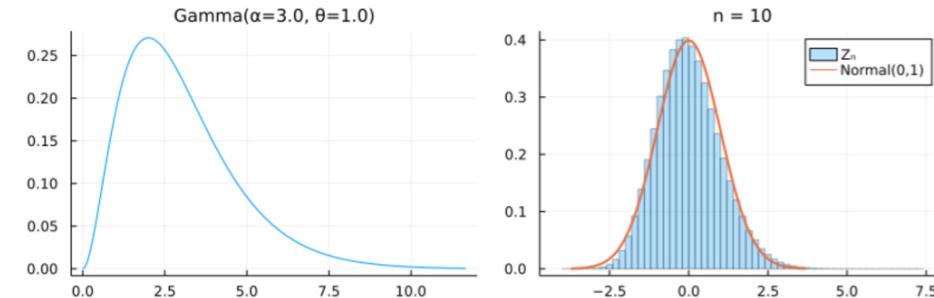
```
# 中心極限定理による収束が速い場合3
plot_central_limit_theorem(Bernoulli(0.5), 10)
```

skewness(dist) = 0.0
kurtosis(dist) = -2.0



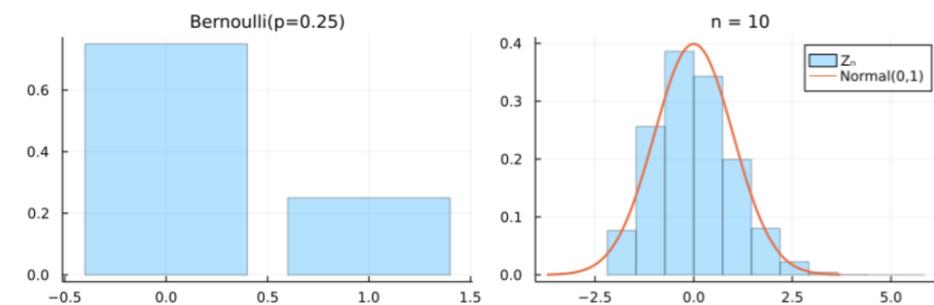
```
# 左右非対称な分布の場合1
plot_central_limit_theorem(Gamma(3, 1), 10)
```

skewness(dist) = 1.1547005383792517
kurtosis(dist) = 2.0



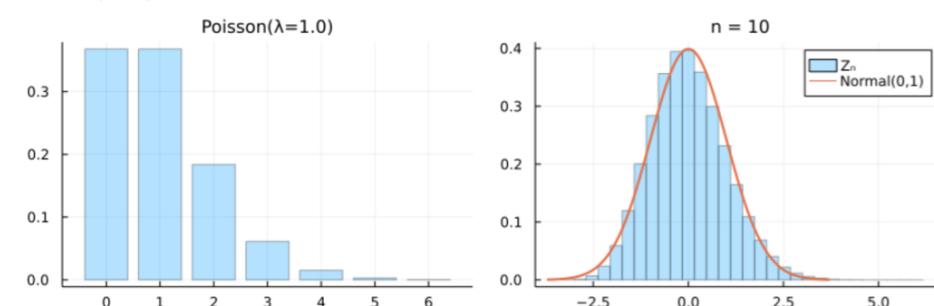
```
# 左右非対称な分布の場合2
plot_central_limit_theorem(Bernoulli(0.25), 10)
```

skewness(dist) = 1.1547005383792517
kurtosis(dist) = -0.6666666666666667



```
# 左右非対称な分布の場合3
plot_central_limit_theorem(Poisson(1), 10)
```

skewness(dist) = 1.0
kurtosis(dist) = 1.0



大きめのnが必要な場合

```
# 中心極限定理による収束が遅い場合1
```

```
# 左右の非対称性が大きな分布を試してみる
```

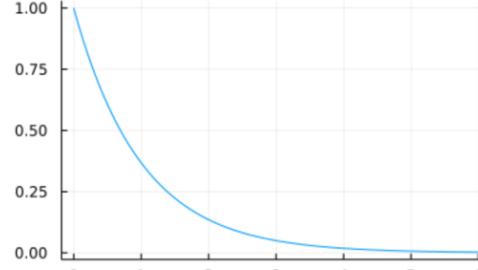
```
# 指数分布は左右の非対称性が大きな分布になっている
```

```
plot_central_limit_theorem(Exponential(), 10)
```

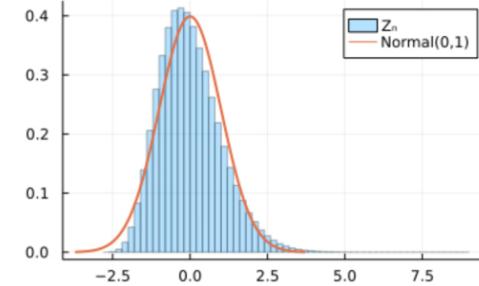
```
skewness(dist) = 2.0
```

```
kurtosis(dist) = 6.0
```

Exponential($\theta=1.0$)



$n = 10$

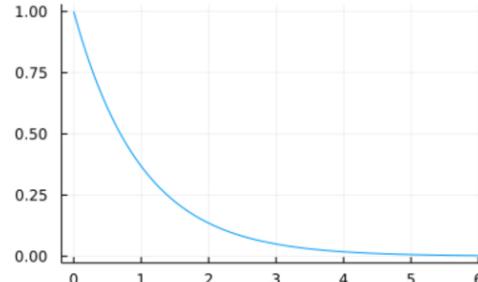


```
plot_central_limit_theorem(Exponential(), 40)
```

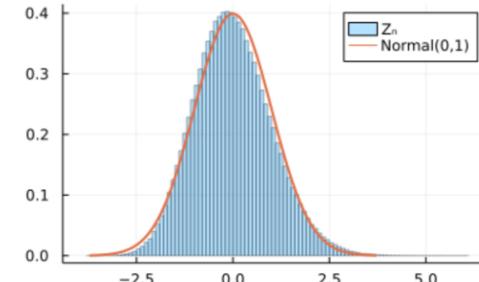
```
skewness(dist) = 2.0
```

```
kurtosis(dist) = 6.0
```

Exponential($\theta=1.0$)



$n = 40$

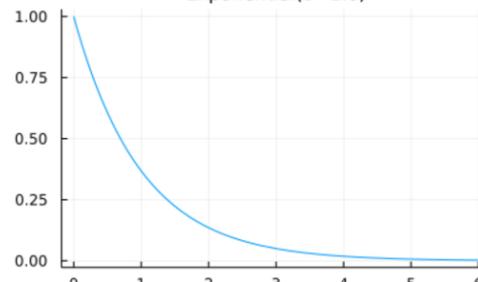


```
plot_central_limit_theorem(Exponential(), 160)
```

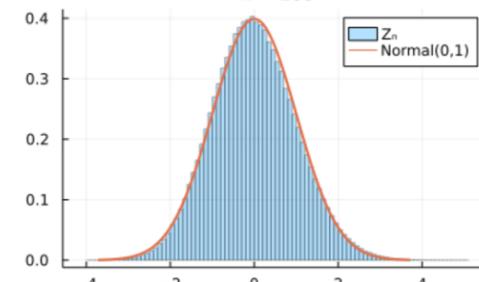
```
skewness(dist) = 2.0
```

```
kurtosis(dist) = 6.0
```

Exponential($\theta=1.0$)



$n = 160$



```
# 中心極限定理による収束が遅い場合2
```

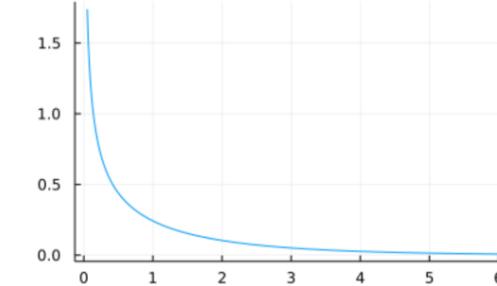
```
# 自由度1の $\chi^2$ 分は左右の非対称性が指数分布よりも大きな分布になっている
```

```
plot_central_limit_theorem(Chisq(1), 10; a=0.05, b=6)
```

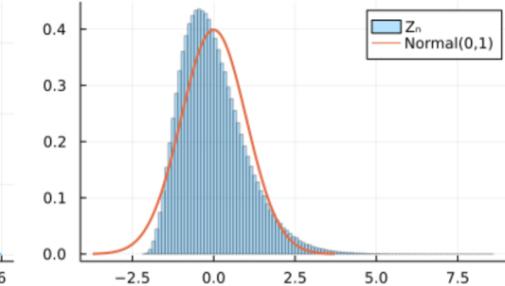
```
skewness(dist) = 2.8284271247461903
```

```
kurtosis(dist) = 12.0
```

Chisq($v=1.0$)



$n = 10$

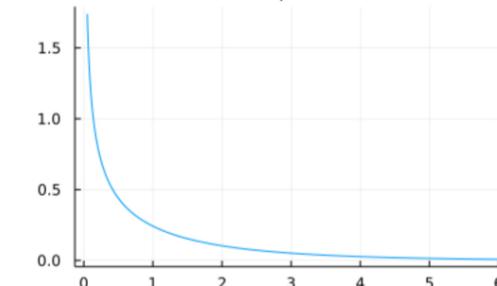


```
plot_central_limit_theorem(Chisq(1), 40; a=0.05, b=6)
```

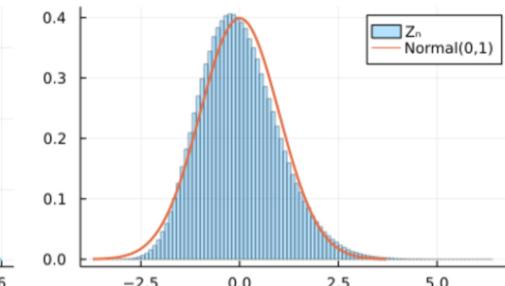
```
skewness(dist) = 2.8284271247461903
```

```
kurtosis(dist) = 12.0
```

Chisq($v=1.0$)



$n = 40$

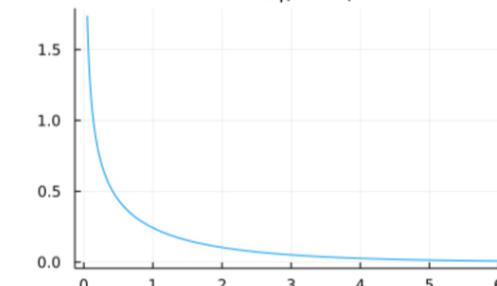


```
plot_central_limit_theorem(Chisq(1), 160; a=0.05, b=6)
```

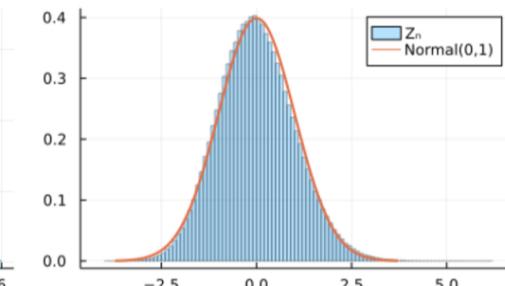
```
skewness(dist) = 2.8284271247461903
```

```
kurtosis(dist) = 12.0
```

Chisq($v=1.0$)



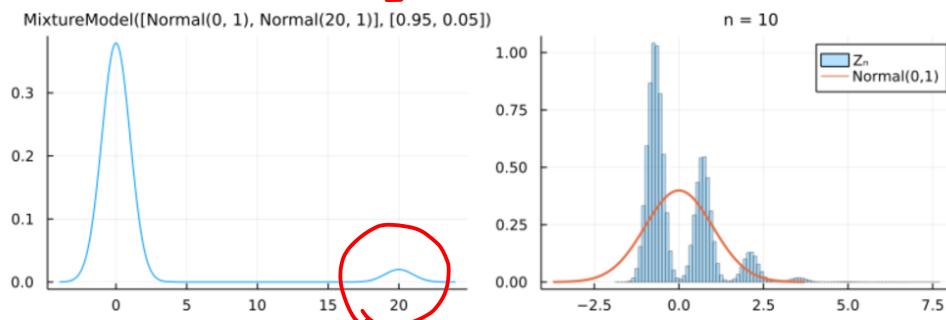
$n = 160$



大きめのnが必要な場合

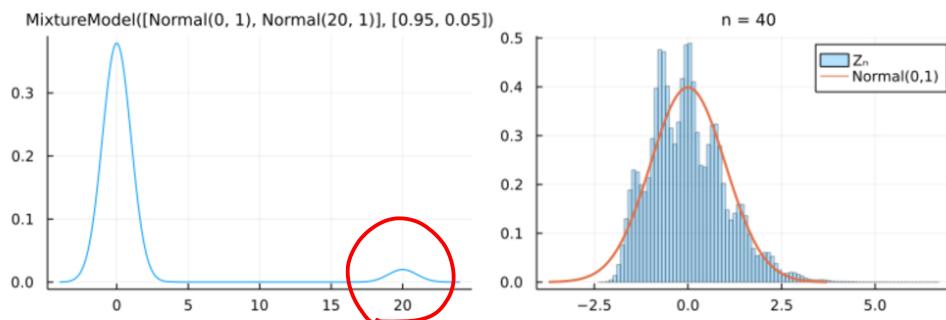
```
# 中心極限定理による収束が遅い場合3
# 以下のような分布distも左右の非対称性が大きな分布に分類される
dist = MixtureModel([Normal(0, 1), Normal(20, 1)], [0.95, 0.05])
disttitle = "MixtureModel([Normal(0, 1), Normal(20, 1)], [0.95, 0.05])"
titlefontsize = 9
a, b = -4, 24
plot_central_limit_theorem(dist, 10; a, b, disttitle, titlefontsize)

skewness(dist) = 3.8236762415246486
kurtosis(dist) = 13.584999999990963
```



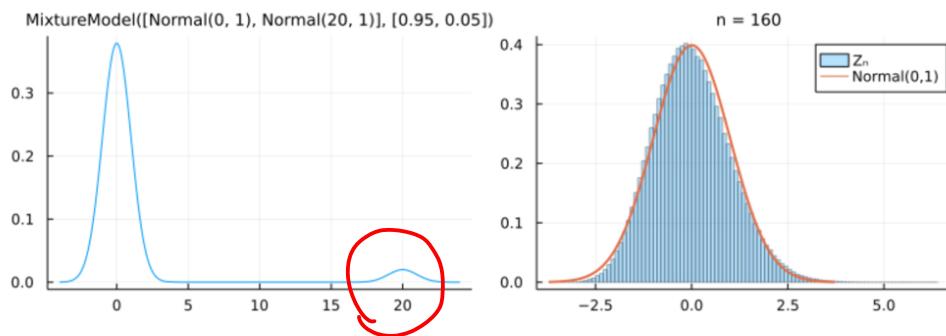
```
plot_central_limit_theorem(dist, 40; a, b, disttitle, titlefontsize)

skewness(dist) = 3.8236762415246486
kurtosis(dist) = 13.584999999990963
```



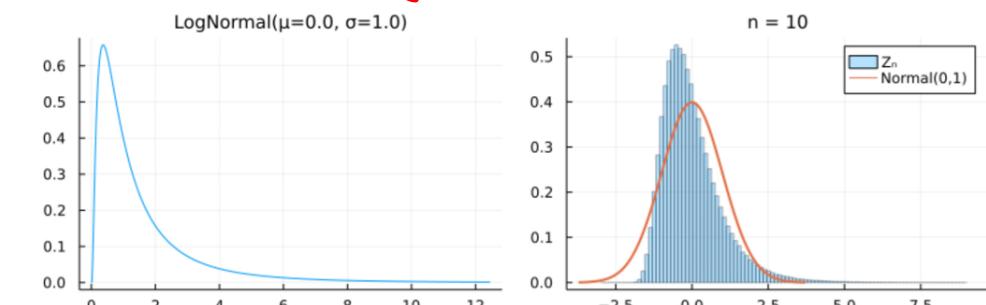
```
plot_central_limit_theorem(dist, 160; a, b, disttitle, titlefontsize)

skewness(dist) = 3.8236762415246486
kurtosis(dist) = 13.584999999990963
```



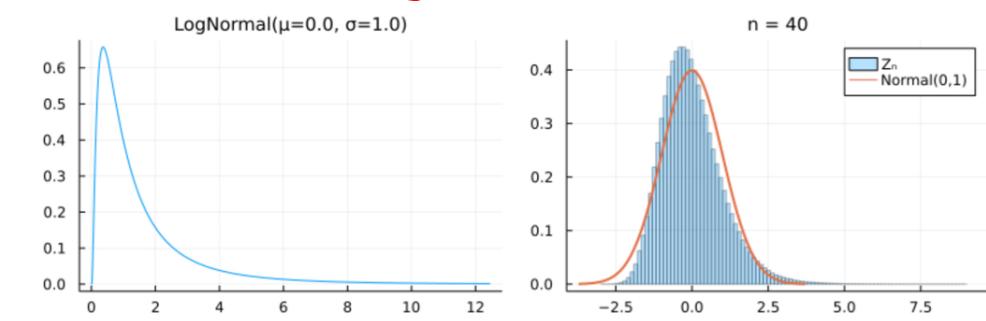
```
# 中心極限定理による収束が遅い場合4
# 対数正規分布は左右の非対称性が非常に大きな分布である
# 右側の値が大きく、外れ値が出やすい
plot_central_limit_theorem(LogNormal(), 10; bin=range(-3, 9, 100))

skewness(dist) = 6.184877138632554
kurtosis(dist) = 110.9363921763115
```



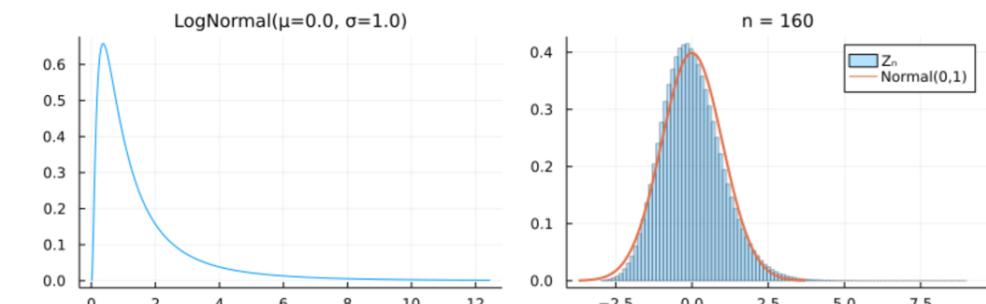
```
plot_central_limit_theorem(LogNormal(), 40; bin=range(-3, 9, 100))

skewness(dist) = 6.184877138632554
kurtosis(dist) = 110.9363921763115
```



```
plot_central_limit_theorem(LogNormal(), 160; bin=range(-3, 9, 100))

skewness(dist) = 6.184877138632554
kurtosis(dist) = 110.9363921763115
```

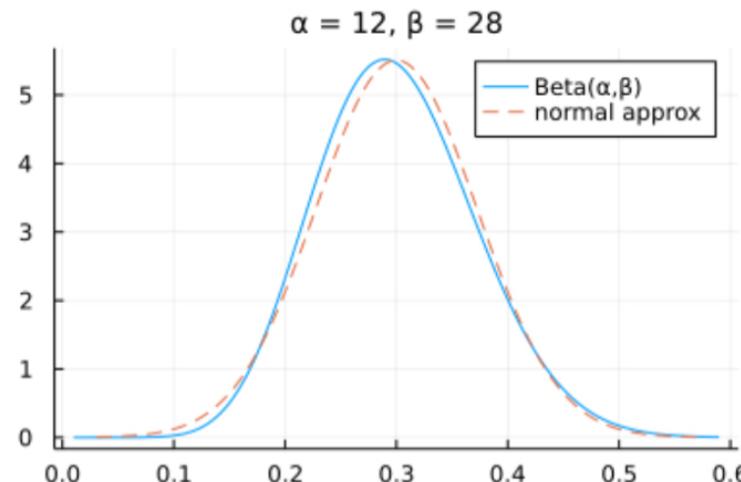
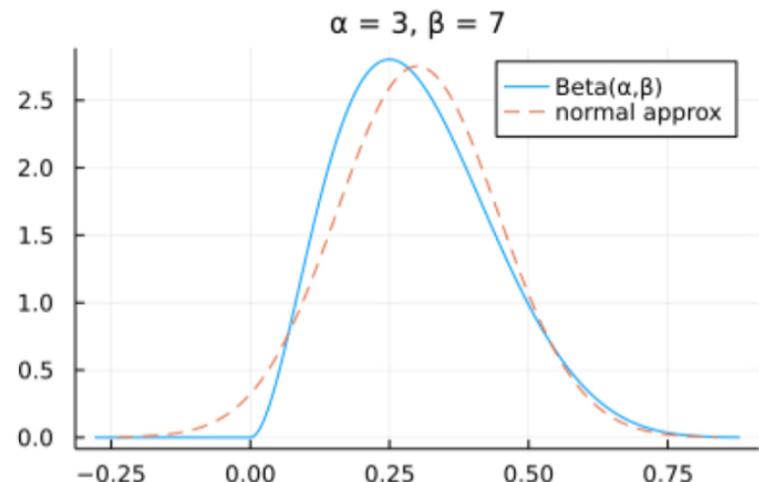


中心極限定理の直接的帰結でなくても「デルタ法」によて

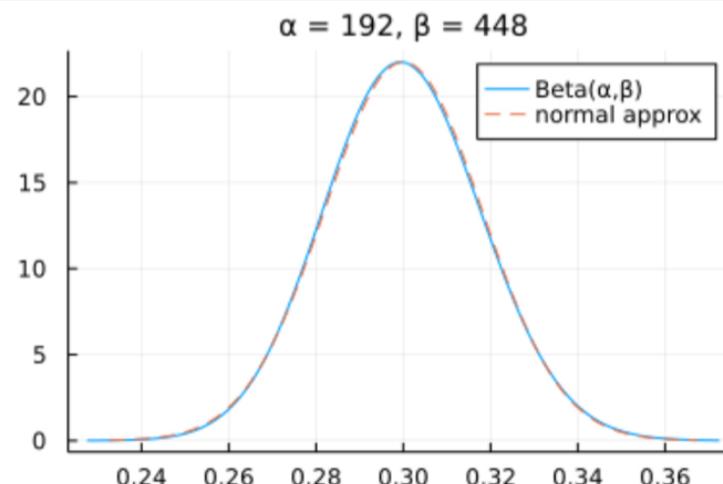
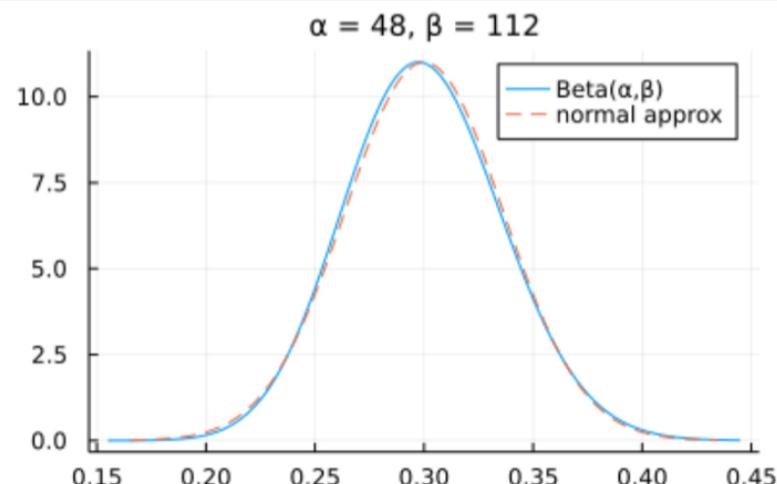
GitHub資料を見よ、

中心極限定理から間接的に正規分布近似できることがわかる場合がたくさんある。

```
plot(plot_betanormal(3, 7), plot_betanormal(12, 28); size=(800, 250))
```



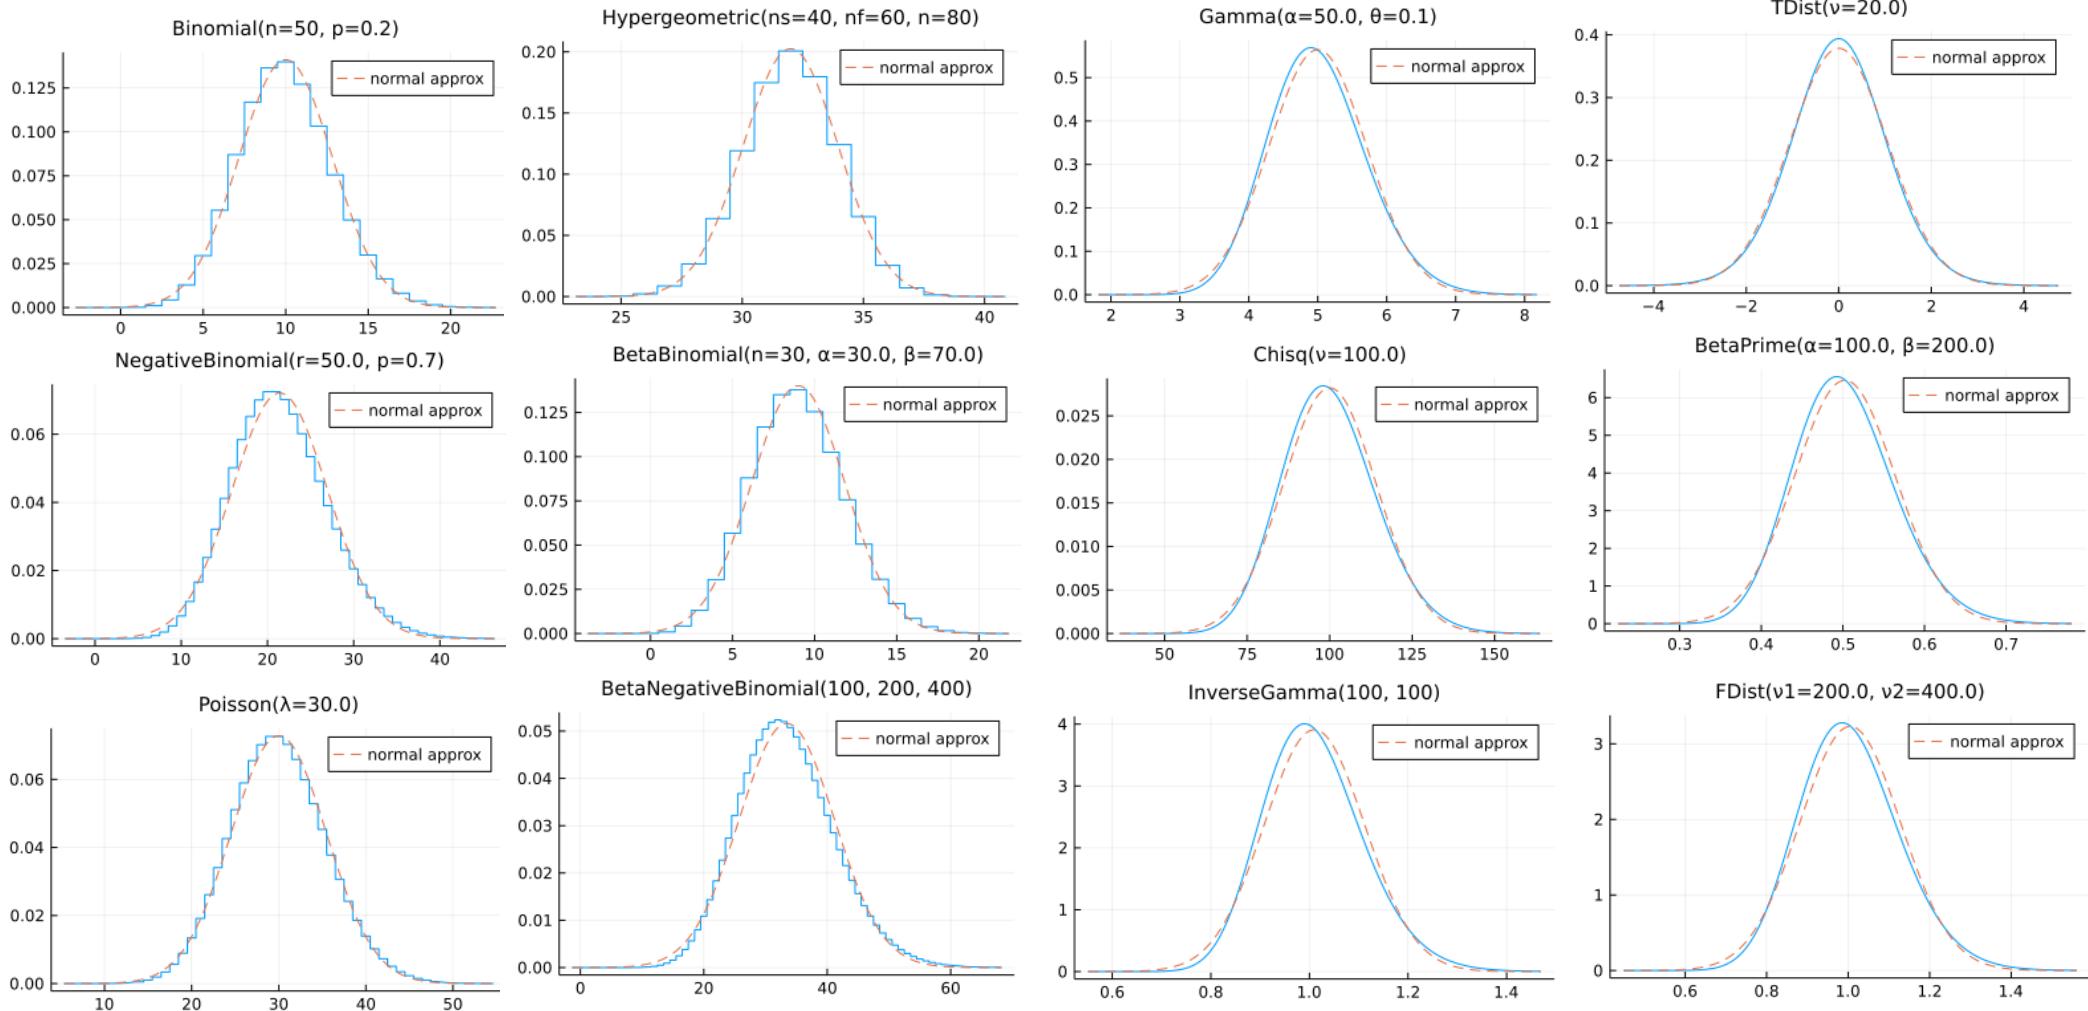
```
plot(plot_betanormal(48, 112), plot_betanormal(192, 448); size=(800, 250))
```



ベータ分布の正規分布近似

正規分布は普偏的！

多くの分布はパラメータに適当な条件を仮定すると正規分布で近似される。



中心極限定理の証明

(の考え方)

詳細は GitHub の資料を参照

理解してほしいが理解できなくても単位は出しin!

どこに神経を集中するべきか

単に正規分布に収束することだけではなく、

(*) どのようにときに正規分布への収束がおそらくこうであるか

がわかるようになるべきである。その部分がしっかりしていれば、論理的に少々ギャップを残してもかまわない。

$\mu = E[X_i]$, $\sigma^2 = \text{Var}(X_i)$ とおく、

(*) の 答え

X_1, X_2, \dots は各々が分布 D にしたがう独立同分布確率変数列であるとする。

$\mu = E[X_i]$, $\sigma^2 = \text{Var}(X_i)$, $Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{X_i - \mu}{\sigma}$ とおく。

Z_n の分布の正規分布への収束の速さについて、

- あるいは 歪度 $\bar{\kappa}_3 = E\left[\left(\frac{X_i - \mu}{\sigma}\right)^3\right]$ の絶対値が大きいと正規分布への収束がおそらくなる。
- せんと $\bar{\kappa}_3 = 0$ のときは尖度 $\bar{\kappa}_4 = E\left[\left(\frac{X_i - \mu}{\sigma}\right)^4\right] - 3$ の絶対値の大きさがきいてくる。

特性函数, モーメント母函数, キュラント母函数 X は確率変数とする.

特性函数 $\varphi_X(t) = E[e^{itX}]$ 常に定義される

$$= M_X(it) = e^{K_X(it)}$$

おおざっぱには
本質的に同じ情報
を持っていると
考えてよい.

モーメント母函数 $M_X(t) = E[e^{tX}] = \varphi_X(-it) = e^{K_X(t)}$

キュラント母函数 $K_X(t) = \log E[e^{tX}] = \log M_X(t) = \log \varphi_X(-it)$

特性函数で期待値を書ける ← これよ), $\varphi_X(t)$, $M_X(t)$, $K_X(t)$ が等しい X たゞは

$$\hat{f}(t) = \int_{-\infty}^{\infty} f(x) e^{-itx} dx \quad (\text{Fourier変換}) \text{ とおくと,}$$

同じ分布を持つことが
わかる.

$$f(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} \hat{f}(t) e^{itx} dt \quad (\text{逆 Fourier変換}).$$

ゆえに,

$$E[f(X)] = \frac{1}{2\pi} \int_{-\infty}^{\infty} \hat{f}(t) E[e^{itX}] dt = \frac{1}{2\pi} \int_{-\infty}^{\infty} \hat{f}(t) \varphi_X(t) dt.$$

したがって, 確率変数 X と Y について適切な意味で $\varphi_X(t)$ と $\varphi_Y(t)$ が近ければ
 $E[f(X)] \approx E[f(Y)]$ ($E[f(X)]$ と $E[f(Y)]$ も近くなる).

例 $Z \sim \text{Normal}(0,1)$ のとき, $M_Z(t) = E[e^{tZ}] = e^{t^2/2}$

証明 $E[e^{tZ}] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{tz} e^{-z^2/2} dz = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}(z-t)^2 + \frac{1}{2}t^2} dz \leftarrow$
 $= \frac{e^{t^2/2}}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}y^2} dy = \frac{e^{t^2/2}}{\sqrt{2\pi}} \sqrt{2\pi} = e^{t^2/2}.$

$z=y+t$
とおく.

f.e.d.

モーメント $\mu_m = \mu_m(X) = E[X^m]$ とおき, X の m 次の モーメント と呼ぶ。

$$M_X(t) = E[e^{tX}] = \sum_{m=0}^{\infty} \mu_m \frac{t^m}{m!}. \quad \leftarrow M_X(t) \text{ はモーメント達の母函数}$$

キュムラント 次の展開で X の キュムラント (cumulant) $\kappa_m = \kappa_m(X)$ を定めろ:

$$K_X(t) = \log M_X(t) = \sum_{m=1}^{\infty} \kappa_m \frac{t^m}{m!} = \underbrace{\mu t + \sigma^2 \frac{t^2}{2} + \kappa_3 \frac{t^3}{3!} + (\mu_4 - 3) \frac{t^4}{4!} + \dots}_{\text{すぐ使う。}}$$

例 $Z \sim \text{Normal}(0,1)$ のとき, $K_Z(t) = \log M_Z(t) = \frac{t^2}{2}$ より,

$$\kappa_1(Z) = 0, \quad \kappa_2(Z) = 1, \quad \kappa_3(Z) = 0, \quad \kappa_4(Z) = 0, \quad \kappa_5(Z) = 0, \dots$$

□

標準化キュムラント X , $\mu = E[X]$, $\sigma^2 = \text{var}(X)$ に対して, $\frac{X-\mu}{\sigma}$ を X の 標準化 と呼ぶ。 $\bar{\kappa}_m(X) = \kappa_m\left(\frac{X-\mu}{\sigma}\right)$ を X の 標準化キュムラント と呼ぶ。

$\bar{\kappa}_3(X) = E\left[\left(\frac{X-\mu}{\sigma}\right)^3\right]$ を 歪度(わいど) と, $\bar{\kappa}_4(X) = E\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] - 3$ を 尖度(せんと) と呼ぶ。

キュムラント母函数を用いた中心極限定理の証明

$$Y_i = \frac{X_i - \mu}{\sigma} \text{ とおくと, } E[Y_i] = 0, \text{ Var}(Y_i) = E[Y_i^2] = \frac{1}{\sigma^2} \overbrace{E[(X_i - \mu)^2]}^{= \sigma^2} = 1 \text{ より},$$

$$\log E[e^{tY_i}] = \frac{t^2}{2} + \bar{\kappa}_3 \frac{t^3}{3!} + \bar{\kappa}_4 \frac{t^4}{4!} + \dots \quad \leftarrow \bar{\kappa}_m = \bar{\kappa}_m(X_i) = \bar{\kappa}_m(Y_i)$$

$$Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{X_i - \mu}{\sigma} = \frac{1}{\sqrt{n}} (Y_1 + \dots + Y_n) \text{ について, } \quad Y_1, \dots, Y_n \text{ たちの独立性より}$$

$$\begin{aligned} \log E[e^{tZ_n}] &= \log E\left[e^{\frac{t}{\sqrt{n}}Y_1} \dots e^{\frac{t}{\sqrt{n}}Y_n}\right] = \log \prod_{i=1}^n E\left[e^{\frac{t}{\sqrt{n}}Y_i}\right] = \sum_{i=1}^n \log E\left[e^{\frac{t}{\sqrt{n}}Y_i}\right] \quad \text{上の式の右に} \\ &= \sum_{i=1}^n \left(\frac{1}{2} \frac{t^2}{n} + \frac{\bar{\kappa}_3}{3!} \frac{t^3}{n\sqrt{n}} + \frac{\bar{\kappa}_4}{4!} \frac{t^4}{n^2} + \dots \right) \quad \frac{t}{\sqrt{n}} \text{ を代入する} \\ &= \frac{t^2}{2} + \frac{\bar{\kappa}_3}{3!} \frac{t^3}{\sqrt{n}} + \frac{\bar{\kappa}_4}{4!} \frac{t^4}{n} + \dots \end{aligned}$$

左側を見れば、
度々 $\bar{\kappa}_3$ と 度々 $\bar{\kappa}_4$ が
現れる

収束を遡ることわかる

なので、 $Z \sim \text{Normal}(0, 1)$ ならば、 $n \rightarrow \infty$ のとき、

$$\log E[e^{tZ_n}] \rightarrow \frac{t^2}{2} = \log E[e^{tZ}]$$

$$\therefore E[e^{tZ_n}] \rightarrow E[e^{tZ}]$$

$$\therefore E[f(Z_n)] \rightarrow E[f(Z)] = \int_{-\infty}^{\infty} f(z) \frac{e^{-z^2/2}}{\sqrt{2\pi}} dz.$$

難な説明だが
正当化できる。

q.e.d.

Fourier解析を使わずに $f(x)$ の Taylor 展開のみを使う 中心極限定理の証明もある。

X_1, X_2, \dots は独立同分布, $E[X_i] = 0, E[X_i^2] = 1$
 Y_1, Y_2, \dots は独立同分布, $Y_k \sim \text{Normal}(0, 1)$

$\left. \begin{array}{l} \\ \end{array} \right\} \tilde{\tau}, X_1, X_2, \dots \text{と } Y_1, Y_2, \dots \text{の全体も独立のとき}$

$A_n^{(k)} = \frac{X_1 + \dots + X_{k-1} + Y_{k+1} + \dots + Y_n}{\sqrt{n}}$ とおき,

$f(a+h) = f(a) + f'(a)h + \frac{f''(a)}{2}h^2 + \frac{f'''(a)}{3!}h^3 + \frac{f^{(4)}(a)}{4!}h^4 + O(h^5)$ を使うと,

$$\begin{aligned} & E\left[f\left(\frac{X_1 + \dots + X_k + Y_{k+1} + \dots + Y_n}{\sqrt{n}}\right)\right] - E\left[f\left(\frac{X_1 + \dots + X_{k-1} + Y_k + \dots + Y_n}{\sqrt{n}}\right)\right] \\ &= \underbrace{\frac{E[f'''(A_n^{(k)})]}{3! n \sqrt{n}}}_{= \bar{K}_3} \underbrace{\frac{E[X_k^3]}{n^2}}_{= \bar{K}_4} + \underbrace{\frac{E[f^{(4)}(A_n^{(k)})]}{4! n^2}}_{= \bar{K}_4} (\underbrace{E[X_k^4] - 3}_{= \bar{K}_4}) + O\left(\frac{1}{n^2 \sqrt{n}}\right) \end{aligned}$$

($E[Y_k] = 0, E[Y_k^2] = 1,$
 $E[Y_k^3] = 0, E[Y_k^4] = 3, \dots$)

$k = 1, 2, \dots, n$ に対する n 個のこれらを足し上げることにより, ある $C_3 > 0, C_4 > 0$ が存在して,

$$\left| E\left[f\left(\frac{X_1 + \dots + X_n}{\sqrt{n}}\right)\right] - \underbrace{E\left[f\left(\frac{Y_1 + \dots + Y_n}{\sqrt{n}}\right)\right]}_{= E[f(z)] \text{ for } z \sim \text{Normal}(0, 1)} \right| \leq \frac{C_3}{\sqrt{n}} |\bar{K}_3| + \frac{C_4}{n} |\bar{K}_4| + O\left(\frac{1}{n \sqrt{n}}\right)$$

の形の評価が得られる。

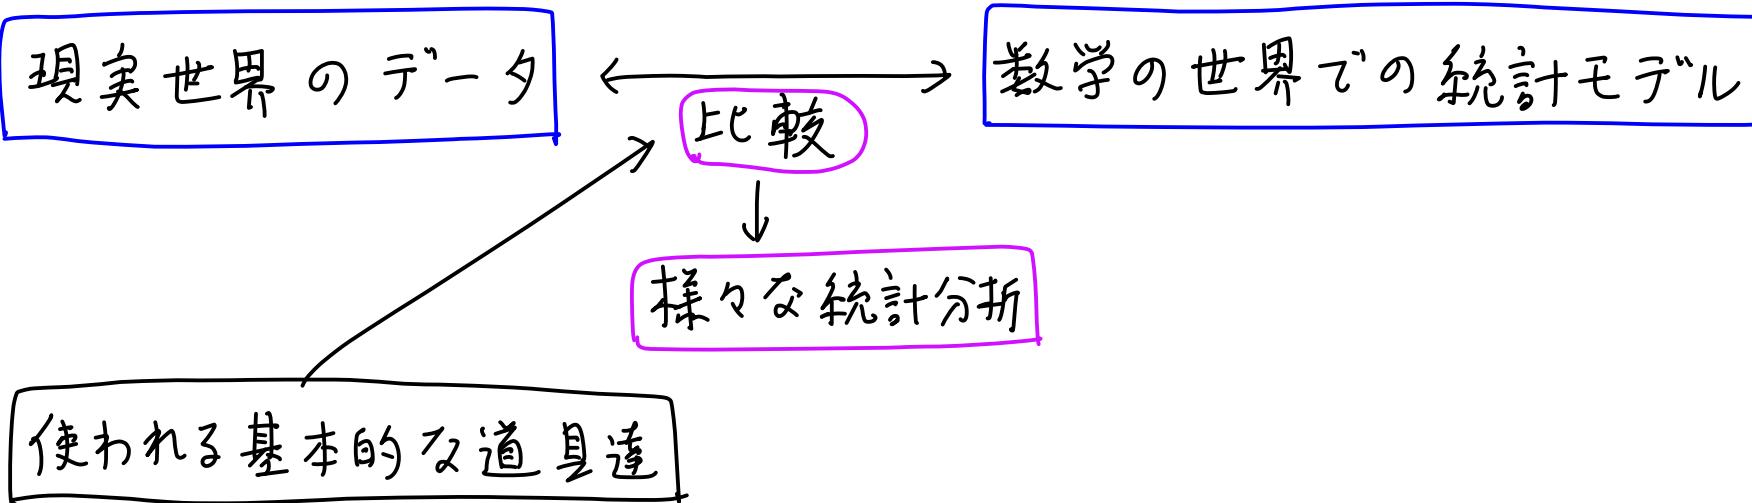
したがって, $n \rightarrow \infty$ のとき, $E\left[f\left(\frac{X_1 + \dots + X_n}{\sqrt{n}}\right)\right] \rightarrow E[f(z)]$ for $z \sim \text{Normal}(0, 1)$.

q.e.d,

条件付き確率分布、尤度、推定、要約

Part 1

Part 2



- 今回
- 統計モデル内の確率分布を現実から得たデータで条件付けて
条件付き確率分布を作ること
 - 統計モデルの現実から得たデータの数値への適合度の指標としての
尤度 (ゆうど, likelihood)

および P値 (ピ-値, P-value) ← 別の回でやる

や 事後分布 や 予測分布 ← この講義よりすすんだ話題

条件付き確率分布

離散分布での条件付き確率分布

$X = (X_1, \dots, X_n)$ に関する確率質量函数 $P(x)$ を考える。

函数 $y = f(x)$ に対応する確率変数 $Y = f(X)$ を考える:

$$E[g(Y)] = \sum_x g(f(x)) P(x). \quad \begin{array}{l} \text{(この函数の期待値が定義されている変数を} \\ \text{確率変数とよぶのである。} \end{array}$$

値 y について、 $P(Y=y) = (Y=y \text{となる確率}) = \sum_{f(x)=y} P(x) > 0$ と仮定する。

条件 $Y=y$ で定義された x の条件付き確率分布 を $\overset{P(x|y)}{\curvearrowleft}$ パラメータ

次の パラメータ y を持つ x の確率質量函数 $P(x|y)$ ($f(x)=y$) によって定める:

$$P(x|y) = \frac{P(x)}{P(Y=y)} \quad (x \text{ は } f(x)=y \text{ をめたるものに制限}),$$

確率の総和が 1 になるとの確認: $\overset{= P(Y=y)}{\curvearrowleft}$

$$\sum_{f(x)=y} \frac{P(x)}{P(Y=y)} = \frac{1}{P(Y=y)} \sum_{f(x)=y} P(x) = 1.$$

$\left\{ \begin{array}{l} f(x)=y \text{ をめた } x \text{ に} \\ \text{制限して,} \\ f(x)=y \text{ をめた } x \text{ の} \\ \text{どれかが生じる確率を} \\ 1 \text{ として } x \text{ の確率} \end{array} \right.$

例 正二十面体のサイコロ:

$$\left\{ \begin{array}{l} \text{6つの面} \rightarrow 1 \quad P(1) = 6/20 \\ \text{5つの面} \rightarrow 2 \quad P(2) = 5/20 \\ \text{4つの面} \rightarrow 3 \quad P(3) = 4/20 \\ \text{3つの面} \rightarrow 4 \quad P(4) = 3/20 \\ \text{2つの面} \rightarrow 5 \quad P(5) = 2/20 \end{array} \right.$$

$$x \in \{1, 2, 3, 4, 5\}$$

$$y = f(x) = \begin{cases} 0 & (x \text{ は偶数}) \\ 1 & (x \text{ は奇数}) \end{cases}, \quad Y = f(X).$$

f(x) の定義

$$P(Y=0) = P(2) + P(4) = 8/20$$

$$P(Y=1) = P(1) + P(3) + P(5) = 12/20$$

条件 $Y=0$ (x は偶数) で定義された x の条件付き確率分布:

$$x \in \{2, 4\}, \quad P(2|0) = \frac{P(2)}{P(Y=0)} = \frac{5/20}{8/20} = \frac{5}{8}, \quad P(4|0) = \frac{P(4)}{P(Y=0)} = \frac{3/20}{8/20} = \frac{3}{8}.$$

$$\underbrace{\begin{matrix} 2 & 2 & 2 & 2 & 2 \end{matrix}}_{5/8} \quad \underbrace{\begin{matrix} 4 & 4 & 4 \end{matrix}}_{3/8} \quad \leftarrow P(x|0) \quad (x \text{ は偶数})$$

条件 $Y=1$ (x は奇数) で定義された x の条件付き確率分布:

$$x \in \{1, 3, 5\}, \quad P(1|1) = \frac{P(1)}{P(Y=1)} = \frac{6}{12}, \quad P(3|1) = \frac{P(3)}{P(Y=1)} = \frac{4}{12}, \quad P(5|1) = \frac{P(5)}{P(Y=1)} = \frac{2}{12}.$$

$$\underbrace{\begin{matrix} 1 & 1 & 1 & 1 & 1 & 1 \end{matrix}}_{6/12} \quad \underbrace{\begin{matrix} 3 & 3 & 3 & 3 \end{matrix}}_{4/12} \quad \underbrace{\begin{matrix} 5 & 5 \end{matrix}}_{2/12} \quad \leftarrow P(x|1) \quad (x \text{ は奇数})$$

離散分布の Bayes の定理 (ベイズの定理)

←有名だから自明でつまらない結果。
知らないともこまらない。

(x, y) に関する確率質量函数 $P(x, y)$ について考える。 $x \leftrightarrow X, y \leftrightarrow Y$

$$P(x) = P(X=x) = \sum_y P(x, y), \quad P(y) = P(Y=y) = \sum_x P(x, y) \text{ と書く}, \quad \leftarrow (1)$$

$$\text{条件付き確率分布の定義: } P(x|y) = \frac{P(x, y)}{P(Y=y)} = \frac{P(x, y)}{P(y)}, \quad P(y|x) = \frac{P(x, y)}{P(X=x)} = \frac{P(x, y)}{P(x)}. \quad \leftarrow (2)$$

$$\text{つまり, } P(x, y) = P(x|y)P(y) = P(y|x)P(x), \quad \leftarrow (2)'$$

$$\text{ゆえに, } P(x) \stackrel{(1)}{=} \sum_y P(x|y)P(y), \quad P(y) \stackrel{(1)}{=} \sum_x P(y|x)P(x), \quad \leftarrow (3)$$

したがって, (1), (2)', (3) から自明

$$P(y|x) \stackrel{(2)'}{=} \frac{P(x|y)P(y)}{P(x)} \stackrel{(3)}{=} \frac{P(x|y)P(y)}{\sum_y P(x|y)P(y)}, \quad \leftarrow \begin{array}{l} \text{Bayes の定理} \\ \downarrow \end{array}$$

$$P(x|y) \stackrel{(2)'}{=} \frac{P(y|x)P(x)}{P(y)} \stackrel{(3)}{=} \frac{P(y|x)P(x)}{\sum_x P(y|x)P(x)}. \quad \leftarrow \begin{cases} P(x, y) = P(x|y)P(y) & (\text{by (2)'}) \\ P(y) = \sum_x P(x, y) & (\text{by (1)}) \\ P(y|x) = \frac{P(x, y)}{P(y)} & (\text{by (2)}) \end{cases}$$

Bayes の定理は $P(x|y)$ と $P(y)$ から $P(y|x)$ を作ったり,

$P(y|x)$ と $P(x)$ から $P(x|y)$ を作ったりするために使われる。

これがOK

2×2の分割表での条件付き確率分布

(偽陽性, 偽陰性の確率について)

← 重要

病気Dにかかっているかどうかの検査をする状況を考える。

検査する人が実際に病気にかかっている確率(有病率)は p であるとする。

その検査の性能は以下の通りとする:

- ・病気Dにかかっている人は 75% の確率で陽性になる。 ← 感度 75%
- ・病気Dにかかっていない人は 95% の確率で陰性になる。 ← 特異度 95%

	病気有	病気無	
陽性	$0.75p$	$0.05(1 - p)$	$0.05 + 0.70p$
陰性	$0.25p$	$0.95(1 - p)$	$0.95 - 0.70p$
	p	$1 - p$	1

← 常にこの表を書くようになると
まちがわすにすむ。

式で書くと、

$$P(\text{陽性}, \text{病気有}) = 0.75p,$$

$$P(\text{陽性}, \text{病気無}) = 0.05(1 - p),$$

$$P(\text{陰性}, \text{病気有}) = 0.25p,$$

$$P(\text{陰性}, \text{病気無}) = 0.95(1 - p).$$



知りたいこと { 陽性のときの, 病気無の条件付き確率 (偽陽性率)
 { 陰性のときの, 病気有の条件付き確率 (偽陰性率) } }

つづく

	病気有	病気無	
陽性	$0.75p$	$0.05(1 - p)$	$0.05 + 0.70p$
陰性	$0.25p$	$0.95(1 - p)$	$0.95 - 0.70p$
	p	$1 - p$	1

$$P(\text{陽性}) = P(\text{陽性}, \text{病気有}) + P(\text{陽性}, \text{病気無}) = 0.05 + 0.70p,$$

$$P(\text{陰性}) = P(\text{陰性}, \text{病気有}) + P(\text{陰性}, \text{病気無}) = 0.95 - 0.70p.$$

$$(\text{偽陽性率}) := P(\text{病気無} | \text{陽性}) = \frac{P(\text{陽性}, \text{病気無})}{P(\text{陽性})} = \frac{0.05(1 - p)}{0.05 + 0.70p},$$

$$(\text{偽陰性率}) := P(\text{病気有} | \text{陰性}) = \frac{P(\text{陰性}, \text{病気有})}{P(\text{陰性})} = \frac{0.25p}{0.95 - 0.70p},$$

自習問題

このように 2×2 の表を書けば易しい!

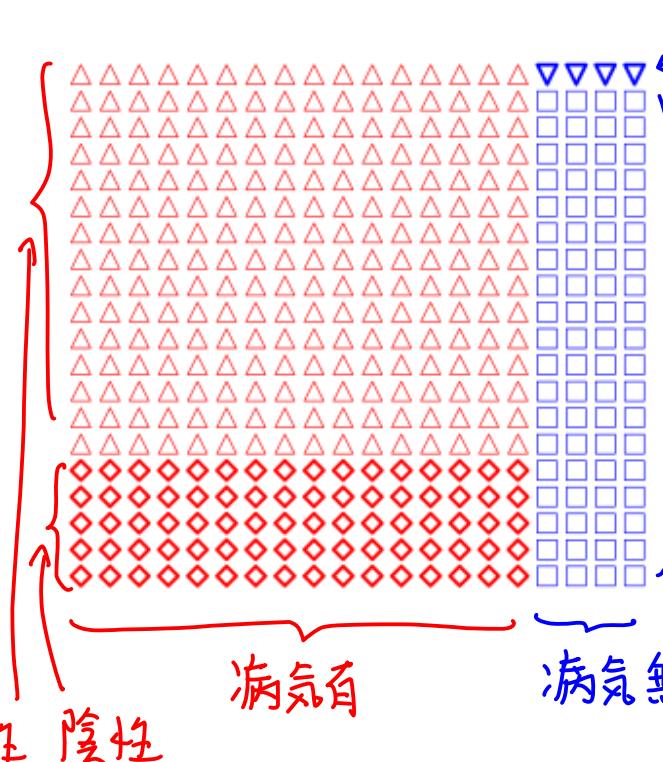
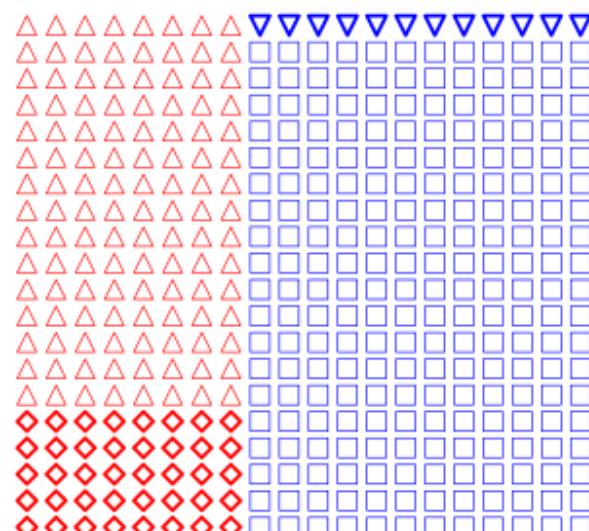
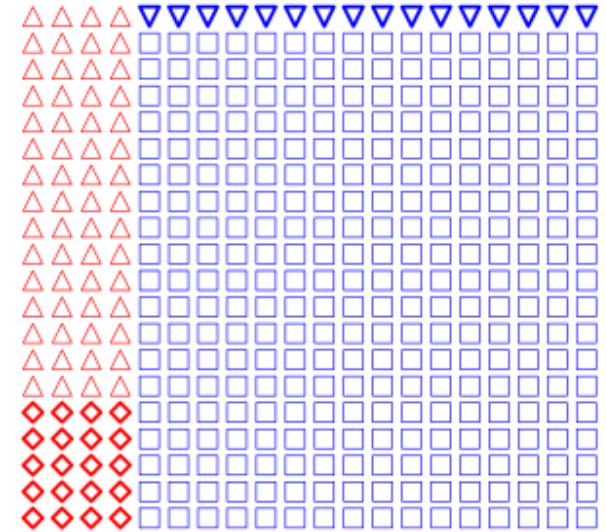
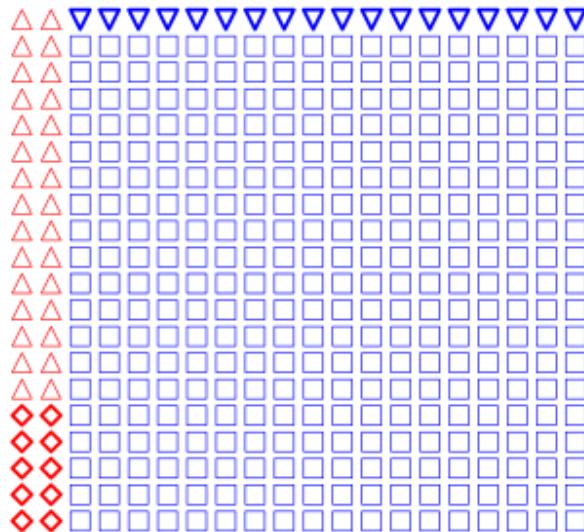
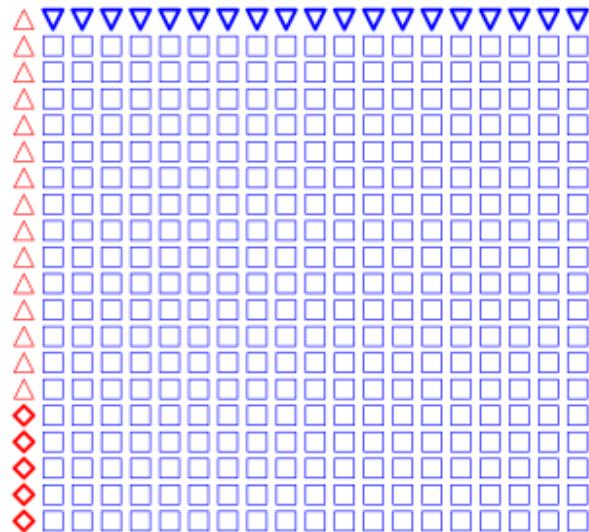
必修の易しい計算問題: 有病率によって偽陽性率と偽陰性率がどのように変化するか

上の状況において、有病率 p が $5\%, 10\%, 20\%, 40\%, 80\%$ の場合の偽陽性率と偽陰性率を求めよ。

次ページ
にヒント
あり!

前ページの自習問題のヒント

赤 = 病気有, 青 = 病気無, \triangle と ∇ は陽性



- \triangle : true-positive (病気有で陽性)
- \diamond : false-negative (病気有で陰性)
- ∇ : false-positive (病気無で陽性)
- \square : true-negative (病気無で陰性)

陽性

陰性

この図を見て
直観的に理解
してもらいたい、

おまけの問題: モンティ・ホール問題 (Monty Hall problem)

以下のようなゲームを考える:

- (1) 親は 1, 2, 3 の中から番号 X を無作為に選んで秘密にしておく.
- (2) あなたは, 1, 2, 3 の中から番号 1 を選んでそれを親に告げる.
- (3) 親は 1, 2, 3 の中から 1 と X 以外の番号 Y を無作為に選んで, あなたに告げる.
- (4) あなたは 1, 2, 3 の中から 1, Y を除いて残った1つの番号 Z を選ぶ.

あなたが最後に選んだ番号 Z が秘密の番号 X に一致する確率を求めよ.

注意: (2)で 1 を選ばずに 1, 2, 3 のどれかを無作為に選んでも結果は同じになる.

代表的誤答例: $Z = X$ となる確率は $1/2$ である. 誤答終

例 親 $X=2 \rightarrow$ あなた 1 \rightarrow 親 $Y=3 \rightarrow$ あなた 1と3以外の $Z=2$

親 $X=1 \rightarrow$ あなた 1 \rightarrow 親 $Y=2 \rightarrow$ あなた $Z=3$

\rightarrow 親 $Y=3 \rightarrow$ あなた $Z=2$

連続分布の場合の条件付き確率分布と Bayes の定理

確率質量函数と和 → 確率密度函数と積分 とするだけで同様

(x, y) の確率密度函数 $p(x, y)$ を考える。

$$p(x) = p(X=x) = \int p(x, y) dy, \quad p(y) = p(Y=y) = \int p(x, y) dx. \quad \leftarrow (1)$$

$$p(x|y) = \frac{p(x, y)}{p(y)}, \quad p(y|x) = \frac{p(x, y)}{p(x)} \quad \leftarrow (2)$$

$$p(x, y) = p(x|y)p(y) = p(y|x)p(x) \quad \leftarrow (2)' \quad \leftarrow \text{これがポイント!}$$

$$p(x) \stackrel{(1)}{=} \int p(x|y)p(y) dy, \quad p(y) \stackrel{(1)}{=} \int p(y|x)p(x) dx \quad \leftarrow (3)$$

$$\begin{aligned} p(y|x) &= \frac{p(x|y)p(y)}{p(x)} \stackrel{(3)}{=} \frac{p(x|y)p(y)}{\int p(x|y)p(y) dy} \\ p(x|y) &= \frac{p(y|x)p(x)}{p(y)} \stackrel{(3)}{=} \frac{p(y|x)p(x)}{\int p(y|x)p(x) dx} \end{aligned} \quad \left\} \text{Bayes の定理}$$

数学に強くなりたい人のための Bayes 統計の自習問題

問題: 連続分布の条件付き確率分布の例 (分散が固定された正規分布モデルのBayes統計)

この節の式には細かい誤りが多数含まれている可能性がある。誤りを見付けたら自分で訂正すること。誤りがなかったら、拍手喝采して欲しい。

$n, \rho > 0$ を任意に取って固定する。 $x, \mu \in \mathbb{R}$ の同時確率密度函数

$$p(x, \mu | n, \rho) = \frac{e^{-n(x-\mu)^2/2}}{\sqrt{2\pi/n}} \frac{e^{-\mu^2/(2\rho^2)}}{\sqrt{2\pi\rho^2}}.$$

(prior)
事前分布

によって定義される $(x, \mu) \in \mathbb{R}^2$ の確率分布を考える。その分布において、変数 x に対応する確率変数 X に関する条件 $X = x$ で定義された μ に関する条件付き確率分布の密度函数が

$$p(\mu | x, n, \rho) = \frac{1}{\sqrt{2\pi\rho^2/(1+n\rho^2)}} \exp\left(-\frac{1+n\rho^2}{2\rho^2} \left(\mu - \frac{n\rho^2 x}{1+n\rho^2}\right)^2\right).$$

になることを示せ。これは平均と分散がそれぞれ

$$\frac{n\rho^2}{1+n\rho^2}x, \quad \frac{\rho^2}{1+n\rho^2}$$

の正規分布である。

注意: 特に, $n \rightarrow \infty$ とすると, 条件 $X = x$ で定義された μ の条件付き確率分布の期待値は x に収束し, 分散は 0 に収束するので, μ の条件付き確率分布は x の近くに集中するようになる。

注意: この問題の例は正規分布モデル $p(x|n, \mu) = e^{-n(x-\mu)^2/2}/\sqrt{2\pi/n}$ と事前分布

$p(\mu|\rho) = e^{-\mu^2/(2\rho^2)}/\sqrt{2\pi\rho^2}$ に関するBayes統計におけるデータの数値 x が定める事後分布 $p(\mu|x, n, \rho)$ を求める計算になっている。 x は標本平均に, n はサンプルサイズに対応しており, $p(x|n, \mu)$ の形は分散 1 の正規分布のサイズ n 標本分布において標本平均の分散が $1/n$ になることを表している。だから, この場合には固定された分散 1 を持つ正規分布の標本分布を統計モデルとして採用している場合になっていると考えて欲しい。 $n = 0$ のとき事後分布が事前分布に一致することにも注意せよ。

注意: 条件付き確率分布の概念はBayes統計に限らず統計学における最も基本的かつ重要な確率論の道具であるが, 特にBayes統計では条件付き確率分布を使った推論が系統的に利用される。

無理して解かなくても良い、

ゆえに文字が小さい、

しかし、目を通していくと、

必要ななったら思い出せといい、

答えは GitHub にある、

事後分布 (posterior)

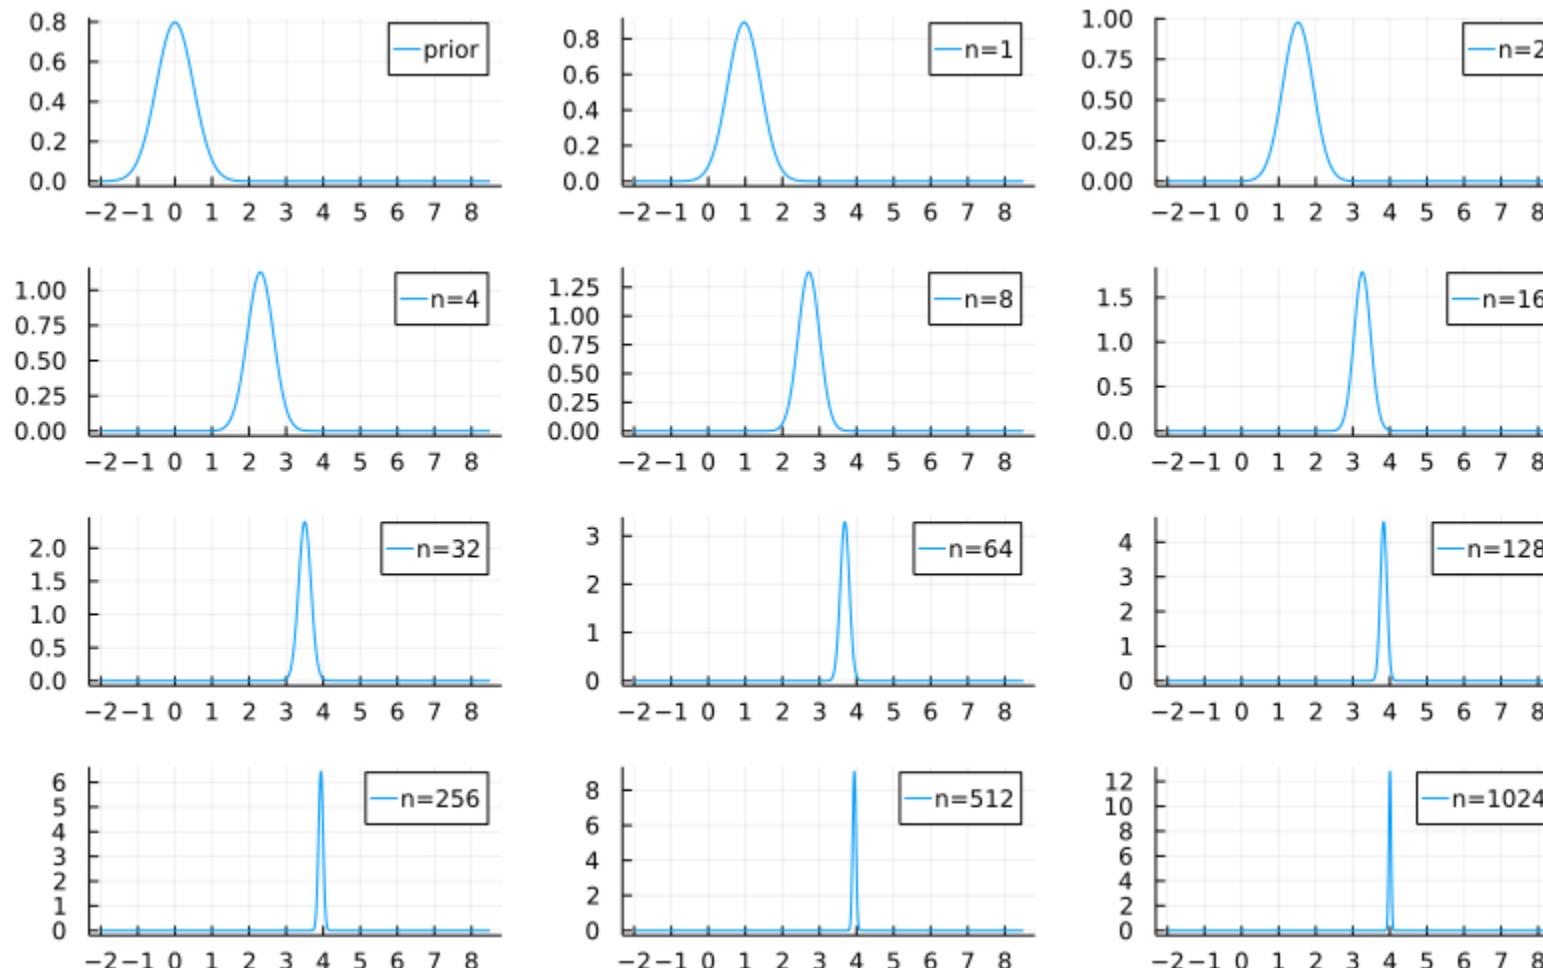
分散が固定された正規分布モデルのBayes統計の事後分布の視覚化

$\mu_0 = 4, \rho = 1/2$ とおく.

平均 $\mu_0 = 4$, 分散 1 の正規分布のサイズ $N = 2^{10}$ の標本 X_1, X_2, \dots, X_N をランダムに生成し, $n = 0, 1, 2, 4, 8, \dots, 1024 = 2^{10}$ について標本平均 $x = \bar{X}_n = (X_1 + \dots + X_n)/n$ を求め, 前節で求めた μ の事後分布 $p(\mu|x, n, \rho)$ をプロットしてみよう.

n を大きくすると μ の事後分布はサンプルを生成した分布の平均値 μ_0 に集中して行く.

これはBayes統計の漸近論的な基礎付けの最も簡単な場合になっている.



前ページの問題9つ目
の解説

データは
平均 4 分散 1 の
正規分布の
n個の乱数
として生成
されている。

$n \rightarrow \infty$ で
事後分布とよばれる
条件付き確率分布
が 4 に集中して
行く！

これも数学に強くなりたい人向けの問題

問題: 2変量の正規分布とその条件付き確率分布の例

$$\Sigma = \begin{bmatrix} a & b \\ b & d \end{bmatrix}$$

は固有値がすべて正の実対称行列であるとし, $\mu = (\mu_x, \mu_y) \in \mathbb{R}^2$ であるとする. このとき,

$$\Sigma^{-1} = \frac{1}{ac - b^2} \begin{bmatrix} c & -b \\ -b & a \end{bmatrix}$$

であり, $(x, y) \in \mathbb{R}^2$ の確率密度函数を

$$\begin{aligned} p(x, y) &= \frac{1}{\det(2\pi\Sigma)^{1/2}} \exp\left(-\frac{1}{2} [x - \mu_x, y - \mu_y] \Sigma^{-1} \begin{bmatrix} x - \mu_x \\ y - \mu_y \end{bmatrix}\right) \\ &= \frac{1}{\sqrt{(2\pi)^2(ac - b^2)}} \exp\left(-\frac{a(y - \mu_y)^2 - 2b(x - \mu_x)(y - \mu_y) + c(x - \mu_x)^2}{2(ac - b^2)}\right) \end{aligned}$$

と定めることができる. これが $\iint_{\mathbb{R}^2} p(x, y) dx dy = 1$ を満たすことは, Σ を直交行列で対角すれば示せる.(詳細は略す. 以下では認めて使ってよい.) この確率密度函数が定める確率分布を **2変量正規分布** と呼び,

$\text{MvNormal}(\mu, \Sigma)$

と表すことにする. μ を平均(もしくは期待値)と呼び, Σ を **分散共分散行列** (variance-covariance matrix)と呼ぶ. (この記号法は, 2変量の場合に限定せずに, 任意の **多変量正規分布** (multivariate normal distribution)にも使用することにする.)

この場合には条件 $X = x$ が定める y に関する条件付き確率分布が, 平均と分散がそれぞれ

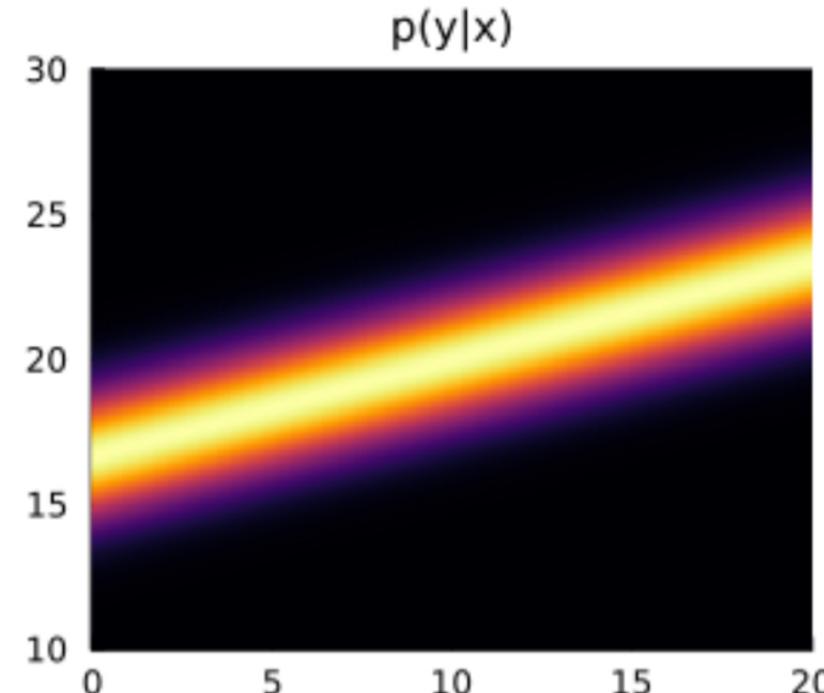
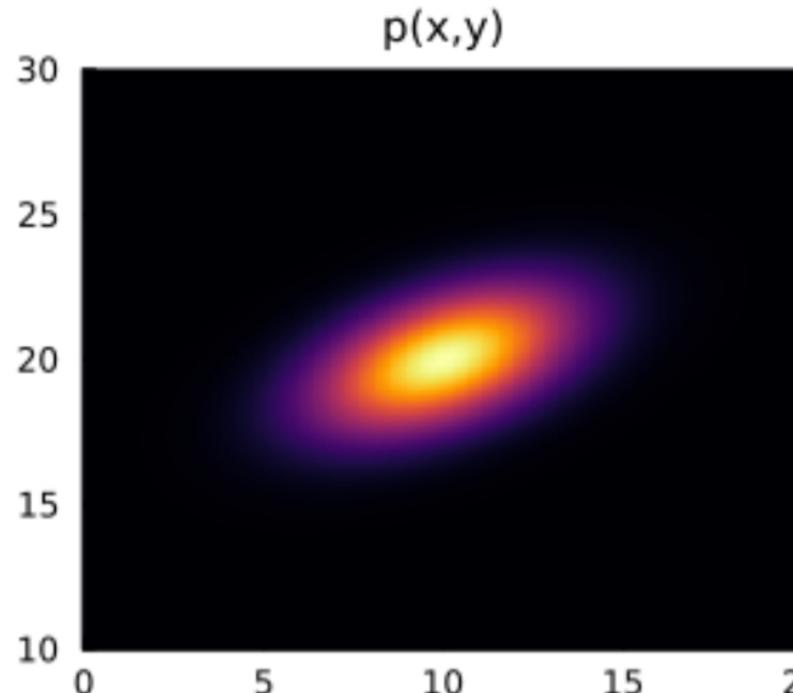
$$\mu = (b/a)(x - \mu_x) + \mu_y, \quad \sigma^2 = (ac - b^2)/a$$

の正規分布になることを示せ.

これも無理して
解かなくてもよい,

前ページのつづき

$\mu = (10, 20)$, $\Sigma = \begin{bmatrix} 6 & 2 \\ 2 & 3 \end{bmatrix}$ の場合の $p(x, y)$ と $p(y|x) = \frac{p(x, y)}{p(x)}$ の視覚化



$$\begin{aligned} p(y|x) &= \frac{p(x, y)}{p(x)} \\ &\propto \int p(x, y) dy \end{aligned}$$

$p(x, y)$ は xy 平面上の確率密度函数になっている。

$p(y|x)$ は各 x ごとに y 軸に平行な直線上の確率密度函数になっている。

その様子の違いの典型例が上のグラフからわかる。

$p(y|x)$ のヒートマップを見れば、パラメータ x を持つ y の確率密度函数は x を y に対応させ
る函数の一般化(x に対する y の値が確率的に揺らぐ)になっていることもわかる。

尤度と推定

尤度は「ゆうど」と読む。尤度(いぬど)ではない。

統計モデルの定義

パラメータ $\theta = (\theta_1, \dots, \theta_d)$ を持つ $x = (x_1, \dots, x_n)$ に関する

確率質量函数 $P(x|\theta)$ または確率密度函数 $p(x|\theta)$ で定まる確率分布を現実世界におけるデータ x の生成のされ方の数学的モデルとみなすとき、その確率分布を 統計モデル と呼ぶ。(単にモデルということも多い。)

尤度の定義

データの数値 x が得られたとき、

パラメータ θ を統計モデル内で数値 x が生成される確率 $P(x|\theta)$ または確率の密度 $p(x|\theta)$ に対応させる函数

$$\theta \mapsto P(x|\theta) \text{ または } \theta \mapsto p(x|\theta)$$

をデータの数値 x に関する統計モデルの 尤度函数 (likelihood function) と呼ぶ。

さらにパラメータの値 θ を与えたときの尤度函数の値 $P(x|\theta)$ または $p(x|\theta)$ をデータの数値 x とパラメータの数値 θ に関する統計モデルの 尤度 (likelihood) と呼ぶ。

尤度の使い方.

尤度 = モデル内でデータと同じ数値が生成される確率または確率密度、

尤度はデータの数値 x へのパラメータ値 θ の統計モデルの ^{フィッティング}適合度の指標の 1つとして基本的かつ重要である。

尤度 = データの数値 x へのモデルの適合度の指標のひとつ

最大法 (maximum likelihood method, 最大推定法, maximum likelihood estimation)

データの数値 x にパラメータ θ を持つ統計モデルを最もよくフィットさせるために尤度が最大になるようなパラメータ値 $\hat{\theta}$ をみつけて、パラメータを $\theta = \hat{\theta}$ と設定することを 最大法 といふ。

最大法の解 $\hat{\theta}$ を 最大推定値 (maximum likelihood estimate) とよぶ。

注意

尤度は「もっともらしさ」の指標としては使えない。

<sup>オーバーフィッティング
の問題がある</sup>

例 Bernoulli 試行 モデルの最大法 $x_i = 1, 0$

あたりが未知の確率で出るルーレットを回した結果を、あたりを1, はずれを0として記録したデータの数値を x_1, x_2, \dots, x_n と書く。
Bernoulli 試行の

$$P(x_1, \dots, x_n | p) = p^{x_1 + \dots + x_n} (1-p)^{n - (x_1 + \dots + x_n)} \leftarrow \text{統計モデル}$$

尤度函数 $L(p) = p^{x_1 + \dots + x_n} (1-p)^{n - (x_1 + \dots + x_n)}$ (x_1, \dots, x_n はデータの数値)

データの要約 $k = x_1 + \dots + x_n$ とおく、「 n 回中 k 回あたりが出た。」

対数尤度函数 $l(p) = \log L(p) = k \log p + (n-k) \log (1-p).$

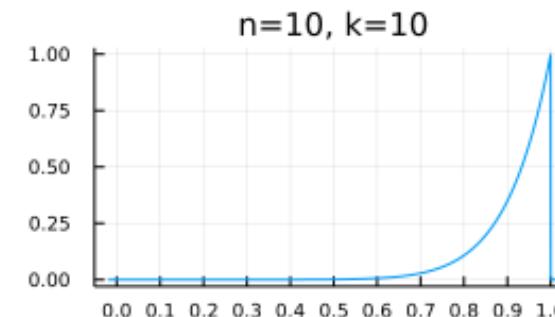
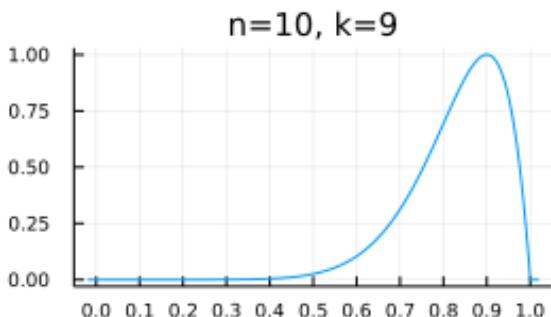
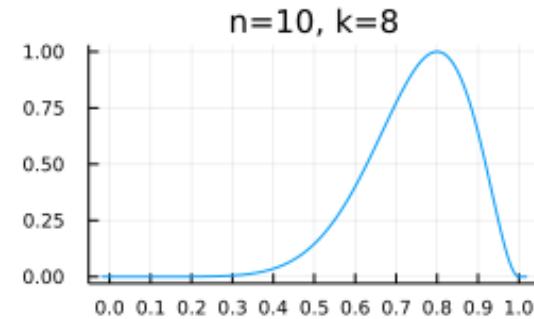
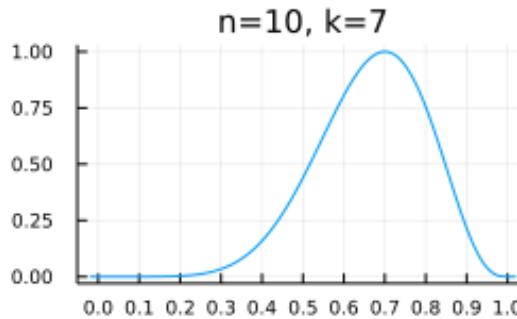
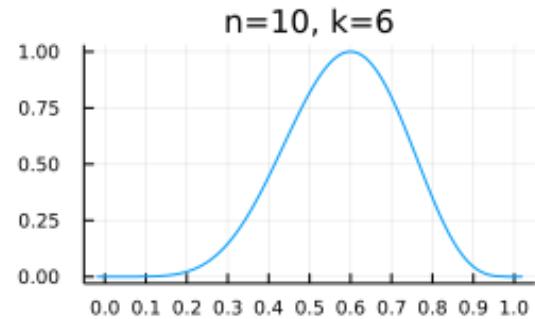
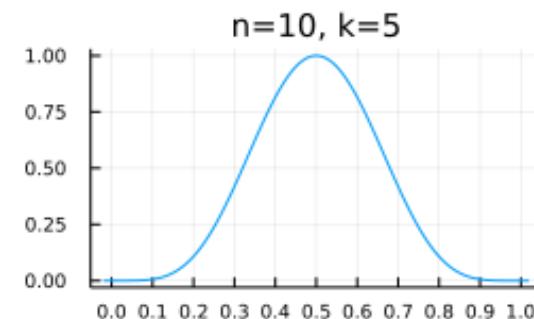
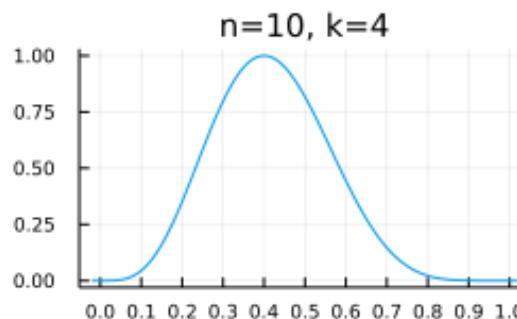
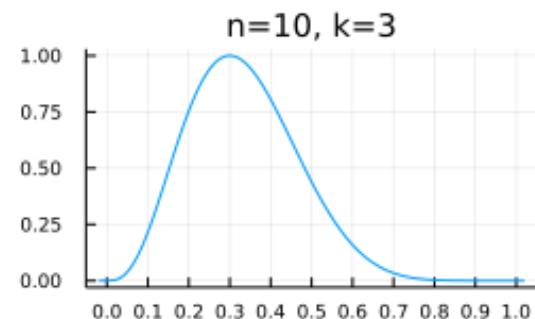
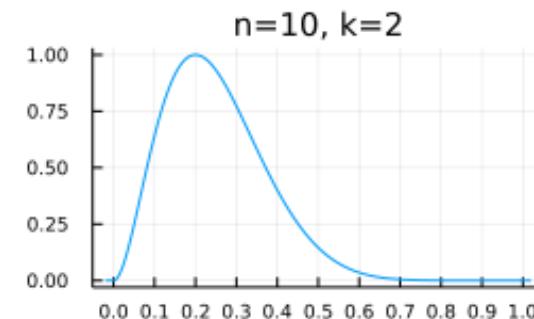
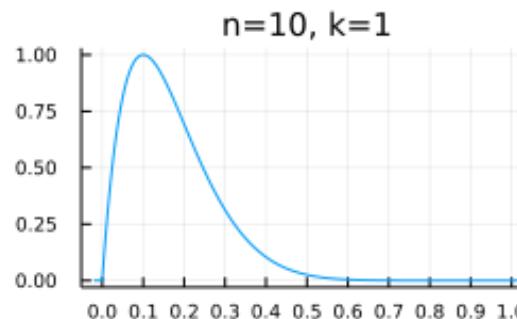
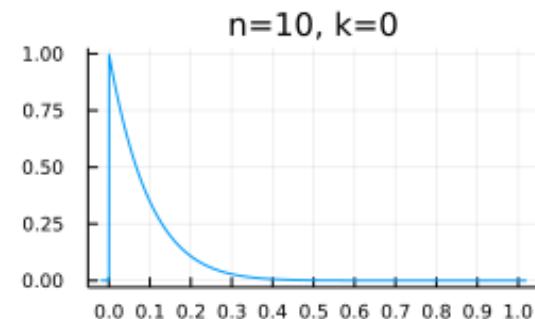
最大法の計算 $l'(p) = \frac{k}{p} - \frac{n-k}{1-p} = \frac{k-np}{p(1-p)} = 0$ の解 $\hat{p} = \frac{k}{n}.$

解釈 n 回中 k 回あたりが出たというデータに最大法の意味で最もフィットする Bernoulli 試行モデルのパラメータ値は $\hat{p} = \frac{k}{n}$ である。

注意 データが運悪くかたよってなければ、ルーレットであたりが出る未知の確率は $\hat{p} = \frac{k}{n}$ に近い値になっているだろうが、運が悪ければダメ！
この「運」を確率論の言葉で見つめることが重要である。

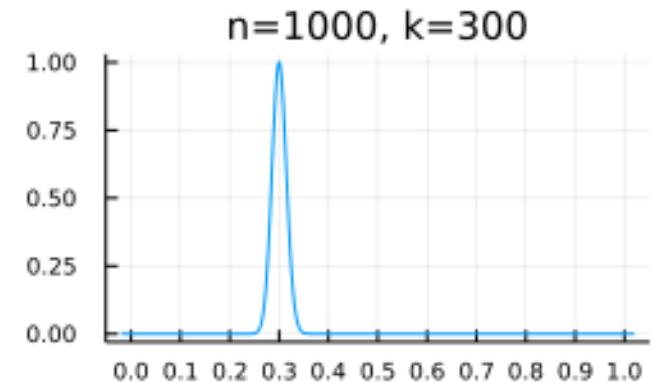
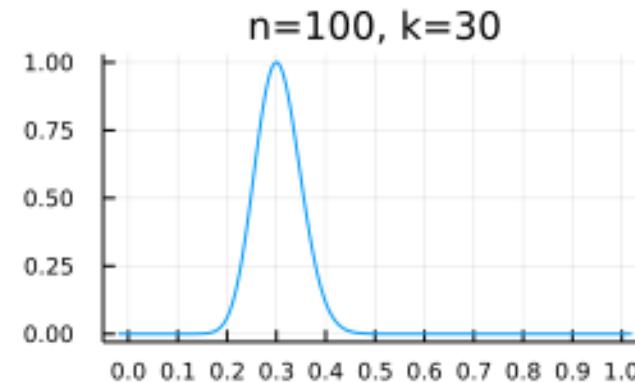
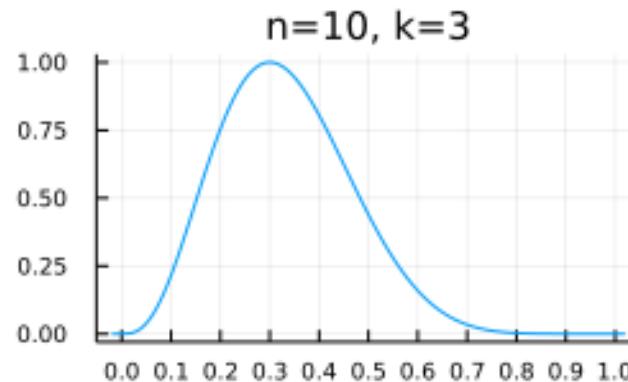
重要

Bernoulli試行モデルの尤度函数（の定数倍）のグラフ (1)



Bernoulli 試行モデルの尤度函数の定数倍のグラフ(2)

k/n を固定して n を大きくした場合には、尤度函数 $L(p)$ の台は k/n に集中して行く。



このグラフから、データに基づくパラメータの推定において、パラメータの推定値としてどれだけの幅を持たせるかについて、尤度函数がなにがしかの情報を持っていそうなこともわかる。

正則モデルと呼ばれるクラスに属する統計モデルでも同様のことが起こる。

重要自習問題

答えは
Github の
資料にある →

- データ中の1番目が
・当たり \Rightarrow モデル内で
1番目の当たりの確率を
1とする.
 - ・はずれ \Rightarrow モデル内で
1番目の当たりの確率を
0とする.
- こうするとモデル1の
最尤法の解になる,

問題: 尤度が高くても全然もっともらしくない例(オーバーフィッティングの例)

データは当たり(1と書く)とはずれ(0と書く)がランダムに出るルーレットを n 回まわして得た 1 と 0 の列 x_1, x_2, \dots, x_n として得られるとする.

統計モデルとして以下の2つを考える.

モデル0: Bernoulli 試行モデル: このモデルのパラメータ $0 \leq p \leq 1$ を持つ確率質量関数は次のように書けるのであった:

$$P_0(x_1, \dots, x_n | p) = p^{x_1 + \dots + x_n} (1 - p)^{n - (x_1 + \dots + x_n)} \quad (x_i = 1, 0).$$

モデル1: ルーレットをまわすごとに当たりが出る確率が変わってもよいと想定したモデル: このモデルは n 個のパラメータ $0 \leq p_1, \dots, p_n \leq 1$ を持つ次の確率質量関数によって与えられる:

$$P_1(x_1, \dots, x_n | p_1, \dots, p_n) = \prod_{i=1}^n (p_i^{x_i} (1 - p_i)^{1-x_i}) \quad (x_i = 1, 0).$$

データ(1と0の列) x_1, \dots, x_n について、モデル0の最尤法の解 $p = \hat{p}$ は $\hat{p} = \frac{k}{n}$ ($k = x_1 + \dots + x_n$) になるのであった. 以下の2つを同時に示せ:

(1) モデル1の最尤法の解 $p_i = \hat{p}_i$ は $\hat{p}_i = x_i$ になる.

(2) どのようなデータ x_1, x_2, \dots, x_n についてもモデル1の最大尤度は離散分布モデルの場合に可能な最大の値 1 になる.

注意: 確率と違って確率密度の値はいくらでも大きくなりえるので、尤度が確率密度の値になる連続分布モデルにおいては尤度はいくらでも大きな値を取り得る. 離散分布モデルの場合には尤度は確率の値になるのでその最大値は 1 になる.

注意: この例はオーバーフィッティング(過剰適合)のシンプルな例になっている. パラメータの個数が多いモデルではオーバーフィッティングし易くなる.

注意: この例を知っているれば、「尤度が高ければもっともらしい」と考えることは単純に誤りであることがわかる. 尤度を常識的な意味でのもっともらしさと繋げるためには特別な条件が必要になる.

数学が強くなりたい人向けの自習問題

問題: 正規分布の標本分布モデルの尤度函数と最尤法

データは n 個の実数達 x_1, \dots, x_n であるとし, 統計モデルとして平均 μ , 分散 σ^2 の正規分布のサイズ n の標本分布を考える. その統計モデルの確率密度函数 $p(x_1, \dots, x_n | \mu, \sigma^2)$ は,

$$p(x_i | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

とおくとき次のように表される:

$$p(x_1, \dots, x_n | \mu, \sigma^2) = \prod_{i=1}^n p(x_i | \mu, \sigma^2).$$

データ x_1, \dots, x_n に関するこのモデルの尤度函数を最大化する $\hat{\mu} = \hat{\mu}, \hat{\sigma}^2 = \hat{\sigma}^2$ はそれぞれ次になることを示せ:

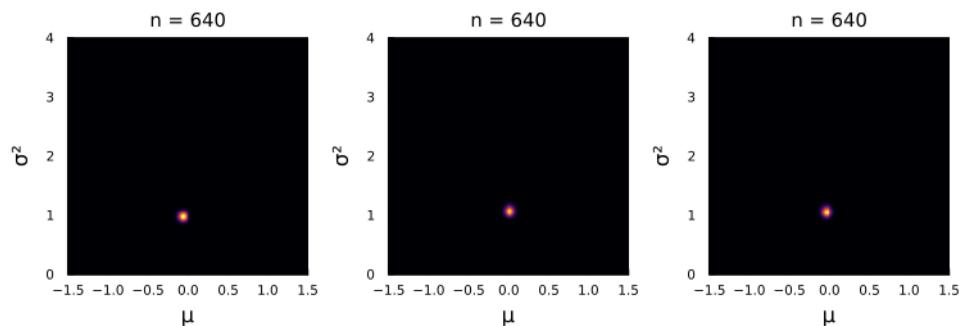
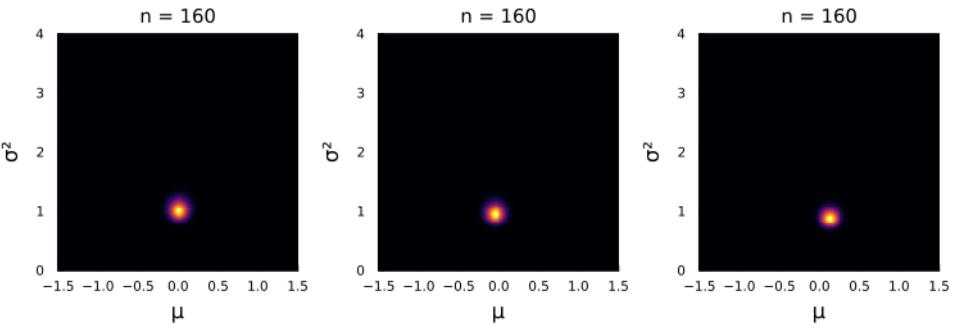
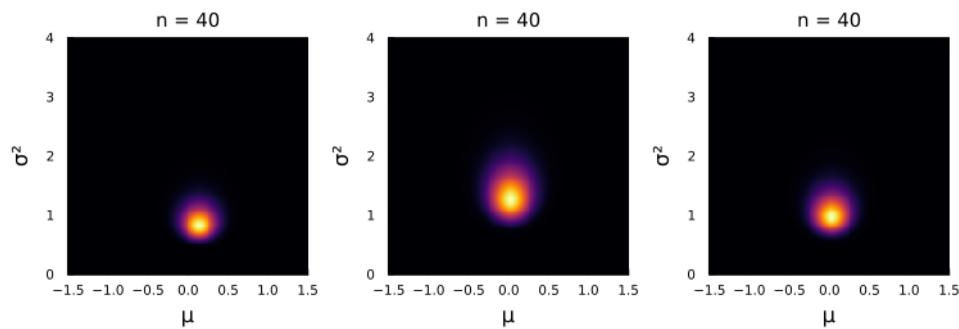
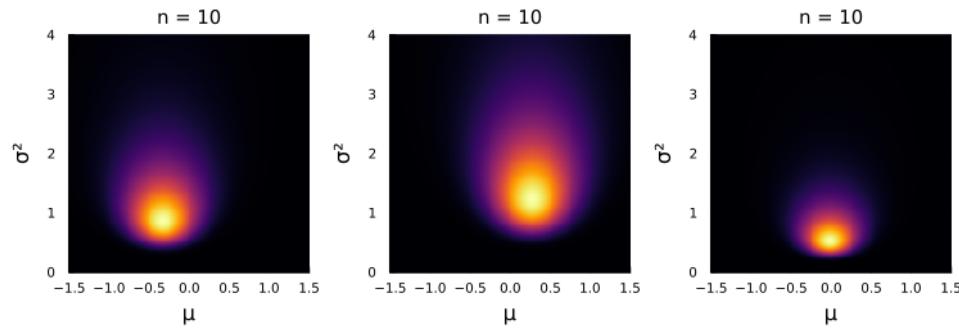
$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2.$$

これは, 正規分布の標本分布モデルの最尤法の解が標本平均と(不偏にするための補正無しの)標本分散になることを意味している.

注意: この結果はデータの標本平均と標本分散を求めるることは, 正規分布の標本分布モデルがデータに最もよくフィットするような μ と σ^2 を求めることに等しいことがわかる. この点は次の節の要約統計の説明でも触れる.

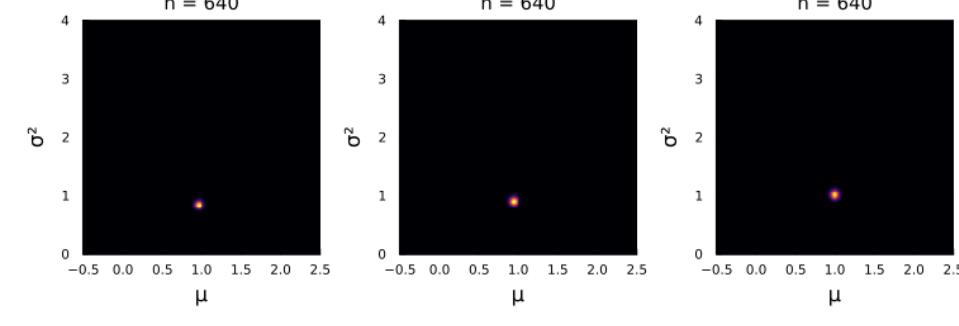
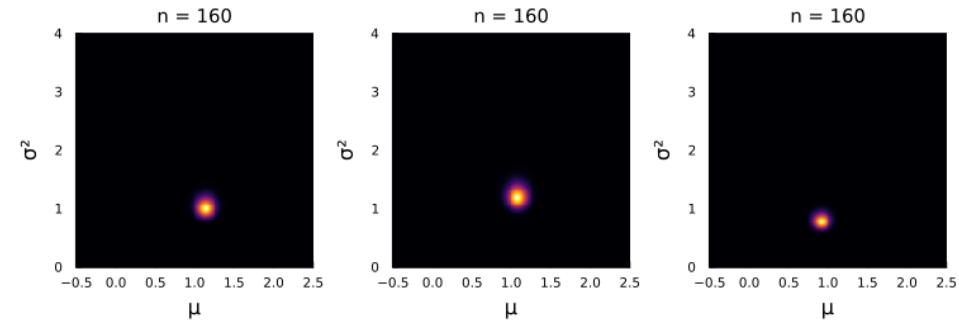
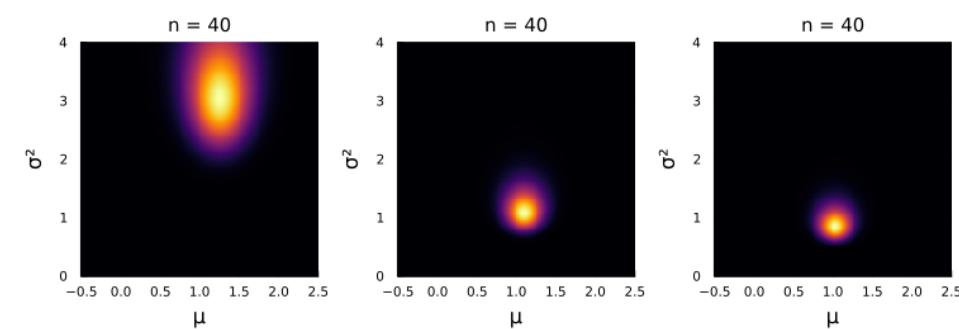
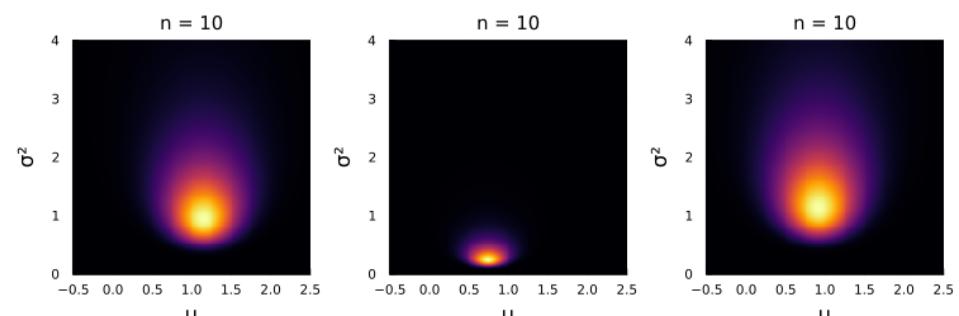
データを $\text{Normal}(0,1)$ で生成

平均 0
分散 1



データを $\text{Exponential}(1)$ で生成

平均 1
分散 1



データの要約の仕方の注意

n 個の 1 と 0 からなるデータ x_1, \dots, x_n の要約

n 個の 1 と 0 からなるデータ x_1, \dots, x_n の要約として, x_1, \dots, x_n の中の 1 の個数 $k = x_1 + \dots + x_n$ がよく使われる. 報告の形式は「 n 個中 k 個が 1 である」になる. その k は Bernoulli 試行モデルの十分統計量になっているのであった.

そのようなデータの要約の仕方は x_1, \dots, x_n が並んでいる順序が重要な場合には適さない.

「 n 個中の k 個が 1 である」と報告するときには n と k の両方の数値を報告することが重要である. なぜならばデータのサイズ n は統計分析の精度を見積もる上で非常に重要な情報だからである.

n の情報を省いて「1 の割合は 30% であった」のように k/n の情報だけを伝えることは好ましくない.

より一般の離散的なデータの要約

n 個の 1, 2, …, r からなるデータ x_1, \dots, x_n の要約として, x_1, \dots, x_n の中含まれる $a = 1, 2, \dots, r$ の個数 k_a がまとめた (k_1, \dots, k_r) がよく使われる. ((k_1, \dots, k_r) はカテゴリカル分布の標本分布モデルの十分統計量になっている.)

そのようなデータの要約の仕方は x_1, \dots, x_n が並んでいる順序が重要な場合には適さない.

データの要約(summary)を報告する場合には, 必ずデータのサイズがわかるように報告しなければいけない. なぜならばデータのサイズ n は統計分析の精度を見積もる上で非常に重要な情報だからである.

例えば「1, 2, 3, 4 の割合がそれぞれ 10%, 20%, 30%, 40% であった」のように k_a/n の情報だけを伝えることは好ましくない. 全体の割合の情報だけではなく, 全体の個数の情報も必ず報告しなければいけない.

n 個の実数からなるデータ x_1, \dots, x_n の要約

n 個の実数からなるデータ x_1, \dots, x_n の要約としては以下がよく使われている:

- 標本平均 \bar{x} と不偏分散 s^2
- 中央値
- 四分位数

標本平均と不偏分散の組み合わせは正規分布の標本分布モデルの十分統計量になっており, それだけではなく, その最尤法の解にもなっているのであった.

標本平均だけではなく, 中央値の情報も報告されているとき, それに大きなずれが存在するならば, 分布に非対称性があることもわかる.

四分位数は外れ値がある場合の分布の散らばり方の要約として頑健である.

以上で挙げた, 標本平均, 不偏分散, 中央値, 四分位数はデータの分布が单峰型の場合にはデータの要約の仕方として適切だが, 山が2以上ある分布の場合には適さない.

この型のデータの様子は, ヒストグラムや経験累積分布函数(x に x 以下の x_i 達の割合を対応させる函数)をプロットして, **データ全体の様子を視覚的に必ず確認した方がよい**.

↑ これが最も重要

n 個の実数の対からなるデータ $(x_1, y_1), \dots, (x_n, y_n)$ の要約

n 個の実数の対からなるデータ $(x_1, y_1), \dots, (x_n, y_n)$ の要約としてよく使われているのは、

- 標本平均 \bar{x}, \bar{y} と不偏分散と不偏共分散 s_x^2, s_y^2, s_{xy}

である。この5つの量を合わせたものは二変量正規分布の標本分布モデルの十分統計量になっている。

それらの統計量を使って線形回帰の結果を表示することもできる。線形回帰もデータの要約の仕方だとみなされる。

このようなデータを取得する場合には x_i と y_i のあいだの関係がどうなっているかに興味がある。

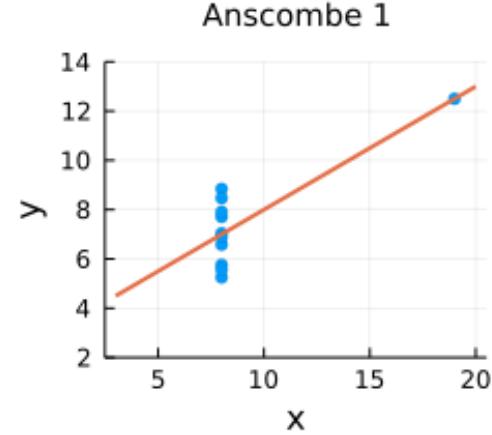
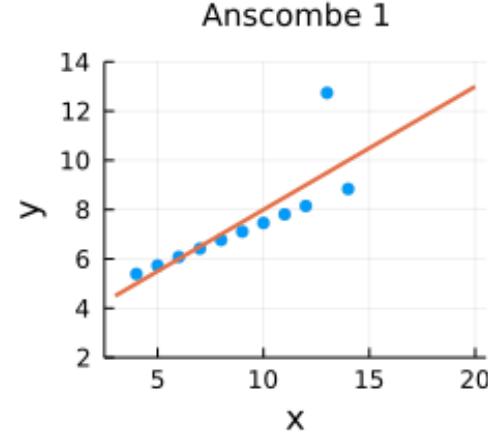
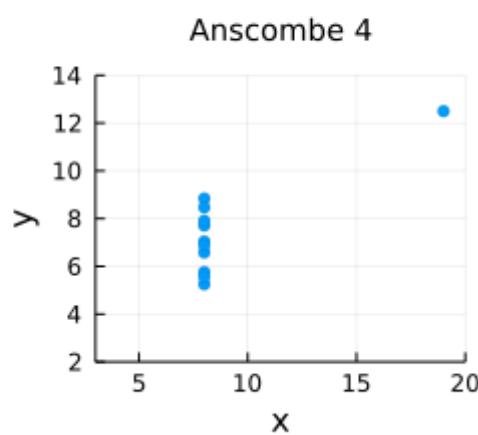
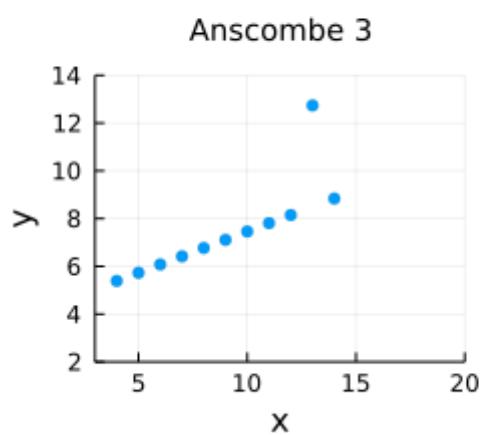
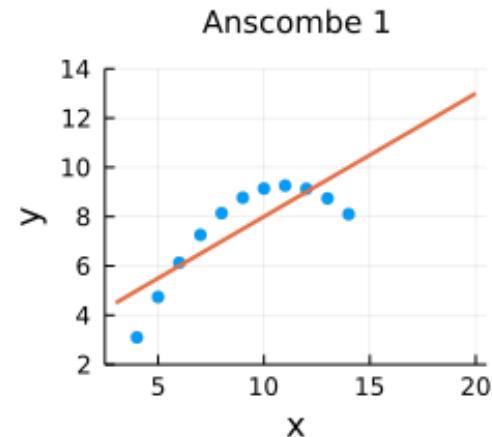
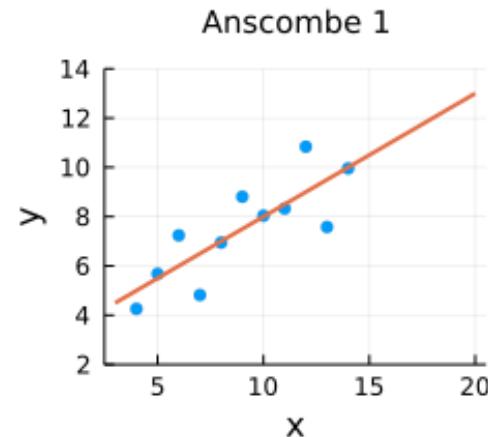
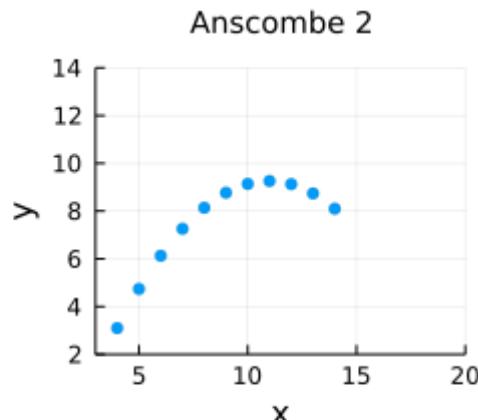
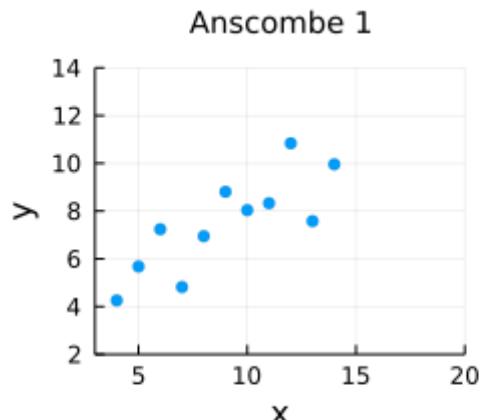
そのときに上の5つの要約統計量(や線形回帰の結果)だけしか見ないと、 x_i と y_i のあいだの重要な関係を見逃してしまうことがある。

この型のデータを扱う場合には、**散布図 (scatter plot)**を書くなどして、データ全体の様子を視覚的に必ず確認した方がよい。

↑ これが最重要、 次ページの例を見よ！

Anscombeの例(アンスコムの例, 再)

以下の散布図(scatter plot)を見れば、要約統計量だけを見てはいけないことがわかる。



☞ 散布図 (scatter plot)
非常によく使う!

もは回り帰直線の情報だけしか
見てないと大変なことになってしまふ。

重要必修自習問題

GitHubのサポートページからデータをダウンロードできる

<https://github.com/genkuroki/Statistics/tree/master/2022> の第06節からデータをダウンロード可能

問題: DataSaurusの例

以下のデータは

- <http://www.thefunctionalart.com/2016/08/download-datasaurus-never-trust-summary.html>

から取得したものである.

- [CSVファイル](#)
- [x座標のみ, y座標のみ](#)
- [x座標のみコンマ付き, y座標のみコンマ付き](#)

詳細な答えか
GitHubにある
資料にある、



以下のデータの左列はx座標のデータであり, 右列はy座標のデータである.

(1) 標本平均 \bar{x} , \bar{y} と不偏分散と不偏共分散 s_x^2 , s_y^2 , s_{xy} を小数点以下2桁以上求めよ.

(2) 何らかの方法で散布図(scatter plot)を描け.

さらに datasaurus same stats についてインターネットで検索して統計分析で注意するべきことを学べるサイトを見つけて内容を理解するように努力せよ.

ヒント: (1),(2)についてはインターネット上で適切に検索すれば以上の問題を解くことができるサイトを発見できる.